Συνεχιζόμενη αυτοεπιβλεπόμενη προεκπαίδευση DINO και DINOv2 σε ενδοσκοπικά δεδομένα

Ταξινόμηση ανατομικών περιοχών του ανώτερου γαστρεντερικού

Βασιλική Μανούση

Επιβλέπων: Λεόντιος Χατζηλεοντιάδης

Υποψήφιος διδάκτορας: Γιώργος Αποστολίδης

Θεσσαλονίκη, Νοέμβριος 2026



Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Κλινικό πλαίσιο και αξιοποίηση Τεχνητής Νοημοσύνης

Διαγνωστική προσέγγιση

- Ανάγκη για έγκαιρη και ακριβή διάγνωση
- Γαστροσκόπηση: άμεση επισκόπηση του γαστρεντερικού βλεννογόνου.
- Περιορισμοί: η εμπειρία του ενδοσκόπου, ο χρόνος παρατήρησης, η συστηματική επισκόπηση όλων των ανατομικών περιοχών, σύνθετη ανατομία στομάχου.

11,3%
παραλειφθέντες καρκίνοι

Σημασία της ποιότητας και της πληρότητας της εξέτασης

Τεχνητή Νοημοσύνη: Αυτόματη αναγνώριση ανατομικής θέσης.
Υποστήριξη παρακολούθησης της ανατομικής κάλυψης και του ποιοτικού ελέγχου της εξέτασης

Ερευνητικό Ερώτημα

Περιορισμένη διαθεσιμότητα επισημασμένων ενδοσκοπικών δεδομένων

⎯ Προεκπαίδευση σε μεγάλες συλλογές εικόνων (π.χ. DINO/DINOv2)

⎯ Domain gap: διαφορές μεταξύ φυσικών και ενδοσκοπικών εικόνων.

Προσέγγιση:

Generic DINO / DINOv2
Ήδη προεκπαιδευμένα μοντέλα της Meta

Continued SSL Pretraining
HyperKvasir · 108.321 εικόνες χωρίς ετικέτες

Domain-Adapted DINO / DINOv2
Αξιολόγηση μέσω ανατομικής ταξινόμησης στο GastroHUN · 23 ανατομικές κατηγορίες

Κεντρικό ερευνητικό ερώτημα

Μπορεί η προσαρμογή των DINO/DINOv2 στο ενδοσκοπικό πεδίο να βελτιώσει τις οπτικές αναπαραστάσεις τους για την ανατομική ταξινόμηση;

DINO και DINOv2

Κοινός μηχανισμός: Self-Distillation χωρίς ετικέτες και δίκτυα teacher-student

Μη επισημειωμένη εικόνα

↓

Augmentations / διαφορετικά crops

Teacher
Global views
↓
ViT + Projection head
Παράγει στόχους, μαθαίνει χωρίς gradients (EMA)

Student
Global + Local views
↓
ViT + Projection head
Μαθαίνει μέσω backpropagation

Συμφωνία προβλέψεων → Self-distillation loss

Ο Teacher ενημερώνεται από τον Student μέσω Exponential Moving Average (EMA).

Χαρακτηριστικό	DINO	DINOv2
Βασικός μηχανισμός	Teacher-student self distillation	Teacher-student self distillation
Δεδομένα Προεκπαίδευσης	ImageNet-1k(~1,28 εκ.)	LVD-142M(~142 εκ.)
Επιμέλεια δεδομένων	Χωρίς ειδική διαδικασία μεγάλης κλίμακας	Αυτοματοοιημένο data curation
Image-level objective	DINO self-distillation	DINO self-distillation
Patch-level objective	Δεν περιλαμβάνεται	iBOT masked image modeling
Regularization	Χωρίς KoLeo	KoLeo regularization
Ενημέρωση teacher	EMA των βαρών του student	EMA των βαρών του student
Teacher targets	Centering & sharpning	Sinkorn-Knopp assignments
Register tokens	Δεν περιλαμβάνεται	Προαιρετικά, σε εκδόσεις με registers
Κλίμακα εκπαίδευσης	Αρχική διαδικασία DINO	Βελτιστοποιημένη για μεγάλα datasets / μοντέλα

Μεθοδολογία

1. Αναπαραγωγή και επέκταση του GastroHUN benchmark

Αναπαραγωγή του benchmark: 16 baselines → Επέκταση με 8 generic DINO/DINOv2 → Κοινό downstream πρωτόκολλο
Frozen: εκπαιδεύεται μόνο το linear head
Partial FT: head + τελευταίο 40% των transformer blocks

2. Continued SSL και επιλογή checkpoint

3 μικρότερες αρχιτεκτονικές DINO/DINOv2: continued SSL στο HyperKvasir → Περιοδική αποθήκευση των βαρών του teacher: υποψήφια checkpoints → Στάδιο 1: frozen linear probing σε όλα τα checkpoints → Top-3 checkpoints → Στάδιο 2: frozen + partial fine-tuning (τελευταίο 40% των blocks) → μέγιστο άθροισμα validation Macro-F1

3. Ελεγχόμενη σύγκριση — ίδια αρχιτεκτονική, ίδιο downstream πρωτόκολλο

Generic — χωρίς πρόσθετη προεκπαίδευση

Generic θ_0 → Αξιολόγηση GastroHUN (frozen / partial FT)

Domain-adapted — μετά από continued SSL

Generic θ_0 → Continued SSL (HyperKvasir) → Επιλογή checkpoint → θ' → Αξιολόγηση GastroHUN (frozen / partial FT)

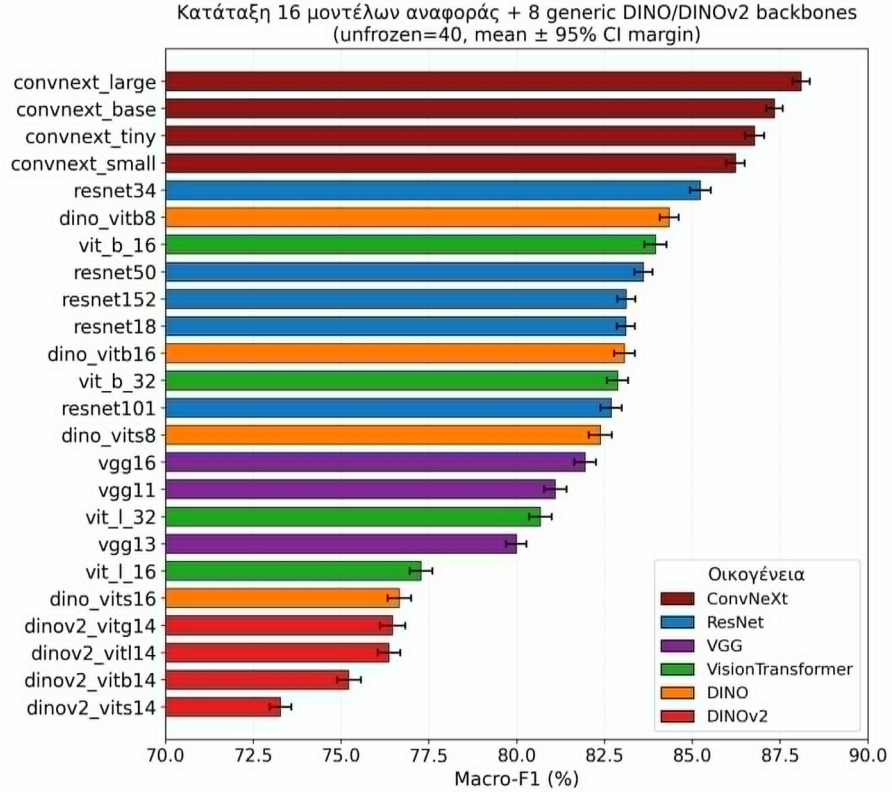
Αναπαραγωγή και Επέκταση GastroHUN

Αναπαραγωγή

Μοντέλο	Δημοσιευμένο	Αναπαραγμένο	Δ
convnext_tiny	86,79 ± 0,26	86,77	−0,02
convnext_small	86,47 ± 0,28	86,23	−0,24
convnext_base	87,16 ± 0,29	87,34	+0,18
convnext_large	88,25 ± 0,22	88,10	−0,16
resnet18	85,08 ± 0,25	83,11	−1,97
resnet34	84,85 ± 0,25	85,23	+0,39
resnet50	84,53 ± 0,29	83,61	−0,92
resnet101	83,59 ± 0,32	82,69	−0,89
resnet152	85,28 ± 0,27	83,12	−2,16
vgg11	78,61 ± 0,28	81,10	+2,49
vgg13	80,65 ± 0,31	79,99	−0,66
vgg16	75,62 ± 0,34	81,95	+6,33
vit_b_16	81,07 ± 0,30	83,95	+2,88
vit_b_32	79,33 ± 0,36	82,87	+3,53
vit_l_16	75,85 ± 0,34	77,28	+1,42
vit_l_32	80,77 ± 0,29	80,67	−0,10

Κατάταξη 24 μοντέλων

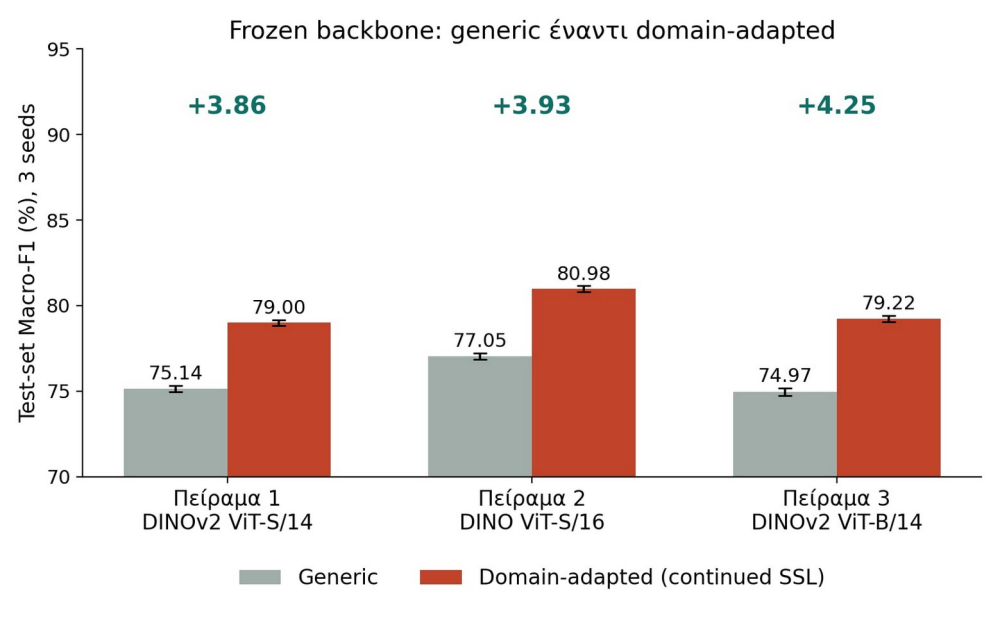
Partial fine-tuning (40%)

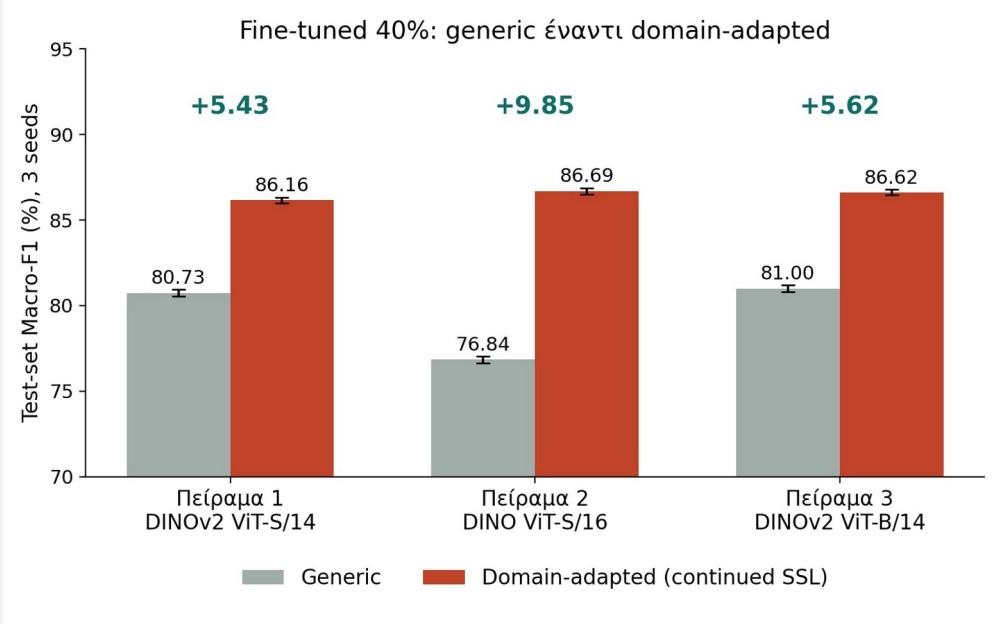


Frozen έναντι partial fine-tuning

Μοντέλο	Frozen	Fine-tuned (40%)	Δ
dino_vits8	79,43	82,38	+2,95
dino_vitb8	79,17	84,34	+5,18
dino_vitb16	78,99	83,07	+4,09
dino_vits16	78,46	76,66	−1,80
vgg13	77,80	79,99	+2,18
vgg11	75,95	81,10	+5,15
vgg16	75,87	81,95	+6,08
dinov2_vits14	75,18	73,27	−1,91
dinov2_vitg14	74,26	76,46	+2,20
convnext_base	73,26	87,34	+14,08
dinov2_vitl14	73,25	76,36	+3,11
convnext_large	73,08	88,10	+15,02
dinov2_vitb14	73,02	75,22	+2,20
vit_l_16	72,91	77,28	+4,37
vit_l_32	71,56	80,67	+9,11
vit_b_32	70,87	82,87	+11,99
convnext_tiny	70,08	86,77	+16,69
vit_b_16	70,06	83,95	+13,90
convnext_small	69,17	86,23	+17,06
resnet18	60,16	83,11	+22,96
resnet101	59,39	82,69	+23,30
resnet50	58,05	83,61	+25,56
resnet34	57,08	85,23	+28,15
resnet152	56,90	83,12	+26,22

Generic vs Domain adapted models after continued ssl

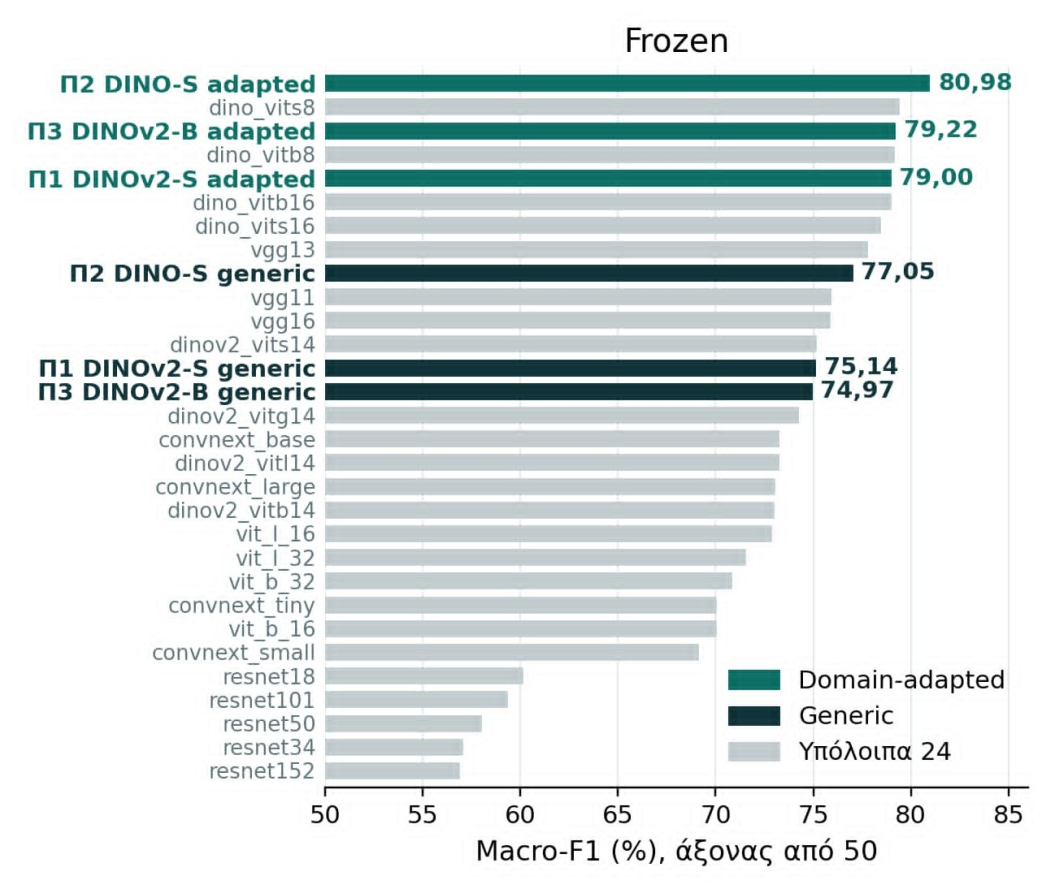


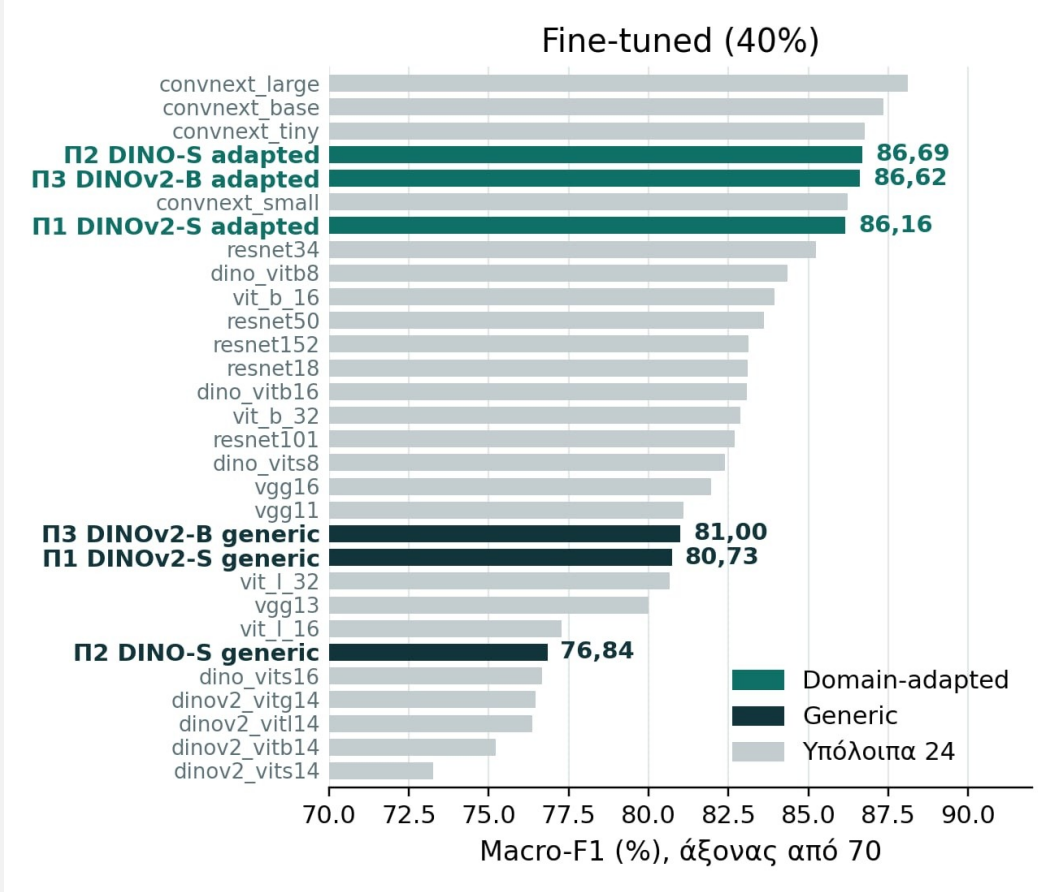


Μοντέλο	Frozen G → A	Fine-tuned G → A
DINOv2 ViT-S/14 + reg4	75,14 → 79,00	80,73 → 86,16
DINO ViT-S/16	77,05 → 80,98	76,84 → 86,69
DINOv2 ViT-B/14 + reg4	74,97 → 79,22	81,00 → 86,62

Και τα 3 μοντέλα βελτιώθηκαν και στις 2 στρατηγικές.
Το σταθερό frozen όφελος αποτελεί την πιο άμεση ένδειξη βελτίωσης των μαθημένων αναπαραστάσεων.

Συγκριτική Κατάταξη στο GastroHUN Benchmark





Κορυφαίες frozen αναπαραστάσεις και ανταγωνιστικές επιδόσεις μετά το fine-tuning

Συζήτηση, Συμπεράσματα και Μελλοντικές Προεκτάσεις

Κύρια συμπεράσματα:

1. Το domain-adapted υπερέχει του generic και στα 3 πειράματα, σε frozen και fine-tuning.
2. Συνεπές frozen όφελος: σημαντική βελτίωση αναπαραστάσεων
3. Τα adapted μοντέλα πέτυχαν ανταγωνιστικές επιδόσεις στο partial fine-tuning του συνολικού benchmark .
4. Η επίδοση εξαρτάται και από το downstream recipe, όχι μόνο από τις αναπαραστάσεις.

Περιορισμοί:

- Μία εκτέλεση SSL pretraining ανά αρχιτεκτονική
- Σταθερό, μη βελτιστοποιημένο downstream recipe
- Διαφορετικά batch sizes λόγω υπολογιστικών περιορισμών
- Ένα downstream dataset και ένα έργο

Μελλοντική έρευνα:

- Πολλαπλά seeds στην προεκπαίδευση
- Συνδυασμός continued SSL με βελτιστοποιημένο recipe
- Αξιολόγηση σε άλλα ενδοσκοπικά datasets και εργασίες
- Μεγαλύτερα backbones και πλήρες fine-tuning



Ευχαριστώ για την προσοχή σας!

Ερωτήσεις;