

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Συνεχιζόμενη αυτοεπιβλεπόμενη προεκπαίδευση αρχιτεκτονικών DINO και DINOv2 σε ενδοσκοπικά δεδομένα για την ταξινόμηση ανατομικών περιοχών του ανώτερου γαστρεντερικού συστήματος

Διπλωματική Εργασία

Βασιλική Μανούση

Επιβλέπων Καθηγητής:
Λεόντιος Χατζηλεοντιάδης

Επιβλέπων Υποψήφιος Διδάκτορας:
Γιώργος Αποστολίδης

Θεσσαλονίκη, Νοέμβριος 2026

Περίληψη

Η ακριβής αναγνώριση της ανατομικής περιοχής σε ενδοσκοπικές εικόνες του ανώτερου γαστρεντερικού συστήματος αποτελεί βασικό δομικό στοιχείο για συστήματα υποβοήθησης της γαστροσκόπησης, ωστόσο τα δεδομένα με ανθρώπινη επισημείωση είναι περιορισμένα. Τα μοντέλα αυτοεπιβλεπόμενης μάθησης DINO και DINOv2 προεκπαιδεύονται σε μεγάλα, γενικού τύπου σύνολα εικόνων χωρίς ετικέτες και έχουν δείξει ισχυρές αναπαραστάσεις σε πολλά πεδία, αλλά παραμένει ανοιχτό αν μια περαιτέρω προσαρμογή τους σε ενδοσκοπικά δεδομένα βελτιώνει την απόδοσή τους σε ένα συγκεκριμένο ιατρικό έργο.

Η παρούσα εργασία εξετάζει το ερώτημα αυτό στο GastroHUN benchmark ταξινόμησης ανατομικών περιοχών. Αρχικά αναπαράχθηκε το benchmark για 16 αρχιτεκτονικές αναφοράς και επεκτάθηκε με οκτώ generic DINO/DINOv2 backbones, με στόχο να διερευνηθούν η υστέρησή τους έναντι των αρχιτεκτονικών αναφοράς και η ευαισθησία τους στη ρύθμιση της εκπαίδευσης. Στη συνέχεια, τρία μοντέλα (DINOv2 ViT-S/14, DINO ViT-S/16 και DINOv2 ViT-B/14) προεκπαιδεύτηκαν περαιτέρω σε 108.321 μη επισημειωμένες εικόνες του HyperKvasir και συγκρίθηκαν με τα αντίστοιχα generic checkpoints. Η σύγκριση έγινε υπό σταθερό downstream πρωτόκολλο, με εκπαίδευση frozen backbone και partial fine-tuning, με τρία seeds και διαστήματα εμπιστοσύνης μέσω bootstrap.

Και στα τρία πειράματα, το domain-adapted checkpoint υπερτερεί στατιστικά σημαντικά του αντίστοιχου generic, τόσο όταν το backbone παραμένει παγωμένο όσο και μετά από partial fine-tuning. Όταν το backbone είναι παγωμένο, το όφελος είναι παρόμοιο και στα τρία μοντέλα, ανεξάρτητα από τη μέθοδο αυτοεπιβλεπόμενης μάθησης και το μέγεθος του backbone. Μετά από fine-tuning, το όφελος είναι μεγαλύτερο και διαφοροποιείται ανάμεσα στα μοντέλα, με το μεγαλύτερο να εμφανίζεται στο DINO, κυρίως επειδή το αντίστοιχο generic μοντέλο έχει ασυνήθιστα χαμηλή επίδοση. Μετά το continued pretraining, και τα τρία μοντέλα κατατάσσονται ανάμεσα στις πρώτες θέσεις της κατάταξης των αρχιτεκτονικών, μαζί με τα κορυφαία ConvNeXt. Η προκαταρκτική διερεύνηση έδειξε επιπλέον ότι η αρχική υστέρηση των generic DINOv2 οφείλεται εν μέρει στη ρύθμιση της εκπαίδευσης και όχι αποκλειστικά στην ποιότητα των αναπαραστάσεων. Τα αποτελέσματα υποδεικνύουν ότι η προσαρμογή σε δεδομένα του ίδιου πεδίου αποτελεί μια πρακτική και συνεπή κατεύθυνση βελτίωσης για αυτοεπιβλεπόμενα μοντέλα στην ενδοσκοπική απεικόνιση.

Λέξεις-κλειδιά: DINO, DINOv2, αυτοεπιβλεπόμενη μάθηση, continued pretraining, γαστροσκόπηση, GastroHUN, Vision Transformers, ταξινόμηση ανατομικών περιοχών

Abstract

Accurate recognition of the anatomical site in endoscopic images of the upper gastrointestinal tract is a key building block of computer-aided gastroscopy systems, yet annotated data remain scarce. The self-supervised models DINO and DINOv2 are pretrained on large, general-purpose collections of unlabeled images and have shown strong representations across many domains, but it remains unclear whether further adapting them to endoscopic data improves their performance on a specific medical task.

This thesis addresses this question on the GastroHUN anatomical site classification benchmark. First, the benchmark was reproduced for 16 reference architectures and extended with eight generic DINO/DINOv2 backbones, in order to investigate their underperformance relative to the reference architectures and their sensitivity to the training configuration. Then, three models (DINOv2 ViT-S/14, DINO ViT-S/16 and DINOv2 ViT-B/14) were further pretrained on 108,321 unlabeled HyperKvasir images and compared with their generic checkpoints under a fixed downstream protocol, using both a frozen backbone and partial fine-tuning, with three seeds and bootstrap confidence intervals.

In all three experiments, the domain-adapted checkpoint significantly outperforms its generic counterpart, both with a frozen backbone and after partial fine-tuning. With a frozen backbone, the gain is similar across the three models, regardless of the self-supervised method and the backbone size. After fine-tuning, the gain is larger and varies across models, with the largest observed for DINO, mainly because its generic counterpart performs unusually poorly. After continued pretraining, all three models rank among the top positions of the architecture ranking, alongside the top ConvNeXt models. The preliminary investigation also showed that the initial underperformance of the generic DINOv2 models is partly due to the training configuration rather than solely to the quality of their representations. The results suggest that adapting to in-domain data is a practical and consistent way of improving self-supervised models in endoscopic imaging.

Key words: DINO, DINOv2, self-supervised learning, continued pretraining, gastroscopy, GastroHUN, Vision Transformers, anatomical site classification

Περιεχόμενα

Περίληψη **i**

Abstract **ii**

1 Εισαγωγή **1**
1.1 Κίνητρο και Κλινικό Πλαίσιο 1
1.2 Απαραίτητες Έννοιες και Ορισμοί 4
1.3 Περιγραφή του Προβλήματος 5
1.4 Στόχοι και Συνεισφορές 7
1.5 Δομή της Διπλωματικής Εργασίας 8

2 Σχετική Βιβλιογραφία **11**
2.1 Τεχνητή Νοημοσύνη στη Γαστρεντερική Ενδοσκόπηση 11
2.2 Αναγνώριση Ανατομικής Θέσης και Ποιοτικός Έλεγχος της Ενδοσκοπικής Εξέτασης 12
2.3 Προεκπαιδευμένα Μοντέλα και Μεταφορά Μάθησης στην Ιατρική Απεικόνιση 13
2.4 Αυτοεπιβλεπόμενη Μάθηση και Domain-Specific Continued Pretraining στην Ιατρική Απεικόνιση 15
2.5 Το Σύνολο Δεδομένων και Benchmark GastroHUN 16

3 Θεωρητικό Υπόβαθρο **18**
3.1 Βασικές Έννοιες Βαθιάς Μάθησης και Συνελικτικών Νευρωνικών Δικτύων 18
3.1.1 Τεχνητά Νευρωνικά Δίκτυα και Εκμάθηση Αναπαραστάσεων 18
3.1.2 Συνελικτικά Νευρωνικά Δίκτυα 19
3.1.3 Σύγχρονες CNN Αρχιτεκτονικές 20
3.2 Vision Transformers 21
3.2.1 Από την Εικόνα στα Patches 21
3.2.2 Self-Attention 22
3.2.3 Multi-Head Self-Attention 24
3.2.4 Transformer Encoder και Positional Embeddings 25
3.2.5 Vision Transformer και `[CLS]` Token 26
3.3 Μεταφορά Μάθησης, Προεκπαίδευση και Προσαρμογή Μοντέλων . 28
3.3.1 Transfer Learning και Pretraining 28
3.3.2 Frozen Feature Extraction και Linear Probing 30
3.3.3 Fine-Tuning: Full και Partial 31
3.4 Αυτοεπιβλεπόμενη Μάθηση 33
3.4.1 Βασικές Αρχές της Self-Supervised Learning 33
3.4.2 Contrastive Learning 34
3.4.3 Non-Contrastive Learning και Self-Distillation 35
3.4.4 Αποφυγή Representation Collapse 36

3.5 DINO . . . 37
3.5.1 Αρχιτεκτονική Teacher--Student . . . 37
3.5.2 Self-Distillation Objective . . . 38
3.5.3 Image Augmentations και Multi-Crop Strategy . . . 39
3.5.4 Centering και Sharpening . . . 40
3.5.5 Exponential Moving Average του Teacher . . . 41
3.6 DINOv2 . . . 41
3.6.1 Motivation και Improved Training Pipeline . . . 41
3.6.2 Dataset Curation . . . 42
3.6.3 iBOT Masked Image Modeling . . . 43
3.6.4 KoLeo Regularization . . . 44
3.6.5 Sinkhorn--Knopp Normalization . . . 45
3.6.6 Register Tokens . . . 46
3.6.7 DINO έναντι DINOv2 . . . 47
3.7 Foundation Models και Domain-Specific Continued Pretraining . . . 48
3.7.1 Foundation Models στην Υπολογιστική Όραση . . . 48
3.7.2 Domain-Specific Adaptation . . . 48
3.7.3 Continued Self-Supervised Pretraining . . . 49

4 Προτεινόμενη Μεθοδολογία **51**
4.1 Ερευνητικός Σχεδιασμός . . . 51
4.2 Σύνολα Δεδομένων και Προετοιμασία . . . 52
4.2.1 HyperKvasir: Σύνολο Continued Self-Supervised Pretraining . . . 52
4.2.2 GastroHUN: Σύνολο Downstream Αξιολόγησης . . . 53
4.3 Καθορισμός του Downstream Training Protocol . . . 53
4.3.1 Αναπαραγωγή και Επέκταση του GastroHUN Benchmark . . . 53
4.3.2 Διερεύνηση Training Configuration . . . 54
4.3.3 Hyperparameter Search και Τελικό Protocol . . . 55
4.4 Πρωτόκολλο Επιλογής και Downstream Αξιολόγησης . . . 56
4.4.1 Επιλογή Domain-Adapted Checkpoint . . . 56
4.4.2 Frozen και Fine-Tuned Evaluation . . . 57
4.4.3 Μετρικές και Στατιστική Σύγκριση . . . 57
4.5 Σχεδιασμός των Επιμέρους Πειραμάτων . . . 58
4.5.1 Πείραμα 1: DINOv2 ViT-S . . . 59
4.5.2 Πείραμα 2: DINO ViT-S . . . 59
4.5.3 Πείραμα 3: DINOv2 ViT-B . . . 59

5 Πειραματική Διαδικασία **61**
5.1 Υπολογιστικό Περιβάλλον και Οργάνωση Υλοποίησης . . . 61
5.2 Πείραμα 1: Continued Pretraining με DINOv2 ViT-S/14 . . . 61
5.2.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης . . . 61
5.2.2 Εκτέλεση και Έλεγχος Σταθερότητας . . . 63
5.2.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση . . . 64
5.3 Πείραμα 2: Continued Pretraining με DINO ViT-S/16 . . . 65
5.3.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης . . . 65
5.3.2 Εκτέλεση και Έλεγχος Σταθερότητας . . . 66
5.3.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση . . . 67
5.4 Πείραμα 3: Continued Pretraining με DINOv2 ViT-B/14 . . . 68

5.4.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης 68
5.4.2 Εκτέλεση και Έλεγχος Σταθερότητας 70
5.4.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση 71
5.5 Αναπαραγωγιμότητα 71

6 Αποτελέσματα **72**
6.1 Προκαταρκτική Διερεύνηση και Καθορισμός του Downstream Training Protocol 72
6.1.1 Αποτελέσματα Αναπαραγωγής και Επέκτασης του GastroHUN 72
6.1.2 Αποτελέσματα Διερεύνησης Training Configuration 75
6.1.3 Αποτελέσματα Βελτιστοποίησης Υπερπαραμέτρων με Optuna 79
6.2 Πείραμα 1: DINOv2 ViT-S/14 --- Generic έναντι Domain-Adapted . . 79
6.2.1 Αποτελέσματα SSL Pretraining 80
6.2.2 Αποτελέσματα Επιλογής Checkpoint 80
6.2.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint . . 82
6.2.4 Τοποθέτηση στο Πλήρες Downstream Benchmark 82
6.3 Πείραμα 2: DINO ViT-S/16 --- Generic έναντι Domain-Adapted 85
6.3.1 Αποτελέσματα SSL Pretraining 85
6.3.2 Αποτελέσματα Επιλογής Checkpoint 85
6.3.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint . . 87
6.3.4 Τοποθέτηση στο Πλήρες Downstream Benchmark 88
6.4 Πείραμα 3: DINOv2 ViT-B/14 --- Generic έναντι Domain-Adapted . . 90
6.4.1 Αποτελέσματα SSL Pretraining 90
6.4.2 Αποτελέσματα Επιλογής Checkpoint 90
6.4.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint . . 92
6.4.4 Τοποθέτηση στο Πλήρες Downstream Benchmark 92
6.5 Συγκεντρωτική Σύγκριση των Τριών Πειραμάτων 95

7 Συζήτηση **96**
7.1 Ερμηνεία της Προκαταρκτικής Διερεύνησης 96
7.1.1 Ερμηνεία: Αναπαραγωγή και Επέκταση 96
7.1.2 Ερμηνεία: Ρύθμιση Εκπαίδευσης 96
7.1.3 Ερμηνεία: Επιβεβαίωση μέσω Optuna 97
7.2 Ερμηνεία του Πειράματος 1: DINOv2 ViT-S/14 97
7.2.1 Ερμηνεία: SSL Pretraining 98
7.2.2 Ερμηνεία: Επιλογή Checkpoint 98
7.2.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint 98
7.2.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark . 99
7.3 Ερμηνεία του Πειράματος 2: DINO ViT-S/16 99
7.3.1 Ερμηνεία: SSL Pretraining 99
7.3.2 Ερμηνεία: Επιλογή Checkpoint 99
7.3.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint 100
7.3.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark . 100
7.4 Ερμηνεία του Πειράματος 3: DINOv2 ViT-B/14 101
7.4.1 Ερμηνεία: SSL Pretraining 101
7.4.2 Ερμηνεία: Επιλογή Checkpoint 101
7.4.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint 101
7.4.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark . 102

7.5 Ερμηνεία της Συγκεντρωτικής Σύγκρισης 102
7.6 Σύγκριση με τη Βιβλιογραφία 103
7.7 Περιορισμοί 104

8 Συμπεράσματα και Μελλοντική Εργασία **107**
8.1 Σύνοψη της Εργασίας 107
8.2 Κύρια Συμπεράσματα 107
8.2.1 Συνέπεια του Οφέλους Continued Pretraining 107
8.2.2 Η Ευαισθησία στο Recipe ως Αρχιτεκτονικο-ειδικό Φαινόμενο 107
8.2.3 Γενίκευση ως προς Μέθοδο SSL και Μέγεθος Backbone . . . 108
8.2.4 Τοποθέτηση απέναντι στη Βιβλιογραφία 108
8.3 Συνεισφορές 108
8.4 Μελλοντική Έρευνα 109

Κεφάλαιο 1: Εισαγωγή

1.1 Κίνητρο και Κλινικό Πλαίσιο

Οι παθήσεις του ανώτερου γαστρεντερικού συστήματος αποτελούν ένα από τα σημαντικότερα προβλήματα δημόσιας υγείας παγκοσμίως, επηρεάζοντας εκατομμύρια ανθρώπους κάθε χρόνο και επιβαρύνοντας σημαντικά τα συστήματα υγειονομικής περίθαλψης [1]. Το ανώτερο γαστρεντερικό σύστημα περιλαμβάνει τον οισοφάγο, το στομάχι και το δωδεκαδάκτυλο, όργανα των οποίων η φυσιολογική λειτουργία είναι απαραίτητη για την πέψη και την απορρόφηση των θρεπτικών συστατικών. Η δυσλειτουργία ή η εμφάνιση παθολογικών αλλοιώσεων στις δομές αυτές μπορεί να οδηγήσει σε ένα ευρύ φάσμα νοσημάτων, από καλοήθεις φλεγμονώδεις καταστάσεις έως επιθετικές κακοήθειες [2].

Οι συχνότερες παθήσεις περιλαμβάνουν τη γαστροοισοφαγική παλινδρόμηση (Gastroesophageal Reflux Disease - GERD), τη γαστρίτιδα, τα πεπτικά έλκη, τις προκαρκινικές αλλοιώσεις, όπως ατροφική γαστρίτιδα και εντερική μεταπλασία, καθώς και νεοπλασίες του οισοφάγου και του στομάχου. Μάλιστα, η λοίμωξη από το *Helicobacter pylori*, η οποία προσβάλλει περίπου το ήμισυ του παγκόσμιου πληθυσμού, αποτελεί τον σημαντικότερο παράγοντα κινδύνου για την ανάπτυξη χρόνιας γαστρίτιδας, πεπτικού έλκους και τελικά γαστρικού αδενοκαρκινώματος [3, 4].

Ιδιαίτερο ενδιαφέρον παρουσιάζει ο καρκίνος του στομάχου, ο οποίος εξακολουθεί να αποτελεί μία από τις πλέον θανατηφόρες μορφές καρκίνου. Σύμφωνα με τα δεδομένα του GLOBOCAN 2022, ο καρκίνος του στομάχου είναι η πέμπτη συχνότερη μορφή καρκίνου παγκοσμίως, με περισσότερα από 968.000 νέα περιστατικά ετησίως, ενώ κατατάσσεται πέμπτος και ως προς τη θνησιμότητα, προκαλώντας περίπου 660.000 θανάτους κάθε χρόνο [1]. Η υψηλή θνησιμότητα της νόσου οφείλεται σε μεγάλο βαθμό στο γεγονός ότι τα πρώιμα στάδια εμφανίζουν συνήθως ήπια ή μη ειδικά συμπτώματα, όπως δυσπεψία, επιγαστρικό άλγος ή αίσθημα πληρότητας, με αποτέλεσμα σημαντικό ποσοστό των ασθενών να διαγιγνώσκεται όταν η νόσος έχει ήδη εξελιχθεί [2].

Η πρόγνωση του καρκίνου του στομάχου εξαρτάται σε σημαντικό βαθμό από το στάδιο στο οποίο πραγματοποιείται η διάγνωση. Όταν η νόσος ανιχνεύεται σε πρώιμο στάδιο, το πενταετές ποσοστό επιβίωσης μπορεί να υπερβαίνει το 90% μετά από κατάλληλη θεραπευτική αντιμετώπιση. Αντίθετα, στα προχωρημένα στάδια της νόσου η πενταετής επιβίωση μειώνεται δραματικά, συνήθως σε ποσοστά της τάξης του 15--20% ή και χαμηλότερα [5, 2]. Το γεγονός αυτό καθιστά την έγκαιρη ανίχνευση τόσο των προκαρκινικών αλλοιώσεων όσο και των πρώιμων νεοπλασιών καθοριστικό παράγοντα για την αποτελεσματική αντιμετώπιση της νόσου και τη βελτίωση της επιβίωσης των ασθενών.

Πέρα από τις κακοήθειες, ιδιαίτερη σημασία παρουσιάζουν και οι προκαρκινικές καταστάσεις, όπως η ατροφική γαστρίτιδα και η εντερική μεταπλασία, οι οποίες μπορούν σταδιακά να εξελιχθούν σε γαστρικό αδενοκαρκίνωμα. Η συστηματική παρακολούθηση των ασθενών που παρουσιάζουν αυτές τις αλλοιώσεις αποτελεί σημαντική στρατηγική πρόληψης, καθώς επιτρέπει την ανίχνευση νεοπλασματικών

μεταβολών σε πρώιμο στάδιο [6, 7].

Η κλινική επιβάρυνση των παθήσεων του ανώτερου γαστρεντερικού συστήματος, σε συνδυασμό με τη σημασία της έγκαιρης διάγνωσης, αναδεικνύει την ανάγκη για αξιόπιστες διαγνωστικές μεθόδους που επιτρέπουν την άμεση και συστηματική αξιολόγηση του γαστρεντερικού βλεννογόνου.

Η οισοφαγογαστροδωδεκαδακτυλοσκόπηση, γνωστή ευρύτερα ως γαστροσκόπηση, και διεθνώς ως *Esophagogastroduodenoscopy* (EGD), αποτελεί μία από τις σημαντικότερες διαγνωστικές μεθόδους για την αξιολόγηση των παθήσεων του ανώτερου γαστρεντερικού συστήματος [8]. Πρόκειται για μία ελάχιστα επεμβατική διαδικασία, κατά την οποία ένα εύκαμπτο ενδοσκόπιο, εξοπλισμένο με κάμερα υψηλής ανάλυσης και κατάλληλη πηγή φωτισμού, εισάγεται μέσω του στόματος και προωθείται διαδοχικά στον οισοφάγο, το στομάχι και το δωδεκαδάκτυλο, επιτρέποντας την άμεση επισκόπηση του βλεννογόνου σε πραγματικό χρόνο.

Σε αντίθεση με άλλες απεικονιστικές μεθόδους, η γαστροσκόπηση παρέχει στον ιατρό τη δυνατότητα παρατήρησης των εσωτερικών ανατομικών δομών και διευκολύνει έτσι τον εντοπισμό φλεγμονών, ελκών, αιμορραγικών βλαβών, πολυπόδων, προκαρκινικών αλλοιώσεων και πιθανών κακοηθειών [6]. Παράλληλα, η συνεχής εξέλιξη της ενδοσκοπικής τεχνολογίας και η ανάπτυξη ενδοσκοπίων υψηλής ευκρίνειας έχουν βελτιώσει σημαντικά την ποιότητα των παραγόμενων εικόνων και τη δυνατότητα απεικόνισης λεπτών μορφολογικών χαρακτηριστικών του βλεννογόνου.

Παρά τις σημαντικές τεχνολογικές εξελίξεις, η διαγνωστική απόδοση της γαστροσκόπησης εξακολουθεί να εξαρτάται σε σημαντικό βαθμό από την ποιότητα και την πληρότητα της ίδιας της εξέτασης: την εμπειρία και την τεχνική του ενδοσκόπου, την ποιότητα προετοιμασίας του ασθενούς, τον καθαρισμό του βλεννογόνου, την επαρκή διάταση του στομάχου, τον διαθέσιμο χρόνο παρατήρησης και τη συστηματική επισκόπηση των επιμέρους ανατομικών περιοχών [8]. Η βελτίωση του απεικονιστικού εξοπλισμού δεν εξασφαλίζει επομένως από μόνη της πλήρη εξέταση του βλεννογόνου --- δυσκολία που επιτείνεται από την ίδια τη σύνθετη ανατομία του στομάχου. Ως κοίλο, τρισδιάστατο όργανο με έντονες βλεννογονικές πτυχές και μεταβαλλόμενο σχήμα ανάλογα με τον βαθμό διάτασης, η πλήρης εξέτασή του απαιτεί διαδοχικούς χειρισμούς προώθησης, απόσυρσης και περιστροφής του ενδοσκοπίου. Περιοχές όπως η καρδιοοισοφαγική συμβολή, ο θόλος, το έλασσον τόξο, η γωνία του στομάχου, το άντρο και ο πυλωρός μπορούν να αποτελέσουν δυνητικά δυσπρόσιτα σημεία, ιδιαίτερα χωρίς συστηματική χαρτογράφηση του βλεννογόνου [9].

Για τη μείωση των μη εξεταζόμενων περιοχών έχει προταθεί το *Systematic Screening Protocol for the Stomach* (SSS), σύμφωνα με το οποίο η επισκόπηση του στομάχου πραγματοποιείται μέσω μιας τυποποιημένης ακολουθίας λήψεων από διαφορετικές ανατομικές θέσεις και οπτικές γωνίες. Το πρωτόκολλο περιλαμβάνει συνολικά 22 αντιπροσωπευτικές ενδοσκοπικές εικόνες και αποσκοπεί στη συστηματική χαρτογράφηση του γαστρικού βλεννογόνου, περιορίζοντας τα λεγόμενα *blind spots* [9, 10].

Πέρα από τη στατική ανατομική πολυπλοκότητα, η ίδια η ενδοσκοπική εικόνα παρουσιάζει σημαντική μεταβλητότητα κατά τη διάρκεια της εξέτασης: η συνεχής κίνηση του ενδοσκοπίου μεταβάλλει τη γωνία λήψης, την απόσταση, την κλίμακα, τον φωτισμό και τον προσανατολισμό, με αποτέλεσμα η ίδια ανατομική περιοχή να εμφανίζεται διαφορετικά σε διαδοχικά καρέ και διαφορετικές περιοχές να παρουσιάζουν παρόμοια μορφολογία, ενώ γαστρικά υγρά, βλέννα, αφρός, αίμα ή υπολείμματα τροφής, κατοπτρικές αντανακλάσεις και ανεπαρκής διάταση περιορίζουν πε-

ραιτέρω την ποιότητα της απεικόνισης [9, 8]. Ιδιαίτερα σημαντικός είναι και ο διαθέσιμος χρόνος παρατήρησης: η ταχεία ολοκλήρωση της εξέτασης περιορίζει τον χρόνο για λεπτομερή επισκόπηση, καθαρισμό του οπτικού πεδίου και επανεξέταση ύποπτων περιοχών, και μελέτες έχουν δείξει ότι οι ενδοσκόποι που αφιερώνουν περισσότερο χρόνο εντοπίζουν περισσότερες νεοπλασματικές αλλοιώσεις [11, 12].

Οι δυσκολίες αυτές αποκτούν ιδιαίτερη κλινική σημασία στην περίπτωση των πρώιμων νεοπλασματικών αλλοιώσεων, οι οποίες μπορεί να είναι μικρές, επίπεδες ή ελαφρώς καταβυθισμένες, με μόνο διακριτικές μεταβολές στο χρώμα, στο αγγειακό πρότυπο ή στην επιφανειακή μορφολογία του βλεννογόνου. Η αναγνώρισή τους εξαρτάται επομένως όχι μόνο από την εμπειρία του εξεταστή, αλλά και από το κατά πόσο η αντίστοιχη περιοχή έχει απεικονιστεί καθαρά, από κατάλληλη οπτική γωνία και για επαρκές χρονικό διάστημα - καθιστώντας την πλήρη ανατομική κάλυψη σημαντική προϋπόθεση για μια υψηλής ποιότητας ενδοσκοπική εξέταση.

Η κλινική σημασία του προβλήματος αναδεικνύεται και από τις μελέτες των λεγόμενων καρκίνων του ανώτερου γαστρεντερικού μετά από προηγούμενη ενδοσκόπηση, οι οποίοι αναφέρονται ως *post-endoscopy upper gastrointestinal cancers* (PEUGIC). Ανάλυση δέκα μελετών και 3.787 ασθενών με καρκίνο του ανώτερου γαστρεντερικού κατέγραψε εκτιμώμενο ποσοστό παραλειφθέντων καρκίνων 6,4% εντός ενός έτους και 11,3% εντός τριών ετών από προηγούμενη ενδοσκόπηση [13]. Αντίστοιχα, πληθυσμιακή μελέτη στην Αγγλία έδειξε ότι περίπου το 8,3% των ασθενών με γαστρικό καρκίνο είχε υποβληθεί σε ενδοσκόπηση κατά τα τρία προηγούμενα έτη χωρίς η κακοήθεια να έχει αναγνωριστεί κατά την αρχική εξέταση [14]. Τα στοιχεία αυτά δεν υποδηλώνουν ότι κάθε τέτοια περίπτωση οφείλεται αποκλειστικά σε ανθρώπινο σφάλμα ή ανεπαρκή ανατομική κάλυψη, καταδεικνύουν όμως ότι η διασφάλιση μιας συστηματικής και ολοκληρωμένης εξέτασης αποτελεί σημαντική παράμετρο της ενδοσκοπικής ποιότητας.

Κατά συνέπεια, η ποιότητα της γαστροσκόπησης δεν θα πρέπει να αξιολογείται αποκλειστικά βάσει της τελικής διάγνωσης. Εξίσου σημαντική είναι η τεκμηρίωση ότι οι απαραίτητες ανατομικές περιοχές απεικονίστηκαν με συστηματικό τρόπο και υπό κατάλληλες συνθήκες ορατότητας. Η φωτογραφική τεκμηρίωση ανατομικών οροσήμων, ο χρόνος εξέτασης και η παρακολούθηση δεικτών που σχετίζονται με παραλείψεις έχουν προταθεί ως στοιχεία για την αξιολόγηση και τη βελτίωση της ποιότητας της ενδοσκόπησης του ανώτερου γαστρεντερικού [8].

Στο πλαίσιο αυτό, τα τελευταία χρόνια έχει αναπτυχθεί έντονο ερευνητικό ενδιαφέρον για την αξιοποίηση της Τεχνητής Νοημοσύνης (*Artificial Intelligence, AI*) στην ενδοσκόπηση. Οι εφαρμογές αυτές δεν περιορίζονται πλέον στην αυτόματη ανίχνευση και ταξινόμηση παθολογικών αλλοιώσεων, αλλά επεκτείνονται και στην παρακολούθηση της ίδιας της διαδικασίας της γαστροσκόπησης. Συστήματα υποβοήθησης μπορούν να αναγνωρίζουν ανατομικά ορόσημα, να καταγράφουν ποιες περιοχές έχουν ήδη εξεταστεί και να επισημαίνουν πιθανά *blind spots*.

Ένα τέτοιο σύστημα ανατομικής αναγνώρισης μπορεί να αντιστοιχίζει κάθε εικόνα ή καρέ σε συγκεκριμένη περιοχή του ανώτερου γαστρεντερικού συστήματος και, μέσω της διαδοχικής ανάλυσης των προβλέψεων, να υποστηρίζει την παρακολούθηση της πορείας της εξέτασης και την εκτίμηση της πληρότητας της ανατομικής κάλυψης. Πρόσφατες μελέτες βαθιάς μάθησης έχουν καταδείξει ότι η αυτόματη ταξινόμηση ενδοσκοπικών εικόνων σε ανατομικές θέσεις είναι τεχνικά εφικτή [15, 16, 17].

Η αξιόπιστη αναγνώριση της ανατομικής θέσης μπορεί επομένως να αποτελέσει

βασικό υποσύστημα ευρύτερων εφαρμογών υποβοηθούμενης ενδοσκόπησης. Δεν αποσκοπεί στην αντικατάσταση της κλινικής κρίσης του γαστρεντερολόγου, αλλά μπορεί να υποστηρίξει την αντικειμενικότερη παρακολούθηση της πορείας της εξέτασης και την αναγνώριση πιθανώς ανεπαρκώς εξετασμένων περιοχών. Μακροπρόθεσμα, μια τέτοια δυνατότητα μπορεί να αποτελέσει δομικό στοιχείο ολοκληρωμένων συστημάτων που συνδυάζουν ανατομική αναγνώριση, έλεγχο ποιότητας και αυτόματη ανίχνευση παθολογικών αλλοιώσεων.

1.2 Απαραίτητες Έννοιες και Ορισμοί

Πριν από τη διατύπωση του ερευνητικού προβλήματος, παρουσιάζονται συνοπτικά ορισμένες βασικές έννοιες που χρησιμοποιούνται στην παρούσα εργασία. Η αναλυτική θεωρητική τους θεμελίωση ακολουθεί στο Κεφάλαιο 3.

Ανατομική ταξινόμηση: Η ανατομική ταξινόμηση (*anatomical classification*) αφορά την αυτόματη αντιστοίχιση μιας ενδοσκοπικής εικόνας σε μία προκαθορισμένη ανατομική περιοχή του γαστρεντερικού συστήματος. Πρόκειται για πρόβλημα πολυταξικής ταξινόμησης (*multi-class classification*), στο οποίο το μοντέλο προβλέπει την ανατομική κατηγορία της εικόνας και όχι την παρουσία ή τη θέση κάποιας παθολογικής αλλοίωσης [15, 16, 17].

Προεκπαίδευση: Η προεκπαίδευση (*pretraining*) είναι η διαδικασία κατά την οποία ένα μοντέλο εκπαιδεύεται αρχικά σε ένα μεγάλο σύνολο δεδομένων, πριν χρησιμοποιηθεί για την τελική εργασία ενδιαφέροντος. Στόχος είναι το μοντέλο να αποκτήσει χρήσιμες οπτικές αναπαραστάσεις, οι οποίες μπορούν στη συνέχεια να μεταφερθούν σε μια περισσότερο εξειδικευμένη εργασία. Με αυτόν τον τρόπο, η εκπαίδευση για το τελικό πρόβλημα δεν ξεκινά από τυχαία αρχικοποιημένες παραμέτρους, αλλά από ένα μοντέλο που έχει ήδη αποκτήσει γνώση από προηγούμενα δεδομένα.

Αυτοεπιβλεπόμενη μάθηση: Η αυτοεπιβλεπόμενη μάθηση (*Self-Supervised Learning, SSL*) αποτελεί μορφή μάθησης κατά την οποία ένα μοντέλο εκπαιδεύεται χωρίς να απαιτούνται χειροκίνητες ετικέτες για κάθε δείγμα. Το εκπαιδευτικό σήμα προκύπτει από τα ίδια τα δεδομένα, επιτρέποντας την αξιοποίηση μεγάλων συλλογών μη επισημασμένων εικόνων για την εκμάθηση χρήσιμων οπτικών αναπαραστάσεων. Η δυνατότητα αυτή είναι ιδιαίτερα σημαντική στην ιατρική απεικόνιση, όπου η συλλογή δεδομένων μπορεί να είναι σχετικά εύκολη, ενώ η αξιόπιστη επισήμανσή τους απαιτεί χρόνο και εξειδικευμένη γνώση. Χαρακτηριστικές μέθοδοι αυτοεπιβλεπόμενης μάθησης στην υπολογιστική όραση αποτελούν τα DINO και DINOv2 [18, 19].

Domain gap και προσαρμογή στο πεδίο: Ο όρος *domain gap* περιγράφει τις διαφορές στην κατανομή και στα οπτικά χαρακτηριστικά μεταξύ των δεδομένων προεκπαίδευσης ενός μοντέλου και εκείνων του πεδίου εφαρμογής του. Για παράδειγμα, ένα μοντέλο που έχει προεκπαιδευτεί σε γενικού σκοπού εικόνες έχει εκτεθεί σε οπτικό περιεχόμενο που μπορεί να διαφέρει σημαντικά από τις εικόνες γαστρεντερικής ενδοσκόπησης.

Η προσαρμογή στο πεδίο (*domain adaptation*) αποσκοπεί στη μείωση αυτής της απόκλισης. Στην παρούσα εργασία, η προσαρμογή πραγματοποιείται μέσω *continued*

pretraining ή *domain-adaptive pretraining*: αντί το ήδη προεκπαιδευμένο μοντέλο να χρησιμοποιηθεί απευθείας στην τελική εργασία, η προεκπαίδευσή του συνεχίζεται σε μη επισημασμένες εικόνες από το πεδίο της γαστρεντερικής ενδοσκόπησης. Στόχος είναι οι ήδη αποκτημένες γενικές οπτικές αναπαραστάσεις να προσαρμοστούν καλύτερα στα ιδιαίτερα χαρακτηριστικά του συγκεκριμένου πεδίου.

Frozen backbone: Ως *backbone* αναφέρεται το κύριο τμήμα ενός μοντέλου που είναι υπεύθυνο για την εξαγωγή οπτικών χαρακτηριστικών από την εικόνα. Στην αξιολόγηση με *frozen backbone*, οι παράμετροι αυτού του τμήματος παραμένουν σταθερές και εκπαιδεύεται μόνο μια νέα κεφαλή ταξινόμησης (*classification head*) για την τελική εργασία. Με αυτόν τον τρόπο μπορεί να αξιολογηθεί κατά πόσο οι αναπαραστάσεις που έχει ήδη μάθει το μοντέλο είναι άμεσα χρήσιμες για το νέο πρόβλημα, χωρίς να τροποποιηθούν κατά την επιβλεπόμενη εκπαίδευση.

Fine-tuning: Στο *fine-tuning*, το προεκπαιδευμένο μοντέλο προσαρμόζεται στην τελική εργασία χρησιμοποιώντας επισημασμένα δεδομένα. Σε αντίθεση με την αξιολόγηση με frozen backbone, οι παράμετροι του backbone επιτρέπεται να ενημερωθούν κατά την εκπαίδευση, ώστε οι ήδη αποκτημένες αναπαραστάσεις να προσαρμοστούν περαιτέρω στο συγκεκριμένο πρόβλημα. Η αξιολόγηση τόσο με frozen backbone όσο και με fine-tuning παρέχει δύο συμπληρωματικές οπτικές για τη χρησιμότητα ενός προεκπαιδευμένου μοντέλου: η πρώτη εξετάζει περισσότερο την ποιότητα των ήδη μαθημένων αναπαραστάσεων, ενώ η δεύτερη και την ικανότητά τους να προσαρμόζονται σε μια συγκεκριμένη downstream εργασία.

1.3 Περιγραφή του Προβλήματος

Η αυτόματη ταξινόμηση ενδοσκοπικών εικόνων ως προς την ανατομική περιοχή που απεικονίζουν αποτελεί ένα απαιτητικό πρόβλημα υπολογιστικής όρασης. Σε αντίθεση με προβλήματα αναγνώρισης αντικειμένων σε φυσικές εικόνες, όπου διαφορετικές κατηγορίες συχνά χαρακτηρίζονται από διακριτά σχήματα και σαφή όρια, οι ανατομικές περιοχές του γαστρεντερικού συστήματος δεν παρουσιάζουν πάντοτε μοναδικά και σταθερά οπτικά χαρακτηριστικά. Η μετάβαση μεταξύ γειτονικών ανατομικών περιοχών μπορεί να είναι συνεχής, ενώ σημαντικό μέρος της εικόνας αποτελείται από βλεννογόνο με παρόμοια υφή και χρωματικά χαρακτηριστικά.

Η δυσκολία αυτή μπορεί να περιγραφεί μέσω δύο συμπληρωματικών χαρακτηριστικών του προβλήματος: της υψηλής ενδοκατηγορικής μεταβλητότητας (*intra-class variability*) και της υψηλής διακατηγορικής ομοιότητας (*inter-class similarity*). Η ίδια ανατομική περιοχή μπορεί να παρουσιάζει σημαντικά διαφορετική εμφάνιση ανάλογα με τη γωνία λήψης, την απόσταση του ενδοσκοπίου, τον προσανατολισμό, τον βαθμό διάτασης και τις συνθήκες φωτισμού. Αντίστροφα, διαφορετικές και ιδιαίτερα γειτονικές ανατομικές περιοχές μπορούν να εμφανίζουν παρόμοια μορφολογία. Κατά συνέπεια, ένα μοντέλο ανατομικής ταξινόμησης πρέπει να είναι ικανό να διακρίνει λεπτές μορφολογικές και ανατομικές διαφορές, παραμένοντας ταυτόχρονα ανθεκτικό σε μεταβολές της απεικόνισης που δεν μεταβάλλουν την πραγματική ανατομική ταυτότητα της εικόνας.

Η δυνατότητα αντιμετώπισης του προβλήματος με μεθόδους βαθιάς μάθησης έχει ήδη καταδειχθεί από προηγούμενες ερευνητικές εργασίες [15, 16, 17]. Ωστόσο,

πέρα από την επιλογή της αρχιτεκτονικής ταξινόμησης, καθοριστικό ρόλο στην απόδοση ενός μοντέλου διαδραματίζει η ποιότητα των οπτικών αναπαραστάσεων που χρησιμοποιεί. Ιδιαίτερα σε εφαρμογές όπου η διαθεσιμότητα επισημασμένων δεδομένων είναι περιορισμένη, η αξιοποίηση προεκπαιδευμένων μοντέλων αποτελεί σημαντική στρατηγική για τη μεταφορά ήδη μαθημένης οπτικής γνώσης στο τελικό πρόβλημα.

Παρά την ικανότητα των σύγχρονων προεκπαιδευμένων μοντέλων να παράγουν γενικές οπτικές αναπαραστάσεις, η αποτελεσματικότητά τους δεν είναι απαραίτητα ίδια σε όλα τα πεδία εφαρμογής. Ειδικότερα, οι εικόνες γαστρεντερικής ενδοσκόπησης παρουσιάζουν χαρακτηριστικά που διαφοροποιούνται σημαντικά από εκείνα των φυσικών εικόνων που χρησιμοποιούνται συνήθως κατά τη γενική προεκπαίδευση. Το γεγονός αυτό εγείρει το ερώτημα κατά πόσο οι αναπαραστάσεις ενός γενικού μοντέλου είναι επαρκώς προσαρμοσμένες για τη διάκριση λεπτών ανατομικών διαφορών ή εάν μπορούν να βελτιωθούν μέσω περαιτέρω εκπαίδευσης σε δεδομένα του ενδοσκοπικού πεδίου.

Μια δυνατότητα διερεύνησης αυτού του ερωτήματος προκύπτει από τη διαθεσιμότητα μη επισημασμένων ενδοσκοπικών δεδομένων. Ενδεικτικά, το σύνολο δεδομένων HyperKvasir περιλαμβάνει μεγάλο όγκο ενδοσκοπικού οπτικού υλικού, το οποίο μπορεί να αξιοποιηθεί για αυτοεπιβλεπόμενη εκμάθηση αναπαραστάσεων χωρίς την ανάγκη πρόσθετων ανατομικών επισημάνσεων [20]. Με τον τρόπο αυτό καθίσταται δυνατή η διερεύνηση μιας ενδιάμεσης φάσης προεκπαίδευσης, κατά την οποία ένα ήδη προεκπαιδευμένο μοντέλο εκτίθεται σε δεδομένα του πεδίου εφαρμογής πριν από την τελική επιβλεπόμενη εκπαίδευση.

Για τη συστηματική αξιολόγηση μιας τέτοιας προσέγγισης απαιτείται ένα κατάλληλα οργανωμένο σύνολο δεδομένων ανατομικής ταξινόμησης. Το GastroHUN παρέχει ένα σχετικό πλαίσιο αναφοράς για εικόνες του ανώτερου γαστρεντερικού συστήματος, με ανατομικές κατηγορίες και διαχωρισμό των δεδομένων σε επίπεδο ασθενούς, περιορίζοντας τον κίνδυνο διαρροής πληροφορίας μεταξύ των συνόλων εκπαίδευσης και αξιολόγησης [21]. Επιπλέον, η αρχική μελέτη του GastroHUN περιλαμβάνει συγκριτική αξιολόγηση διαφορετικών προεκπαιδευμένων αρχιτεκτονικών υπό κοινό πειραματικό πρωτόκολλο, προσφέροντας ένα σημείο αναφοράς για τη μελέτη εναλλακτικών στρατηγικών αξιοποίησης προεκπαιδευμένων μοντέλων.

Ωστόσο, η σύγκριση προεκπαιδευμένων αρχιτεκτονικών στην τελική εργασία δεν απαντά από μόνη της στο ερώτημα κατά πόσο μια ενδιάμεση φάση αυτοεπιβλεπόμενης προσαρμογής μπορεί να βελτιώσει τη χρησιμότητα των οπτικών αναπαραστάσεων. Το ερευνητικό κενό στο οποίο εστιάζει η παρούσα εργασία αφορά ακριβώς αυτή τη διάσταση: την επίδραση της συνέχισης της αυτοεπιβλεπόμενης προεκπαίδευσης σε μη επισημασμένα ενδοσκοπικά δεδομένα στην απόδοση μοντέλων ανατομικής ταξινόμησης.

Συγκεκριμένα, διερευνάται κατά πόσο η προσαρμογή γενικά προεκπαιδευμένων μοντέλων DINO και DINOv2 στο ενδοσκοπικό πεδίο μπορεί να οδηγήσει σε περισσότερο κατάλληλες οπτικές αναπαραστάσεις, σε σύγκριση με την απευθείας αξιοποίηση των αρχικών τους βαρών. Η ανατομική ταξινόμηση χρησιμοποιείται ως downstream εργασία αξιολόγησης, επιτρέποντας τη μελέτη τόσο της ποιότητας των ήδη μαθημένων αναπαραστάσεων όσο και της δυνατότητας περαιτέρω προσαρμογής τους μέσω επιβλεπόμενης εκπαίδευσης. Η προσέγγιση αυτή αποτελεί τη βάση για τη διατύπωση των ερευνητικών στόχων και συνεισφορών που παρουσιάζονται στην επόμενη ενότητα.

1.4 Στόχοι και Συνεισφορές

Η παρούσα εργασία διερευνά κατά πόσο η συνέχιση της αυτοεπιβλεπόμενης προεκπαίδευσης (*continued self-supervised pretraining*) γενικά προεκπαιδευμένων μοντέλων σε μη επισημασμένα δεδομένα γαστρεντερικής ενδοσκόπησης μπορεί να βελτιώσει τη χρησιμότητα των οπτικών αναπαραστάσεών τους για την ανατομική ταξινόμηση. Η βασική ερευνητική υπόθεση εξετάζεται μέσω ελεγχόμενων συγκρίσεων μεταξύ των αρχικών (*generic*) και των προσαρμοσμένων στο πεδίο (*domain-adapted*) εκδοχών των ίδιων μοντέλων.

Για τη διερεύνηση της υπόθεσης αυτής, οι κύριοι στόχοι της εργασίας είναι οι ακόλουθοι:

1. **Επέκταση του πλαισίου αξιολόγησης GastroHUN.** Το αρχικό benchmark [21] επεκτείνεται με γενικά προεκπαιδευμένα μοντέλα των οικογενειών DINO [18] και DINOv2 [19], διαφορετικών αρχιτεκτονικών μεγεθών, ώστε να αξιολογηθεί η συμπεριφορά τους σε σύγκριση με τις δημοσιευμένες αρχιτεκτονικές αναφοράς.

2. **Ανάπτυξη αναπαράξιμου πλαισίου continued pretraining.** Υλοποιείται διαδικασία περαιτέρω αυτοεπιβλεπόμενης προεκπαίδευσης, η οποία ξεκινά από επίσημα generic checkpoints και αξιοποιεί μη επισημασμένες ενδοσκοπικές εικόνες από το HyperKvasir [20]. Η διαδικασία εφαρμόζεται σε τρεις διαμορφώσεις μοντέλων, ώστε να εξεταστεί η επίδραση της προσαρμογής υπό διαφορετικές συνθήκες:

   - **Πείραμα 1 -- Βασική διερεύνηση:** DINOv2 ViT-S/14 με register tokens.
   - **Πείραμα 2 -- Διαφορετική μέθοδος αυτοεπιβλεπόμενης μάθησης:** DINO ViT-S/16.
   - **Πείραμα 3 -- Μεγαλύτερη αρχιτεκτονική:** DINOv2 ViT-B/14 με register tokens.

3. **Ελεγχόμενη σύγκριση generic και domain-adapted αναπαραστάσεων.** Σε κάθε πείραμα συγκρίνονται μοντέλα ίδιας αρχιτεκτονικής, με το domain-adapted μοντέλο να προκύπτει από τη συνέχιση της προεκπαίδευσης του αντίστοιχου generic checkpoint. Με τον τρόπο αυτό περιορίζεται η επίδραση αρχιτεκτονικών διαφορών και καθίσταται δυνατή η συστηματική εξέταση της πρόσθετης αυτοεπιβλεπόμενης προσαρμογής.

4. **Αξιολόγηση της downstream χρησιμότητας και της σταθερότητας των αποτελεσμάτων.** Τα μοντέλα αξιολογούνται στο GastroHUN τόσο με frozen backbone όσο και με partial fine-tuning. Η σύγκριση περιλαμβάνει τρεις ανεξάρτητες εκτελέσεις με διαφορετικούς τυχαίους σπόρους και στατιστική αξιολόγηση των διαφορών, προκειμένου να εξεταστεί η ευρωστία των συμπερασμάτων.

5. **Συστηματική επιλογή checkpoints.** Η επιλογή των κατάλληλων checkpoints από τη διαδικασία continued pretraining πραγματοποιείται μέσω πολυσταδιακής αξιολόγησης, με έμφαση στη χρησιμότητα των μαθημένων αναπαραστάσεων για την τελική εργασία και όχι αποκλειστικά στην εξέλιξη της αυτοεπιβλεπόμενης συνάρτησης απώλειας.

6. **Διερεύνηση της γενικευσιμότητας της προσαρμογής.** Μέσω της εφαρμογής της ίδιας ερευνητικής στρατηγικής σε DINO και DINOv2, καθώς και σε δύο διαφορετικά μεγέθη αρχιτεκτονικής DINOv2, εξετάζεται κατά πόσο η επίδραση του continued pretraining εξαρτάται από τη μέθοδο αυτοεπιβλεπόμενης μάθησης ή από την κλίμακα του backbone.

1.5 Δομή της Διπλωματικής Εργασίας

Η παρούσα διπλωματική εργασία οργανώνεται σε οκτώ κύρια κεφάλαια, τα οποία συμπληρώνονται από τη βιβλιογραφία. Η διάρθρωσή της ακολουθεί μια σταδιακή μετάβαση από την παρουσίαση του κλινικού και ερευνητικού προβλήματος και την ανασκόπηση της σχετικής βιβλιογραφίας προς το απαραίτητο θεωρητικό υπόβαθρο, την ανάπτυξη της προτεινόμενης μεθοδολογίας, την πειραματική αξιολόγηση και, τέλος, την ερμηνεία των αποτελεσμάτων και την εξαγωγή συμπερασμάτων.

Το **Κεφάλαιο 1** αποτελεί την εισαγωγή της εργασίας και παρουσιάζει το κλινικό και ερευνητικό πλαίσιο του προβλήματος. Αναδεικνύεται η σημασία της έγκαιρης διάγνωσης παθήσεων του ανώτερου γαστρεντερικού συστήματος και παρουσιάζεται ο ρόλος της γαστροσκόπησης ως βασικού διαγνωστικού εργαλείου. Παράλληλα, εξετάζονται οι προκλήσεις που σχετίζονται με την ποιότητα και την πληρότητα της ενδοσκοπικής εξέτασης, καθώς και οι δυνατότητες της Τεχνητής Νοημοσύνης για την υποστήριξή της. Στη συνέχεια εισάγεται το πρόβλημα της αυτόματης αναγνώρισης ανατομικών περιοχών σε ενδοσκοπικές εικόνες, παρουσιάζονται οι απαραίτητες βασικές έννοιες και διατυπώνονται το ερευνητικό πρόβλημα, οι στόχοι και οι συνεισφορές της εργασίας.

Στο **Κεφάλαιο 2** πραγματοποιείται ανασκόπηση της σχετικής βιβλιογραφίας. Παρουσιάζονται προηγούμενες ερευνητικές προσεγγίσεις που αξιοποιούν την Τεχνητή Νοημοσύνη και τη βαθιά μάθηση στη γαστρεντερική ενδοσκόπηση, με έμφαση στην ανάλυση ενδοσκοπικών εικόνων, στην υποστήριξη της ποιότητας της εξέτασης και στην αυτόματη αναγνώριση ανατομικών περιοχών. Επιπλέον, εξετάζονται μελέτες που αξιοποιούν προεκπαιδευμένα μοντέλα, Vision Transformers και τεχνικές αυτοεπιβλεπόμενης μάθησης στην ιατρική απεικόνιση, με ιδιαίτερο ενδιαφέρον για τη μεταφορά και προσαρμογή οπτικών αναπαραστάσεων σε εξειδικευμένα πεδία. Μέσα από τη συγκριτική εξέταση των προηγούμενων εργασιών αναδεικνύονται οι δυνατότητες και οι περιορισμοί των υφιστάμενων προσεγγίσεων και προσδιορίζεται η θέση της παρούσας μελέτης στο ερευνητικό πεδίο.

Στο **Κεφάλαιο 3** αναπτύσσεται το θεωρητικό υπόβαθρο που απαιτείται για την κατανόηση της προτεινόμενης προσέγγισης. Παρουσιάζονται οι βασικές αρχές της μηχανικής και της βαθιάς μάθησης, τα συνελικτικά νευρωνικά δίκτυα, οι Vision Transformers, καθώς και οι έννοιες της προεκπαίδευσης και της μεταφοράς μάθησης. Ιδιαίτερη έμφαση δίνεται στην αυτοεπιβλεπόμενη μάθηση και στις μεθόδους DINO και DINOv2, με ανάλυση της αρχιτεκτονικής teacher--student, των στρατηγικών δημιουργίας πολλαπλών όψεων της ίδιας εικόνας και των βασικών μηχανισμών εκπαίδευσης. Εξετάζονται επίσης τα χαρακτηριστικά του DINOv2, όπως το iBOT masking και τα register tokens, καθώς και οι κύριες διαφοροποιήσεις του από το DINO. Το κεφάλαιο ολοκληρώνεται με την παρουσίαση της έννοιας των foundation models και της σημασίας τους για τη μεταφορά γενικών οπτικών αναπαραστάσεων

σε εξειδικευμένες εφαρμογές.

Στο **Κεφάλαιο 4** παρουσιάζονται η προτεινόμενη μεθοδολογία και ο συνολικός σχεδιασμός της ερευνητικής προσέγγισης. Αρχικά περιγράφονται τα χρησιμοποιούμενα σύνολα δεδομένων και ο διακριτός ρόλος τους στην αυτοεπιβλεπόμενη προεκπαίδευση και στην τελική αξιολόγηση, καθώς και η στρατηγική *domain-adaptive continued self-supervised pretraining* σε μη επισημασμένα ενδοσκοπικά δεδομένα. Στη συνέχεια παρουσιάζεται ο καθορισμός του downstream training protocol: η αναπαραγωγή και επέκταση του πλαισίου αξιολόγησης του GastroHUN με γενικά προεκπαιδευμένα μοντέλα DINO και DINOv2, η διερεύνηση εναλλακτικών διαμορφώσεων εκπαίδευσης (κανονικοποίηση, στρατηγική learning rate) και η αυτοματοποιημένη αναζήτηση υπερπαραμέτρων που οδηγεί στο τελικό πρωτόκολλο. Αναλύεται η λογική της ελεγχόμενης σύγκρισης μεταξύ generic και domain-adapted checkpoints της ίδιας αρχιτεκτονικής και περιγράφεται το πρωτόκολλο επιλογής checkpoint, οι στρατηγικές frozen και partial fine-tuning αξιολόγησης, καθώς και οι χρησιμοποιούμενες μετρικές και στατιστικές διαδικασίες σύγκρισης. Τέλος, παρουσιάζεται ο σχεδιασμός των τριών πειραμάτων continued pretraining: του βασικού πειράματος με DINOv2 ViT-S/14, της επέκτασης στο DINO ViT-S/16 και της επέκτασης στο DINOv2 ViT-B/14.

Στο **Κεφάλαιο 5** περιγράφεται αναλυτικά η πειραματική διαδικασία μέσω της οποίας υλοποιείται η προτεινόμενη μεθοδολογία. Παρουσιάζονται το υπολογιστικό περιβάλλον και οι διαθέσιμοι υπολογιστικοί πόροι. Στη συνέχεια, για καθένα από τα τρία πειράματα continued pretraining περιγράφονται το αρχικό checkpoint και οι ρυθμίσεις προεκπαίδευσης, η εκτέλεση και ο έλεγχος σταθερότητας της αυτοεπιβλεπόμενης εκπαίδευσης, καθώς και η εφαρμογή του πρωτοκόλλου επιλογής checkpoint και η τελική downstream εκτέλεση με τρεις τυχαίους σπόρους. Το κεφάλαιο ολοκληρώνεται με συζήτηση της αναπαραγωγιμότητας της πειραματικής διαδικασίας.

Στο **Κεφάλαιο 6** παρουσιάζονται τα πειραματικά αποτελέσματα της εργασίας. Αρχικά εξετάζεται η επίδοση των γενικά προεκπαιδευμένων DINO και DINOv2 μοντέλων σε σύγκριση με τις αρχιτεκτονικές αναφοράς του αρχικού GastroHUN benchmark. Στη συνέχεια παρουσιάζονται η εξέλιξη του continued self-supervised pretraining, η αξιολόγηση των ενδιάμεσων checkpoints και τα αποτελέσματα των ελεγχόμενων συγκρίσεων μεταξύ generic και domain-adapted μοντέλων. Τα αποτελέσματα καλύπτουν τις αξιολογήσεις με frozen backbone και partial fine-tuning, τις επαναλαμβανόμενες εκτελέσεις και τα συμπληρωματικά πειράματα με εναλλακτικές downstream διαμορφώσεις. Επιπλέον, περιλαμβάνεται διακριτή διερευνητική ανάλυση *best-recipe-per-model*, στην οποία κάθε μοντέλο εξετάζεται με την καλύτερη αξιολογημένη διαμόρφωση εκπαίδευσης, χωρίς να συγχέεται η ανάλυση αυτή με την κύρια ελεγχόμενη σύγκριση υπό κοινές συνθήκες. Το κεφάλαιο ολοκληρώνεται με τη συγκεντρωτική σύγκριση των τριών πειραμάτων.

Στο **Κεφάλαιο 7** πραγματοποιείται η συζήτηση και ερμηνεία των πειραματικών αποτελεσμάτων σε σχέση με την αρχική ερευνητική υπόθεση. Εξετάζεται κατά πόσο η περαιτέρω αυτοεπιβλεπόμενη προεκπαίδευση σε μη επισημασμένα ενδοσκοπικά δεδομένα επηρεάζει τη χρησιμότητα των γενικών οπτικών αναπαραστάσεων για την ανατομική ταξινόμηση. Παράλληλα, αναλύονται οι διαφορές μεταξύ frozen και fine-tuned αξιολόγησης, η επίδραση των διαφορετικών downstream training recipes και η συμπεριφορά των DINO και DINOv2 ως προς την προσαρμογή τους στο ενδοσκοπικό πεδίο. Τα ευρήματα συσχετίζονται με τη σχετική βιβλιογραφία και εξετάζεται κατά πόσο υποστηρίζουν τη γενικευσιμότητα της στρατηγικής ως προς τη

μέθοδο αυτοεπιβλεπόμενης μάθησης και το μέγεθος του backbone. Τέλος, συζητούνται οι βασικοί περιορισμοί της μελέτης και οι παράγοντες που επηρεάζουν την ερμηνεία και τη δυνατότητα γενίκευσης των αποτελεσμάτων.

Στο **Κεφάλαιο 8** συνοψίζονται τα κύρια συμπεράσματα της διπλωματικής εργασίας και παρουσιάζονται οι συνεισφορές της σε σχέση με τους αρχικούς στόχους και τη σχετική βιβλιογραφία. Παρουσιάζονται τα βασικά συμπεράσματα σχετικά με τη συνέπεια του οφέλους του domain-adaptive continued self-supervised pretraining, την αρχιτεκτονικο-ειδική ευαισθησία στο downstream recipe και τη γενίκευση του ευρήματος ως προς τη μέθοδο αυτοεπιβλεπόμενης μάθησης και το μέγεθος backbone. Παράλληλα, διατυπώνονται κατευθύνσεις για μελλοντική έρευνα.

Μετά την ολοκλήρωση των κύριων κεφαλαίων ακολουθεί η **Βιβλιογραφία**, στην οποία παρατίθενται οι επιστημονικές πηγές που χρησιμοποιήθηκαν για την τεκμηρίωση της εργασίας.

Κεφάλαιο 2: Σχετική Βιβλιογραφία

2.1 Τεχνητή Νοημοσύνη στη Γαστρεντερική Ενδοσκόπηση

Η εφαρμογή της Τεχνητής Νοημοσύνης στη γαστρεντερική ενδοσκόπηση έχει εξελιχθεί από την ανάλυση αποθηκευμένων εικόνων στην ανάπτυξη συστημάτων πραγματικού χρόνου που υποστηρίζουν τον ενδοσκόπο κατά τη διάρκεια της εξέτασης [22, 23]. Δύο βασικές κατηγορίες εφαρμογών είναι τα συστήματα υποβοηθούμενης ανίχνευσης (*computer-aided detection, CADe*), τα οποία εντοπίζουν πιθανές παθολογικές περιοχές, και τα συστήματα υποβοηθούμενης διάγνωσης (*computer-aided diagnosis, CADx*), που επιχειρούν να χαρακτηρίσουν τη φύση ήδη εντοπισμένων αλλοιώσεων [24].

Η ανίχνευση πολυπόδων κατά την κολονοσκόπηση αποτελεί μία από τις περισσότερο μελετημένες εφαρμογές CADe. Οι Wang et al. [25] ανέπτυξαν σύστημα βαθιάς μάθησης πραγματικού χρόνου, το οποίο πέτυχε ευαισθησία 94,38% και ειδικότητα 95,92% σε ανεξάρτητο σύνολο 27 113 εικόνων. Η κλινική χρησιμότητα τέτοιων συστημάτων διερευνήθηκε σε τυχαιοποιημένες μελέτες, όπως εκείνη των Repici et al. [26], όπου η χρήση του GI Genius συσχετίστηκε με αυξημένη ανίχνευση αδενωμάτων. Αντίστοιχα ευρήματα έχουν αναφερθεί σε μετα-αναλύσεις [27]. Παράλληλα, τα συστήματα CADx έχουν εφαρμοστεί στον χαρακτηρισμό ορθοκολικών πολυπόδων, με στόχο την εκτίμηση της ιστολογικής τους φύσης [24].

Στην ενδοσκόπηση του ανώτερου γαστρεντερικού, οι εφαρμογές περιλαμβάνουν την ανίχνευση γαστρικού καρκίνου, νεοπλασιών του οισοφάγου, αλλοιώσεων του οισοφάγου Barrett και λοίμωξης από *Helicobacter pylori* [28, 29]. Οι Hirasawa et al. [30] ανέπτυξαν συνελικτικό νευρωνικό δίκτυο (CNN) που αναγνώρισε 71 από 77 καρκινικές βλάβες, επιτυγχάνοντας ευαισθησία 92,2%. Επιπλέον, μετα-ανάλυση των Lui et al. [28], η οποία περιέλαβε 23 μελέτες και 969 318 εικόνες, ανέδειξε υψηλή διαγνωστική απόδοση των συστημάτων Τεχνητής Νοημοσύνης σε διαφορετικές εφαρμογές της ανώτερης γαστρεντερικής ενδοσκόπησης.

Παρά τα ενθαρρυντικά αποτελέσματα, η υψηλή απόδοση σε αναδρομικά σύνολα εικόνων δεν εξασφαλίζει αντίστοιχο κλινικό όφελος. Διαφορές μεταξύ ασθενών, εξοπλισμού και συνθηκών απεικόνισης μπορούν να επηρεάσουν τη γενίκευση των μοντέλων, καθιστώντας απαραίτητη την εξωτερική και προοπτική επικύρωση [31, 29]. Χαρακτηριστικά, σε τυχαιοποιημένη μελέτη 320 ασθενών υψηλού κινδύνου, οι Nakao et al. [32] δεν διαπίστωσαν στατιστικά σημαντική βελτίωση στην ανίχνευση πλακώδους καρκινώματος του οισοφάγου από μη ειδικούς ενδοσκόπους με τη χρήση Τεχνητής Νοημοσύνης (47% έναντι 45%, $P = 0{,}93$).

Η βιβλιογραφία καταδεικνύει επομένως τη δυνατότητα των συστημάτων CADe και CADx να υποστηρίζουν την ανίχνευση και τον χαρακτηρισμό παθολογικών ευρημάτων, αλλά και την ανάγκη αξιολόγησης της πραγματικής κλινικής τους αποτελεσματικότητας. Επιπλέον, η λειτουργία τους προϋποθέτει ότι οι αντίστοιχες ανατομικές περιοχές έχουν απεικονιστεί επαρκώς. Για τον λόγο αυτό, η αυτόματη αναγνώ-

ριση της ανατομικής θέσης και η παρακολούθηση της κάλυψης της εξέτασης αποτελούν συμπληρωματικές ερευνητικές κατευθύνσεις, οι οποίες εξετάζονται στην επόμενη ενότητα.

2.2 Αναγνώριση Ανατομικής Θέσης και Ποιοτικός Έλεγχος της Ενδοσκοπικής Εξέτασης

Η αυτόματη αναγνώριση ανατομικής θέσης αποτελεί σημαντική ερευνητική κατεύθυνση στη γαστρεντερική ενδοσκόπηση, καθώς μπορεί να υποστηρίξει τόσο την ταξινόμηση ενδοσκοπικών εικόνων όσο και την παρακολούθηση της ανατομικής κάλυψης μιας εξέτασης. Πρόκειται για απαιτητικό πρόβλημα υπολογιστικής όρασης, καθώς γειτονικές ανατομικές περιοχές συχνά παρουσιάζουν υψηλή οπτική ομοιότητα, ενώ η εμφάνιση της ίδιας περιοχής μεταβάλλεται ανάλογα με τον ασθενή, τη γωνία θέασης, τον φωτισμό και τις συνθήκες απεικόνισης [33]. Οι δυσκολίες αυτές εντείνονται όταν η ταξινόμηση αφορά πολλές λεπτομερείς (*fine-grained*) ανατομικές κατηγορίες.

Μία από τις πρώτες συστηματικές προσεγγίσεις παρουσιάστηκε από τους Takiyama et al. [15], οι οποίοι χρησιμοποίησαν GoogLeNet για την ταξινόμηση εικόνων σε τέσσερις ευρείες ανατομικές περιοχές (λάρυγγα, οισοφάγο, στόμαχο και δωδεκαδάκτυλο), με επιπλέον διαχωρισμό του στομάχου σε τρία τμήματα (άνω, μέση και κάτω περιοχή). Το μοντέλο εκπαιδεύτηκε σε 27 335 εικόνες και αξιολογήθηκε σε 17 081 ανεξάρτητες εικόνες, επιτυγχάνοντας ακρίβεια περίπου 97%. Παρότι τα αποτελέσματα ανέδειξαν τις δυνατότητες των συνελικτικών δικτύων, η ταξινόμηση αφορούσε σχετικά ευρείες ανατομικές κατηγορίες.

Η σύνδεση της ανατομικής αναγνώρισης με τον ποιοτικό έλεγχο της εξέτασης αναδείχθηκε από συστήματα πραγματικού χρόνου. Οι Wu et al. [34] ανέπτυξαν το WISENSE, το οποίο παρακολουθούσε 26 γαστρικές θέσεις και εντόπιζε πιθανές μη εξετασμένες περιοχές. Σε τυχαιοποιημένη μελέτη 324 ασθενών, το ποσοστό τυφλών σημείων μειώθηκε από 22,46% σε 5,86% με τη χρήση του WISENSE ($p < 0{,}001$). Αντίστοιχα, το ENDOANGEL αξιολογήθηκε σε πολυκεντρική τυχαιοποιημένη μελέτη 1 050 ασθενών από πέντε νοσοκομεία, παρουσιάζοντας μικρότερο μέσο αριθμό τυφλών σημείων σε σχέση με τη συμβατική εξέταση (5,38 έναντι 9,82, $p < 0{,}001$) [35]. Τα αποτελέσματα αυτά υποστηρίζουν την πρακτική χρησιμότητα της ανατομικής παρακολούθησης για τη βελτίωση της πληρότητας της γαστροσκόπησης.

Παράλληλα, η έρευνα επεκτάθηκε προς λεπτομερέστερη ταξινόμηση ανατομικών θέσεων και αξιοποίηση της χρονικής πληροφορίας. Οι He et al. [33] μελέτησαν την αναγνώριση 11 γαστρικών landmarks σε εικόνες από 211 ασθενείς, αναδεικνύοντας παράλληλα τον περιορισμό της ανεξάρτητης ανάλυσης μεμονωμένων εικόνων. Οι Li et al. [36] αντιμετώπισαν τη διάσταση αυτή μέσω του συστήματος *Intelligent Detection Endoscopic Assistant* (IDEA), το οποίο συνδύαζε CNN και LSTM για την αναγνώριση 31 ανατομικών θέσεων από τον υποφάρυγγα έως το δωδεκαδάκτυλο. Το σύστημα πέτυχε ακρίβεια 95,30% σε αξιολόγηση 129 ενδοσκοπικών βίντεο, καταδεικνύοντας τη δυνατότητα αξιοποίησης της χρονικής ακολουθίας για τη συνεχή ανατομική παρακολούθηση.

Νεότερες μελέτες επικεντρώθηκαν σε περισσότερο λεπτομερή προβλήματα ταξινόμησης. Οι Sun et al. [37] εξέτασαν 12 ανατομικές θέσεις, επιτυγχάνοντας F1-score 92,43%, ενώ οι Su et al. [16] αξιολόγησαν το MogaNet σε οκτώ θέσεις, αναφέροντας

F1-score 0,964. Σε μεγαλύτερη κλίμακα, οι Yuan et al. [17] ανέπτυξαν το AIMED με 160 308 εικόνες και 27 ανατομικές κατηγορίες, επιτυγχάνοντας μέση ακρίβεια 99,40%. Οι μελέτες αυτές αναδεικνύουν τη μετάβαση από την αναγνώριση ευρέων ανατομικών τμημάτων προς τη διάκριση πολλών οπτικά συγγενών θέσεων.

Ωστόσο, οι υψηλές επιδόσεις σε εσωτερικά σύνολα αξιολόγησης δεν συνεπάγονται απαραίτητα αντίστοιχη γενίκευση. Οι Zhang et al. [38], συγκρίνοντας CNN και Vision Transformer αρχιτεκτονικές σε συμβατική και capsule gastroduodenoscopy, ανέφεραν μείωση της μέσης ακρίβειας ενός CNN από 0,9251 στην εσωτερική αξιολόγηση σε 0,8376 στην προοπτική αξιολόγηση. Επιπλέον, οι Vision Transformers δεν ξεπέρασαν το CNN στις συγκεκριμένες πειραματικές συνθήκες. Τα ευρήματα αυτά υπογραμμίζουν ότι η αρχιτεκτονική πολυπλοκότητα δεν εγγυάται καλύτερη γενίκευση και ότι η αξιολόγηση σε ανεξάρτητα δεδομένα είναι καθοριστική.

Η σύγκριση των παραπάνω αποτελεσμάτων απαιτεί προσοχή, καθώς οι μελέτες διαφέρουν ως προς τον αριθμό και τη λεπτομέρεια των ανατομικών κατηγοριών, τα σύνολα δεδομένων, τις μετρικές και τα πρωτόκολλα αξιολόγησης. Επιπλέον, η συχνή χρήση ιδιωτικών ή κεντρο-ειδικών δεδομένων περιορίζει την αναπαραγωγιμότητα και την άμεση σύγκριση διαφορετικών μεθόδων. Στην κατεύθυνση της περισσότερο τυποποιημένης αξιολόγησης, οι Bravo et al. [21] παρουσίασαν το δημόσιο GastroHUN, το οποίο περιλαμβάνει ένα απαιτητικό πρόβλημα αναγνώρισης 23 ανατομικών κατηγοριών και εξετάζεται αναλυτικότερα στην Ενότητα 2.5.

Συνολικά, η βιβλιογραφία καταδεικνύει τη μετάβαση από την ταξινόμηση λίγων ευρέων ανατομικών περιοχών προς τη λεπτομερή αναγνώριση γαστρικών θέσεων και την ενσωμάτωση της ανατομικής πληροφορίας σε συστήματα ποιοτικού ελέγχου πραγματικού χρόνου. Παρά την πρόοδο, η διάκριση οπτικά συγγενών περιοχών και η γενίκευση σε διαφορετικές συνθήκες παραμένουν σημαντικές προκλήσεις, αναδεικνύοντας την ανάγκη διερεύνησης κατάλληλων οπτικών αναπαραστάσεων για το ενδοσκοπικό πεδίο.

2.3 Προεκπαιδευμένα Μοντέλα και Μεταφορά Μάθησης στην Ιατρική Απεικόνιση

Η περιορισμένη διαθεσιμότητα μεγάλων και αξιόπιστα επισημασμένων ιατρικών συνόλων δεδομένων έχει καταστήσει τη μεταφορά μάθησης (*transfer learning*) βασική στρατηγική για την ανάπτυξη μοντέλων βαθιάς μάθησης στην ιατρική απεικόνιση [39, 40]. Μία από τις συνηθέστερες προσεγγίσεις είναι η αξιοποίηση μοντέλων προεκπαιδευμένων στο ImageNet [41], τα οποία προσαρμόζονται στη συνέχεια σε εξειδικευμένα ιατρικά προβλήματα. Η αποτελεσματικότητα της στρατηγικής αυτής βασίζεται στη δυνατότητα μεταφοράς οπτικών χαρακτηριστικών μεταξύ διαφορετικών εργασιών, αν και τα χαρακτηριστικά των βαθύτερων επιπέδων τείνουν να εξαρτώνται περισσότερο από το αρχικό πρόβλημα προεκπαίδευσης [42].

Η χρησιμότητα του ImageNet pretraining στην ιατρική απεικόνιση έχει καταδειχθεί σε προηγούμενες μελέτες, ιδιαίτερα όταν τα διαθέσιμα επισημασμένα δεδομένα είναι περιορισμένα [43]. Ωστόσο, το όφελος της γενικής προεκπαίδευσης εξαρτάται από το downstream πρόβλημα και τις συνθήκες εκπαίδευσης. Οι Raghu et al. [44] διαπίστωσαν ότι η μεταφορά από το ImageNet δεν οδηγεί απαραίτητα σε σημαντική βελτίωση της τελικής απόδοσης σε ιατρικά προβλήματα, ενώ μέρος της μεταφερόμενης πληροφορίας σχετίζεται κυρίως με τα αρχικά επίπεδα του δικτύου. Αντίστοιχα,

οι He et al. [45] έδειξαν ότι, υπό κατάλληλες συνθήκες και με επαρκή δεδομένα, η εκπαίδευση από τυχαία αρχικοποίηση μπορεί να προσεγγίσει την τελική απόδοση ενός προεκπαιδευμένου μοντέλου, παρότι η προεκπαίδευση συχνά επιταχύνει τη σύγκλιση.

Τα ευρήματα αυτά αναδεικνύουν τη σημασία του *domain gap*, δηλαδή των διαφορών μεταξύ των δεδομένων προεκπαίδευσης και του πεδίου εφαρμογής. Οι φυσικές εικόνες του ImageNet διαφέρουν από τις ιατρικές εικόνες ως προς το περιεχόμενο, τις υφές και τις συνθήκες απεικόνισης, με αποτέλεσμα οι γενικά προεκπαιδευμένες αναπαραστάσεις να μην είναι απαραίτητα οι καταλληλότερες για κάθε εξειδικευμένο πρόβλημα. Στο πλαίσιο αυτό, η αυτοεπιβλεπόμενη μάθηση (*self-supervised learning, SSL*) προσφέρει τη δυνατότητα αξιοποίησης μη επισημασμένων εικόνων για την εκμάθηση αναπαραστάσεων προσαρμοσμένων στο εκάστοτε πεδίο.

Οι Anton et al. [46] συνέκριναν γενικά και in-domain self-supervised μοντέλα σε διαφορετικά σύνολα ιατρικών εικόνων, αναδεικνύοντας αφενός την ισχυρή μεταφερσιμότητα των αναπαραστάσεων που αποκτώνται από γενικά δεδομένα και αφετέρου τη δυνατότητα της in-domain προεκπαίδευσης να προσφέρει υψηλότερη απόδοση σε εργασίες του ίδιου πεδίου, με αντίστοιχη όμως μείωση της απόδοσης εκτός του πεδίου προεκπαίδευσης. Παράλληλα, το Models Genesis έδειξε ότι η αυτοεπιβλεπόμενη προεκπαίδευση σε μη επισημασμένες ιατρικές εικόνες μπορεί να παράγει χρήσιμες αναπαραστάσεις για διαφορετικά downstream προβλήματα [47].

Ιδιαίτερα σχετική είναι η μελέτη των Azizi et al. [48], οι οποίοι διερεύνησαν τη διαδοχική αξιοποίηση γενικών και domain-specific δεδομένων κατά την αυτοεπιβλεπόμενη προεκπαίδευση. Ξεκινώντας από γενική προεκπαίδευση και συνεχίζοντας σε μη επισημασμένες ιατρικές εικόνες, έδειξαν ότι η πρόσθετη domain-specific φάση μπορεί να βελτιώσει τις αναπαραστάσεις πριν από την τελική supervised εκπαίδευση. Η προσέγγιση αυτή συνδέεται με την ανάπτυξη των *foundation models*, τα οποία παρέχουν ευρείες οπτικές αναπαραστάσεις που μπορούν στη συνέχεια να προσαρμοστούν σε εξειδικευμένες εφαρμογές [49, 50].

Η προβληματική αυτή είναι ιδιαίτερα σημαντική στη γαστρεντερική ενδοσκόπηση, όπου οι μεταβολές φωτισμού, οι κατοπτρικές ανακλάσεις, οι παραμορφώσεις των ιστών και η οπτική ομοιότητα γειτονικών ανατομικών περιοχών δημιουργούν ιδιαίτερες απαιτήσεις για τις οπτικές αναπαραστάσεις [33, 16]. Παρότι η χρήση ImageNet-pretrained μοντέλων παραμένει διαδεδομένη σε προβλήματα ενδοσκοπικής ταξινόμησης [16], τα προηγούμενα ευρήματα υποδεικνύουν ότι η πρόσθετη προσαρμογή σε μη επισημασμένα δεδομένα του ενδοσκοπικού πεδίου αποτελεί μια ερευνητική κατεύθυνση που αξίζει να εξεταστεί.

Συνεπώς, πέρα από την εκπαίδευση από τυχαία αρχικοποίηση και την άμεση μεταφορά ενός γενικά προεκπαιδευμένου μοντέλου, αναδεικνύεται η δυνατότητα συνέχισης της αυτοεπιβλεπόμενης προεκπαίδευσης σε δεδομένα του πεδίου εφαρμογής. Οι σχετικές μελέτες που εξετάζουν ειδικότερα την αυτοεπιβλεπόμενη μάθηση και το domain-specific continued pretraining στη γαστρεντερική ενδοσκόπηση παρουσιάζονται στην επόμενη ενότητα.

2.4 Αυτοεπιβλεπόμενη Μάθηση και Domain-Specific Continued Pretraining στην Ιατρική Απεικόνιση

Η αυτοεπιβλεπόμενη μάθηση (*self-supervised learning, SSL*) επιτρέπει την αξιοποίηση μη επισημασμένων ιατρικών εικόνων για την εκμάθηση οπτικών αναπαραστάσεων, περιορίζοντας την εξάρτηση από τη χειροκίνητη επισήμανση δεδομένων [47, 48]. Στο πλαίσιο της προσαρμογής σε εξειδικευμένα πεδία διακρίνονται δύο βασικές στρατηγικές: η αυτοεπιβλεπόμενη προεκπαίδευση από τυχαία αρχικοποίηση σε δεδομένα του πεδίου εφαρμογής και η συνέχιση της προεκπαίδευσης ενός ήδη γενικά προεκπαιδευμένου μοντέλου (*domain-specific continued pretraining*). Η δεύτερη στρατηγική επιδιώκει να συνδυάσει τις γενικές οπτικές αναπαραστάσεις του αρχικού μοντέλου με χαρακτηριστικά περισσότερο προσαρμοσμένα στο νέο πεδίο.

Στη γαστρεντερική ενδοσκόπηση, οι Sanderson και Matuszewski [51] συνέκριναν supervised και self-supervised ImageNet pretraining με αυτοεπιβλεπόμενη προεκπαίδευση σε περίπου 100 000 μη επισημασμένες εικόνες του HyperKvasir. Παρά την άμεση συνάφεια των ενδοσκοπικών δεδομένων, τα ImageNet self-supervised μοντέλα υπερείχαν στις περισσότερες downstream εφαρμογές. Το εύρημα αυτό υποδεικνύει ότι η ομοιότητα του πεδίου προεκπαίδευσης με το τελικό πρόβλημα δεν εξασφαλίζει από μόνη της καλύτερες αναπαραστάσεις, καθώς σημαντικό ρόλο διαδραματίζουν επίσης η κλίμακα και η ποικιλία των δεδομένων.

Αντίθετα, οι Boers et al. [52] διερεύνησαν την αυτοεπιβλεπόμενη προεκπαίδευση σε περισσότερες από πέντε εκατομμύρια ενδοσκοπικές εικόνες από οκτώ κέντρα, εξετάζοντας διαφορετικές μεθόδους, μεταξύ των οποίων το DINO. Η μελέτη έδειξε ότι η in-domain προεκπαίδευση μπορεί να υπερέχει της προεκπαίδευσης σε φυσικές εικόνες σε πολλαπλά downstream ενδοσκοπικά προβλήματα. Στην ίδια ερευνητική κατεύθυνση, το GastroNet-5M αξιοποίησε περίπου 4,8 εκατομμύρια μη επισημασμένες εικόνες για την ανάπτυξη και αξιολόγηση εξειδικευμένων ενδοσκοπικών αναπαραστάσεων [53].

Ιδιαίτερο ενδιαφέρον παρουσιάζει η διερεύνηση της αρχικοποίησης από τους Boers et al. [52]. Στην περίπτωση του ResNet50, η εκκίνηση από προεκπαιδευμένα βάρη φυσικών εικόνων υπερείχε της τυχαίας αρχικοποίησης στην πλειονότητα των πειραμάτων. Ωστόσο, αντίστοιχη ελεγχόμενη σύγκριση δεν πραγματοποιήθηκε για το DINO ViT-S/16, το οποίο αναφέρεται με τυχαία αρχικοποίηση. Επομένως, τα αποτελέσματα παρέχουν ενδείξεις για τη σημασία της αρχικοποίησης, χωρίς να απομονώνουν την πρόσθετη αξία του continued pretraining σε έναν ήδη αυτοεπιβλεπόμενα προεκπαιδευμένο Vision Transformer.

Πιο άμεσο προηγούμενο για τη στρατηγική της διαδοχικής προεκπαίδευσης αποτελεί η εργασία των Roth et al. [54]. Οι συγγραφείς ξεκίνησαν από έναν ήδη προεκπαιδευμένο EVA-02 Vision Transformer και πραγματοποίησαν πρόσθετη domain-adaptive προεκπαίδευση σε περισσότερες από 226 000 γαστρεντερικές ενδοσκοπικές εικόνες πριν από το downstream fine-tuning. Η μελέτη τεκμηριώνει τη δυνατότητα προσαρμογής ενός γενικά προεκπαιδευμένου μοντέλου σε ενδοσκοπικά δεδομένα, διαφοροποιείται όμως από την παρούσα εργασία ως προς την αρχιτεκτονική, τον στόχο προεκπαίδευσης και το downstream πρόβλημα, καθώς αξιοποιεί EVA-02 με masked image modeling για την ταξινόμηση παθολογικών ευρημάτων σε capsule endoscopy.

Παράλληλα, η ανάπτυξη εξειδικευμένων foundation models για την ενδοσκόπηση

έχει ενισχυθεί από προσεγγίσεις όπως τα Endo-FM και ArgesFM, οι οποίες αξιοποιούν μεγάλης κλίμακας ενδοσκοπικά δεδομένα και αυτοεπιβλεπόμενη μάθηση [55, 56]. Ιδιαίτερα σχετικό είναι το EndoDINO [57], το οποίο εφαρμόζει μεθοδολογία DINOv2 σε γαστρεντερικά δεδομένα και αξιολογεί frozen representations, μεταξύ άλλων, στην ταξινόμηση ανατομικών landmarks. Ωστόσο, η προσέγγιση επικεντρώνεται στην ανάπτυξη εξειδικευμένου ενδοσκοπικού foundation model και όχι στην ελεγχόμενη σύγκριση ενός δημοσιευμένου generic DINOv2 checkpoint πριν και μετά από πρόσθετη domain-specific αυτοεπιβλεπόμενη προεκπαίδευση.

Πέρα από την ενδοσκόπηση, η ίδια στρατηγική διαδοχικής προεκπαίδευσης έχει εφαρμοστεί επιτυχώς και σε άλλα εξειδικευμένα πεδία της ιατρικής απεικόνισης. Στην αιματολογία, το DinoBloom [58] αξιοποιεί προσαρμοσμένο pipeline DINOv2 πάνω σε περισσότερες από 380.000 εικόνες λευκών αιμοσφαιρίων από 13 δημόσια σύνολα δεδομένων περιφερικού αίματος και μυελού των οστών. Στην ψηφιακή παθολογοανατομία, μία ανεξάρτητη μελέτη [59] δείχνει ότι η προσαρμογή ενός DINOv2 ViT-S με περιορισμένους υπολογιστικούς πόρους (μία GPU) μπορεί να ξεπεράσει εξειδικευμένα μοντέλα όπως τα CTransPath και RetCCL. Σε κυτταρική τμηματοποίηση, το DINOCell [60] εφαρμόζει αντίστοιχη στρατηγική. Οι τρεις αυτές εργασίες μοιράζονται με την παρούσα εργασία τη βασική μεθοδολογική επιλογή της συνέχισης προεκπαίδευσης ήδη εκπαιδευμένων DINO/DINOv2 backbones σε εξειδικευμένα ιατρικά δεδομένα, και αξιοποιήθηκαν ως σημεία αναφοράς για πρακτικές επιλογές της μεθοδολογίας που ακολουθεί (Κεφάλαιο 5).

Συνολικά, η βιβλιογραφία δείχνει ότι έχουν διερευνηθεί τόσο η αυτοεπιβλεπόμενη εκπαίδευση σε ενδοσκοπικά δεδομένα από τυχαία αρχικοποίηση όσο και η προσαρμογή γενικά προεκπαιδευμένων μοντέλων. Ωστόσο, τα ευρήματα δεν είναι ομοιόμορφα και οι μεθοδολογικές διαφορές μεταξύ των μελετών δυσχεραίνουν την απομόνωση της επίδρασης της πρόσθετης domain-specific προεκπαίδευσης. Στο πλαίσιο αυτό, η παρούσα εργασία εξετάζει την πρόσθετη αξία του continued self-supervised pretraining σε ήδη προεκπαιδευμένους DINO και DINOv2 Vision Transformers, συγκρίνοντας κάθε domain-adapted μοντέλο με το αντίστοιχο generic checkpoint της ίδιας αρχιτεκτονικής. Η αξιολόγηση πραγματοποιείται σε fine-grained αναγνώριση ανατομικών θέσεων, τόσο με frozen backbone όσο και με partial fine-tuning, ενώ η χρήση διαφορετικών αυτοεπιβλεπόμενων μεθόδων και μεγεθών backbone επιτρέπει τη διερεύνηση της γενικευσιμότητας των παρατηρούμενων επιδράσεων.

2.5 Το Σύνολο Δεδομένων και Benchmark GastroHUN

Οι Bravo et al. [21] παρουσίασαν το GastroHUN, ένα δημόσια διαθέσιμο σύνολο δεδομένων και πλαίσιο αξιολόγησης (*benchmark*) για την αυτόματη αναγνώριση γαστρικών ανατομικών θέσεων. Σε αντίθεση με ενδοσκοπικά datasets που επικεντρώνονται στην ανίχνευση παθολογικών ευρημάτων, το GastroHUN οργανώνεται γύρω από τη συστηματική ανατομική κάλυψη του στομάχου, καθιστώντας το κατάλληλο για τη μελέτη της αναγνώρισης θέσης και της πληρότητας της γαστροσκόπησης.

Το dataset περιλαμβάνει συνολικά 8 834 ενδοσκοπικές εικόνες από 387 ασθενείς, καθώς και επισημασμένες ακολουθίες και πλήρεις βιντεοενδοσκοπήσεις [21]. Για την ταξινόμηση ορίζονται 22 συγκεκριμένες ανατομικές θέσεις και μία επιπλέον κατηγορία μη κατάλληλων εικόνων (*unqualified images*), διαμορφώνοντας ένα πρόβλημα 23 κατηγοριών -- ένα απαιτητικό πρόβλημα *fine-grained* ανατομικής ταξινό-

μησης, καθώς απαιτεί τη διάκριση οπτικά συγγενών περιοχών του ίδιου οργάνου. Ιδιαίτερο χαρακτηριστικό του benchmark είναι ο διαχωρισμός των δεδομένων σε επίπεδο ασθενούς (*patient-level split*), ο οποίος περιορίζει τον κίνδυνο διαρροής πληροφορίας μεταξύ των συνόλων εκπαίδευσης, επικύρωσης και ελέγχου.

Το αρχικό supervised benchmark περιλάμβανε αρχιτεκτονικές των οικογενειών ResNet, VGG, ConvNeXt και Vision Transformer, με προεκπαίδευση στο ImageNet [21]. Η αξιολόγηση βασίστηκε, μεταξύ άλλων, στη μετρική Macro-F1, η οποία αποδίδει ίση βαρύτητα στις επιμέρους κατηγορίες ανεξάρτητα από τη συχνότητά τους. Την υψηλότερη επίδοση μεταξύ των εξεταζόμενων μοντέλων σημείωσε το ConvNeXt-Large, με Macro-F1 $88{,}25 \pm 0{,}22$.

Ωστόσο, το δημοσιευμένο benchmark δεν περιλάμβανε γενικά προεκπαιδευμένα αυτοεπιβλεπόμενα μοντέλα των οικογενειών DINO και DINOv2. Η παρούσα εργασία επεκτείνει την αρχική αξιολόγηση με τέτοια μοντέλα και χρησιμοποιεί το GastroHUN ως κοινό downstream πλαίσιο για τη σύγκριση generic και domain-adapted checkpoints της ίδιας αρχιτεκτονικής. Ο σταθερός διαχωρισμός των δεδομένων και το κοινό πρόβλημα ταξινόμησης επιτρέπουν τη διερεύνηση της επίδρασης του continued self-supervised pretraining υπό ελεγχόμενες συνθήκες. Η προετοιμασία των δεδομένων και τα ακριβή πρωτόκολλα εκπαίδευσης και αξιολόγησης περιγράφονται στο κεφάλαιο της Μεθοδολογίας. Το θεωρητικό υπόβαθρο των σχετικών αρχιτεκτονικών και μεθόδων παρουσιάζεται στο επόμενο κεφάλαιο.

Κεφάλαιο 3: Θεωρητικό Υπόβαθρο

3.1 Βασικές Έννοιες Βαθιάς Μάθησης και Συνελικτικών Νευρωνικών Δικτύων

3.1.1 Τεχνητά Νευρωνικά Δίκτυα και Εκμάθηση Αναπαραστάσεων

Τα τεχνητά νευρωνικά δίκτυα (*Artificial Neural Networks, ANNs*) αποτελούν τη βάση της σύγχρονης βαθιάς μάθησης και μπορούν να θεωρηθούν ως παραμετρικά μοντέλα που μετασχηματίζουν μία είσοδο σε μία έξοδο μέσω διαδοχικών υπολογιστικών επιπέδων. Σε αντίθεση με παραδοσιακές προσεγγίσεις μηχανικής μάθησης, όπου η εξαγωγή χαρακτηριστικών βασιζόταν συχνά σε χειροκίνητα σχεδιασμένους περιγραφείς, τα βαθιά δίκτυα μπορούν να μαθαίνουν αυτόματα χρήσιμες αναπαραστάσεις απευθείας από τα δεδομένα [61, 62].

Η βασική λειτουργία ενός νευρωνικού επιπέδου συνδυάζει έναν γραμμικό μετασχηματισμό με μία μη γραμμική συνάρτηση ενεργοποίησης:

$$\mathbf{h} = \phi(\mathbf{W}\mathbf{x} + \mathbf{b}), \tag{3.1}$$

όπου $\mathbf{W}$ και $\mathbf{b}$ είναι οι εκπαιδεύσιμες παράμετροι και $\phi(\cdot)$ μία συνάρτηση ενεργοποίησης, όπως η *Rectified Linear Unit* (ReLU). Η μη γραμμικότητα επιτρέπει στο δίκτυο να μοντελοποιεί σύνθετες σχέσεις, καθώς χωρίς αυτήν η σύνθεση πολλαπλών γραμμικών επιπέδων θα ισοδυναμούσε με έναν ενιαίο γραμμικό μετασχηματισμό [63, 64].

Με τη διαδοχική σύνθεση πολλών επιπέδων, η αρχική πληροφορία μετασχηματίζεται σταδιακά σε εσωτερικές αναπαραστάσεις. Στην υπολογιστική όραση, ένα δίκτυο μπορεί επομένως να θεωρηθεί ως μία παραμετρική συνάρτηση

$$\mathbf{h} = f_\theta(\mathbf{x}), \tag{3.2}$$

όπου $\mathbf{x}$ είναι η εικόνα, θ οι εκπαιδεύσιμες παράμετροι και $\mathbf{h}$ η αναπαράσταση *(representation)* που παράγεται από το δίκτυο.

Η εκπαίδευση συνιστά πρόβλημα βελτιστοποίησης. Στην επιβλεπόμενη μάθηση, για ένα σύνολο $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ και ένα μοντέλο F_Θ, μπορεί να οριστεί η μέση συνάρτηση απώλειας *(loss function)*

$$\mathcal{L}(\Theta) = \frac{1}{N}\sum_{i=1}^{N} \ell\left(F_\Theta(\mathbf{x}_i), y_i\right). \tag{3.3}$$

η οποία ποσοτικοποιεί τη διαφορά μεταξύ των προβλέψεων και των επιθυμητών εξόδων.

Οι κλίσεις της ως προς τις παραμέτρους υπολογίζονται μέσω οπισθοδιάδοσης (*backpropagation*) και χρησιμοποιούνται από τον αλγόριθμο βελτιστοποίησης για την

ενημέρωση του μοντέλου [65, 64]. Στην απλούστερη μορφή της καθόδου κλίσης *(gradient descent)*, η ενημέρωση των παραμέτρων μπορεί να εκφραστεί ως

$$\Theta \leftarrow \Theta - \eta \nabla_{\Theta} \mathcal{L}(\Theta), \tag{3.4}$$

όπου $\nabla_{\Theta} \mathcal{L}(\Theta)$ είναι η κλίση της συνάρτησης απώλειας ως προς τις παραμέτρους του μοντέλου και η είναι ο ρυθμός μάθησης (*learning rate*). Ο ρυθμός μάθησης καθορίζει το μέγεθος της μεταβολής των παραμέτρων σε κάθε βήμα βελτιστοποίησης και αποτελεί μία από τις βασικότερες υπερπαραμέτρους της διαδικασίας εκπαίδευσης [64]. Στην πράξη χρησιμοποιούνται συνήθως πιο εξελιγμένοι optimizers και learning-rate schedules, οι οποίοι παρουσιάζονται όπου απαιτείται στη Μεθοδολογία.

Ιδιαίτερα σημαντική για την παρούσα εργασία είναι η έννοια της *εκμάθησης αναπαραστάσεων* (*representation learning*). Αντί τα χαρακτηριστικά να σχεδιάζονται εκ των προτέρων, τα διαδοχικά επίπεδα ενός βαθιού δικτύου μαθαίνουν μετασχηματισμούς που κωδικοποιούν σταδιακά περισσότερο αφηρημένη και χρήσιμη πληροφορία [61, 62]. Ένα μοντέλο μπορεί έτσι να διαχωριστεί εννοιολογικά σε έναν εξαγωγέα χαρακτηριστικών ή *backbone*, που παράγει την αναπαράσταση, και σε μία κεφαλή *(head)*, η οποία αξιοποιεί αυτή την αναπαράσταση για την εκτέλεση ενός συγκεκριμένου downstream task. Για ένα πρόβλημα ταξινόμησης, η διαδικασία μπορεί να εκφραστεί ως

$$\mathbf{h} = f_{\theta}(\mathbf{x}), \qquad \hat{\mathbf{y}} = g_{\phi}(\mathbf{h}), \tag{3.5}$$

όπου f_{θ} είναι το backbone, $\mathbf{h}$ η εξαγόμενη αναπαράσταση και g_{ϕ} η κεφαλή ταξινόμησης.

Η διάκριση αυτή είναι θεμελιώδης για την παρούσα εργασία, καθώς επιτρέπει ένα προεκπαιδευμένο backbone να επαναχρησιμοποιηθεί σε νέα προβλήματα είτε με σταθερές παραμέτρους είτε μέσω περαιτέρω προσαρμογής τους. Η λογική αυτή αποτελεί τη βάση της προεκπαίδευσης και της μεταφοράς μάθησης, οι οποίες αναλύονται στην Ενότητα 3.3.

3.1.2 Συνελικτικά Νευρωνικά Δίκτυα

Τα Συνελικτικά Νευρωνικά Δίκτυα (*Convolutional Neural Networks, CNNs*) αποτέλεσαν για μεγάλο χρονικό διάστημα την κυρίαρχη αρχιτεκτονική για την επεξεργασία εικόνων. Σε αντίθεση με τα πλήρως συνδεδεμένα δίκτυα, αξιοποιούν τη χωρική δομή της εικόνας κυρίως μέσω της *τοπικής συνδεσιμότητας (local connectivity)* και του *διαμοιρασμού βαρών (weight sharing)*, επιτρέποντας την αποδοτική εκμάθηση τοπικών οπτικών προτύπων [66, 67, 62].

Η βασική τους λειτουργία είναι η συνέλιξη *(convolution)*. Σε ένα συνελικτικό επίπεδο, ένα σύνολο εκπαιδεύσιμων φίλτρων ή πυρήνων *(filters/kernels)* μικρού μεγέθους εφαρμόζεται σε τοπικές περιοχές της εισόδου και μετακινείται κατά μήκος των χωρικών της διαστάσεων. Για μία απλοποιημένη μονοκαναλική δισδιάστατη είσοδο $\mathbf{X}$ και έναν εκπαιδεύσιμο πυρήνα $\mathbf{K}$, η λειτουργία μπορεί να γραφτεί ως

$$Y(i,j) = \sum_{m} \sum_{n} X(i+m, j+n) K(m,n). \tag{3.6}$$

Το αποτέλεσμα $\mathbf{Y}$ αποτελεί έναν χάρτη χαρακτηριστικών (*feature map*). Η συγκεκριμένη πράξη αντιστοιχεί αυστηρά σε *cross-correlation*, αλλά στη βιβλιογραφία

της βαθιάς μάθησης αναφέρεται συνήθως ως convolution [64]. Στην πράξη χρησιμοποιούνται πολλαπλά κανάλια και φίλτρα, τα οποία μαθαίνονται κατά την εκπαίδευση και αποκρίνονται σε διαφορετικά οπτικά πρότυπα.

Η εφαρμογή του ίδιου φίλτρου σε διαφορετικές χωρικές θέσεις αποτελεί το *weight sharing*, μειώνοντας τον αριθμό των παραμέτρων και επιτρέποντας την ανίχνευση παρόμοιων μοτίβων σε διαφορετικά σημεία της εικόνας. Η συνέλιξη παρουσιάζει επίσης *translation equivariance*: υπό κατάλληλες συνθήκες, η μετατόπιση της εισόδου προκαλεί αντίστοιχη μετατόπιση του feature map [64]. Η ιδιότητα αυτή δεν ισοδυναμεί με πλήρη translation invariance, καθώς η συμπεριφορά του συνολικού δικτύου επηρεάζεται και από λειτουργίες όπως stride, padding και υποδειγματοληψία.

Η στοίβαξη συνελικτικών επιπέδων οδηγεί σε ιεραρχική εκμάθηση χαρακτηριστικών. Τα πρώτα επίπεδα τείνουν να αποκρίνονται σε απλούστερα τοπικά μοτίβα, όπως ακμές και υφές, ενώ βαθύτερα επίπεδα συνδυάζουν την πληροφορία σε πιο σύνθετες και σημασιολογικά χρήσιμες αναπαραστάσεις [68]. Παράλληλα, pooling ή strided convolutions μειώνουν σταδιακά τις χωρικές διαστάσεις, ενώ το *receptive field* αυξάνεται, επιτρέποντας στις βαθύτερες μονάδες να ενσωματώνουν πληροφορία από μεγαλύτερες περιοχές της εικόνας [64].

Η τοπικότητα και το weight sharing αποτελούν χαρακτηριστικές *inductive biases* των CNNs: η αρχιτεκτονική ενσωματώνει την υπόθεση ότι γειτονικά pixels σχετίζονται μεταξύ τους και ότι παρόμοια μοτίβα μπορούν να εμφανίζονται σε διαφορετικές χωρικές θέσεις. Οι ιδιότητες αυτές συνέβαλαν καθοριστικά στην αποτελεσματικότητα των CNNs ως visual backbones [62].

3.1.3 Σύγχρονες CNN Αρχιτεκτονικές

Η εξέλιξη των CNNs οδήγησε σε βαθύτερες και αποτελεσματικότερες αρχιτεκτονικές. Για την παρούσα εργασία ιδιαίτερο ενδιαφέρον παρουσιάζουν οι οικογένειες **VGG**, **ResNet** και **ConvNeXt**, καθώς αντιπροσωπεύουν διαφορετικά στάδια αυτής της εξέλιξης και περιλαμβάνονται στα CNN μοντέλα αναφοράς του GastroHUN [21].

Η **VGG** βασίζεται σε μία απλή και ομοιογενή σχεδίαση με διαδοχικές συνελίξεις μικρών πυρήνων 3×3 και ενδιάμεση υποδειγματοληψία [69]. Η στοίβαξη μικρών πυρήνων επιτρέπει την αύξηση του αποτελεσματικού receptive field και την εισαγωγή περισσότερων μη γραμμικοτήτων. Οι γνωστότερες παραλλαγές, VGG-16 και VGG-19, περιλαμβάνουν αντίστοιχα 16 και 19 επίπεδα με εκπαιδεύσιμες παραμέτρους. Παρά την απλότητα και την επιρροή της, η οικογένεια χαρακτηρίζεται από μεγάλο αριθμό παραμέτρων και σημαντικό υπολογιστικό κόστος.

Η αύξηση του βάθους δεν οδηγεί από μόνη της σε αποτελεσματικότερη εκπαίδευση. Οι He et al. ανέδειξαν το *degradation problem*, όπου βαθύτερα συμβατικά δίκτυα μπορούσαν να εμφανίζουν μεγαλύτερο training error από ρηχότερα αντίστοιχά τους [70]. Η οικογένεια **ResNet** αντιμετώπισε το πρόβλημα μέσω υπολειμματικών συνδέσεων *(residual connections)*. Αν ο επιθυμητός μετασχηματισμός είναι $\mathcal{H}(\mathbf{x})$, ορίζεται

$$\mathcal{F}(\mathbf{x}, \mathbf{W}) = \mathcal{H}(\mathbf{x}) - \mathbf{x}, \tag{3.7}$$

και η έξοδος του residual block γράφεται ως

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \mathbf{W}) + \mathbf{x}. \tag{3.8}$$

Η σύνδεση ταυτότητας *(identity shortcut)* παρέχει άμεση διαδρομή μεταξύ εισόδου και εξόδου και διευκολύνει τη βελτιστοποίηση πολύ βαθύτερων δικτύων. Όταν δεν απαιτείται πρόσθετος μετασχηματισμός, η identity mapping μπορεί να προσεγγιστεί μέσω $\mathcal{F}(\mathbf{x}, \mathbf{W}) \approx 0$. Η αρχική εργασία παρουσίασε, μεταξύ άλλων, τις ResNet-50, ResNet-101 και ResNet-152 [70].

Η **ConvNeXt** επανεξέτασε τη σχεδίαση των CNNs υπό το πρίσμα της επιτυχίας των Vision Transformers [71]. Ξεκινώντας από μία ResNet, εισήγαγε σύγχρονες σχεδιαστικές επιλογές όπως *depthwise convolutions*, μεγαλύτερους kernels, inverted bottlenecks, *Layer Normalization* αντί Batch Normalization και GELU αντί ReLU. Παρά τις αλλαγές αυτές, παραμένει αμιγώς συνελικτική αρχιτεκτονική και δεν χρησιμοποιεί self-attention, δείχνοντας ότι ένας κατάλληλα εκσυγχρονισμένος CNN σχεδιασμός μπορεί να παραμένει ανταγωνιστικός απέναντι σε Transformer-based μοντέλα [71].

Οι τρεις οικογένειες συνοψίζουν διαφορετικά στάδια της εξέλιξης των CNNs: η VGG ανέδειξε τη σημασία μιας βαθιάς και ομοιογενούς αρχιτεκτονικής, η ResNet επέτρεψε την αποτελεσματική εκπαίδευση πολύ βαθύτερων δικτύων μέσω residual connections και η ConvNeXt εκσυγχρόνισε το CNN paradigm αξιοποιώντας νεότερες σχεδιαστικές αρχές. Παράλληλα, αποτελούν χρήσιμα σημεία αναφοράς για την παρούσα εργασία, καθώς αντίστοιχες αρχιτεκτονικές περιλαμβάνονται στο benchmark του GastroHUN [21].

Σε αντίθεση με τις ισχυρές επαγωγικές προκαταλήψεις των CNNs και την προοδευτική σύνθεση τοπικών χαρακτηριστικών, οι Vision Transformers αναπαριστούν την εικόνα ως ακολουθία επιμέρους τμημάτων και μοντελοποιούν τις μεταξύ τους σχέσεις μέσω *self-attention*. Η διαφορετική αυτή προσέγγιση παρουσιάζεται στην επόμενη ενότητα.

3.2 Vision Transformers

3.2.1 Από την Εικόνα στα Patches

Η αρχιτεκτονική Transformer αναπτύχθηκε αρχικά για την επεξεργασία ακολουθιών και επομένως, για να εφαρμοστεί σε εικόνες, απαιτείται πρώτα η μετατροπή της δισδιάστατης χωρικής πληροφορίας σε μία ακολουθία διανυσμάτων. Ο Vision Transformer (ViT) επιτυγχάνει αυτή τη μετατροπή διαιρώντας την εικόνα σε μη επικαλυπτόμενες περιοχές σταθερού μεγέθους, οι οποίες ονομάζονται *patches* και αντιμετωπίζονται ως τα βασικά στοιχεία της ακολουθίας εισόδου του Transformer [72]. Με τον τρόπο αυτό, τα patches διαδραματίζουν για μία εικόνα έναν ρόλο ανάλογο με εκείνον των tokens σε μία ακολουθία κειμένου.

Έστω μία εικόνα $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$, όπου H και W είναι το ύψος και το πλάτος της εικόνας και C ο αριθμός των καναλιών. Εάν η εικόνα διαιρεθεί σε τετραγωνικά patches διαστάσεων $P \times P$, τότε, όταν οι διαστάσεις της εικόνας είναι ακέραια πολλαπλάσια του P, ο αριθμός των patches είναι

$$N = \frac{H}{P}\frac{W}{P} = \frac{HW}{P^2}. \tag{3.9}$$

Κάθε patch έχει διαστάσεις $P \times P \times C$ και αρχικά μετατρέπεται σε ένα μονοδιάστατο διάνυσμα $\mathbf{x}_p^i \in \mathbb{R}^{P^2 C}$. Το διάνυσμα αυτό προβάλλεται στη συνέχεια γραμμικά σε έναν χώρο σταθερής διάστασης D, δημιουργώντας το αντίστοιχο *patch embedding*:

$$\mathbf{e}_i = \mathbf{x}_p^i \mathbf{E}, \qquad \mathbf{E} \in \mathbb{R}^{(P^2C)\times D}, \tag{3.10}$$

όπου $\mathbf{E}$ είναι ένας εκπαιδεύσιμος πίνακας προβολής και D η διάσταση των embeddings του μοντέλου [72]. Η διαδικασία αυτή είναι εννοιολογικά ανάλογη με τη δημιουργία embeddings σε άλλες εφαρμογές των Transformers: κάθε αρχικό στοιχείο εισόδου μετατρέπεται σε ένα διάνυσμα σταθερής διάστασης, κατάλληλο για επεξεργασία από τα επόμενα επίπεδα του μοντέλου. Η αρχική εικόνα αναπαρίσταται επομένως ως μία ακολουθία

$$\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_N, \tag{3.11}$$

στην οποία κάθε διάνυσμα αντιστοιχεί σε μία συγκεκριμένη περιοχή της εικόνας και λειτουργεί ως *token* για τον Transformer.

Το μέγεθος του patch καθορίζει άμεσα το μήκος της παραγόμενης ακολουθίας. Μικρότερα patches οδηγούν σε μεγαλύτερο αριθμό tokens και λεπτομερέστερη χωρική διαμέριση της εικόνας, αλλά αυξάνουν παράλληλα το υπολογιστικό κόστος της μετέπειτα επεξεργασίας τους. Η σχέση αυτή είναι ιδιαίτερα σημαντική για τον μηχανισμό *self-attention* και αναλύεται στην επόμενη υποενότητα. Για παράδειγμα, σε μία εικόνα 224×224 pixels, ένα μοντέλο με patch size 14×14 παράγει

$$N = \frac{224}{14}\frac{224}{14} = 16 \times 16 = 256 \tag{3.12}$$

patch tokens. Η σημειογραφία *ViT-S/14*, η οποία είναι ιδιαίτερα σημαντική για τα μοντέλα DINOv2 που εξετάζονται στην παρούσα εργασία, δηλώνει μεταξύ άλλων ότι χρησιμοποιούνται patches μεγέθους 14×14 pixels [19]. Η πλήρης ερμηνεία της ονομασίας των διαφορετικών ViT παραλλαγών παρουσιάζεται στη συνέχεια της ενότητας.

Η παραπάνω διαδικασία μετατρέπει συνεπώς μία εικόνα από έναν δισδιάστατο πίνακα εικονοστοιχείων σε μία ακολουθία διανυσματικών αναπαραστάσεων σταθερής διάστασης. Σε αντίθεση με τη διαδοχική τοπική επεξεργασία των CNNs, τα patch tokens μπορούν στη συνέχεια να αλληλεπιδρούν άμεσα μεταξύ τους στο πλαίσιο του Transformer. Ο μηχανισμός που επιτρέπει αυτή την ανταλλαγή πληροφορίας είναι το *self-attention* και παρουσιάζεται στην επόμενη υποενότητα.

3.2.2 Self-Attention

Μετά τη μετατροπή της εικόνας σε μία ακολουθία από patch embeddings, το επόμενο ζητούμενο είναι η ανταλλαγή πληροφορίας μεταξύ των επιμέρους tokens. Ο μηχανισμός *self-attention* επιτρέπει σε κάθε token να υπολογίζει μία νέα αναπαράσταση λαμβάνοντας υπόψη ταυτόχρονα τις αναπαραστάσεις όλων των tokens της ίδιας ακολουθίας. Με αυτόν τον τρόπο, η πληροφορία που αντιστοιχεί σε μία περιοχή της εικόνας μπορεί να συσχετιστεί άμεσα με πληροφορία από άλλες, ακόμη και απομακρυσμένες, περιοχές [73, 72].

Έστω ότι τα N tokens οργανώνονται σε έναν πίνακα $\mathbf{X} \in \mathbb{R}^{N\times D}$, όπου D είναι η διάσταση κάθε embedding. Από τον ίδιο πίνακα εισόδου παράγονται, μέσω τριών εκπαιδεύσιμων γραμμικών προβολών, οι πίνακες *Query* ($\mathbf{Q}$), *Key* ($\mathbf{K}$) και *Value* ($\mathbf{V}$):

$$\mathbf{Q} = \mathbf{X}\mathbf{W}^Q, \qquad \mathbf{K} = \mathbf{X}\mathbf{W}^K, \qquad \mathbf{V} = \mathbf{X}\mathbf{W}^V, \tag{3.13}$$

όπου $\mathbf{W}^Q, \mathbf{W}^K$ και $\mathbf{W}^V$ είναι εκπαιδεύσιμοι πίνακες προβολής. Στην απλούστερη περίπτωση μπορούν να θεωρηθούν ως $\mathbf{W}^Q, \mathbf{W}^K \in \mathbb{R}^{D \times d_k}$ και $\mathbf{W}^V \in \mathbb{R}^{D \times d_v}$, όπου d_k και d_v είναι οι διαστάσεις των αντίστοιχων προβολών [73]. Ο όρος *self-attention* προκύπτει από το γεγονός ότι τα queries, keys και values προέρχονται από την ίδια ακολουθία εισόδου.

Διαισθητικά, το *query* ενός token εκφράζει την πληροφορία που χρησιμοποιείται για να αναζητηθούν σχετικά στοιχεία στα υπόλοιπα tokens, ενώ τα *keys* χρησιμοποιούνται για τον υπολογισμό της σχετικότητας μεταξύ τους και τα *values* περιέχουν την πληροφορία που τελικά συνδυάζεται. Η συμβατότητα μεταξύ ενός query και των keys υπολογίζεται μέσω εσωτερικών γινομένων. Για όλα τα tokens ταυτόχρονα, οι βαθμολογίες αυτές περιέχονται στον πίνακα $\mathbf{QK}^T$.

Στον *scaled dot-product attention*, οι βαθμολογίες διαιρούνται με $\sqrt{d_k}$, όπου d_k είναι η διάσταση των query και key vectors, και στη συνέχεια εφαρμόζεται η συνάρτηση softmax:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d_k}}\right)\mathbf{V}. \tag{3.14}$$

Ο παράγοντας κλιμάκωσης $1/\sqrt{d_k}$ περιορίζει την αύξηση του μεγέθους των εσωτερικών γινομένων όταν η διάσταση d_k είναι μεγάλη, αποτρέποντας την είσοδο της softmax σε περιοχές όπου οι κλίσεις της γίνονται πολύ μικρές [73].

Ο πίνακας

$$\mathbf{A} = \text{softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d_k}}\right) \tag{3.15}$$

περιέχει τα *attention weights*. Κάθε γραμμή του $\mathbf{A}$ αντιστοιχεί σε ένα token και, μετά την εφαρμογή της softmax, τα στοιχεία της είναι μη αρνητικά και αθροίζουν σε 1. Επομένως, η νέα αναπαράσταση κάθε token προκύπτει ως σταθμισμένος συνδυασμός των value vectors όλων των tokens, με μεγαλύτερα βάρη να αντιστοιχούν σε ισχυρότερες συσχετίσεις. Επειδή τα βάρη αυτά υπολογίζονται δυναμικά από το περιεχόμενο της εισόδου, οι αλληλεπιδράσεις μεταξύ των tokens εξαρτώνται από την ίδια την εικόνα και δεν είναι προκαθορισμένες [73].

Η δυνατότητα αυτή διαφοροποιεί ουσιαστικά το self-attention από τη βασική λειτουργία της συνέλιξης. Σε ένα CNN, ένα συνελικτικό φίλτρο επεξεργάζεται άμεσα μία περιορισμένη τοπική περιοχή και η πληροφορία από απομακρυσμένες θέσεις συνδυάζεται σταδιακά μέσω διαδοχικών επιπέδων. Αντίθετα, σε ένα επίπεδο self-attention κάθε patch token μπορεί να αλληλεπιδράσει άμεσα με όλα τα υπόλοιπα tokens της εικόνας, επιτρέποντας τη μοντελοποίηση σχέσεων μεγάλης εμβέλειας ήδη μέσα σε ένα επίπεδο [72].

Η καθολική αυτή αλληλεπίδραση έχει και υπολογιστικό κόστος. Για N tokens, ο υπολογισμός του πίνακα $\mathbf{QK}^T$ παράγει έναν πίνακα $N \times N$, με αποτέλεσμα το κόστος του self-attention ως προς το μήκος της ακολουθίας να αυξάνεται τετραγωνικά, δηλαδή ως $\mathcal{O}(N^2)$ [73]. Αυτό εξηγεί γιατί το μέγεθος των patches που παρουσιάστηκε στην προηγούμενη υποενότητα επηρεάζει σημαντικά το υπολογιστικό κόστος ενός Vision Transformer: μικρότερα patches οδηγούν σε περισσότερα tokens και συνεπώς σε μεγαλύτερο πίνακα attention.

Μέχρι στιγμής περιγράφηκε ένας μοναδικός μηχανισμός attention. Στην πράξη, οι Transformers χρησιμοποιούν πολλαπλούς τέτοιους μηχανισμούς παράλληλα, επιτρέποντας στο μοντέλο να εξετάζει διαφορετικές σχέσεις μεταξύ των tokens σε δια-

φορετικούς χώρους αναπαράστασης. Η επέκταση αυτή ονομάζεται *Multi-Head Self-Attention* και παρουσιάζεται στην επόμενη υποενότητα.

3.2.3 Multi-Head Self-Attention

Ο μηχανισμός self-attention που παρουσιάστηκε στην προηγούμενη υποενότητα υπολογίζει ένα ενιαίο σύνολο συσχετίσεων μεταξύ των tokens. Στην πράξη, οι Transformers χρησιμοποιούν την επέκταση *Multi-Head Self-Attention* (MHSA), στην οποία το attention υπολογίζεται παράλληλα από πολλαπλές κεφαλές (*attention heads*), καθεμία με διαφορετικές εκπαιδεύσιμες προβολές. Με αυτόν τον τρόπο, το μοντέλο μπορεί να επεξεργάζεται τις σχέσεις μεταξύ των tokens σε διαφορετικούς χώρους αναπαράστασης [73].

Για κάθε attention head h, η ίδια ακολουθία εισόδου $\mathbf{X} \in \mathbb{R}^{N \times D}$ προβάλλεται μέσω διαφορετικών εκπαιδεύσιμων πινάκων σε queries, keys και values:

$$\mathbf{Q}_h = \mathbf{X}\mathbf{W}_h^Q, \qquad \mathbf{K}_h = \mathbf{X}\mathbf{W}_h^K, \qquad \mathbf{V}_h = \mathbf{X}\mathbf{W}_h^V. \tag{3.16}$$

Κάθε κεφαλή εφαρμόζει στη συνέχεια ανεξάρτητα τον μηχανισμό scaled dot-product attention:

$$\text{head}_h = \text{Attention}\left(\mathbf{Q}_h, \mathbf{K}_h, \mathbf{V}_h\right). \tag{3.17}$$

Επειδή κάθε head διαθέτει διαφορετικούς εκπαιδεύσιμους πίνακες προβολής, μπορεί να σχηματίζει διαφορετικά πρότυπα attention και να δίνει έμφαση σε διαφορετικές σχέσεις μεταξύ των tokens. Στην περίπτωση μιας εικόνας, αυτό επιτρέπει στο μοντέλο να εξετάζει παράλληλα διαφορετικές αλληλεπιδράσεις μεταξύ των επιμέρους περιοχών της, αντί να περιορίζεται σε ένα μοναδικό σύνολο attention weights [73, 72].

Για H attention heads και συνολική διάσταση embedding D, χρησιμοποιείται συνήθως διάσταση ανά head

$$d_h = \frac{D}{H}. \tag{3.18}$$

Οι αντίστοιχοι πίνακες προβολής μπορούν τότε να γραφούν ως $\mathbf{W}_h^Q, \mathbf{W}_h^K, \mathbf{W}_h^V \in \mathbb{R}^{D \times d_h}$. Οι έξοδοι των H attention heads συνενώνονται (*concatenation*) και προβάλλονται μέσω ενός επιπλέον εκπαιδεύσιμου πίνακα $\mathbf{W}^O$:

$$\text{MultiHead}(\mathbf{X}) = \text{Concat}\left(\text{head}_1, \ldots, \text{head}_H\right)\mathbf{W}^O, \tag{3.19}$$

όπου $\mathbf{W}^O \in \mathbb{R}^{(Hd_h) \times D}$. Εφόσον $Hd_h = D$, η συνένωση των επιμέρους heads επαναφέρει συνολικά τη διάσταση D, πριν από την τελική γραμμική προβολή [73].

Η κατανομή της συνολικής διάστασης σε πολλαπλές κεφαλές επιτρέπει την παράλληλη εφαρμογή attention σε διαφορετικούς υποχώρους αναπαράστασης, χωρίς κάθε head να λειτουργεί στην πλήρη διάσταση D. Έτσι, το Multi-Head Self-Attention δεν αποτελεί απλώς επανάληψη του ίδιου μηχανισμού, αλλά παρέχει στο μοντέλο τη δυνατότητα να σχηματίζει ταυτόχρονα διαφορετικά πρότυπα συσχέτισης μεταξύ των tokens [73].

Το Multi-Head Self-Attention παρέχει επομένως έναν μηχανισμό μέσω του οποίου κάθε token μπορεί να ενσωματώνει πληροφορία από ολόκληρη την ακολουθία με περισσότερους από έναν τρόπους. Ωστόσο, το attention αποτελεί μόνο ένα μέρος ενός

πλήρους Transformer encoder block. Η έξοδός του συνδυάζεται με επιπλέον στοιχεία, όπως residual connections, Layer Normalization και ένα feed-forward δίκτυο, ενώ απαιτείται επίσης η ενσωμάτωση πληροφορίας για τη θέση των patch tokens στην αρχική εικόνα. Τα στοιχεία αυτά παρουσιάζονται στην επόμενη υποενότητα.

3.2.4 Transformer Encoder και Positional Embeddings

Οι μηχανισμοί self-attention και multi-head self-attention επιτρέπουν την ανταλλαγή πληροφορίας μεταξύ των tokens, αλλά από μόνοι τους δεν αποτελούν ένα πλήρες Transformer. Στον Vision Transformer, τα tokens επεξεργάζονται από μία ακολουθία *Transformer encoder blocks*, καθένα από τα οποία συνδυάζει Multi-Head Self-Attention (MHSA), κανονικοποίηση, residual connections και ένα πολυεπίπεδο δίκτυο τύπου MLP [73, 72].

Πριν από την είσοδο στον Transformer encoder είναι απαραίτητο να ενσωματωθεί πληροφορία σχετικά με τη θέση των patches. Το self-attention, χωρίς πρόσθετη πληροφορία θέσης, είναι *permutation-equivariant*: εάν μεταβληθεί η σειρά των tokens, οι αντίστοιχες έξοδοι μεταβάλλονται με την ίδια σειρά, χωρίς ο ίδιος ο μηχανισμός να διαθέτει εγγενή γνώση της αρχικής τους διάταξης. Στην περίπτωση μιας εικόνας, όμως, η θέση ενός patch και η χωρική διάταξη των επιμέρους περιοχών αποτελούν σημαντικό μέρος της οπτικής πληροφορίας. Για τον λόγο αυτό απαιτείται η εισαγωγή πληροφορίας θέσης στην ακολουθία των tokens [73, 72].

Στον αρχικό Transformer, η πληροφορία αυτή εισαγόταν μέσω σταθερών ημιτονοειδών *positional encodings* [73]. Ο Vision Transformer χρησιμοποιεί αντίθετα εκπαιδεύσιμα μονοδιάστατα *positional embeddings*, τα οποία προστίθενται στα embeddings εισόδου πριν αυτά εισέλθουν στον Transformer encoder [72]. Για ένα patch token $\mathbf{e}_i$ και το positional embedding $\mathbf{p}_i$ της αντίστοιχης θέσης, η αρχική του αναπαράσταση μπορεί να γραφεί ως

$$\mathbf{z}_0^i = \mathbf{e}_i + \mathbf{p}_i, \qquad \mathbf{p}_i \in \mathbb{R}^D. \tag{3.20}$$

Σε επίπεδο ολόκληρης της ακολουθίας, η ίδια διαδικασία γράφεται ως

$$\mathbf{Z}_0 = \mathbf{Z}_{\text{tokens}} + \mathbf{E}_{pos}. \tag{3.21}$$

Με την πρόσθεση αυτή, κάθε token συνδυάζει την αναπαράσταση του περιεχομένου του με πληροφορία που σχετίζεται με τη θέση του στην αρχική διάταξη των patches. Οι Dosovitskiy et al. εξέτασαν επίσης διαφορετικούς τρόπους κωδικοποίησης της χωρικής πληροφορίας, συμπεριλαμβανομένων δισδιάστατων positional embeddings, χωρίς να παρατηρήσουν σημαντική βελτίωση έναντι των απλούστερων εκπαιδεύσιμων μονοδιάστατων embeddings [72].

Η ακολουθία που προκύπτει επεξεργάζεται στη συνέχεια από διαδοχικά Transformer encoder blocks. Στην αρχιτεκτονική ViT χρησιμοποιείται διάταξη *pre-normalization*, στην οποία η *Layer Normalization* (LN) εφαρμόζεται πριν από το MHSA και πριν από το MLP [72]. Για το ℓ-οστό encoder block, η λειτουργία μπορεί να περιγραφεί ως

$$\mathbf{Z}'_\ell = \mathbf{Z}_{\ell-1} + \text{MHSA}\left(\text{LN}\left(\mathbf{Z}_{\ell-1}\right)\right), \tag{3.22}$$

και στη συνέχεια

$$\mathbf{Z}_\ell = \mathbf{Z}'_\ell + \text{MLP}\left(\text{LN}\left(\mathbf{Z}'_\ell\right)\right). \tag{3.23}$$

Η διάταξη αυτή διαφέρει από εκείνη του αρχικού Transformer, στον οποίο η Layer Normalization εφαρμοζόταν μετά την residual πρόσθεση, δηλαδή σύμφωνα με μία *post-normalization* διαμόρφωση [73]. Στον ViT, αντίθετα, η κανονικοποίηση προηγείται κάθε επιμέρους υποεπιπέδου [72].

Οι δύο προσθέσεις στους παραπάνω τύπους αντιστοιχούν στις *residual connections*. Όπως και στα residual δίκτυα που παρουσιάστηκαν στην Ενότητα 3.1, οι συνδέσεις αυτές επιτρέπουν στην είσοδο ενός υποεπιπέδου να παρακάμπτει άμεσα τον αντίστοιχο μετασχηματισμό και να προστίθεται στην έξοδό του, διευκολύνοντας τη ροή της πληροφορίας και τη βελτιστοποίηση βαθιών δικτύων [70, 73].

Η Layer Normalization κανονικοποιεί τις ενεργοποιήσεις σε επίπεδο κάθε δείγματος ανεξάρτητα από τα υπόλοιπα δείγματα του mini-batch και συμβάλλει στη σταθερότητα της εκπαίδευσης [74]. Σε αντίθεση με το Batch Normalization, δεν βασίζεται σε στατιστικά στοιχεία που υπολογίζονται μεταξύ διαφορετικών δειγμάτων ενός mini-batch, χαρακτηριστικό που την καθιστά κατάλληλη για την αρχιτεκτονική Transformer [74, 73].

Το δεύτερο βασικό υποεπίπεδο κάθε encoder block είναι το MLP, το οποίο εφαρμόζεται ανεξάρτητα σε κάθε token. Στον Vision Transformer αποτελείται από δύο γραμμικούς μετασχηματισμούς με μία μη γραμμική συνάρτηση ενεργοποίησης GELU μεταξύ τους [72, 75]. Σχηματικά,

$$\mathrm{MLP}(\mathbf{x}) = \mathbf{W}_2\,\mathrm{GELU}\left(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1\right) + \mathbf{b}_2. \tag{3.24}$$

Τα δύο βασικά υποεπίπεδα έχουν επομένως συμπληρωματικούς ρόλους. Το MHSA επιτρέπει την ανταλλαγή πληροφορίας μεταξύ διαφορετικών tokens, ενώ το MLP μετασχηματίζει περαιτέρω την αναπαράσταση κάθε token ξεχωριστά. Με την επανάληψη L encoder blocks, οι αρχικές αναπαραστάσεις των patches εξελίσσονται σταδιακά σε αναπαραστάσεις που ενσωματώνουν πληροφορία από το ευρύτερο περιεχόμενο της εικόνας.

Η πλήρης πορεία της πληροφορίας μπορεί επομένως να συνοψιστεί σχηματικά ως

$$\text{Patch Embeddings} \rightarrow \text{Positional Embeddings} \rightarrow [\text{LN} \rightarrow \text{MHSA} \rightarrow \text{Residual} \rightarrow \text{LN} \rightarrow \text{MLP} \rightarrow \text{Residual}]^{L}. \tag{3.25}$$

Μετά τη διέλευση από τα διαδοχικά encoder blocks, ο Vision Transformer διαθέτει πλέον μία εμπλουτισμένη αναπαράσταση για κάθε token της ακολουθίας. Παραμένει όμως το ερώτημα πώς από αυτές τις επιμέρους αναπαραστάσεις προκύπτει μία συνολική αναπαράσταση της εικόνας, κατάλληλη για εργασίες όπως η ταξινόμηση. Για τον σκοπό αυτό, η αρχιτεκτονική ViT εισάγει ένα ειδικό *classification token* (`[CLS]`), ο ρόλος του οποίου παρουσιάζεται στην επόμενη υποενότητα.

3.2.5 Vision Transformer και `[CLS]` Token

Συνδυάζοντας τα επιμέρους στοιχεία των προηγούμενων υποενοτήτων προκύπτει η πλήρης αρχιτεκτονική του *Vision Transformer* (ViT). Μία εικόνα διαιρείται αρχικά σε patches, τα οποία μετατρέπονται σε embeddings σταθερής διάστασης και εμπλουτίζονται με πληροφορία θέσης. Η ακολουθία αυτή επεξεργάζεται στη συνέχεια από διαδοχικά Transformer encoder blocks, επιτρέποντας στα patch tokens να ανταλλάσσουν πληροφορία μέσω του μηχανισμού self-attention [72].

Για εργασίες ταξινόμησης απαιτείται τελικά μία ενιαία αναπαράσταση ολόκληρης της εικόνας και όχι μόνο οι επιμέρους αναπαραστάσεις των patches. Για τον σκοπό αυτό, ο ViT εισάγει ένα ειδικό εκπαιδεύσιμο token, το *classification token* ή `[CLS]` token, ακολουθώντας αντίστοιχη πρακτική από την αρχιτεκτονική BERT [76, 72]. Το `[CLS]` token δεν προέρχεται από κάποια συγκεκριμένη περιοχή της εικόνας και επομένως δεν αντιστοιχεί σε pixels. Αποτελεί μία ανεξάρτητη εκπαιδεύσιμη διανυσματική παράμετρο, η οποία προστίθεται στην αρχή της ακολουθίας των patch embeddings.

Εάν $\mathbf{x}_{\text{class}} \in \mathbb{R}^D$ είναι το εκπαιδεύσιμο `[CLS]` token και $\mathbf{x}_p^i\mathbf{E}$ το embedding του i-οστού patch, τότε η αρχική ακολουθία εισόδου του ViT γράφεται ως

$$\mathbf{Z}_0 = \left[\mathbf{x}_{\text{class}}; \mathbf{x}_p^1\mathbf{E}; \mathbf{x}_p^2\mathbf{E}; \ldots; \mathbf{x}_p^N\mathbf{E}\right] + \mathbf{E}_{pos}, \qquad \mathbf{E}_{pos} \in \mathbb{R}^{(N+1)\times D}. \tag{3.26}$$

Η ακολουθία έχει επομένως μήκος $N + 1$: περιλαμβάνει N patch tokens και ένα επιπλέον `[CLS]` token, ενώ και το τελευταίο διαθέτει το δικό του εκπαιδεύσιμο positional embedding [72].

Το `[CLS]` token διέρχεται από όλα τα Transformer encoder blocks μαζί με τα patch tokens. Μέσω του self-attention μπορεί να αλληλεπιδρά με αυτά και να ενσωματώνει πληροφορία από διαφορετικές περιοχές της εικόνας. Καθώς η ακολουθία διαδίδεται μέσα από τα διαδοχικά encoder blocks, η αναπαράσταση του `[CLS]` token ενημερώνεται επανειλημμένα με βάση τις αλληλεπιδράσεις του με τα υπόλοιπα tokens. Για τον λόγο αυτό, η τελική του κατάσταση μπορεί να χρησιμοποιηθεί ως συνολική αναπαράσταση της εικόνας για την εργασία ταξινόμησης [72].

Εάν $\mathbf{Z}_L$ είναι η έξοδος του τελευταίου Transformer encoder block και $\mathbf{Z}_L^0$ αντιστοιχεί στο `[CLS]` token, η τελική αναπαράσταση της εικόνας στον αρχικό ViT γράφεται ως

$$\mathbf{h} = \text{LN}\left(\mathbf{Z}_L^0\right), \tag{3.27}$$

και στη συνέχεια δίνεται στην κεφαλή ταξινόμησης για την παραγωγή της τελικής πρόβλεψης [72]. Η έκφραση αυτή συγκεκριμενοποιεί για την περίπτωση του Vision Transformer τη γενικότερη σχέση $\mathbf{h} = f_\theta(\mathbf{x})$ που παρουσιάστηκε στην Ενότητα 3.1.1: το backbone f_θ μετατρέπει την εικόνα $\mathbf{x}$ σε μία διανυσματική αναπαράσταση $\mathbf{h}$, η οποία μπορεί στη συνέχεια να αξιοποιηθεί από ένα downstream μοντέλο.

Είναι σημαντικό ότι το `[CLS]` token δεν αποτελεί έναν προκαθορισμένο μέσο όρο των patch representations. Η συνολική αναπαράστασή του διαμορφώνεται κατά την εκπαίδευση μέσω των διαδοχικών αλληλεπιδράσεων self-attention με τα υπόλοιπα tokens. Παράλληλα, τα τελικά patch tokens εξακολουθούν να παρέχουν επιμέρους αναπαραστάσεις των περιοχών της εικόνας και μπορούν επίσης να αξιοποιηθούν σε εφαρμογές όπου απαιτείται περισσότερο τοπική πληροφορία.

Οι διαφορετικές εκδόσεις του Vision Transformer χαρακτηρίζονται συνήθως από μία ονομασία της μορφής *ViT-X/P*, όπου το πρώτο μέρος δηλώνει το μέγεθος της αρχιτεκτονικής και το δεύτερο το μέγεθος των patches. Για παράδειγμα, η ονομασία *ViT-B/16* δηλώνει την παραλλαγή *Base* με patches 16×16 pixels, ενώ η *ViT-L/16* αντιστοιχεί σε μεγαλύτερη αρχιτεκτονική με το ίδιο patch size [72]. Οι διαφορετικές κλίμακες διαφοροποιούνται σε χαρακτηριστικά όπως η διάσταση των embeddings, ο αριθμός των Transformer blocks και ο αριθμός των attention heads.

Η ίδια βασική αρχιτεκτονική αποτελεί τον οπτικό backbone και μεταγενέστερων μεθόδων αυτοεπιβλεπόμενης μάθησης που εξετάζονται στην παρούσα εργα-

σία. Ειδικότερα, τα DINO και DINOv2 αξιοποιούν Vision Transformers όχι απλώς ως επιβλεπόμενους ταξινομητές, αλλά ως δίκτυα εκμάθησης γενικών οπτικών αναπαραστάσεων. Στην περίπτωση του DINOv2, μία ιδιαίτερα σημαντική παραλλαγή για την παρούσα εργασία είναι το *ViT-S/14*: το ``S'' δηλώνει την έκδοση *Small*, ενώ το ``14'' αντιστοιχεί σε patches 14×14 pixels [19]. Η συγκεκριμένη διαμόρφωση χρησιμοποιεί διάσταση embedding $D = 384$, 12 Transformer blocks και 6 attention heads [19].

Συνολικά, η λειτουργία ενός Vision Transformer μπορεί να περιγραφεί σχηματικά ως

$$\begin{aligned}\text{Image} \rightarrow \text{Patches} \rightarrow \text{Patch Embeddings} \rightarrow \texttt{[CLS]} + \text{Positional Embeddings} \\ \rightarrow \text{Transformer Encoder Blocks} \rightarrow \texttt{[CLS] Representation} \rightarrow \text{Downstream Task}.\end{aligned} \tag{3.28}$$

Ο Vision Transformer παρέχει επομένως την αρχιτεκτονική βάση πάνω στην οποία μπορούν να εκπαιδευτούν ισχυρές οπτικές αναπαραστάσεις. Το επόμενο ερώτημα δεν αφορά πλέον τη δομή του backbone, αλλά τον τρόπο με τον οποίο αποκτώνται και αξιοποιούνται τα βάρη του. Αυτό οδηγεί στη μεταφορά μάθησης και στην προεκπαίδευση μοντέλων, οι οποίες παρουσιάζονται στην επόμενη ενότητα.

3.3 Μεταφορά Μάθησης, Προεκπαίδευση και Προσαρμογή Μοντέλων

3.3.1 Transfer Learning και Pretraining

Η εκπαίδευση ενός βαθιού νευρωνικού δικτύου δεν είναι απαραίτητο να ξεκινά κάθε φορά από τυχαία αρχικοποιημένες παραμέτρους. Μία ευρέως χρησιμοποιούμενη στρατηγική είναι η αρχική εκπαίδευση του μοντέλου σε ένα σύνολο δεδομένων ή μία εργασία και η μετέπειτα αξιοποίηση των παραμέτρων που έχουν ήδη μαθευτεί σε ένα διαφορετικό πρόβλημα. Η διαδικασία της αρχικής εκπαίδευσης αναφέρεται ως *pretraining*, ενώ οι παράμετροι που προκύπτουν αποτελούν τα *pretrained weights* του μοντέλου.

Η βασική ιδέα πίσω από αυτή την προσέγγιση είναι ότι κατά το pretraining το δίκτυο μπορεί να μάθει αναπαραστάσεις οι οποίες δεν είναι αποκλειστικά χρήσιμες για το αρχικό πρόβλημα. Στην υπολογιστική όραση, για παράδειγμα, ένα μοντέλο μπορεί να μάθει χαρακτηριστικά που σχετίζονται με ακμές, υφές, σχήματα και περισσότερο σύνθετες οπτικές δομές. Μέρος αυτής της γνώσης μπορεί να παραμένει χρήσιμο όταν το μοντέλο μεταφέρεται σε ένα νέο σύνολο δεδομένων ή σε μία διαφορετική εργασία. Η δυνατότητα επαναχρησιμοποίησης ήδη μαθημένων αναπαραστάσεων αποτελεί τη βάση του *transfer learning* [42].

Για την περιγραφή της διαδικασίας είναι χρήσιμη η διάκριση μεταξύ *source* και *target*. Ως *source domain* νοείται το πεδίο δεδομένων από το οποίο προέρχεται η πληροφορία που χρησιμοποιείται για την αρχική μάθηση, ενώ ως *target domain* το πεδίο στο οποίο επιθυμούμε να αξιοποιήσουμε τη γνώση αυτή. Αντίστοιχα, η εργασία στην οποία χρησιμοποιείται τελικά το pretrained μοντέλο αναφέρεται ως *downstream task* [77].

Σχηματικά, εάν ένα μοντέλο f_θ προεκπαιδευτεί σε ένα source dataset $\mathcal{D}_S$, η διαδικασία παράγει ένα σύνολο pretrained παραμέτρων θ_{pre}. Οι παράμετροι αυτές μπο-

ρούν στη συνέχεια να χρησιμοποιηθούν για την εφαρμογή ή την προσαρμογή του μοντέλου σε ένα target dataset $\mathcal{D}_T$:

$$\mathcal{D}_S \xrightarrow{\text{pretraining}} \theta_{\text{pre}} \xrightarrow{\text{transfer}} \mathcal{D}_T. \tag{3.29}$$

Η διαδικασία αυτή διαφέρει από την εκπαίδευση *from scratch*, στην οποία οι παράμετροι θ αρχικοποιούνται χωρίς προηγουμένως μαθημένη πληροφορία και πρέπει να εκτιμηθούν αποκλειστικά από τα δεδομένα του target task. Αντίθετα, στο transfer learning το μοντέλο ξεκινά από ήδη μαθημένες παραμέτρους, οι οποίες κωδικοποιούν πληροφορία που αποκτήθηκε κατά το pretraining.

Ως προς το σήμα μάθησης, το pretraining μπορεί να πραγματοποιηθεί με διαφορετικούς τρόπους. Στην *επιβλεπόμενη προεκπαίδευση* (*supervised pretraining*) χρησιμοποιούνται διαθέσιμες ετικέτες, με χαρακτηριστικό παράδειγμα την εκπαίδευση οπτικών μοντέλων για ταξινόμηση εικόνων σε μεγάλα επισημασμένα σύνολα δεδομένων όπως το ImageNet [41]. Αντίθετα, στην *αυτοεπιβλεπόμενη προεκπαίδευση* (*self-supervised pretraining*) η εκμάθηση αναπαραστάσεων πραγματοποιείται χωρίς ανθρώπινες ετικέτες, αξιοποιώντας εκπαιδευτικά σήματα που προκύπτουν από τα ίδια τα δεδομένα. Η δεύτερη περίπτωση είναι ιδιαίτερα σημαντική για την παρούσα εργασία και αναλύεται στην Ενότητα 3.4.

Η αποτελεσματικότητα της μεταφοράς εξαρτάται, μεταξύ άλλων, από το είδος των αναπαραστάσεων που έχουν αποκτηθεί και από τη σχέση μεταξύ source και target προβλήματος. Οι Yosinski et al. έδειξαν ότι τα πρώιμα επίπεδα βαθιών οπτικών δικτύων τείνουν να περιέχουν περισσότερο γενικά χαρακτηριστικά, ενώ τα βαθύτερα επίπεδα γίνονται περισσότερο εξειδικευμένα ως προς την αρχική εργασία. Παράλληλα, η μεταφερσιμότητα των χαρακτηριστικών μειώνεται καθώς αυξάνεται η απόσταση μεταξύ του αρχικού και του νέου προβλήματος [42]. Η επιτυχία του transfer learning επομένως δεν προϋποθέτει ότι source και target είναι ταυτόσημα, αλλά επηρεάζεται από το κατά πόσο οι αναπαραστάσεις που αποκτήθηκαν κατά το pretraining παραμένουν χρήσιμες στο νέο πρόβλημα.

Όταν το pretraining πραγματοποιείται σε μεγάλα και ετερογενή σύνολα δεδομένων, επιδιώκεται συχνά η απόκτηση περισσότερο γενικών ή *generic representations*, οι οποίες μπορούν να αξιοποιηθούν σε διαφορετικές downstream εργασίες. Αυτή η λογική είναι ιδιαίτερα σημαντική για σύγχρονα pretrained visual backbones, όπως οι Vision Transformers που παρουσιάστηκαν στην προηγούμενη ενότητα. Αντί το backbone να εκπαιδεύεται εξαρχής για κάθε νέο πρόβλημα, μπορεί να χρησιμοποιηθεί ένα ήδη pretrained checkpoint και στη συνέχεια να αξιολογηθεί ή να προσαρμοστεί στο εκάστοτε target task.

Ωστόσο, η γενικότητα μιας αναπαράστασης δεν συνεπάγεται ότι είναι εξίσου κατάλληλη για κάθε πεδίο εφαρμογής. Όταν η κατανομή και τα οπτικά χαρακτηριστικά των δεδομένων του target domain διαφέρουν σημαντικά από εκείνα των δεδομένων pretraining, εμφανίζεται ένα *domain gap*. Όσο μεγαλύτερη είναι η απόσταση μεταξύ source και target domain, τόσο λιγότερο μεταφέρσιμες μπορεί να είναι ορισμένες από τις ήδη μαθημένες αναπαραστάσεις [42]. Σε περιπτώσεις όπου η μεταφερόμενη γνώση επηρεάζει αρνητικά τη μάθηση στο target πρόβλημα, στη βιβλιογραφία χρησιμοποιείται ο όρος *negative transfer* [77].

Η παραπάνω διάκριση είναι ιδιαίτερα σημαντική στην ιατρική απεικόνιση, όπου ένα μοντέλο μπορεί να έχει προεκπαιδευτεί σε φυσικές εικόνες και στη συνέχεια να εφαρμοστεί σε ένα οπτικά διαφορετικό ιατρικό domain. Όπως συζητήθηκε στην Ενότητα 2.3, η χρησιμότητα της μεταφοράς από natural-image pretraining εξαρτά-

ται από το συγκεκριμένο dataset και downstream task και δεν πρέπει να θεωρείται δεδομένη σε κάθε περίπτωση [44].

Το ζήτημα αυτό συνδέεται άμεσα με την παρούσα εργασία. Ένα γενικά προεκπαιδευμένο οπτικό μοντέλο μπορεί να παρέχει ισχυρές αρχικές αναπαραστάσεις, χωρίς αυτές να έχουν αποκτηθεί ειδικά από ενδοσκοπικές εικόνες. Προκύπτει επομένως το ερώτημα κατά πόσο οι generic representations μπορούν να προσαρμοστούν περαιτέρω στο target domain αξιοποιώντας δεδομένα από το ίδιο το πεδίο εφαρμογής. Η διαδικασία αυτή θα οδηγήσει αργότερα στην έννοια του *domain-specific continued pretraining*.

Πριν εξεταστεί όμως η περαιτέρω προσαρμογή ενός pretrained μοντέλου, είναι απαραίτητο να διαχωριστούν δύο βασικοί τρόποι αξιοποίησής του σε ένα downstream task. Στην πρώτη περίπτωση, το pretrained backbone παραμένει σταθερό και χρησιμοποιείται ως εξαγωγέας χαρακτηριστικών. Στη δεύτερη, οι παράμετροι του backbone επιτρέπεται να μεταβληθούν ώστε οι αναπαραστάσεις του να προσαρμοστούν στο νέο πρόβλημα. Οι δύο αυτές περιπτώσεις αντιστοιχούν στο *frozen feature extraction* και στο *full fine-tuning* και παρουσιάζονται στις επόμενες υποενότητες.

3.3.2 Frozen Feature Extraction και Linear Probing

Ένας από τους βασικότερους τρόπους αξιοποίησης ενός προεκπαιδευμένου μοντέλου είναι η χρήση του ως σταθερού εξαγωγέα χαρακτηριστικών (*feature extractor*). Στην περίπτωση αυτή, οι παράμετροι του pretrained backbone διατηρούνται αμετάβλητες κατά την εκπαίδευση στο downstream task και ενημερώνονται μόνο οι παράμετροι της νέας κεφαλής που τοποθετείται πάνω από την παραγόμενη αναπαράσταση. Η διαδικασία αυτή αναφέρεται ως *frozen feature extraction*.

Έστω ένα pretrained backbone $f_{\theta_{\text{pre}}}$, το οποίο για μία εικόνα $\mathbf{x}_i$ παράγει την αναπαράσταση

$$\mathbf{h}_i = f_{\theta_{\text{pre}}}(\mathbf{x}_i). \tag{3.30}$$

Πάνω στην αναπαράσταση $\mathbf{h}_i$ εφαρμόζεται μία εκπαιδεύσιμη κεφαλή ταξινόμησης g_ϕ. Για ένα downstream σύνολο δεδομένων $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$, η εκπαίδευση μπορεί να διατυπωθεί ως

$$\min_{\phi} \frac{1}{N} \sum_{i=1}^{N} \ell\left(g_\phi\left(f_{\theta_{\text{pre}}}(\mathbf{x}_i)\right), y_i\right), \qquad \theta = \theta_{\text{pre}} \text{ σταθερό}. \tag{3.31}$$

Επομένως, κατά την εκπαίδευση ενημερώνονται μόνο οι παράμετροι ϕ της downstream κεφαλής, ενώ οι παράμετροι του backbone παραμένουν σταθερές. Το backbone δεν έχει συνεπώς τη δυνατότητα να μεταβάλει τις αναπαραστάσεις του ώστε να προσαρμοστεί στις ετικέτες του νέου προβλήματος. Η downstream απόδοση εξαρτάται έτσι σε σημαντικό βαθμό από το πόσο χρήσιμη είναι ήδη η πληροφορία που περιέχεται στις pretrained representations.

Μία ιδιαίτερα διαδεδομένη μορφή frozen evaluation είναι το *linear probing*. Στην περίπτωση αυτή, η κεφαλή g_ϕ περιορίζεται σε έναν γραμμικό ταξινομητή:

$$\mathbf{z}_i = \mathbf{W}\mathbf{h}_i + \mathbf{b}, \tag{3.32}$$

όπου $\mathbf{W}$ και $\mathbf{b}$ αποτελούν τις εκπαιδεύσιμες παραμέτρους της κεφαλής, ενώ το pretrained backbone παραμένει πλήρως παγωμένο. Για ένα πρόβλημα ταξινόμησης

πολλαπλών κλάσεων, τα logits $\mathbf{z}_i$ μπορούν στη συνέχεια να μετατραπούν σε πιθανότητες μέσω της συνάρτησης softmax.

Επειδή ο γραμμικός ταξινομητής έχει περιορισμένη δυνατότητα να μετασχηματίσει τα χαρακτηριστικά του backbone, η απόδοσή του παρέχει μία ένδειξη για το κατά πόσο η πληροφορία που απαιτείται από το downstream task είναι ήδη προσβάσιμη μέσω ενός απλού γραμμικού διαχωρισμού των pretrained representations. Για τον λόγο αυτό, το linear evaluation χρησιμοποιείται ευρέως για την αξιολόγηση αναπαραστάσεων που έχουν αποκτηθεί μέσω αυτοεπιβλεπόμενης μάθησης και αποτελεί βασικό πρωτόκολλο αξιολόγησης τόσο στο DINO όσο και στο DINOv2 [18, 19].

Είναι ωστόσο σημαντικό να διακρίνεται το *linear probing* από τη γενικότερη έννοια του *frozen feature extraction*. Στη δεύτερη περίπτωση, το backbone παραμένει επίσης σταθερό, αλλά η downstream κεφαλή δεν είναι απαραίτητο να είναι γραμμική. Μπορεί, για παράδειγμα, να περιλαμβάνει περισσότερα επίπεδα και μη γραμμικές ενεργοποιήσεις. Επομένως, κάθε linear probe αποτελεί μία μορφή frozen evaluation, αλλά κάθε frozen evaluation δεν αποτελεί απαραίτητα linear probe.

Το frozen feature extraction παρουσιάζει επίσης υπολογιστικά πλεονεκτήματα, καθώς δεν απαιτεί υπολογισμό gradients ούτε ενημέρωση των παραμέτρων του backbone. Επιπλέον, όταν οι είσοδοι που παρέχονται στο backbone παραμένουν σταθερές μεταξύ των epochs, οι παραγόμενες αναπαραστάσεις μπορούν να υπολογιστούν εκ των προτέρων και να αποθηκευτούν, επιτρέποντας την εκπαίδευση της downstream κεφαλής χωρίς επαναλαμβανόμενη εκτέλεση του backbone.

Πέρα από το υπολογιστικό όφελος, το frozen evaluation είναι ιδιαίτερα χρήσιμο για τη σύγκριση διαφορετικών pretrained backbones. Εφόσον οι παράμετροι του backbone δεν μεταβάλλονται, μία σύγκριση υπό το ίδιο downstream protocol παρέχει μία περισσότερο άμεση ένδειξη για τη χρησιμότητα των αναπαραστάσεων που είχαν αποκτηθεί πριν από την downstream εκπαίδευση. Η ερμηνεία αυτή απαιτεί κοινές συνθήκες αξιολόγησης, καθώς η τελική επίδοση εξακολουθεί να επηρεάζεται από παράγοντες όπως η αρχιτεκτονική της κεφαλής, η διαδικασία βελτιστοποίησης και η προεπεξεργασία των δεδομένων.

Η λογική αυτή είναι άμεσα σχετική με την παρούσα εργασία. Η σύγκριση ενός generic pretrained backbone με την αντίστοιχη domain-adapted εκδοχή του υπό τις ίδιες συνθήκες frozen evaluation επιτρέπει να διερευνηθεί εάν το continued pretraining έχει οδηγήσει σε αναπαραστάσεις περισσότερο χρήσιμες για την αναγνώριση ανατομικής θέσης σε ενδοσκοπικές εικόνες. Εφόσον το backbone παραμένει σταθερό κατά το downstream training, μία διαφορά στην απόδοση παρέχει πιο άμεση ένδειξη διαφορών στις αναπαραστάσεις που είχαν αποκτηθεί πριν από την εκπαίδευση του downstream classifier.

Το frozen evaluation, ωστόσο, εξετάζει τη χρησιμότητα των ήδη υπαρχουσών αναπαραστάσεων χωρίς περαιτέρω μεταβολή του backbone. Ένα διαφορετικό ερώτημα είναι πόσο αποτελεσματικά μπορεί το pretrained μοντέλο να προσαρμοστεί όταν επιτραπεί η ενημέρωση των παραμέτρων του χρησιμοποιώντας τα δεδομένα και τις ετικέτες του downstream task. Η περίπτωση αυτή αντιστοιχεί στο *full fine-tuning* και εξετάζεται στην επόμενη υποενότητα.

3.3.3 Fine-Tuning: Full και Partial

Σε αντίθεση με το frozen feature extraction, όπου οι παράμετροι του pretrained backbone παραμένουν σταθερές, στο *fine-tuning* επιτρέπεται η ενημέρωση μέρους ή

του συνόλου των παραμέτρων του backbone κατά την εκπαίδευση στο downstream task. Με αυτόν τον τρόπο, οι αναπαραστάσεις που αποκτήθηκαν κατά το pretraining μπορούν να προσαρμοστούν στις απαιτήσεις του νέου προβλήματος. Ανάλογα με το εύρος των παραμέτρων που ενημερώνονται, διακρίνονται δύο βασικές στρατηγικές: το *full fine-tuning* και το *partial fine-tuning*.

Στο *full fine-tuning*, όλες οι παράμετροι του backbone και της κεφαλής ταξινόμησης είναι εκπαιδεύσιμες. Έστω ένα pretrained backbone f_θ και μία κεφαλή ταξινόμησης g_ϕ. Η πρόβλεψη του μοντέλου γράφεται ως

$$\hat{\mathbf{y}}_i = g_\phi\left(f_\theta(\mathbf{x}_i)\right). \tag{3.33}$$

Οι παράμετροι του backbone αρχικοποιούνται από τα pretrained weights,

$$\theta^{(0)} = \theta_{\text{pre}}, \tag{3.34}$$

αλλά δεν παραμένουν σταθερές κατά την downstream εκπαίδευση. Για ένα σύνολο δεδομένων $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$, βελτιστοποιούνται τόσο οι παράμετροι θ του backbone όσο και οι παράμετροι ϕ της κεφαλής:

$$\min_{\theta,\phi} \frac{1}{N} \sum_{i=1}^{N} \ell\left(g_\phi\left(f_\theta(\mathbf{x}_i)\right), y_i\right). \tag{3.35}$$

Κατά τη βελτιστοποίηση, τα gradients διαδίδονται από την κεφαλή ταξινόμησης προς το backbone και ενημερώνονται και τα δύο σύνολα παραμέτρων:

$$\theta \leftarrow \theta - \eta_\theta \nabla_\theta \mathcal{L}, \qquad \phi \leftarrow \phi - \eta_\phi \nabla_\phi \mathcal{L}, \tag{3.36}$$

όπου η_θ και η_ϕ συμβολίζουν τους αντίστοιχους ρυθμούς μάθησης (*learning rates*), οι οποίοι μπορούν να είναι ίσοι ή διαφορετικοί.

Επομένως, στο full fine-tuning οι pretrained αναπαραστάσεις δεν χρησιμοποιούνται ως σταθερά χαρακτηριστικά, αλλά μπορούν να μεταβληθούν σε ολόκληρο το backbone, ώστε να εξειδικευτούν στο downstream task. Η αρχική κατάσταση θ_{pre} λειτουργεί ως σημείο εκκίνησης της βελτιστοποίησης και όχι ως σταθερό σύνολο παραμέτρων.

Η αρχικοποίηση από pretrained weights διαφοροποιεί επίσης το fine-tuning από την εκπαίδευση *from scratch*. Στη δεύτερη περίπτωση, το backbone πρέπει να μάθει τις οπτικές αναπαραστάσεις ξεκινώντας από τυχαία αρχικοποιημένες παραμέτρους. Αντίθετα, στο fine-tuning η βελτιστοποίηση αξιοποιεί ήδη μαθημένα χαρακτηριστικά, τα οποία ενδέχεται να είναι μεταφέρσιμα στο νέο πρόβλημα. Η αποτελεσματικότητα αυτής της μεταφοράς εξαρτάται από τη διαδικασία pretraining, το μέγεθος και τη φύση του downstream dataset και τη σχέση μεταξύ source και target domain [42, 44].

Ιδιαίτερη σημασία έχει η επιλογή του learning rate. Επειδή το backbone ξεκινά από ήδη μαθημένες παραμέτρους, υπερβολικά μεγάλες ενημερώσεις μπορούν να αλλοιώσουν χρήσιμη πληροφορία που αποκτήθηκε κατά το pretraining. Για τον λόγο αυτό, το learning rate αποτελεί κρίσιμη υπερπαράμετρο της διαδικασίας και συχνά επιλέγεται μικρότερο από εκείνο που θα χρησιμοποιούνταν κατά την εκπαίδευση από τυχαία αρχικοποίηση [78].

Παρά τη μεγαλύτερη δυνατότητα προσαρμογής, το full fine-tuning δεν εγγυάται πάντοτε καλύτερη γενίκευση. Η ενημέρωση μεγάλου αριθμού παραμέτρων μπορεί

να αυξήσει την ευαισθησία της εκπαίδευσης και τον κίνδυνο υπερπροσαρμογής (*overfitting*), ιδιαίτερα όταν το downstream dataset είναι περιορισμένο. Συνεπώς, η τελική απόδοση εξαρτάται τόσο από την ποιότητα των αρχικών αναπαραστάσεων όσο και από τη στρατηγική βελτιστοποίησης.

Μία εναλλακτική προσέγγιση είναι το *partial fine-tuning*, το οποίο βρίσκεται μεταξύ του πλήρως frozen backbone και του full fine-tuning. Σε αυτή τη στρατηγική, ένα μέρος του backbone παραμένει σταθερό και ενημερώνονται μόνο επιλεγμένα επίπεδα ή transformer blocks, μαζί με την κεφαλή ταξινόμησης. Έτσι, περιορίζεται ο αριθμός των εκπαιδεύσιμων παραμέτρων και το υπολογιστικό κόστος της οπισθοδιάδοσης, ενώ οι αναπαραστάσεις των frozen τμημάτων του δικτύου διατηρούνται αμετάβλητες.

Η επιλογή των επιπέδων που θα παραμείνουν εκπαιδεύσιμα αποτελεί επιπλέον υπερπαράμετρο της διαδικασίας fine-tuning. Συνήθως, η προσαρμογή επικεντρώνεται στα βαθύτερα επίπεδα του backbone, καθώς αυτά βρίσκονται πλησιέστερα στην έξοδο του δικτύου και μπορούν να εξειδικευτούν περισσότερο στο downstream task. Ωστόσο, η καταλληλότερη επιλογή εξαρτάται από την αρχιτεκτονική, το μέγεθος του διαθέσιμου συνόλου δεδομένων και τη μεταφερσιμότητα των χαρακτηριστικών μεταξύ των διαφορετικών επιπέδων [42].

Η βασική διαφορά μεταξύ full και partial fine-tuning αφορά, επομένως, το εύρος της προσαρμογής: στο πρώτο ενημερώνεται ολόκληρο το backbone, ενώ στο δεύτερο μόνο ένα επιλεγμένο τμήμα του. Και οι δύο στρατηγικές διαφέρουν από το frozen evaluation, στο οποίο το backbone παραμένει πλήρως σταθερό και εκπαιδεύεται αποκλειστικά η downstream κεφαλή.

Στην παρούσα εργασία, η διάκριση αυτή είναι σημαντική για την αξιολόγηση των pretrained αναπαραστάσεων. Το frozen evaluation επιτρέπει την εξέταση της χρησιμότητας των χαρακτηριστικών χωρίς μεταβολή του backbone, ενώ το partial fine-tuning εξετάζει την απόδοση όταν επιτρέπεται περιορισμένη supervised προσαρμογή. Η συγκεκριμένη επιλογή των εκπαιδεύσιμων επιπέδων και το αντίστοιχο πειραματικό πρωτόκολλο παρουσιάζονται στο κεφάλαιο της μεθοδολογίας.

Με την παρουσίαση του transfer learning, του frozen feature extraction και των στρατηγικών fine-tuning έχει αποσαφηνιστεί ο τρόπος αξιοποίησης των pretrained αναπαραστάσεων σε ένα νέο task. Παραμένει, ωστόσο, το ερώτημα πώς μπορούν να αποκτηθούν ισχυρές οπτικές αναπαραστάσεις χωρίς ανθρώπινες ετικέτες κατά το pretraining. Το ερώτημα αυτό οδηγεί στην *αυτοεπιβλεπόμενη μάθηση*, η οποία παρουσιάζεται στην επόμενη ενότητα.

3.4 Αυτοεπιβλεπόμενη Μάθηση

3.4.1 Βασικές Αρχές της Self-Supervised Learning

Στην επιβλεπόμενη μάθηση (*supervised learning*), η εκπαίδευση βασίζεται σε ζεύγη εισόδου και ανθρώπινης ετικέτας $(\mathbf{x}_i, y_i)$. Η συλλογή τέτοιων επισημειωμένων δεδομένων μπορεί να είναι ιδιαίτερα απαιτητική, ειδικά στην ιατρική απεικόνιση, όπου η αξιόπιστη επισήμανση συχνά απαιτεί εξειδικευμένη γνώση. Η *αυτοεπιβλεπόμενη μάθηση* (*Self-Supervised Learning -- SSL*) επιχειρεί να αξιοποιήσει μη επισημειωμένα δεδομένα δημιουργώντας το learning signal από τη δομή ή από μετασχηματισμούς των ίδιων των δεδομένων, χωρίς να απαιτούνται ανθρώπινες ετικέτες κατά το pretraining [79, 80].

Βασικός στόχος της SSL είναι η εκμάθηση μιας συνάρτησης

$$\mathbf{h} = f_\theta(\mathbf{x}), \tag{3.37}$$

η οποία μετατρέπει μία εικόνα $\mathbf{x}$ σε μία αναπαράσταση $\mathbf{h}$ που διατηρεί χρήσιμη πληροφορία για το περιεχόμενό της και μπορεί αργότερα να αξιοποιηθεί σε downstream tasks, όπως ταξινόμηση, ανίχνευση ή τμηματοποίηση.

Ιστορικά, αρκετές self-supervised μέθοδοι βασίστηκαν σε βοηθητικά προβλήματα (*pretext tasks*), των οποίων οι στόχοι μπορούσαν να παραχθούν αυτόματα από τα δεδομένα. Παραδείγματα αποτελούν η πρόβλεψη της περιστροφής μιας εικόνας και της σχετικής θέσης διαφορετικών περιοχών της [81, 82]. Σκοπός αυτών των εργασιών δεν είναι η ίδια η τελική πρόβλεψη, αλλά η εκμάθηση οπτικών χαρακτηριστικών που μπορούν να μεταφερθούν σε άλλα προβλήματα.

Οι σύγχρονες μέθοδοι SSL βασίζονται συχνά στη δημιουργία διαφορετικών μετασχηματισμένων όψεων (*views*) της ίδιας εικόνας. Για δύο στοχαστικούς μετασχηματισμούς t_1 και t_2,

$$\tilde{\mathbf{x}}_1 = t_1(\mathbf{x}), \qquad \tilde{\mathbf{x}}_2 = t_2(\mathbf{x}). \tag{3.38}$$

Το self-supervised objective αξιοποιεί τη σχέση μεταξύ των δύο views ώστε το μοντέλο να μάθει αναπαραστάσεις συνεπείς ως προς μεταβολές που θεωρούνται μη ουσιώδεις. Συνεπώς, τα augmentations δεν αποτελούν απλώς τεχνική αύξησης των δεδομένων, αλλά μέρος του learning signal, καθώς επηρεάζουν τις αναλλοιότητες (*invariances*) που μαθαίνει το μοντέλο [83].

Η μορφή του objective διαφέρει μεταξύ των οικογενειών SSL. Οι contrastive μέθοδοι χρησιμοποιούν positive και negative pairs, ενώ non-contrastive και self-distillation προσεγγίσεις επιτυγχάνουν μάθηση χωρίς explicit negative pairs [83, 84, 85, 18]. Μία ακόμη κατεύθυνση είναι οι masked ή reconstruction-based μέθοδοι, στις οποίες αποκρύπτεται μέρος της εισόδου και το μοντέλο καλείται να ανακτήσει την πληροφορία που λείπει, όπως στα Masked Autoencoders [86].

Μετά το self-supervised pretraining, το backbone μπορεί να αξιολογηθεί μέσω frozen feature extraction ή linear probing ή να προσαρμοστεί περαιτέρω μέσω fine-tuning, όπως περιγράφηκε στις προηγούμενες ενότητες. Στην παρούσα εργασία, αυτή η δυνατότητα είναι ιδιαίτερα σημαντική, καθώς επιτρέπει την αξιοποίηση μη επισημειωμένων ενδοσκοπικών εικόνων για την περαιτέρω προσαρμογή ήδη προεκπαιδευμένων οπτικών αναπαραστάσεων, χωρίς ανατομικές ετικέτες κατά το self-supervised στάδιο.

3.4.2 Contrastive Learning

Μία από τις βασικές προσεγγίσεις της SSL είναι η *contrastive learning*. Διαφορετικές όψεις της ίδιας εικόνας αντιμετωπίζονται ως *positive pair*, ενώ όψεις διαφορετικών εικόνων μπορούν να λειτουργήσουν ως *negative pairs*. Το μοντέλο εκπαιδεύεται ώστε οι αναπαραστάσεις ενός positive pair να παρουσιάζουν μεγαλύτερη ομοιότητα από εκείνες διαφορετικών δειγμάτων, χωρίς να χρησιμοποιούνται προκαθορισμένες semantic labels [87, 83, 84].

Η επιλογή των augmentations είναι κρίσιμη: τα δύο views πρέπει να διαφέρουν αρκετά ώστε το πρόβλημα να μην είναι τετριμμένο, αλλά να διατηρούν επαρκή κοινή

πληροφορία. Το SimCLR έδειξε ότι η σύνθεση των augmentations επηρεάζει σημαντικά την ποιότητα των representations που προκύπτουν από το contrastive pretraining [83].

Συχνά, μετά το backbone f_θ χρησιμοποιείται μία *projection head* g:

$$\mathbf{h}_i = f_\theta(\tilde{\mathbf{x}}_i), \qquad \mathbf{z}_i = g(\mathbf{h}_i). \tag{3.39}$$

Η $\mathbf{z}_i$ χρησιμοποιείται για τον υπολογισμό του contrastive objective, ενώ η representation $\mathbf{h}_i$ του backbone μπορεί να διατηρηθεί για downstream χρήση. Στο SimCLR, η χρήση μη γραμμικής projection head βελτιώνει την ποιότητα των representations που αξιολογούνται downstream [83].

Μία βασική contrastive συνάρτηση απώλειας είναι η *InfoNCE*. Για ένα anchor $\mathbf{z}_i$, το αντίστοιχο positive $\mathbf{z}_j$ και ένα σύνολο υποψήφιων representations μπορεί να γραφεί ως

$$\mathcal{L}_{i,j} = -\log \frac{\exp\left(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau\right)}{\sum_{k \neq i} \exp\left(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau\right)}, \tag{3.40}$$

όπου $\mathrm{sim}(\cdot,\cdot)$ είναι συνήθως cosine similarity και τ η παράμετρος θερμοκρασίας. Η ελαχιστοποίηση της loss αυξάνει τη σχετική ομοιότητα του positive pair έναντι των negatives [87, 83].

Οι contrastive μέθοδοι διαφέρουν και στον τρόπο διαχείρισης των negatives. Στο SimCLR προέρχονται από το mini-batch, ενώ το *Momentum Contrast -- MoCo* χρησιμοποιεί μία ουρά (*queue*) από representations και έναν momentum-updated key encoder, επιτρέποντας τη διατήρηση μεγαλύτερου συνόλου αρνητικών παραδειγμάτων [83, 84]. Μία σχετική δυσκολία είναι τα *false negatives*, όπου διαφορετικές εικόνες που αντιμετωπίζονται ως negatives μπορεί στην πραγματικότητα να έχουν παρόμοιο σημασιολογικό περιεχόμενο [88].

Η επιτυχία μεθόδων χωρίς explicit negative pairs έδειξε, ωστόσο, ότι τα negatives δεν αποτελούν απαραίτητη προϋπόθεση για την εκμάθηση ισχυρών representations. Αυτό οδηγεί στις non-contrastive και self-distillation προσεγγίσεις.

3.4.3 Non-Contrastive Learning και Self-Distillation

Στις *non-contrastive* προσεγγίσεις, η εκπαίδευση εξακολουθεί συχνά να βασίζεται σε διαφορετικά views της ίδιας εικόνας, χωρίς όμως το objective να απαιτεί την άμεση σύγκρισή τους με explicit negative examples [85, 89, 18].

Χαρακτηριστικό παράδειγμα αποτελεί το *Bootstrap Your Own Latent -- BYOL*, το οποίο χρησιμοποιεί ένα *online network* και ένα *target network*. Το online network περιλαμβάνει encoder, projection head και prediction head και εκπαιδεύεται ώστε να προσεγγίζει την αναπαράσταση που παράγει το target network για μία διαφορετική όψη της ίδιας εικόνας. Το target network δεν ενημερώνεται απευθείας μέσω backpropagation, αλλά οι παράμετροί του εξελίσσονται ως εκθετικός κινητός μέσος των παραμέτρων του online network [85].

Οι non-contrastive μέθοδοι δεν ταυτίζονται, ωστόσο, με τη self-distillation. Το *Barlow Twins*, για παράδειγμα, δεν χρησιμοποιεί teacher--student αρχιτεκτονική, αλλά βασίζεται στη *redundancy reduction*: ενθαρρύνει τις αντίστοιχες διαστάσεις των representations δύο views να συμφωνούν, ενώ μειώνει τη συσχέτιση μεταξύ διαφορετικών διαστάσεων [89].

Ιδιαίτερο ενδιαφέρον για την παρούσα εργασία παρουσιάζει η *self-distillation*. Στην κλασική knowledge distillation, ένα ήδη εκπαιδευμένο teacher model παρέχει στόχους σε ένα student model [90]. Στη self-distillation δεν απαιτείται ένας ανεξάρτητος εξωτερικός teacher, καθώς ο εκπαιδευτικός στόχος παράγεται μέσα από την ίδια τη διαδικασία εκπαίδευσης.

Σε μία γενική teacher--student διατύπωση,

$$\mathbf{p}_s = f_{\theta_s}(\tilde{\mathbf{x}}_1), \qquad \mathbf{p}_t = f_{\theta_t}(\tilde{\mathbf{x}}_2), \tag{3.41}$$

και ο student εκπαιδεύεται ώστε να προσεγγίζει τον στόχο που παρέχει ο teacher:

$$\mathcal{L}_{\text{SSL}} = D(\mathbf{p}_t, \mathbf{p}_s), \tag{3.42}$$

όπου η ακριβής μορφή της D, των εξόδων και της ενημέρωσης των δύο δικτύων εξαρτάται από τη μέθοδο.

Η λογική αυτή βρίσκεται στον πυρήνα του *DINO -- self-DIstillation with NO labels*. Στο DINO, ο student μαθαίνει να αντιστοιχίζει τις κατανομές εξόδου ενός teacher για διαφορετικές όψεις της ίδιας εικόνας, χωρίς ανθρώπινες ετικέτες ή explicit negative pairs [18]. Ο teacher εξελίσσεται κατά τη διάρκεια της εκπαίδευσης με βάση τον student. Η ακριβής αρχιτεκτονική, η ενημέρωση του teacher και η συνάρτηση απώλειας παρουσιάζονται στην Ενότητα 3.5.

Η απουσία explicit negatives δημιουργεί, ωστόσο, ένα κρίσιμο ερώτημα: τι εμποδίζει τα δύο δίκτυα να παράγουν την ίδια μη πληροφοριακή έξοδο για κάθε εικόνα; Το ζήτημα αυτό οδηγεί στο *representation collapse*.

3.4.4 Αποφυγή Representation Collapse

Ως *representation collapse* περιγράφεται η κατάσταση κατά την οποία οι παραγόμενες αναπαραστάσεις χάνουν την πληροφορία που απαιτείται για τη διάκριση διαφορετικών εισόδων. Στην ακραία μορφή του, το *complete collapse*, διαφορετικές εικόνες αντιστοιχίζονται ουσιαστικά στην ίδια αναπαράσταση:

$$f_\theta(\mathbf{x}) \approx \mathbf{c}, \qquad \forall \mathbf{x}. \tag{3.43}$$

Υπάρχει επίσης το *dimensional collapse*, όπου οι representations δεν είναι απαραίτητα ίδιες, αλλά η μεταβλητότητά τους περιορίζεται σε υποχώρο μικρότερης διάστασης, με αποτέλεσμα μέρος των διαθέσιμων διαστάσεων να μεταφέρει ελάχιστη ή πλεονάζουσα πληροφορία [91, 92].

Ο κίνδυνος της τετριμμένης λύσης μπορεί να γίνει αντιληπτός μέσω ενός απλού agreement objective:

$$\mathcal{L} = \|f_\theta(\tilde{\mathbf{x}}_1) - f_\theta(\tilde{\mathbf{x}}_2)\|_2^2 . \tag{3.44}$$

Εάν $f_\theta(\mathbf{x}) = \mathbf{c}$ για κάθε $\mathbf{x}$, η συγκεκριμένη απλοποιημένη loss μηδενίζεται χωρίς να έχει μαθευτεί χρήσιμη πληροφορία. Το παράδειγμα αυτό δεν αποτελεί τη loss του DINO, αλλά δείχνει γιατί η συμφωνία μεταξύ διαφορετικών views δεν επαρκεί από μόνη της για την εκμάθηση πληροφοριακών representations [85, 89].

Στις contrastive μεθόδους, τα negatives αντιτίθενται άμεσα στο complete collapse, καθώς διαφορετικά δείγματα πρέπει να παραμένουν διαχωρίσιμα στον representation space [83, 84]. Οι non-contrastive μέθοδοι χρησιμοποιούν άλλους μηχανισμούς. Το

BYOL βασίζεται στην ασυμμετρία μεταξύ online και target branches και στη διαφορετική ενημέρωσή τους, ενώ το Barlow Twins συνδυάζει τη συμφωνία μεταξύ views με redundancy reduction [85, 89].

Το DINO αντιμετωπίζει επίσης το collapse χωρίς explicit negatives. Σε υψηλό επίπεδο, συνδυάζει έναν teacher που ενημερώνεται σταδιακά από τον student με κατάλληλο έλεγχο της κατανομής εξόδου του teacher. Οι μηχανισμοί *centering* και *sharpening* αποτελούν σημαντικά στοιχεία αυτής της διαδικασίας [18], αλλά η ακριβής λειτουργία τους παρουσιάζεται στην Ενότητα 3.5.

Η αποφυγή του collapse αποτελεί βασική προϋπόθεση για την εκμάθηση χρήσιμων self-supervised representations: μία χαμηλή training loss δεν αρκεί εάν μπορεί να επιτευχθεί μέσω τετριμμένης λύσης. Με την έννοια αυτή ολοκληρώνεται το γενικό θεωρητικό υπόβαθρο της SSL και μπορεί πλέον να εξεταστεί ειδικότερα το DINO, το οποίο συνδυάζει teacher--student self-distillation, πολλαπλά views και μηχανισμούς αποφυγής collapse για την εκμάθηση οπτικών αναπαραστάσεων χωρίς ετικέτες.

3.5 DINO

3.5.1 Αρχιτεκτονική Teacher--Student

Το *DINO (self-DIstillation with NO labels)* είναι μία μέθοδος αυτοεπιβλεπόμενης μάθησης που βασίζεται σε αρχιτεκτονική *teacher--student*, επιτρέποντας την εκμάθηση οπτικών αναπαραστάσεων χωρίς ανθρώπινες ετικέτες ή ρητά αρνητικά ζεύγη (*explicit negative pairs*) [18]. Στην αρχική εργασία, η προεκπαίδευση πραγματοποιείται κυρίως στο ImageNet-1k, χρησιμοποιώντας τις εικόνες εκπαίδευσης χωρίς τις κατηγορικές ετικέτες τους [18, 41]. Η έμφαση της μεθόδου βρίσκεται στον μηχανισμό self-distillation και όχι στη δημιουργία ενός νέου συνόλου δεδομένων μεγάλης κλίμακας, όπως συμβαίνει αργότερα με το DINOv2.

Η βασική αρχή είναι ότι δύο δίκτυα επεξεργάζονται διαφορετικές μετασχηματισμένες όψεις της ίδιας εικόνας και ο student εκπαιδεύεται ώστε να προσεγγίζει την έξοδο του teacher. Τα δύο δίκτυα διαθέτουν την ίδια αρχιτεκτονική, αλλά διαφορετικές παραμέτρους, θ_s και θ_t. Για δύο όψεις $\tilde{\mathbf{x}}_s$ και $\tilde{\mathbf{x}}_t$, οι έξοδοί τους γράφονται ως

$$\mathbf{z}_s = g_{\theta_s}(\tilde{\mathbf{x}}_s), \qquad \mathbf{z}_t = g_{\theta_t}(\tilde{\mathbf{x}}_t). \tag{3.45}$$

Στην περίπτωση των Vision Transformers, κάθε κλάδος περιλαμβάνει το ViT backbone και μία projection head που χρησιμοποιείται κατά την αυτοεπιβλεπόμενη εκπαίδευση [18].

Η βασική ασυμμετρία αφορά την ενημέρωση των παραμέτρων. Ο student βελτιστοποιείται μέσω backpropagation με βάση τη self-distillation loss, ενώ ο teacher δεν λαμβάνει gradients. Αντίθετα, οι παράμετροί του ενημερώνονται ως εκθετικός κινητός μέσος (*Exponential Moving Average -- EMA*) των παραμέτρων του student. Επομένως, ο teacher δεν αποτελεί ανεξάρτητα προεκπαιδευμένο ή σταθερό μοντέλο, αλλά έναν δυναμικό και χρονικά εξομαλυμένο εκπαιδευτικό στόχο [18]. Ο ακριβής μηχανισμός ενημέρωσης παρουσιάζεται αναλυτικά στην Ενότητα 3.5.5.

Η εκπαίδευση βασίζεται στην αντιστοίχιση των προβλέψεων των δύο δικτύων για διαφορετικές όψεις της ίδιας εικόνας. Στην τυπική multi-crop διαμόρφωση, ο teacher επεξεργάζεται μόνο τις δύο μεγαλύτερες όψεις (*global crops*), ενώ ο student

επεξεργάζεται τόσο global όσο και μικρότερες τοπικές όψεις (*local crops*). Με αυτόν τον τρόπο, ο student ενθαρρύνεται να παράγει συνεπείς προβλέψεις ακόμη και όταν διαθέτει περιορισμένη οπτική πληροφορία [18].

Η συνάρτηση απώλειας, οι μετασχηματισμοί εικόνων, οι μηχανισμοί αποφυγής representation collapse και η ενημέρωση του teacher παρουσιάζονται αναλυτικά στις επόμενες υποενότητες.

3.5.2 Self-Distillation Objective

Στο DINO, ο student εκπαιδεύεται ώστε να προσεγγίζει την κατανομή εξόδου του teacher για διαφορετικές όψεις της ίδιας εικόνας. Κάθε δίκτυο παράγει μέσω της τελικής κεφαλής ένα διάνυσμα K logits, τα οποία μετατρέπονται σε κατανομή πιθανότητας μέσω της συνάρτησης softmax.

Για τον student, η κατανομή υπολογίζεται με παράμετρο θερμοκρασίας τ_s:

$$P_s(\mathbf{x})^{(k)} = \frac{\exp\left(g_{\theta_s}(\mathbf{x})^{(k)}/\tau_s\right)}{\sum_{k'=1}^{K} \exp\left(g_{\theta_s}(\mathbf{x})^{(k')}/\tau_s\right)}. \tag{3.46}$$

Αντίστοιχα, η κατανομή του teacher χρησιμοποιεί ξεχωριστή θερμοκρασία τ_t και ένα διάνυσμα κεντραρίσματος $\mathbf{c}$:

$$P_t(\mathbf{x})^{(k)} = \frac{\exp\left(\left(g_{\theta_t}(\mathbf{x})^{(k)} - c^{(k)}\right)/\tau_t\right)}{\sum_{k'=1}^{K} \exp\left(\left(g_{\theta_t}(\mathbf{x})^{(k')} - c^{(k')}\right)/\tau_t\right)}. \tag{3.47}$$

Οι K διαστάσεις των κατανομών δεν αντιστοιχούν σε προκαθορισμένες σημασιολογικές κατηγορίες. Αντί για ανθρώπινες ετικέτες, ο teacher παρέχει δυναμικά τους εκπαιδευτικούς στόχους του student [18].

Στην πράξη, κάθε μία από τις K διαστάσεις αντιστοιχεί σε ένα ξεχωριστό εκπαιδεύσιμο διάνυσμα βάρους μέσα στο τελευταίο layer της κεφαλής -- ένα *prototype*. Ο αριθμός K επιλέγεται σκόπιμα πολύ μεγαλύτερος από τις πραγματικές σημασιολογικές κατηγορίες που υπάρχουν σε οποιοδήποτε σύνολο δεδομένων, ώστε το δίκτυο να αναγκάζεται σε λεπτές διακρίσεις, δημιουργώντας ένα υπερπλήρες λεξιλόγιο οπτικών εννοιών αντί για λίγες χοντροκομμένες κατηγορίες.

Η προσέγγιση αυτή έχει τις ρίζες της σε παλαιότερες clustering-based μεθόδους αυτοεπιβλεπόμενης μάθησης, όπως το DeepCluster και το SwAV, μία εναλλακτική στο ρητό contrastive learning (Ενότητα 3.4.2) [93, 94]: αντί η εκπαίδευση να βασίζεται άμεσα σε συγκρίσεις ζευγών εικόνων, κάθε όψη αντιστοιχίζεται σε ένα από τα K prototypes, με τις διαφορετικές όψεις της ίδιας εικόνας να ενθαρρύνονται να καταλήγουν στο ίδιο prototype.

Για μία teacher view $\mathbf{x}_t$ και μία διαφορετική student view $\mathbf{x}_s$, η συμφωνία των κατανομών επιτυγχάνεται μέσω της *cross-entropy*:

$$H\left(P_t(\mathbf{x}_t), P_s(\mathbf{x}_s)\right) = -\sum_{k=1}^{K} P_t(\mathbf{x}_t)^{(k)} \log P_s(\mathbf{x}_s)^{(k)}. \tag{3.48}$$

Η κατανομή του teacher λειτουργεί ως στόχος, ενώ τα gradients υπολογίζονται αποκλειστικά για τον student. Η προσέγγιση σχετίζεται με την κλασική knowledge

distillation, με τη διαφορά ότι ο teacher δεν είναι ανεξάρτητα προεκπαιδευμένο μοντέλο, αλλά εξελίσσεται κατά τη διάρκεια της αυτοεπιβλεπόμενης εκπαίδευσης [90, 18].

Αν $\mathcal{V}$ είναι το σύνολο των όψεων που επεξεργάζεται ο student και $\mathcal{V}_g$ οι global views του teacher, η συνολική συνάρτηση απώλειας του DINO γράφεται ως

$$\mathcal{L}_{\text{DINO}} = \sum_{\mathbf{x}_t \in \mathcal{V}_g} \sum_{\substack{\mathbf{x}_s \in \mathcal{V} \\ \mathbf{x}_s \neq \mathbf{x}_t}} H\left(P_t(\mathbf{x}_t), P_s(\mathbf{x}_s)\right). \tag{3.49}$$

Η αντιστοίχιση διαφορετικών όψεων ενθαρρύνει τη συνέπεια των προβλέψεων παρά τους μετασχηματισμούς της εικόνας. Έτσι, το DINO επιτυγχάνει self-distillation χωρίς ανθρώπινα labels και χωρίς explicit negative examples [18]. Η επιλογή των global και local views αναλύεται στην επόμενη υποενότητα, ενώ ο ρόλος του centering και των παραμέτρων θερμοκρασίας στην αποφυγή του representation collapse εξετάζεται στην Ενότητα 3.5.4.

3.5.3 Image Augmentations και Multi-Crop Strategy

Οι διαφορετικές όψεις της ίδιας εικόνας αποτελούν βασικό μέρος του εκπαιδευτικού σήματος (*learning signal*) του DINO και όχι απλώς τεχνική αύξησης των δεδομένων. Μέσω των augmentations καθορίζονται οι μεταβολές ως προς τις οποίες το μοντέλο ενθαρρύνεται να αποκτήσει αναλλοιωτότητα (*invariance*). Οι όψεις πρέπει επομένως να διαφέρουν αρκετά ώστε το αυτοεπιβλεπόμενο πρόβλημα να μην είναι τετριμμένο, διατηρώντας παράλληλα επαρκή κοινή σημασιολογική πληροφορία [83, 18].

Η διαδικασία δημιουργίας των όψεων περιλαμβάνει χωρικούς και φωτομετρικούς μετασχηματισμούς, όπως *random resized cropping*, *horizontal flipping*, *color jittering*, μετατροπή σε grayscale, *Gaussian blur* και *solarization* [18]. Κεντρικό στοιχείο αποτελεί η *multi-crop strategy*, η οποία βασίζεται στην αντίστοιχη προσέγγιση του SwAV [94, 18].

Το DINO δημιουργεί δύο *global views*, που καλύπτουν μεγαλύτερες περιοχές της αρχικής εικόνας, και πολλαπλές *local views*, που περιλαμβάνουν μικρότερες περιοχές. Στην τυπική διαμόρφωση χρησιμοποιούνται δύο global crops ανάλυσης 224×224 και πολλαπλά local crops ανάλυσης 96×96 pixels [18].

Αν το σύνολο των παραγόμενων όψεων ορίζεται ως

$$\mathcal{V} = \left\{ \mathbf{x}_1^g, \mathbf{x}_2^g, \mathbf{x}_1^l, \ldots, \mathbf{x}_n^l \right\}, \tag{3.50}$$

τότε ο teacher επεξεργάζεται αποκλειστικά τις δύο global views, ενώ ο student επεξεργάζεται όλες τις διαθέσιμες όψεις:

$$\mathcal{V}_t = \{\mathbf{x}_1^g, \mathbf{x}_2^g\}, \qquad \mathcal{V}_s = \mathcal{V}. \tag{3.51}$$

Οι κατανομές εξόδου του teacher για τις global views χρησιμοποιούνται ως εκπαιδευτικοί στόχοι για τις διαφορετικές όψεις του student. Έτσι, ο student μπορεί να εκπαιδεύεται ώστε οι προβλέψεις που προκύπτουν από μία τοπική περιοχή να συμφωνούν με εκείνες που παράγονται από μία ευρύτερη όψη της ίδιας εικόνας. Η διαδικασία αυτή ενθαρρύνει τη σύνδεση τοπικής και συνολικής οπτικής πληροφορίας [18].

Παράλληλα, οι local views έχουν χαμηλότερη ανάλυση και, για σταθερό μέγεθος patch σε έναν Vision Transformer, παράγουν μικρότερες ακολουθίες tokens. Επομένως, η χρήση τους επιτρέπει την αξιοποίηση περισσότερων όψεων κατά την εκπαίδευση με χαμηλότερο υπολογιστικό κόστος σε σχέση με τη χρήση αποκλειστικά global crops [94].

Συνολικά, τα augmentations καθορίζουν τις επιθυμητές αναλλοιότητες των αναπαραστάσεων, ενώ η multi-crop στρατηγική ενισχύει τη συνέπεια μεταξύ τοπικής και ευρύτερης οπτικής πληροφορίας. Η συγκεκριμένη επιλογή των crops και των παραμέτρων των μετασχηματισμών που χρησιμοποιούνται στην παρούσα εργασία παρουσιάζεται στο κεφάλαιο της Πειραματικής Διαδικασίας.

3.5.4 Centering και Sharpening

Η αντιστοίχιση των κατανομών εξόδου του teacher και του student δεν αρκεί από μόνη της για την αποφυγή τετριμμένων λύσεων. Εάν ο teacher παρήγαγε την ίδια κατανομή για όλες τις εικόνες, ο student θα μπορούσε να την προσεγγίσει χωρίς να μάθει πληροφοριακές αναπαραστάσεις. Για τον περιορισμό αυτού του κινδύνου, το DINO χρησιμοποιεί δύο συμπληρωματικούς μηχανισμούς στη διαμόρφωση της κατανομής εξόδου του teacher: το *centering* και το *sharpening* [18].

Όπως παρουσιάστηκε στον ορισμό της κατανομής P_t στην Ενότητα 3.5.2, το centering εφαρμόζεται αφαιρώντας από τα logits του teacher ένα διάνυσμα κέντρου $\mathbf{c}$. Το κέντρο ενημερώνεται ως εκθετικός κινητός μέσος των εξόδων του teacher σε επίπεδο batch:

$$\mathbf{c} \leftarrow m_c \mathbf{c} + (1 - m_c) \frac{1}{B} \sum_{i=1}^{B} g_{\theta_t}(\mathbf{x}_i), \tag{3.52}$$

όπου B είναι ο αριθμός των εξόδων του teacher στο batch και m_c ο συντελεστής momentum του κέντρου. Η αφαίρεση του κινούμενου μέσου περιορίζει την τάση συγκεκριμένων διαστάσεων της εξόδου να κυριαρχούν συστηματικά στις προβλέψεις του teacher [18].

Το *sharpening*, αντίθετα, ελέγχεται μέσω της θερμοκρασίας τ_t στη συνάρτηση softmax του teacher. Μικρότερες τιμές της θερμοκρασίας ενισχύουν τις σχετικές διαφορές μεταξύ των logits, παράγοντας περισσότερο συγκεντρωμένες κατανομές πιθανότητας. Αντίθετα, μεγαλύτερες τιμές οδηγούν σε πιο ομαλές κατανομές.

Για παράδειγμα, για ένα σύνολο logits $\mathbf{z} = [2{,}0,\ 1{,}0,\ 0{,}5,\ 0{,}3]$, μία σχετικά υψηλή θερμοκρασία ($\tau = 5$) δίνει κατανομή softmax περίπου $[0{,}306,\ 0{,}250,\ 0{,}226,\ 0{,}218]$ -- σχεδόν ομοιόμορφη, παρά τις υπαρκτές διαφορές στα αρχικά logits. Με πολύ μικρότερη θερμοκρασία ($\tau = 0{,}07$), η ίδια ακριβώς ακολουθία logits δίνει κατανομή περίπου $[1{,}000,\ 0{,}000,\ 0{,}000,\ 0{,}000]$ -- οι ίδιες μικρές διαφορές μεγεθύνονται δραματικά σε σχεδόν πλήρη σιγουριά.

Οι δύο μηχανισμοί λειτουργούν συμπληρωματικά, αποτρέποντας στην πράξη δύο διαφορετικές εκδοχές του ίδιου complete collapse (Ενότητα 3.4.4), $f_\theta(\mathbf{x}) \approx \mathbf{c}$ για κάθε $\mathbf{x}$: χωρίς centering, το $\mathbf{c}$ θα μπορούσε να είναι μία κατανομή συγκεντρωμένη σε μία συγκεκριμένη, σταθερή διάσταση για όλες τις εικόνες· χωρίς sharpening, θα μπορούσε αντίθετα να είναι η ομοιόμορφη κατανομή, ίδια και αδιάφορη για κάθε είσοδο. Και στις δύο περιπτώσεις, καμία πληροφορία για το ποια εικόνα είναι ποια δεν θα περνούσε στον student, κι έτσι ο συνδυασμός τους αποκλείει αμφότερες τις

διαδρομές προς την τετριμμένη λύση και συμβάλλει στη δημιουργία πληροφοριακών εκπαιδευτικών στόχων.

3.5.5 Exponential Moving Average του Teacher

Στο DINO, ο teacher δεν ενημερώνεται μέσω backpropagation, καθώς κατά τον υπολογισμό της self-distillation loss εφαρμόζεται *stop-gradient* στον αντίστοιχο κλάδο. Οι παράμετροί του ενημερώνονται μέσω εκθετικού κινητού μέσου (*Exponential Moving Average -- EMA*) των παραμέτρων του student [18]. Μετά από κάθε βήμα βελτιστοποίησης του student, η ενημέρωση πραγματοποιείται σύμφωνα με τη σχέση

$$\theta_t \leftarrow m_t\theta_t + (1 - m_t)\theta_s, \tag{3.53}$$

όπου θ_t και θ_s είναι οι παράμετροι του teacher και του student αντίστοιχα, ενώ $m_t \in [0, 1)$ είναι ο συντελεστής momentum του teacher.

Η επαναλαμβανόμενη εφαρμογή της παραπάνω ενημέρωσης καθιστά τον teacher μία χρονικά εξομαλυμένη (*temporally smoothed*) εκδοχή του student. Όσο το m_t πλησιάζει τη μονάδα, τόσο μικρότερη είναι η επίδραση των πρόσφατων μεταβολών του student στις παραμέτρους του teacher. Στο αρχικό DINO, το teacher momentum αυξάνεται σταδιακά προς τη μονάδα κατά τη διάρκεια της εκπαίδευσης [18].

Με αυτόν τον τρόπο, ο teacher παρέχει έναν σχετικά σταθερό αλλά διαρκώς εξελισσόμενο εκπαιδευτικό στόχο. Ο student προσαρμόζεται άμεσα μέσω των gradients της συνάρτησης απώλειας, ενώ ο teacher ακολουθεί σταδιακά την εξέλιξή του. Συναφείς μηχανισμοί ενημέρωσης μέσω momentum χρησιμοποιούνται επίσης στις μεθόδους MoCo και BYOL [84, 85].

Συνολικά, το DINO συνδυάζει την αρχιτεκτονική teacher--student, τη δημιουργία πολλαπλών όψεων μέσω της multi-crop στρατηγικής, τη βελτιστοποίηση της cross-view self-distillation loss και τους μηχανισμούς centering, sharpening και EMA. Ο συνδυασμός αυτών των στοιχείων επιτρέπει την εκμάθηση οπτικών αναπαραστάσεων χωρίς ανθρώπινες ετικέτες ή ρητά αρνητικά παραδείγματα (*explicit negative pairs*) και αποτελεί τη βάση για την ανάπτυξη του DINOv2 [18].

3.6 DINOv2

3.6.1 Motivation και Improved Training Pipeline

Το DINOv2 αποτελεί εξέλιξη του DINO, με βασικό στόχο την εκμάθηση γενικού σκοπού οπτικών χαρακτηριστικών (*general-purpose visual features*), τα οποία μπορούν να αξιοποιηθούν σε διαφορετικά σύνολα δεδομένων και downstream εργασίες [19]. Η ανάπτυξή του βασίζεται στην επιδίωξη δημιουργίας ισχυρών και μεταφέρσιμων οπτικών αναπαραστάσεων μέσω αυτοεπιβλεπόμενης μάθησης μεγάλης κλίμακας.

Το DINOv2 διατηρεί τη βασική αρχιτεκτονική teacher--student και την ενημέρωση του teacher μέσω εκθετικού κινητού μέσου (*Exponential Moving Average -- EMA*), αλλά επεκτείνει την αρχική μέθοδο σε τρεις κύριους άξονες.

Πρώτον, δίνεται ιδιαίτερη έμφαση στην ποιότητα, την ποικιλία και την κλίμακα των δεδομένων προεκπαίδευσης, μέσω της δημιουργίας του επιμελημένου συνόλου

LVD-142M, το οποίο περιλαμβάνει περίπου 142 εκατομμύρια εικόνες. Η διαδικασία αυτή παρουσιάζεται αναλυτικά στην Ενότητα 3.6.2 [19].

Δεύτερον, η image-level self-distillation συμπληρώνεται από masked image modeling βασισμένο στο iBOT, το οποίο εισάγει έναν επιπλέον εκπαιδευτικό στόχο σε επίπεδο επιμέρους patches. Παράλληλα, ενσωματώνεται ο μηχανισμός KoLeo regularization, ο οποίος ενθαρρύνει τη μεγαλύτερη διασπορά των καθολικών αναπαραστάσεων στον χώρο χαρακτηριστικών [19, 95]. Οι δύο μηχανισμοί αναλύονται στις Ενότητες 3.6.3 και 3.6.4. Οι τρεις αυτοί όροι (DINO, iBOT, KoLeo) συνδυάζονται τελικά σε μία ενιαία συνάρτηση απώλειας, όπως παρουσιάζεται αναλυτικά στο τέλος της Ενότητας 3.6.4.

Τρίτον, εισάγονται βελτιώσεις στη διαδικασία εκπαίδευσης, οι οποίες επιτρέπουν την αποτελεσματικότερη κλιμάκωση σε μεγαλύτερα σύνολα δεδομένων και Vision Transformer μοντέλα [19]. Μία από αυτές αφορά τον σχηματισμό των εκπαιδευτικών στόχων του teacher: ενώ στο αρχικό DINO χρησιμοποιούνται οι μηχανισμοί centering και sharpening (Ενότητα 3.5.4), το DINOv2 αξιοποιεί τη διαδικασία *Sinkhorn--Knopp*, αρχικά προτεινόμενη στο SwAV [94], για την κανονικοποίηση των teacher assignments. Η διαδικασία αυτή παρουσιάζεται αναλυτικά στην Ενότητα 3.6.5.

Επιπλέον, το DINOv2 ενσωματώνει βελτιστοποιήσεις στην υλοποίηση της εκπαίδευσης, όπως αποδοτικότερες πράξεις attention και τεχνικές περιορισμού των απαιτήσεων μνήμης. Οι βελτιώσεις αυτές διευκολύνουν την προεκπαίδευση μεγαλύτερων Vision Transformer μοντέλων σε εκτεταμένα σύνολα δεδομένων, χωρίς να μεταβάλλουν τη βασική λογική της teacher--student self-distillation [19].

Τέλος, το DINOv2 εξακολουθεί να βασίζεται αποκλειστικά σε οπτική πληροφορία για την αυτοεπιβλεπόμενη προεκπαίδευση, χωρίς να απαιτεί ανθρώπινες ετικέτες, captions ή ζεύγη εικόνας--κειμένου [19].

3.6.2 Dataset Curation

Η αποτελεσματικότητα της αυτοεπιβλεπόμενης προεκπαίδευσης μεγάλης κλίμακας δεν εξαρτάται αποκλειστικά από τον αριθμό των εικόνων, αλλά και από την ποιότητα και την ποικιλία τους. Για τον λόγο αυτό, η επιμέλεια των δεδομένων (*data curation*) αποτελεί βασικό στοιχείο της μεθοδολογίας του DINOv2 [19].

Η διαδικασία συνδυάζει επιμελημένα σύνολα δεδομένων αναφοράς (*curated reference datasets*), όπως τα ImageNet-22k, ImageNet-1k και Google Landmarks, με μία πολύ μεγαλύτερη συλλογή εικόνων από το διαδίκτυο. Μετά την αρχική επεξεργασία, η μη επιμελημένη συλλογή (*uncurated pool*) περιλαμβάνει περίπου 1,2 δισεκατομμύρια μοναδικές εικόνες, από τις οποίες επιλέγεται ένα μικρότερο και περισσότερο ελεγχόμενο υποσύνολο [19].

Αρχικά εφαρμόζεται διαδικασία εντοπισμού και αφαίρεσης διπλότυπων εικόνων (*deduplication*), αξιοποιώντας τη μέθοδο *Self-Supervised Copy Detection -- SSCD* για την αναγνώριση εικόνων με πολύ υψηλή οπτική ομοιότητα (*near-duplicates*) [96]. Επιπλέον, αφαιρούνται εικόνες που παρουσιάζουν μεγάλη ομοιότητα με δεδομένα αξιολόγησης, ώστε να περιοριστεί ο κίνδυνος επικάλυψης μεταξύ των συνόλων προεκπαίδευσης και ελέγχου [19].

Στη συνέχεια εφαρμόζεται *self-supervised image retrieval*, κατά το οποίο οι εικόνες αναπαρίστανται μέσω οπτικών διανυσμάτων χαρακτηριστικών (*visual embeddings*). Με βάση την ομοιότητα αυτών των αναπαραστάσεων, ανακτώνται εικόνες από τη

μη επιμελημένη συλλογή που παρουσιάζουν οπτική συνάφεια με τα σύνολα αναφοράς. Για μεγαλύτερα reference datasets χρησιμοποιείται *sample-based retrieval*, μέσω αναζήτησης πλησιέστερων γειτόνων (*nearest-neighbor search*). Αντίθετα, για μικρότερα reference datasets εφαρμόζεται *cluster-based retrieval*, όπου οι εικόνες της μη επιμελημένης συλλογής ομαδοποιούνται μέσω k-means και επιλέγονται εικόνες από συναφείς ομάδες (*clusters*) [19].

Το αποτέλεσμα αυτής της διαδικασίας είναι το LVD-142M, ένα επιμελημένο σύνολο περίπου 142 εκατομμυρίων εικόνων, το οποίο χρησιμοποιείται για την προεκπαίδευση του DINOv2 [19].

Στην παρούσα εργασία δεν επιχειρείται η αναπαραγωγή της διαδικασίας δημιουργίας του LVD-142M. Αντίθετα, διερευνάται κατά πόσο η περαιτέρω αυτοεπιβλεπόμενη προεκπαίδευση ενός ήδη προεκπαιδευμένου backbone σε ένα μικρότερο, αλλά εξειδικευμένο σύνολο εικόνων γαστρεντερικής ενδοσκόπησης, το HyperKvasir, μπορεί να βελτιώσει την προσαρμογή των οπτικών αναπαραστάσεων στο συγκεκριμένο πεδίο [20].

3.6.3 iBOT Masked Image Modeling

Μία από τις βασικές επεκτάσεις του DINOv2 είναι η ενσωμάτωση του *masked image modeling* μέσω της μεθόδου iBOT (*image BERT pre-training with Online Tokenizer*) [95, 19]. Ο μηχανισμός αυτός αξιοποιεί μασκαρισμένα patches και τις προβλέψεις ενός teacher μοντέλου, ώστε ο student να μαθαίνει τοπικές οπτικές αναπαραστάσεις από το περιεχόμενο της εικόνας.

Έστω ότι μία εικόνα χωρίζεται σε N patches και ορίζεται η δυαδική μάσκα

$$\mathbf{m} = (m_1, \ldots, m_N), \qquad m_i \in \{0, 1\}, \tag{3.54}$$

όπου $m_i = 1$ δηλώνει masked patch. Ο student επεξεργάζεται τη μασκαρισμένη όψη της εικόνας, στην οποία τα επιλεγμένα patches αντικαθίστανται από ένα εκπαιδεύσιμο *mask token*. Το masking εφαρμόζεται αποκλειστικά στα global crops (Ενότητα 3.5.3)· τα local crops παραμένουν αμασκάριστα. Αντίθετα, ο teacher επεξεργάζεται την αντίστοιχη μη μασκαρισμένη όψη, παρέχοντας τις κατανομές εξόδου που χρησιμοποιούνται ως εκπαιδευτικοί στόχοι. Η διαδικασία βασίζεται σε *block-wise masking*, κατά το οποίο αποκρύπτονται συνεκτικές χωρικές περιοχές της εικόνας [95].

Για κάθε patch i, οι κατανομές εξόδου του teacher και του student συμβολίζονται με $P_t^{(i)}$ και $P_s^{(i)}$, αντίστοιχα. Η συνάρτηση απώλειας του iBOT ορίζεται ως

$$\mathcal{L}_{\text{iBOT}} = -\frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \sum_{k=1}^{K} P_t^{(i)}(k) \log P_s^{(i)}(k), \tag{3.55}$$

όπου $\mathcal{M} = \{i : m_i = 1\}$ είναι το σύνολο των masked patches και K η διάσταση της κατανομής εξόδου. Η απώλεια υπολογίζεται αποκλειστικά στις μασκαρισμένες θέσεις, ενθαρρύνοντας τον student να προβλέπει τις κατανομές του teacher αξιοποιώντας την ορατή πληροφορία και τις χωρικές συσχετίσεις μεταξύ των patches [95, 19].

Σε αντίθεση με προσεγγίσεις masked image modeling που επιδιώκουν την ανακατασκευή των αρχικών τιμών RGB, το iBOT χρησιμοποιεί ως στόχους τις κατανομές που παράγονται από τον teacher. Πρόκειται επομένως για μία μορφή *masked*

self-distillation στον χώρο των αναπαραστάσεων, όπου ο teacher λειτουργεί ως *online tokenizer* [95].

Στο DINOv2, ο στόχος αυτός λειτουργεί συμπληρωματικά προς την image-level self-distillation του DINO, ενώ χρησιμοποιείται ξεχωριστή κεφαλή προβολής (*projection head*) για τις αναπαραστάσεις των patch tokens [19]. Με αυτόν τον συνδυασμό, η εκπαίδευση αξιοποιεί τόσο την πληροφορία που αφορά τη συνολική εικόνα όσο και τις τοπικές οπτικές δομές. Η εκμάθηση αυτών των τοπικών δομών αποδεικνύεται ιδιαίτερα χρήσιμη για dense downstream εργασίες, όπως η σημασιολογική κατάτμηση (*semantic segmentation*), όπου απαιτούνται ακριβείς αναπαραστάσεις σε επίπεδο μεμονωμένων περιοχών της εικόνας και όχι μόνο μία συνολική περίληψη [95].

3.6.4 KoLeo Regularization

Το DINOv2 ενσωματώνει επιπλέον τον μηχανισμό κανονικοποίησης *KoLeo regularization*, ο οποίος ενθαρρύνει τη μεγαλύτερη διασπορά των καθολικών αναπαραστάσεων (*global representations*) στον χώρο χαρακτηριστικών [19]. Ο μηχανισμός βασίζεται στον εκτιμητή διαφορικής εντροπίας των Kozachenko και Leonenko [97] και αποσκοπεί στον περιορισμό της υπερβολικής συγκέντρωσης διαφορετικών αναπαραστάσεων σε μικρές περιοχές του χώρου χαρακτηριστικών.

Έστω $\mathbf{x}_1, \ldots, \mathbf{x}_n$ οι ℓ_2-κανονικοποιημένες αναπαραστάσεις του `[CLS]` token για τις n εικόνες ενός batch. Για κάθε αναπαράσταση $\mathbf{x}_i$, ορίζεται η ευκλείδεια απόσταση από τον πλησιέστερο γείτονά της ως

$$d_i = \min_{j \neq i} \|\mathbf{x}_i - \mathbf{x}_j\|_2 . \tag{3.56}$$

Ο εκτιμητής των Kozachenko και Leonenko συνδέει τη διαφορική εντροπία με τον λογάριθμο των αποστάσεων από τους πλησιέστερους γείτονες. Με βάση αυτή την αρχή, ο όρος κανονικοποίησης KoLeo διατυπώνεται ως

$$\mathcal{L}_{\text{KoLeo}} = -\frac{1}{n} \sum_{i=1}^{n} \log d_i, \tag{3.57}$$

όπου n είναι ο αριθμός των αναπαραστάσεων του batch. Η ελαχιστοποίηση της παραπάνω συνάρτησης ενθαρρύνει την αύξηση των αποστάσεων μεταξύ γειτονικών αναπαραστάσεων, συμβάλλοντας σε μεγαλύτερη εκτιμώμενη εντροπία και διασπορά στον χώρο χαρακτηριστικών [19].

Η ℓ_2-κανονικοποίηση περιορίζει τις αναπαραστάσεις στη μοναδιαία υπερσφαίρα, αποτρέποντας την τεχνητή αύξηση των αποστάσεων μέσω της απλής μεγέθυνσης του μέτρου των διανυσμάτων. Επομένως, ο KoLeo ενθαρρύνει τη χωρική διασπορά των χαρακτηριστικών χωρίς να επιτρέπει την ανεξέλεγκτη αύξηση της νόρμας τους.

Επειδή οι αποστάσεις υπολογίζονται μεταξύ των αναπαραστάσεων του εκάστοτε batch, ο KoLeo εξαρτάται από τη σύνθεσή του (*batch-dependent*). Με μεγαλύτερο batch, η εκτίμηση της απόστασης πλησιέστερου γείτονα γίνεται πιο αξιόπιστη ένδειξη της τοπικής πυκνότητας των αναπαραστάσεων· με λίγα δείγματα, ο πλησιέστερος γείτονας μπορεί να είναι τυχαία κοντά ή μακριά. Σε αντίθεση με τους εκπαιδευτικούς στόχους DINO και iBOT, δεν βασίζεται στην αντιστοίχιση προβλέψεων teacher και student, αλλά δρα απευθείας στη γεωμετρία του χώρου αναπαραστάσεων. Με αυτόν τον τρόπο λειτουργεί συμπληρωματικά προς τη self-distillation, ενθαρρύνοντας μεγαλύτερη ποικιλία στις αναπαραστάσεις που μαθαίνει το μοντέλο.

Με την ενσωμάτωση του KoLeo, η συνολική συνάρτηση απώλειας που βελτιστοποιείται κατά την προεκπαίδευση του DINOv2 συνδυάζει τους τρεις επιμέρους όρους που παρουσιάστηκαν:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + \lambda_{\text{KoLeo}}\mathcal{L}_{\text{KoLeo}}, \tag{3.58}$$

όπου λ_{KoLeo} είναι ένας συντελεστής στάθμισης, τυπικά πολύ μικρότερος της μονάδας. Το DINO και το iBOT συμμετέχουν με πλήρες βάρος, καθώς αποτελούν τους δύο βασικούς εκπαιδευτικούς στόχους (σε επίπεδο εικόνας και patch αντίστοιχα), ενώ το KoLeo συμμετέχει με πολύ μικρότερο βάρος, καθώς ο ρόλος του είναι επικουρικός: δεν παρέχει εκπαιδευτικό στόχο για το «τι είναι» μια εικόνα, απλώς αποτρέπει τη συγκέντρωση των αναπαραστάσεων, χωρίς να επισκιάζει τους δύο κύριους στόχους.

3.6.5 Sinkhorn--Knopp Normalization

Οι K διαστάσεις της εξόδου της κεφαλής του teacher παραμένουν οι ίδιες με αυτές της Ενότητας 3.5.2· στο πλαίσιο του SwAV ερμηνεύονται απλώς γεωμετρικά, ως K εκπαιδεύσιμα πρωτότυπα (*prototypes*), όπου κάθε logit $g_{\theta_t}(\mathbf{x})^{(k)}$ εκφράζει την ομοιότητα της αναπαράστασης της εικόνας με το πρωτότυπο k. Έστω λοιπόν ένας πίνακας ομοιοτήτων (logits) $\mathbf{S} \in \mathbb{R}^{K\times B}$ μεταξύ των K πρωτοτύπων του teacher και των B εξόδων του στο τρέχον batch. Ο αλγόριθμος αρχικοποιεί τον πίνακα

$$\mathbf{Q}^{(0)} = \exp(\mathbf{S}/\varepsilon), \tag{3.59}$$

όπου ε είναι μία παράμετρος θερμοκρασίας, και στη συνέχεια εφαρμόζει εναλλάξ κανονικοποίηση γραμμών και στηλών για έναν μικρό, σταθερό αριθμό επαναλήψεων T:

$$\mathbf{Q}^{(t)}_{k,\cdot} \leftarrow \frac{1}{K}\cdot\frac{\mathbf{Q}^{(t-1)}_{k,\cdot}}{\sum_j \mathbf{Q}^{(t-1)}_{k,j}}, \qquad \mathbf{Q}^{(t)}_{\cdot,i} \leftarrow \frac{1}{B}\cdot\frac{\mathbf{Q}^{(t)}_{\cdot,i}}{\sum_k \mathbf{Q}^{(t)}_{k,i}}, \qquad t = 1,\dots,T. \tag{3.60}$$

Οι δύο κανονικοποιήσεις αντιμάχονται μεταξύ τους -- η ικανοποίηση της μίας διαταράσσει ελαφρώς την άλλη -- και για τον λόγο αυτό εφαρμόζονται εναλλάξ, επαναλαμβανόμενα, μέχρι να προσεγγιστεί μια αμοιβαία ισορροπία. Η διαδικασία αυτή αποτελεί την κλασική επαναληπτική λύση ενός προβλήματος ισορροπημένης μεταφοράς μάζας (*balanced optimal transport*) με εντροπική κανονικοποίηση [94].

Η πρώτη κανονικοποίηση εξασφαλίζει ότι κάθε prototype k λαμβάνει ακριβώς ίση συνολική μάζα αντιστοίχισης $1/K$ μέσα στο batch, αποτρέποντας τη συστηματική κυριαρχία συγκεκριμένων prototypes -- τον ίδιο ρόλο που έπαιζε το centering στο αρχικό DINO. Η δεύτερη κανονικοποίηση εξασφαλίζει αντίστοιχα ότι κάθε δείγμα i συνεισφέρει ακριβώς συνολική μάζα $1/B$ στο σύνολο των prototypes, διατηρώντας έτσι σταθερή τη συνολική μάζα αντιστοίχισης σε κάθε βήμα και επιτρέποντας στον αλγόριθμο να συγκλίνει ακόμη και όταν $K \neq B$. Μετά τις T επαναλήψεις, ο πίνακας επαναβαθμονομείται ($\mathbf{Q}^{(T)} \leftarrow B\cdot\mathbf{Q}^{(T)}$) ώστε κάθε στήλη να αθροίζει εκ νέου στη μονάδα, δηλαδή να αποτελεί έγκυρη κατανομή πιθανότητας του δείγματος i στα K prototypes, και το αποτέλεσμα χρησιμοποιείται ως ο εκπαιδευτικός στόχος του teacher, αναλαμβάνοντας τον ρόλο που έπαιζε η κατανομή P_t στο αρχικό DINO (Ενότητα 3.5.2).

Σε αντίθεση με το centering, το οποίο ενημερώνεται σταδιακά ως κινητός μέσος κατά τη διάρκεια της εκπαίδευσης, η κανονικοποίηση Sinkhorn--Knopp υπολογίζεται εξ ολοκλήρου εντός κάθε batch ξεχωριστά, χωρίς εξάρτηση από προηγούμενα batches [19, 94]. Η αποτελεσματικότητα αυτής της ισορροπίας εξαρτάται άμεσα από το μέγεθος του batch σε σχέση με τον αριθμό K των prototypes: όσο μικρότερο είναι το batch, τόσο λιγότερο ουσιαστική είναι η κατανομή της μάζας αντιστοίχισης μεταξύ τόσων πολλών prototypes.

3.6.6 Register Tokens

Τα *register tokens* αποτελούν μεταγενέστερη επέκταση των Vision Transformers και δεν περιλαμβάνονται στην αρχική διατύπωση του DINOv2 [19, 98]. Οι Darcet et al. παρατήρησαν ότι σε επαρκώς μεγάλα και καλά εκπαιδευμένα Vision Transformer μοντέλα, ορισμένα patch tokens αποκτούν ασυνήθιστα μεγάλη νόρμα (*high-norm tokens*), ιδιαίτερα σε περιοχές της εικόνας με περιορισμένη τοπική πληροφορία. Τα tokens αυτά φαίνεται να αξιοποιούνται για την αποθήκευση και επεξεργασία μη τοπικής πληροφορίας, αντί να αναπαριστούν αποκλειστικά το περιεχόμενο της αντίστοιχης χωρικής περιοχής. Η συμπεριφορά αυτή μπορεί να δημιουργήσει ανεπιθύμητα artifacts στους χάρτες χαρακτηριστικών και προσοχής (*feature and attention maps*) [98].

Για την αντιμετώπιση του φαινομένου, προτείνεται η προσθήκη R εκπαιδεύσιμων register tokens, τα οποία δεν αντιστοιχούν σε συγκεκριμένες χωρικές περιοχές της εικόνας. Σε έναν Vision Transformer με N patch tokens, η ακολουθία εισόδου μπορεί να εκφραστεί ως

$$\mathbf{Z}_0 = [\mathbf{z}_{\text{CLS}}; \mathbf{r}_1, \ldots, \mathbf{r}_R; \mathbf{z}_{p,1}, \ldots, \mathbf{z}_{p,N}], \tag{3.61}$$

όπου $\mathbf{z}_{\text{CLS}}$ είναι το class token, $\mathbf{r}_1, \ldots, \mathbf{r}_R$ τα register tokens και $\mathbf{z}_{p,1}, \ldots, \mathbf{z}_{p,N}$ οι αναπαραστάσεις των επιμέρους patches.

Τα register tokens συμμετέχουν κανονικά στον μηχανισμό self-attention, επιτρέποντας στο μοντέλο να αξιοποιεί πρόσθετες εκπαιδεύσιμες θέσεις για την επεξεργασία και τη συγκέντρωση πληροφορίας. Με αυτόν τον τρόπο μειώνεται η ανάγκη χρήσης πραγματικών patch tokens για λειτουργίες που δεν σχετίζονται άμεσα με το τοπικό οπτικό περιεχόμενο. Η προσθήκη τους περιορίζει την εμφάνιση high-norm artifacts και οδηγεί σε ομαλότερους χάρτες χαρακτηριστικών και προσοχής [98].

Παρότι συμμετέχουν στους υπολογισμούς του Transformer, τα register tokens δεν αντιμετωπίζονται ως χωρικές αναπαραστάσεις της εικόνας, καθώς δεν αντιστοιχούν σε συγκεκριμένα patches. Επίσης, οι βασικοί εκπαιδευτικοί στόχοι DINO και iBOT εξακολουθούν να εφαρμόζονται στις αντίστοιχες καθολικές και patch-level αναπαραστάσεις, χωρίς να ορίζονται ξεχωριστοί στόχοι πρόβλεψης για τα register tokens [98].

Στο πλαίσιο αυτής της επέκτασης έχουν διατεθεί εκδόσεις του DINOv2 με τέσσερα register tokens, παράλληλα με τις αντίστοιχες εκδόσεις χωρίς registers. Η διάκριση αυτή είναι σημαντική για την παρούσα εργασία, καθώς στις συγκρίσεις μεταξύ generic-pretrained και domain-adapted DINOv2 μοντέλων διατηρείται η ίδια αρχιτεκτονική ως προς την παρουσία και τον αριθμό των register tokens. Με αυτόν τον τρόπο, οι διαφορές στην απόδοση μπορούν να εξεταστούν χωρίς να συγχέονται με αλλαγές στη συγκεκριμένη αρχιτεκτονική επιλογή. Οι ακριβείς εκδόσεις των μοντέλων και οι αντίστοιχες ρυθμίσεις παρουσιάζονται στο κεφάλαιο της μεθοδολογίας.

3.6.7 DINO έναντι DINOv2

Το DINOv2 διατηρεί τη βασική αρχιτεκτονική teacher--student και τον μηχανισμό αυτοεπιβλεπόμενης μάθησης του DINO, αλλά εισάγει σημαντικές επεκτάσεις ως προς τα δεδομένα προεκπαίδευσης, τους εκπαιδευτικούς στόχους και την αποδοτικότητα της διαδικασίας εκπαίδευσης [18, 19]. Οι βασικές διαφορές των δύο μεθόδων συνοψίζονται στον Πίνακα 3.1.

Πίνακας 3.1: Σύγκριση των βασικών χαρακτηριστικών των DINO και DINOv2.

Χαρακτηριστικό	**DINO**	**DINOv2**
Βασικός μηχανισμός	Teacher--student self-distillation	Teacher--student self-distillation
Δεδομένα προεκπαίδευσης	Κυρίως ImageNet-1k (∼1,28M)	LVD-142M (∼142M)
Επιμέλεια δεδομένων μεγάλης κλίμακας	Δεν αποτελεί βασικό στοιχείο της μεθόδου	Αυτοματοποιημένη διαδικασία data curation
Image-level objective	DINO self-distillation	DINO self-distillation
Patch-level objective	Δεν περιλαμβάνεται	iBOT masked image modeling
Regularization αναπαραστάσεων	Δεν περιλαμβάνει KoLeo	KoLeo regularization
Ενημέρωση teacher	EMA των παραμέτρων του student	EMA των παραμέτρων του student
Κανονικοποίηση teacher targets	Centering και sharpening	Sinkhorn--Knopp assignments
Κλιμάκωση εκπαίδευσης	Αρχική διαδικασία εκπαίδευσης DINO	Βελτιστοποιημένη διαδικασία για μεγαλύτερα μοντέλα και σύνολα δεδομένων

Τα register tokens δεν αποτελούν εγγενή διαφορά μεταξύ των αρχικών DINO και DINOv2, καθώς εισήχθησαν μεταγενέστερα και ενσωματώθηκαν σε ξεχωριστές εκδόσεις DINOv2 με registers, όπως παρουσιάστηκε στην Ενότητα 3.6.6 [98].

Μία πρακτική συνέπεια της αλλαγής στην κανονικοποίηση των teacher targets είναι η αυξημένη ευαισθησία του DINOv2 στο μέγεθος του batch, σε σχέση με το αρχικό DINO: το centering του DINO ενημερώνεται σταδιακά ως κινητός μέσος σε πολλά διαδοχικά batches, ώστε και μικρότερα batches να συνεισφέρουν αθροιστικά σε μια σταθερή εκτίμηση· αντίθετα, η κανονικοποίηση Sinkhorn--Knopp του DINOv2 υπολογίζεται αποκλειστικά εντός του τρέχοντος batch (Ενότητα 3.6.5), χωρίς καμία μνήμη από προηγούμενα batches, καθιστώντας την αποτελεσματικότητά της άμεσα εξαρτημένη από το μέγεθος του εκάστοτε batch σε σχέση με τον αριθμό των prototypes. Το στοιχείο αυτό αποκτά ιδιαίτερη πρακτική σημασία στο πλαίσιο της παρούσας εργασίας, όπου οι διαθέσιμοι υπολογιστικοί πόροι περιορίζουν σημαντικά το εφικτό μέγεθος batch.

Η σύγκριση των δύο μεθόδων είναι ιδιαίτερα σημαντική για την παρούσα εργασία, καθώς η εφαρμογή domain-specific continued self-supervised pretraining σε backbones των οικογενειών DINO και DINOv2 επιτρέπει τη διερεύνηση της επίδρασης της προσαρμογής σε μη επισημασμένες εικόνες γαστρεντερικής ενδοσκόπησης. Με αυτόν

τον τρόπο εξετάζεται κατά πόσο τα οφέλη της πρόσθετης προεκπαίδευσης εμφανίζονται σε διαφορετικές εκδόσεις της οικογένειας DINO και όχι αποκλειστικά σε μία συγκεκριμένη αρχιτεκτονική.

3.7 Foundation Models και Domain-Specific Continued Pretraining

3.7.1 Foundation Models στην Υπολογιστική Όραση

Ο όρος *foundation model* περιγράφει μοντέλα που προεκπαιδεύονται σε δεδομένα μεγάλης κλίμακας και μπορούν στη συνέχεια να προσαρμοστούν ή να επαναχρησιμοποιηθούν σε ένα ευρύ φάσμα downstream εργασιών [49]. Σε αντίθεση με μοντέλα που εκπαιδεύονται εξαρχής για ένα συγκεκριμένο πρόβλημα, τα foundation models επιδιώκουν την εκμάθηση γενικών αναπαραστάσεων, οι οποίες μπορούν να αποτελέσουν κοινή βάση για διαφορετικές εφαρμογές.

Στην υπολογιστική όραση, η βασική αυτή ιδέα εκφράζεται μέσω της ήδη εισαχθείσας σχέσης $\mathbf{h} = f_\theta(\mathbf{x})$ (Ενότητα 3.1.1), όπου ένας προεκπαιδευμένος οπτικός κωδικοποιητής (*visual encoder*) f_θ παράγει μία οπτική αναπαράσταση $\mathbf{h}$ από την εικόνα εισόδου $\mathbf{x}$, αξιοποιήσιμη σε διαφορετικές downstream εργασίες μέσω στρατηγικών όπως η εξαγωγή χαρακτηριστικών με παγωμένο backbone (*frozen feature extraction*), το linear probing και το fine-tuning (Ενότητα 3.3).

Τα visual foundation models διαφέρουν ως προς τα δεδομένα και το εκπαιδευτικό σήμα (*learning signal*) που χρησιμοποιούν. Για παράδειγμα, το CLIP μαθαίνει κοινές αναπαραστάσεις εικόνας και κειμένου από ζεύγη image--text μεγάλης κλίμακας [99], ενώ το Segment Anything Model (SAM) αποτελεί foundation model προσανατολισμένο στη γενικεύσιμη κατάτμηση εικόνων μέσω prompts (*promptable segmentation*) [100]. Επομένως, ο όρος foundation model δεν περιγράφει μία συγκεκριμένη αρχιτεκτονική ή εκπαιδευτικό στόχο, αλλά ένα γενικότερο πρότυπο προεκπαίδευσης μεγάλης κλίμακας και επαναχρησιμοποίησης μοντέλων σε διαφορετικές εφαρμογές.

Στην κατηγορία των γενικού σκοπού οπτικών μοντέλων εντάσσεται και το DINOv2, το οποίο έχει σχεδιαστεί για την εκμάθηση μεταφέρσιμων οπτικών αναπαραστάσεων μέσω αυτοεπιβλεπόμενης προεκπαίδευσης μεγάλης κλίμακας [19]. Οι αναπαραστάσεις του μπορούν να αξιοποιηθούν σε εργασίες όπως η ταξινόμηση εικόνων (*image classification*), η σημασιολογική τμηματοποίηση (*semantic segmentation*) και η εκτίμηση βάθους (*depth estimation*).

Ωστόσο, η γενικευτική ικανότητα ενός foundation model δεν συνεπάγεται ότι οι αναπαραστάσεις του είναι εξίσου κατάλληλες για κάθε πεδίο εφαρμογής. Όταν τα δεδομένα μιας νέας εργασίας παρουσιάζουν σημαντικές διαφορές από εκείνα της αρχικής προεκπαίδευσης, η περαιτέρω προσαρμογή του μοντέλου μπορεί να συμβάλει στην αποτελεσματικότερη αξιοποίηση των χαρακτηριστικών του. Το ζήτημα αυτό είναι ιδιαίτερα σημαντικό σε εξειδικευμένα πεδία, όπως η ιατρική απεικόνιση, και αποτελεί το αντικείμενο της επόμενης υποενότητας.

3.7.2 Domain-Specific Adaptation

Η αποτελεσματικότητα της μεταφοράς ενός προεκπαιδευμένου μοντέλου εξαρτάται, μεταξύ άλλων, από τη σχέση μεταξύ των δεδομένων προεκπαίδευσης και της

νέας εφαρμογής, καθώς οι αναπαραστάσεις τείνουν να γίνονται περισσότερο εξειδικευμένες στα βαθύτερα επίπεδα ενός δικτύου [42]. Όταν οι κατανομές των δεδομένων διαφέρουν, προκύπτει το φαινόμενο της μετατόπισης πεδίου (*domain shift*) ή της απόκλισης μεταξύ πεδίων (*domain gap*) [77, 101]. Αν P_{source} και P_{target} συμβολίζουν τις κατανομές του πεδίου προέλευσης (*source domain*) και του πεδίου-στόχου (*target domain*), αντίστοιχα, τότε μία γενική μορφή της διαφοράς αυτής είναι:

$$P_{\text{source}}(\mathbf{x}, y) \neq P_{\text{target}}(\mathbf{x}, y). \tag{3.62}$$

όπου $\mathbf{x}$ είναι η εικόνα εισόδου και y η αντίστοιχη ετικέτα. Στην περίπτωση της αυτοεπιβλεπόμενης προεκπαίδευσης, όπου δεν απαιτούνται ανθρώπινες ετικέτες για τον σχηματισμό του εκπαιδευτικού σήματος, ιδιαίτερο ενδιαφέρον παρουσιάζει η διαφορά στην κατανομή των ίδιων των εικόνων:

$$P_{\text{source}}(\mathbf{x}) \neq P_{\text{target}}(\mathbf{x}). \tag{3.63}$$

Η γαστρεντερική ενδοσκόπηση αποτελεί χαρακτηριστικό παράδειγμα εξειδικευμένου οπτικού πεδίου. Οι ενδοσκοπικές εικόνες περιλαμβάνουν ιδιαίτερα χαρακτηριστικά, όπως βλεννογονικές υφές, αγγειακά πρότυπα, λεπτές ανατομικές διαφοροποιήσεις, μεταβολές φωτισμού και τεχνουργήματα (*artifacts*) της διαδικασίας απεικόνισης. Επομένως, ένα μοντέλο προεκπαιδευμένο σε γενικού σκοπού οπτικά δεδομένα μπορεί να διαθέτει ισχυρές και μεταφέρσιμες αναπαραστάσεις, χωρίς αυτές να είναι απαραίτητα βέλτιστα προσαρμοσμένες στο ενδοσκοπικό πεδίο.

Η προσαρμογή σε εξειδικευμένο πεδίο (*domain-specific adaptation*) επιδιώκει να περιορίσει αυτή την απόκλιση, αξιοποιώντας ένα ήδη προεκπαιδευμένο μοντέλο ως σημείο εκκίνησης και προσαρμόζοντας τις αναπαραστάσεις του στα χαρακτηριστικά του πεδίου-στόχου. Σε αντίθεση με την εκπαίδευση ενός νέου μοντέλου από τυχαία αρχικοποίηση, η προσέγγιση αυτή αξιοποιεί τις ήδη αποκτηθείσες γενικές οπτικές αναπαραστάσεις και επιδιώκει να τις εμπλουτίσει με χαρακτηριστικά περισσότερο σχετικά με τη νέα εφαρμογή.

Η διαδικασία αυτή συνεπάγεται έναν πιθανό συμβιβασμό (*trade-off*) μεταξύ γενικότητας (*generality*) και εξειδίκευσης (*specialization*). Η ανεπαρκής προσαρμογή μπορεί να διατηρήσει αναπαραστάσεις περισσότερο ευθυγραμμισμένες με το αρχικό πεδίο προεκπαίδευσης, ενώ η υπερβολική εξειδίκευση ενδέχεται να περιορίσει μέρος της αρχικής γενικευτικής τους ικανότητας.

Η προσαρμογή μπορεί να πραγματοποιηθεί μέσω επιβλεπόμενου fine-tuning, όταν υπάρχουν επισημασμένα δεδομένα του πεδίου-στόχου, ή μέσω ενός επιπλέον σταδίου αυτοεπιβλεπόμενης προεκπαίδευσης, αξιοποιώντας μη επισημασμένα δεδομένα του ίδιου πεδίου. Η δεύτερη στρατηγική αποτελεί το *continued self-supervised pretraining*, το οποίο εξετάζεται αναλυτικά στην επόμενη υποενότητα.

3.7.3 Continued Self-Supervised Pretraining

Στο *continued self-supervised pretraining*, η εκπαίδευση ξεκινά από ένα ήδη προεκπαιδευμένο μοντέλο γενικού σκοπού (*generic-pretrained model*) και συνεχίζεται σε μη επισημασμένα δεδομένα ενός εξειδικευμένου πεδίου-στόχου (*target domain*). Η προσέγγιση αυτή σχετίζεται με το *domain-adaptive pretraining*, το οποίο έχει μελετηθεί συστηματικά στην επεξεργασία φυσικής γλώσσας, όπου ένα πρόσθετο στάδιο προεκπαίδευσης σε μη επισημασμένα δεδομένα του πεδίου-στόχου έχει οδηγήσει σε βελτιώσεις σε downstream εργασίες [102].

Έστω θ_0 οι παράμετροι ενός γενικά προεκπαιδευμένου οπτικού κωδικοποιητή (*visual encoder*) και $\mathcal{D}_{\text{domain}}$ ένα σύνολο μη επισημασμένων εικόνων από το πεδίο-στόχο. Σε υψηλό επίπεδο, η διαδικασία μπορεί να εκφραστεί ως:

$$\theta_{\text{domain}} = \arg\min_{\theta} \mathbb{E}_{\mathbf{x}\sim\mathcal{D}_{\text{domain}}} \left[\mathcal{L}_{\text{SSL}}(\mathbf{x};\theta)\right], \qquad \theta^{(0)} = \theta_0. \tag{3.64}$$

όπου $\mathcal{L}_{\text{SSL}}$ συμβολίζει τον αυτοεπιβλεπόμενο εκπαιδευτικό στόχο και $\theta^{(0)} = \theta_0$ δηλώνει ότι η βελτιστοποίηση ξεκινά από τις παραμέτρους του αρχικού προεκπαιδευμένου μοντέλου. Η παραπάνω έκφραση αποτελεί συνοπτική μαθηματική περιγραφή και όχι τον πλήρη ορισμό του εκάστοτε εκπαιδευτικού στόχου. Στις μεθόδους DINO και DINOv2, για παράδειγμα, η αυτοεπιβλεπόμενη απώλεια βασίζεται σε πολλαπλές επαυξημένες όψεις (*augmented views*) και στην αντιστοίχιση προβλέψεων teacher--student, όπως αναλύθηκε στις προηγούμενες ενότητες.

Η βασική διαφορά από την αυτοεπιβλεπόμενη προεκπαίδευση από τυχαία αρχικοποίηση είναι ότι το μοντέλο διαθέτει ήδη έναν διαμορφωμένο χώρο οπτικών αναπαραστάσεων, ο οποίος προέκυψε από την αρχική προεκπαίδευση. Το πρόσθετο στάδιο εκπαίδευσης επιδιώκει να προσαρμόσει αυτές τις αναπαραστάσεις στα ιδιαίτερα χαρακτηριστικά του νέου πεδίου, χωρίς να απαιτεί ανθρώπινες ετικέτες.

Η συνολική διαδικασία μπορεί να συνοψιστεί ως εξής:

Generic Pretraining $\longrightarrow$ *Domain-Specific Continued SSL* $\longrightarrow$ *Downstream Adaptation*

Η βασική υπόθεση είναι ότι η αρχική προεκπαίδευση παρέχει ένα ισχυρό σημείο εκκίνησης, ενώ η πρόσθετη αυτοεπιβλεπόμενη εκπαίδευση μπορεί να ενισχύσει την αναπαράσταση οπτικών μοτίβων που χαρακτηρίζουν το πεδίο-στόχο. Ωστόσο, η αποτελεσματικότητα της διαδικασίας δεν είναι εγγυημένη και εξαρτάται από παράγοντες όπως η ποσότητα και η ποικιλία των διαθέσιμων δεδομένων, η απόσταση μεταξύ των πεδίων προέλευσης και στόχου, καθώς και οι επιλογές της διαδικασίας εκπαίδευσης. Επομένως, η επίδραση του continued pretraining αποτελεί εμπειρικό ερώτημα που πρέπει να εξετάζεται μέσω σύγκρισης με το αντίστοιχο generic-pretrained μοντέλο.

Η αξιολόγηση μπορεί να πραγματοποιηθεί με τα συμπληρωματικά downstream πρωτόκολλα που παρουσιάστηκαν στην Ενότητα 3.3 -- frozen feature extraction και fine-tuning -- επιτρέποντας αντίστοιχα την αξιολόγηση της διακριτικής ικανότητας των ήδη αποκτημένων αναπαραστάσεων, ή το κατά πόσο αυτές αποτελούν αποτελεσματική αρχικοποίηση για περαιτέρω επιβλεπόμενη προσαρμογή.

Στην παρούσα εργασία, η παραπάνω στρατηγική εφαρμόζεται σε προεκπαιδευμένα μοντέλα των οικογενειών DINO και DINOv2. Ως αρχικά σημεία εκκίνησης χρησιμοποιούνται generic-pretrained checkpoints, ενώ η πρόσθετη αυτοεπιβλεπόμενη προεκπαίδευση πραγματοποιείται σε μη επισημασμένες εικόνες γαστρεντερικής ενδοσκόπησης από το σύνολο HyperKvasir [20]. Στη συνέχεια, τα generic-pretrained και τα αντίστοιχα domain-adapted μοντέλα αξιολογούνται στην ταξινόμηση ανατομικής θέσης του συνόλου GastroHUN, μέσω πρωτοκόλλων frozen backbone και fine-tuning.

Με αυτόν τον τρόπο διερευνάται κατά πόσο η πρόσθετη αυτοεπιβλεπόμενη προεκπαίδευση σε εξειδικευμένα δεδομένα μπορεί να βελτιώσει την καταλληλότητα των οπτικών αναπαραστάσεων για την αναγνώριση λεπτών ανατομικών διαφοροποιήσεων. Οι ακριβείς αρχιτεκτονικές, τα σύνολα δεδομένων, οι ρυθμίσεις εκπαίδευσης και τα πρωτόκολλα αξιολόγησης παρουσιάζονται στο επόμενο κεφάλαιο.

Κεφάλαιο 4: Προτεινόμενη Μεθοδολογία

4.1 Ερευνητικός Σχεδιασμός

Η παρούσα εργασία διερευνά κατά πόσο το domain-specific continued self-supervised pretraining (Ενότητα 3.7.3) μπορεί να βελτιώσει τις οπτικές αναπαραστάσεις προεκπαιδευμένων μοντέλων DINO και DINOv2 για την αναγνώριση ανατομικής θέσης σε εικόνες γαστρεντερικής ενδοσκόπησης.

Ο πειραματικός σχεδιασμός βασίζεται στη σύγκριση δύο κλάδων που ξεκινούν από το ίδιο generic-pretrained checkpoint. Στον πρώτο, οι αρχικές παράμετροι του backbone διατηρούνται ως σημείο αναφοράς (*generic baseline*), ενώ στον δεύτερο εφαρμόζεται πρόσθετο αυτοεπιβλεπόμενο pretraining στο HyperKvasir, χωρίς χρήση ετικετών. Από τα παραγόμενα domain-adapted checkpoints επιλέγεται ένα, βάσει της απόδοσης στο validation set του GastroHUN, σύμφωνα με τη διαδικασία της Ενότητας 4.4.1.

Έστω θ_0 οι παράμετροι του αρχικού generic-pretrained backbone και θ' οι παράμετροι του επιλεγμένου domain-adapted checkpoint. Η συνολική διαδικασία συνοψίζεται ως εξής:

$$\text{Generic:} \quad \theta_0 \longrightarrow \text{Downstream Evaluation}$$

$$\text{Domain-adapted:} \quad \theta_0 \xrightarrow{\text{Continued SSL}} \theta' \longrightarrow \text{Downstream Evaluation}$$

Τα δύο checkpoints αξιολογούνται στα ίδια patient-level splits του GastroHUN, με κοινό πρωτόκολλο εκπαίδευσης και δύο στρατηγικές: frozen linear probing και partial fine-tuning (Ενότητα 4.4.2). Το test set χρησιμοποιείται αποκλειστικά για την τελική αξιολόγηση, χωρίς να συμμετέχει στην επιλογή checkpoint.

Για τη διερεύνηση της αποτελεσματικότητας και της εφαρμοσιμότητας της προσέγγισης σχεδιάστηκαν τρία συμπληρωματικά πειράματα:

1. **DINOv2 ViT-S:** διερεύνηση της επίδρασης του continued pretraining σε ένα generic-pretrained DINOv2 backbone [19].

2. **DINO ViT-S:** εξέταση της εφαρμοσιμότητας της προσέγγισης στην αρχική μέθοδο DINO [18].

3. **DINOv2 ViT-B:** διερεύνηση της αποτελεσματικότητας της ίδιας στρατηγικής σε μεγαλύτερο DINOv2 backbone.

Σε κάθε πείραμα, η σύγκριση πραγματοποιείται μεταξύ checkpoints της ίδιας αρχιτεκτονικής, ώστε η βασική ελεγχόμενη διαφοροποίηση να είναι η εφαρμογή ή μη του πρόσθετου continued pretraining. Τα τρία πειράματα επιτρέπουν επιπλέον τη διερεύνηση διαφορών μεταξύ DINO και DINOv2, καθώς και μεταξύ διαφορετικών μεγεθών backbone.

Το κεντρικό ερευνητικό ερώτημα διατυπώνεται ως εξής:

> *Μπορεί το domain-specific continued self-supervised pretraining σε μη επισημασμένες εικόνες γαστρεντερικής ενδοσκόπησης να βελτιώσει τις αναπαραστάσεις generic-pretrained μοντέλων της οικογένειας DINO για το downstream task της αναγνώρισης ανατομικής θέσης, και πώς επηρεάζεται η αποτελεσματικότητά του από τη μέθοδο αυτοεπιβλεπόμενης μάθησης και την κλίμακα του backbone;*

Τα σύνολα δεδομένων, το downstream training protocol, η διαδικασία επιλογής και αξιολόγησης checkpoints και ο αναλυτικός σχεδιασμός των πειραμάτων παρουσιάζονται στις επόμενες ενότητες.

4.2 Σύνολα Δεδομένων και Προετοιμασία

Η πειραματική μεθοδολογία βασίζεται σε δύο διακριτά σύνολα δεδομένων: το HyperKvasir, το οποίο χρησιμοποιείται για το domain-specific continued self-supervised pretraining χωρίς αξιοποίηση ετικετών, και το GastroHUN, το οποίο χρησιμοποιείται για τη downstream εκπαίδευση και αξιολόγηση της αναγνώρισης ανατομικής θέσης.

4.2.1 HyperKvasir: Σύνολο Continued Self-Supervised Pretraining

Το HyperKvasir αποτελεί δημόσια διαθέσιμο σύνολο δεδομένων γαστρεντερικής ενδοσκόπησης, με εικόνες από το ανώτερο και κατώτερο γαστρεντερικό σύστημα. Περιλαμβάνει 110.079 στατικές εικόνες, εκ των οποίων 10.662 επισημασμένες και 99.417 μη επισημασμένες, καθώς και 374 βίντεο [20]. Στην παρούσα εργασία χρησιμοποιήθηκαν αρχικά όλες οι στατικές εικόνες, χωρίς αξιοποίηση των ετικετών τους, ενώ τα βίντεο εξαιρέθηκαν.

Η προετοιμασία του corpus περιλάμβανε καθαρισμό, προεπεξεργασία και αφαίρεση σχεδόν πανομοιότυπων εικόνων. Στο μη επισημασμένο τμήμα εφαρμόστηκε cropping για τον περιορισμό των μαύρων περιθωρίων του ενδοσκοπικού οπτικού πεδίου. Επιπλέον, εντοπίστηκαν στοιχεία διεπαφής, όπως το εικονίδιο *ScopeGuide* και επικαλύψεις κειμένου, τα οποία καταγράφηκαν ως χωρικές περιοχές αποκλεισμού (*exclusion regions*) αντί να αφαιρεθούν από τις αποθηκευμένες εικόνες. Συνολικά καταγράφηκαν 47.727 τέτοιες περιοχές σε περίπου 23.800 εικόνες, ώστε να αποφεύγονται κατά τη δειγματοληψία crops στην εκπαίδευση DINOv2.

Στη συνέχεια απορρίφθηκαν 111 μη αναγνώσιμες, υπερβολικά σκοτεινές ή ανεπαρκείς σε διαστάσεις εικόνες, ενώ οι υπόλοιπες αναπροσαρμόστηκαν ώστε η μικρότερη πλευρά τους να έχει μήκος 256 pixels.

Για τον περιορισμό της πλεονάζουσας πληροφορίας εφαρμόστηκε αφαίρεση σχεδόν διπλότυπων εικόνων (*near-duplicate removal*), με χρήση perceptual hash (*pHash*) 64 bit, απόστασης Hamming ≤ 3 για τον εντοπισμό υποψήφιων διπλοτύπων και Locality-Sensitive Hashing (LSH) για αποδοτική αναζήτηση. Από κάθε ομάδα διατηρήθηκε μία αντιπροσωπευτική εικόνα, με προτεραιότητα στις εικόνες του επισημασμένου τμήματος και, στη συνέχεια, σε κριτήρια ποιότητας. Η διαδικασία αφαίρεσε 1.647 εικόνες, οδηγώντας στο τελικό corpus:

$$110\,079 \longrightarrow 109\,968 \longrightarrow \boxed{108\,321 \text{ εικόνες}}.$$

Το τελικό corpus των 108.321 εικόνων χρησιμοποιήθηκε για το continued self-supervised pretraining των εξεταζόμενων μοντέλων.

4.2.2 GastroHUN: Σύνολο Downstream Αξιολόγησης

Για τη downstream εκπαίδευση και αξιολόγηση χρησιμοποιήθηκε το GastroHUN [21], το οποίο παρουσιάστηκε στην Ενότητα 2.5. Συγκεκριμένα, επιλέχθηκε το επίσημο υποσύνολο *Complete agreement*, που περιλαμβάνει 5.318 εικόνες από 385 ασθενείς, κατανεμημένες σε 23 κατηγορίες: 22 ανατομικές θέσεις του στομάχου και την κατηγορία *OTHERCLASS*.

Χρησιμοποιήθηκαν οι επίσημοι διαχωρισμοί εκπαίδευσης, επικύρωσης και ελέγχου σε επίπεδο ασθενούς (*patient-level splits*), ώστε εικόνες του ίδιου ασθενούς να μην εμφανίζονται σε διαφορετικά υποσύνολα, περιορίζοντας τον κίνδυνο διαρροής πληροφορίας (*data leakage*) λόγω οπτικά παρόμοιων εικόνων από την ίδια εξέταση. Η κατανομή παρουσιάζεται στον Πίνακα 4.1.

Πίνακας 4.1: Κατανομή του υποσυνόλου Complete agreement του GastroHUN ανά ασθενή και εικόνα.

Split	**Ασθενείς**	**Εικόνες**
Training	269	3.722
Validation	58	793
Test	58	803
Σύνολο	**385**	**5.318**

Οι διαχωρισμοί αυτοί διατηρήθηκαν αμετάβλητοι σε όλες τις downstream συγκρίσεις, εξασφαλίζοντας κοινά δεδομένα εκπαίδευσης, επιλογής μοντέλων και τελικής αξιολόγησης.

4.3 Καθορισμός του Downstream Training Protocol

Πριν από τα κύρια πειράματα continued self-supervised pretraining, πραγματοποιήθηκε προκαταρκτική διερεύνηση του downstream training pipeline με generic-pretrained μοντέλα. Η διαδικασία περιλάμβανε αναπαραγωγή και επέκταση του GastroHUN benchmark, αξιολόγηση επιλογών προεπεξεργασίας και βελτιστοποίησης, καθώς και αναζήτηση υπερπαραμέτρων.

4.3.1 Αναπαραγωγή και Επέκταση του GastroHUN Benchmark

Αρχικά πραγματοποιήθηκε αναπαραγωγή του image-classification benchmark του GastroHUN [21], με στόχο τον έλεγχο του downstream pipeline και τη σύγκριση των επιδόσεων Macro-F1 με τις δημοσιευμένες τιμές αναφοράς. Εξετάστηκαν οι 16 αρχιτεκτονικές της αρχικής μελέτης: τέσσερα μοντέλα ConvNeXt, πέντε ResNet, τρία VGG και τέσσερα Vision Transformers. Ακολουθήθηκε το δημοσιευμένο πρωτόκολλο, με χρήση του υποσυνόλου *Complete agreement*, των επίσημων patient-level διαχωρισμών (Ενότητα 4.2.2) και partial fine-tuning με 40% unfrozen layers του backbone.

Ο επίσημος κώδικας του benchmark δεν καθορίζει σταθερό τυχαίο σπόρο (*random seed*) εκπαίδευσης, με αποτέλεσμα κάθε εκτέλεση να οδηγεί σε ελαφρώς διαφορετική αρχικοποίηση και σειρά δειγματοληψίας δεδομένων. Η αναπαραγωγή αντιστοιχεί επιπλέον σε μία μόνο εκτέλεση ανά μοντέλο, χωρίς τη χρήση πολλαπλών seeds.

Στη συνέχεια, το benchmark επεκτάθηκε με οκτώ generic-pretrained self-supervised backbones: DINO ViT-S/8, ViT-S/16, ViT-B/8 και ViT-B/16 [18], καθώς και DINOv2 ViT-S/14, ViT-B/14, ViT-L/14 και ViT-g/14 [19]. Χρησιμοποιήθηκαν αποκλειστικά τα αρχικά pretrained checkpoints, χωρίς domain-specific continued pretraining, επιτρέποντας τη συγκριτική αξιολόγηση των αναπαραστάσεων DINO και DINOv2 στο ίδιο benchmark.

Πέρα από το partial fine-tuning, τα ίδια 24 μοντέλα αξιολογήθηκαν και με πλήρως *frozen* backbone (*linear probing*), όπου εκπαιδεύεται μόνο ο ταξινομητής, ενώ οι παράμετροι του backbone παραμένουν σταθερές. Με αυτόν τον τρόπο εξετάστηκε η γραμμική διαχωρισιμότητα των pretrained αναπαραστάσεων χωρίς προσαρμογή του backbone στο GastroHUN. Τα αναλυτικά αποτελέσματα της αναπαραγωγής (Πίνακας 6.1, Σχήμα 6.1), της επέκτασης (Πίνακας 6.2, Σχήμα 6.2) και της σύγκρισης frozen/fine-tuned (Πίνακας 6.3, Σχήμα 6.3) παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.1.1.

Η σύγκριση μεταξύ frozen και fine-tuned επιδόσεων ανέδειξε διαφορετικά μοτίβα ανά οικογένεια αρχιτεκτονικής, υποδεικνύοντας ότι η κατάταξη των μοντέλων μετά το fine-tuning δεν αντικατοπτρίζει απαραίτητα τη γραμμική διαχωρισιμότητα των αρχικών pretrained αναπαραστάσεων. Η διαφορετική ανταπόκριση των αρχιτεκτονικών στο ίδιο downstream training protocol υποδηλώνει ότι οι επιλογές βελτιστοποίησης ενδέχεται να επηρεάζουν τη σχετική τους απόδοση. Για τον λόγο αυτό, στην επόμενη ενότητα εξετάζεται η επίδραση της κανονικοποίησης και των learning rates στα generic DINO/DINOv2 backbones.

4.3.2 Διερεύνηση Training Configuration

Με αφετηρία τις διαφοροποιήσεις που παρατηρήθηκαν μεταξύ frozen και fine-tuned επιδόσεων στην προηγούμενη ενότητα, διερευνήθηκε η επίδραση των επιλογών προεπεξεργασίας και βελτιστοποίησης στην απόδοση των generic DINO/DINOv2 backbones. Οι δύο παράγοντες εξετάστηκαν σε διακριτές προκαταρκτικές συγκρίσεις: η κανονικοποίηση στα οκτώ generic DINO/DINOv2 backbones και η στρατηγική learning rate στο σύνολο των 24 αρχιτεκτονικών του επεκταμένου benchmark.

Η προεπεξεργασία των εικόνων περιλάμβανε αναπροσαρμογή σε ανάλυση 224×224 pixels με παρεμβολή Lanczos, μετατροπή σε tensors και κανονικοποίηση ανά κανάλι. Η ίδια διαδικασία εφαρμόστηκε στα σύνολα εκπαίδευσης, επικύρωσης και ελέγχου, χωρίς στοχαστικές επαυξήσεις δεδομένων (*stochastic augmentations*).

Αρχικά συγκρίθηκαν δύο στρατηγικές κανονικοποίησης, βάσει των στατιστικών του GastroHUN και του ImageNet:

$$\boldsymbol{\mu}_{\text{GastroHUN}} = [0.5990,\ 0.3664,\ 0.2769],$$
$$\boldsymbol{\sigma}_{\text{GastroHUN}} = [0.2847,\ 0.2190,\ 0.1772],$$

$$\boldsymbol{\mu}_{\text{ImageNet}} = [0.485,\ 0.456,\ 0.406],$$
$$\boldsymbol{\sigma}_{\text{ImageNet}} = [0.229,\ 0.224,\ 0.225].$$

Οι δύο στρατηγικές κανονικοποίησης συγκρίθηκαν στα οκτώ generic DINO/DINOv2 backbones, ενώ η στρατηγική learning rate (ενιαίο learning rate έναντι discriminative learning rates, με τιμές 10^{-5} για το backbone και 7×10^{-4} για το classification head) συγκρίθηκε στο σύνολο των 24 αρχιτεκτονικών του επεκταμένου benchmark. Τα αναλυτικά αποτελέσματα της κανονικοποίησης (Πίνακας 6.4, Σχήμα 6.4) και της στρατηγικής learning rate (Πίνακας 6.5, Σχήμα 6.5) παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.1.2, μαζί με μια συγκεντρωτική κατάταξη με το καλύτερο recipe ανά μοντέλο ως προς τη στρατηγική learning rate (Πίνακας 6.6, Σχήμα 6.6).

Και οι δύο παράγοντες ανέδειξαν σαφή εξάρτηση από τη συγκεκριμένη αρχιτεκτονική και οικογένεια μοντέλου, χωρίς μία ρύθμιση να υπερισχύει ομοιόμορφα. Παρά τις ενδείξεις ότι εναλλακτικές επιλογές θα μπορούσαν να βελτιώσουν περαιτέρω την επίδοση ορισμένων backbones, στα τρία κύρια πειράματα continued pretraining υιοθετήθηκε σταθερό downstream configuration, με κανονικοποίηση βάσει των στατιστικών του GastroHUN και ενιαίο learning rate 7×10^{-4} για το backbone και το classification head. Η κανονικοποίηση GastroHUN διατηρήθηκε ακόμη και στις περιπτώσεις όπου η ImageNet είχε αποδώσει καλύτερα στις προκαταρκτικές δοκιμές, χωρίς να θεωρείται βέλτιστη για κάθε backbone. Αντίστοιχα, δεν υιοθετήθηκαν τα discriminative learning rates, παρά τη βελτίωση που παρουσίασαν στα generic DINOv2 μοντέλα. Οι ίδιες ρυθμίσεις εφαρμόστηκαν στα generic και domain-adapted checkpoints κάθε αρχιτεκτονικής, ώστε η επίδραση του continued pretraining να αξιολογείται υπό κοινές συνθήκες προεπεξεργασίας και βελτιστοποίησης. Η περαιτέρω βελτιστοποίηση των ρυθμίσεων αυτών αποτελεί πιθανή κατεύθυνση μελλοντικής έρευνας.

Η συμπληρωματική αναζήτηση υπερπαραμέτρων παρουσιάζεται στην Ενότητα 4.3.3.

4.3.3 Hyperparameter Search και Τελικό Protocol

Το recipe fine-tuning των 16 αρχικών αρχιτεκτονικών αναφοράς προέρχεται απευθείας από το πρωτότυπο GastroHUN benchmark και δεν αμφισβητήθηκε περαιτέρω. Για τα τέσσερα DINO/DINOv2 backbones που ενσωματώθηκαν σε αυτή την εργασία πέραν των 16 αυτών αρχιτεκτονικών --- DINO ViT-S/16, DINO ViT-B/8, DINOv2 ViT-S/14 και DINOv2 ViT-L/14 --- χρησιμοποιήθηκε το Optuna [103] για τη συστηματική διερεύνηση του αν υπάρχει περιθώριο βελτιστοποίησης πέραν των recipes που εξετάστηκαν χειροκίνητα στην Ενότητα 4.3.2.

Για κάθε backbone πραγματοποιήθηκαν 20 trials, με χρήση του Tree-structured Parzen Estimator (TPE) για τη δειγματοληψία υπερπαραμέτρων και του MedianPruner για την πρόωρη διακοπή μη υποσχόμενων δοκιμών. Ο χώρος αναζήτησης περιλάμβανε το learning rate του classification head στο διάστημα $[10^{-4},\ 3 \times 10^{-3}]$ και τον λόγο learning rate backbone προς head στο διάστημα $[10^{-3},\ 1]$. Για τον περιορισμό του υπολογιστικού κόστους προηγήθηκε αρχική εκπαίδευση 10 epochs ανά backbone, με επαναχρησιμοποίηση του αντίστοιχου checkpoint στα trials. Οι επιλεγμένες διαμορφώσεις αξιολογήθηκαν στη συνέχεια με εκπαίδευση έως 100 epochs και early stopping με patience 10.

Το DINOv2 ViT-g/14 εξαιρέθηκε από την πλήρη αναζήτηση λόγω του υψηλού υπολογιστικού κόστους του, το οποίο εκτιμήθηκε σε περίπου 65 φορές εκείνο του οικονομικότερου εξεταζόμενου μοντέλου. Για το συγκεκριμένο backbone χρησιμοποιήθηκε log-linear παρεμβολή του λόγου learning rate backbone/head από μικρότερα DINOv2 μοντέλα, αντί ανεξάρτητης αναζήτησης Optuna.

Οι διαμορφώσεις που ανέδειξε η αναζήτηση επιβεβαιώθηκαν με πλήρη εκπαίδευση (100 epochs, patience 10) και αξιολόγηση στο test set, με την ίδια bootstrap μεθοδολογία του υπόλοιπου κεφαλαίου. Τα αναλυτικά αποτελέσματα (Πίνακας 6.7, Σχήμα 6.7) παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.1.3.

Η αναζήτηση αυτή αποτέλεσε ξεχωριστή διερεύνηση πέραν των τριών κύριων πειραμάτων continued pretraining και δεν χρησιμοποιήθηκε για εξατομικευμένη βελτιστοποίησή τους --- πέραν της διαφορετικής κλίμακας (DINOv2 ViT-B/14 δεν συμπεριλήφθηκε καν στην αναζήτηση), τα εξεταζόμενα backbones αντιστοιχούν στις plain εκδόσεις χωρίς register tokens, ενώ τα τρία κύρια πειράματα χρησιμοποίησαν τις αντίστοιχες `+reg4` παραλλαγές. Στα τελευταία εφαρμόστηκε σταθερό downstream protocol, με τις ρυθμίσεις του Πίνακα 4.2, κοινές για τα generic και domain-adapted checkpoints της ίδιας αρχιτεκτονικής. Η αξιοποίηση του per-architecture βελτιστοποιημένου recipe που ανέδειξε το Optuna για το DINOv2 αποτελεί πιθανή κατεύθυνση μελλοντικής έρευνας.

Πίνακας 4.2: Βασικές ρυθμίσεις του downstream training protocol στα τρία κύρια πειράματα continued pretraining.

Παράμετρος	**Τελική ρύθμιση**
Ανάλυση εισόδου	224×224 pixels
Μέθοδος αναπροσαρμογής	Lanczos
Κανονικοποίηση	GastroHUN statistics
Stochastic augmentations	Δεν εφαρμόστηκαν
Learning rate backbone	7×10^{-4}
Learning rate classification head	7×10^{-4}
Partial fine-tuning	Τελευταίο 40% των transformer blocks
Frozen evaluation	Πλήρως frozen backbone

Οι παραπάνω ρυθμίσεις διατηρήθηκαν σταθερές εντός κάθε ζεύγους generic και domain-adapted checkpoints, ώστε οι διαφορές απόδοσης να εξετάζονται υπό κοινές συνθήκες downstream εκπαίδευσης.

4.4 Πρωτόκολλο Επιλογής και Downstream Αξιολόγησης

Η επιλογή των domain-adapted checkpoints και η τελική αξιολόγησή τους ακολουθούν κοινό πρωτόκολλο στα τρία κύρια πειράματα. Η διαδικασία διαχωρίζει την επιλογή μοντέλου, η οποία βασίζεται αποκλειστικά στο validation set, από την τελική αποτίμηση της απόδοσης στο test set.

4.4.1 Επιλογή Domain-Adapted Checkpoint

Κατά το continued self-supervised pretraining αποθηκεύονται περιοδικά checkpoints του teacher backbone, του οποίου οι παράμετροι ενημερώνονται μέσω Exponential Moving Average (EMA) των παραμέτρων του student. Η επιλογή του καταλληλότερου domain-adapted checkpoint πραγματοποιείται σε δύο στάδια, βάσει της downstream απόδοσης στο validation set του GastroHUN.

Στο πρώτο στάδιο εφαρμόζεται frozen linear probing σε κάθε υποψήφιο checkpoint. Οι αναπαραστάσεις των εικόνων εξάγονται και αποθηκεύονται με το backbone σε frozen κατάσταση και χρησιμοποιούνται για την εκπαίδευση ενός γραμμικού ταξινομητή. Η ίδια διαδικασία εφαρμόζεται στο αρχικό generic checkpoint ως σημείο αναφοράς. Τα domain-adapted checkpoints κατατάσσονται βάσει του validation Macro-F1 και επιλέγονται τα τρία καλύτερα.

Το πρώτο στάδιο λειτουργεί ως υπολογιστικά οικονομικό φίλτρο και όχι ως οριστικό κριτήριο επιλογής, καθώς η κατάταξη βάσει frozen linear probing δεν ταυτίζεται απαραίτητα με την κατάταξη που προκύπτει μετά από supervised προσαρμογή του backbone. Για τον λόγο αυτό, στο δεύτερο στάδιο τα τρία επιλεγμένα checkpoints αξιολογούνται τόσο με frozen backbone όσο και με partial fine-tuning, χρησιμοποιώντας μία εκτέλεση ανά στρατηγική χωρίς ρητό καθορισμό τυχαίας σποράς. Η τελική επιλογή βασίζεται στο άθροισμα των δύο validation Macro-F1 scores (ο ακριβής ορισμός της μετρικής δίνεται στην Ενότητα 4.4.3):

$$S_{\text{val}} = F_{1,\text{val}}^{\text{frozen}} + F_{1,\text{val}}^{\text{fine-tuned}}.$$

Το κριτήριο αυτό συνεκτιμά τη γραμμική διαχωρισιμότητα των frozen αναπαραστάσεων και την απόδοση μετά από supervised προσαρμογή, καθώς η κατάταξη των checkpoints στις δύο στρατηγικές δεν είναι απαραίτητα ίδια. Το test set δεν χρησιμοποιείται σε κανένα στάδιο της επιλογής.

4.4.2 Frozen και Fine-Tuned Evaluation

Η downstream αξιολόγηση πραγματοποιείται με δύο συμπληρωματικές στρατηγικές, frozen linear probing και partial fine-tuning, όπως παρουσιάστηκαν θεωρητικά στις Ενότητες 3.3.2 και 3.3.3. Και οι δύο εφαρμόζονται με τον ίδιο τρόπο στα generic και domain-adapted checkpoints κάθε αρχιτεκτονικής.

Στο frozen setting, όλες οι παράμετροι του backbone παραμένουν σταθερές (`unfrozen_layers=0`) και εκπαιδεύεται αποκλειστικά ένα γραμμικό classification head (`nn.Linear`) για την πρόβλεψη των 23 κατηγοριών του GastroHUN.

Στο partial fine-tuning, εκπαιδεύονται το classification head και το τελευταίο 40% των transformer blocks, ενώ τα υπόλοιπα blocks παραμένουν frozen. Η συγκεκριμένη διαμόρφωση επιτρέπει τη μερική προσαρμογή του backbone στο downstream πρόβλημα.

Και στις δύο στρατηγικές εφαρμόζονται οι ρυθμίσεις του κοινού downstream training protocol (Πίνακας 4.2), ώστε οι διαφορές απόδοσης μεταξύ generic και domain-adapted checkpoints να εξετάζονται υπό συγκρίσιμες συνθήκες.

4.4.3 Μετρικές και Στατιστική Σύγκριση

Ως κύρια μετρική αξιολόγησης χρησιμοποιείται το macro-averaged F1-score (*Macro-F1*), το οποίο υπολογίζεται ως ο αριθμητικός μέσος των F1-scores των 23 κατηγοριών του GastroHUN:

$$F_{1,\text{macro}} = \frac{1}{C} \sum_{c=1}^{C} F_{1,c}, \qquad C = 23,$$

όπου $F_{1,c}$ είναι το F1-score της κατηγορίας c. Η μετρική αυτή αποδίδει ίσο βάρος σε κάθε κατηγορία, ανεξάρτητα από τη συχνότητά της, και είναι κατάλληλη για την αξιολόγηση σε συνθήκες ανισορροπίας κλάσεων.

Για την εκτίμηση της μεταβλητότητας της απόδοσης χρησιμοποιείται η επίσημη διαδικασία bootstrap αξιολόγησης του GastroHUN, με 100 επαναδειγματοληψίες του test set, σύμφωνα με το αρχείο `ScenarioA-B_bootstrap.json` [21]. Για κάθε επαναδειγματοληψία υπολογίζεται το Macro-F1, σχηματίζοντας μία κατανομή τιμών ανά εκτέλεση εκπαίδευσης.

Τα διαστήματα εμπιστοσύνης 95% υπολογίζονται με την προσέγγιση Student-t:

$$CI_{95\%} = \bar{F}_1 \pm t_{0.975,n-1} \frac{s_{F_1}}{\sqrt{n}},$$

όπου $\bar{F}_1$ είναι η μέση τιμή των Macro-F1 scores, s_{F_1} η τυπική απόκλισή τους και n το πλήθος των τιμών που χρησιμοποιούνται στον υπολογισμό.

Κατά τη διαδικασία επιλογής checkpoint χρησιμοποιείται μία εκτέλεση χωρίς ρητό καθορισμό τυχαίας σποράς, όπως περιγράφεται στην Ενότητα 4.4.1. Αντίθετα, στην τελική αξιολόγηση πραγματοποιούνται τρεις εκτελέσεις downstream εκπαίδευσης με διαφορετικά seeds. Με 100 bootstrap επαναδειγματοληψίες ανά seed προκύπτουν συνολικά 300 τιμές Macro-F1 για τη συγκεντρωτική περιγραφή της απόδοσης.

Στις προκαταρκτικές συγκρίσεις των supervised baselines και των generic DINO/DINOv2 backbones χρησιμοποιείται μία εκτέλεση εκπαίδευσης ανά μοντέλο. Επομένως, τα αντίστοιχα διαστήματα εμπιστοσύνης αποτυπώνουν τη μεταβλητότητα από το bootstrap resampling του test set, αλλά όχι τη μεταβλητότητα μεταξύ διαφορετικών εκπαιδεύσεων. Στις τελικές συγκρίσεις generic και domain-adapted checkpoints, οι τρεις εκτελέσεις επιτρέπουν επιπλέον την παρατήρηση διαφορών μεταξύ seeds. Συνεπώς, τα διαστήματα των δύο περιπτώσεων δεν αποτυπώνουν ακριβώς τις ίδιες πηγές αβεβαιότητας.

Ωστόσο, οι bootstrap τιμές δεν αποτελούν ανεξάρτητα πειράματα, καθώς προέρχονται από επαναδειγματοληψίες του ίδιου test set. Ειδικότερα, η συγκέντρωση 300 τιμών από τρία seeds δεν ισοδυναμεί με 300 ανεξάρτητες εκτελέσεις εκπαίδευσης. Κατά συνέπεια, τα διαστήματα εμπιστοσύνης που υπολογίζονται από τις συγκεντρωτικές τιμές με την παραπάνω προσέγγιση ενδέχεται να υποεκτιμούν την αβεβαιότητα και ερμηνεύονται κυρίως περιγραφικά. Επιπλέον, η επικάλυψη ή μη των διαστημάτων εμπιστοσύνης δεν θεωρείται από μόνη της τυπικός έλεγχος στατιστικής σημαντικότητας.

4.5 Σχεδιασμός των Επιμέρους Πειραμάτων

Η πειραματική μελέτη οργανώνεται σε τρία πειράματα continued self-supervised pretraining, τα οποία διαφοροποιούνται ως προς την οικογένεια και το μέγεθος του Vision Transformer backbone. Στόχος είναι να διερευνηθεί η επίδραση της προσαρμογής στο ενδοσκοπικό πεδίο σε διαφορετικές αρχιτεκτονικές, με κοινό πρωτόκολλο επιλογής checkpoints και downstream αξιολόγησης, όπως περιγράφηκε στις προηγούμενες ενότητες.

4.5.1 Πείραμα 1: DINOv2 ViT-S

Το πρώτο πείραμα χρησιμοποιεί το DINOv2 ViT-S/14, με patch size 14×14 και τέσσερα register tokens. Ως μικρότερο backbone της οικογένειας DINOv2 που εξετάζεται στα κύρια πειράματα, αποτελεί την αφετηρία για τη διερεύνηση του domain-specific continued self-supervised pretraining.

Στόχος είναι να εξεταστεί κατά πόσο η περαιτέρω αυτοεπιβλεπόμενη προεκπαίδευση σε ενδοσκοπικές εικόνες οδηγεί σε αναπαραστάσεις περισσότερο χρήσιμες για την αναγνώριση ανατομικής θέσης στο GastroHUN. Για τον σκοπό αυτό, το domain-adapted checkpoint συγκρίνεται με το αρχικό generic-pretrained checkpoint της ίδιας αρχιτεκτονικής, υπό κοινές συνθήκες downstream αξιολόγησης.

Το πείραμα λειτουργεί επίσης ως σημείο αναφοράς για τη σύγκριση με το μεγαλύτερο DINOv2 ViT-B/14 του τρίτου πειράματος.

4.5.2 Πείραμα 2: DINO ViT-S

Το δεύτερο πείραμα χρησιμοποιεί το DINO ViT-S/16, με patch size 16×16 και χωρίς register tokens. Σε αντίθεση με το πρώτο πείραμα, το backbone προέρχεται από την αρχική μεθοδολογία DINO, επιτρέποντας τη διερεύνηση του domain-specific continued self-supervised pretraining σε διαφορετική οικογένεια αυτοεπιβλεπόμενων μοντέλων.

Το domain-adapted checkpoint συγκρίνεται με το αντίστοιχο generic-pretrained checkpoint της ίδιας αρχιτεκτονικής, ώστε να αξιολογηθεί η επίδραση της προσαρμογής στο ενδοσκοπικό πεδίο υπό κοινές συνθήκες downstream εκπαίδευσης.

Η σύγκριση με το DINOv2 ViT-S/14 του πρώτου πειράματος παρέχει επιπλέον ενδείξεις για τη συμπεριφορά των δύο οικογενειών σε μικρή αρχιτεκτονική κλίμακα. Ωστόσο, τα μοντέλα διαφέρουν ως προς το patch size, τη χρήση register tokens και τις συνθήκες αρχικής προεκπαίδευσης, πέρα από τη μεθοδολογία DINO/DINOv2. Επομένως, τυχόν διαφορές απόδοσης δεν μπορούν να αποδοθούν αποκλειστικά στη μέθοδο αυτοεπιβλεπόμενης μάθησης.

4.5.3 Πείραμα 3: DINOv2 ViT-B

Το τρίτο πείραμα χρησιμοποιεί το DINOv2 ViT-B/14, με patch size 14×14 και τέσσερα register tokens. Σε σύγκριση με το DINOv2 ViT-S/14 του πρώτου πειράματος, διαθέτει μεγαλύτερη αρχιτεκτονική χωρητικότητα, επιτρέποντας τη διερεύνηση της επίδρασης του domain-specific continued self-supervised pretraining σε διαφορετική κλίμακα μοντέλου.

Όπως και στα προηγούμενα πειράματα, το domain-adapted checkpoint συγκρίνεται με το αντίστοιχο generic-pretrained checkpoint της ίδιας αρχιτεκτονικής, υπό κοινό downstream πρωτόκολλο. Η σύγκριση με το Πείραμα 1 επιτρέπει επιπλέον να εξεταστεί κατά πόσο τα οφέλη του continued pretraining εμφανίζονται τόσο σε μικρότερα όσο και σε μεγαλύτερα DINOv2 backbones.

Ωστόσο, τα δύο πειράματα δεν πραγματοποιήθηκαν υπό απολύτως ίδιες συνθήκες continued pretraining. Λόγω περιορισμών μνήμης, στο Πείραμα 3 χρησιμοποιήθηκε batch size 128, έναντι 224 στο Πείραμα 1. Με κοινό στόχο τις 100.000 iterations, οι δύο διαμορφώσεις αντιστοιχούν σε περίπου 12,8 και 22,4 εκατομμύρια image-views, αντίστοιχα.

Επιπλέον, με την εφαρμογή του κανόνα κλιμάκωσης του learning rate βάσει της τετραγωνικής ρίζας του batch size (*square-root scaling*), το effective learning rate διαμορφώθηκε σε περίπου $7{,}07 \times 10^{-5}$ για το ViT-B/14 και $9{,}35 \times 10^{-5}$ για το ViT-S/14.

Κατά συνέπεια, τυχόν διαφορές στην τελική απόδοση ή στο όφελος από το continued pretraining δεν μπορούν να αποδοθούν αποκλειστικά στο μέγεθος του backbone, καθώς διαφοροποιούνται επίσης ο συνολικός αριθμός image-views και οι συνθήκες βελτιστοποίησης.

Κεφάλαιο 5: Πειραματική Διαδικασία

5.1 Υπολογιστικό Περιβάλλον και Οργάνωση Υλοποίησης

Η ανάπτυξη του κώδικα και οι αρχικές δοκιμές πραγματοποιήθηκαν σε τοπικό υπολογιστή, ενώ η αυτοεπιβλεπόμενη προεκπαίδευση και η downstream αξιολόγηση εκτελέστηκαν στην υποδομή υψηλών επιδόσεων Aristotle HPC του Αριστοτελείου Πανεπιστημίου Θεσσαλονίκης. Οι εργασίες υποβάλλονταν μέσω SLURM [104], στη διαμέριση `ampere`, με χρήση μίας GPU NVIDIA A100 40 GB ανά εργασία. Για το continued pretraining χρησιμοποιήθηκε η κατηγορία υπηρεσίας `ampere-extd`.

Η υλοποίηση βασίστηκε σε Python και PyTorch [105], με διακριτά virtual environments για τα repositories προεκπαίδευσης και κοινό περιβάλλον για τη downstream αξιολόγηση. Το τελευταίο αξιοποιούσε PyTorch Lightning [106], `scikit-learn`, `pandas` και Optuna [103].

Ο κώδικας οργανώθηκε σε τρία repositories: το `continue_ssl_pretrain_dinov2` για τα Πειράματα 1 και 3, το `continue_ssl_pretrain_dino_v1` για το Πείραμα 2 και το `gastrohun-dino` για την κοινή downstream εκπαίδευση και αξιολόγηση. Στο τελευταίο χρησιμοποιήθηκαν διακριτά Git branches ανά πείραμα.

Οι εκτελέσεις οργανώθηκαν μέσω SLURM scripts, με μεμονωμένα jobs για το continued pretraining και κυρίως job arrays για τη downstream αξιολόγηση. Τα αρχεία ρυθμίσεων, τα logs, τα checkpoints και τα αποτελέσματα αποθηκεύονταν σε ξεχωριστούς καταλόγους ανά πείραμα και στρατηγική εκπαίδευσης, διευκολύνοντας την ιχνηλασιμότητα και την αναπαραγωγή των πειραματικών διαδικασιών.

5.2 Πείραμα 1: Continued Pretraining με DINOv2 ViT-S/14

Στο πρώτο πείραμα πραγματοποιήθηκε continued self-supervised pretraining του DINOv2 ViT-S/14 στις προεπεξεργασμένες εικόνες του HyperKvasir. Στην παρούσα ενότητα παρουσιάζονται οι ρυθμίσεις προεκπαίδευσης, οι προκαταρκτικοί έλεγχοι σταθερότητας και η επιλογή του τελικού domain-adapted checkpoint.

5.2.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης

Ως αρχικό checkpoint χρησιμοποιήθηκε το επίσημο προεκπαιδευμένο `dinov2_vits14_reg4` [19, 98]. Για τη συμβατότητα με τις αρχικές παραμέτρους, η αρχιτεκτονική διαμορφώθηκε με `ffn_layer=mlp`, `block_chunks=0` και `layerscale=1e-5`, χωρίς τροποποίηση της βασικής δομής του backbone.

Η διαδικασία continued pretraining βασίστηκε στην υλοποίηση DINOv2, με προσαρμογές στους διαθέσιμους υπολογιστικούς πόρους και λαμβάνοντας υπόψη συναφείς προσεγγίσεις domain-specific προεκπαίδευσης, όπως το DINOCell [60].

Ο αριθμός prototypes των DINO και iBOT heads μειώθηκε από 65.536 σε 8.192, με bottleneck διάστασης 256. Η επιλογή αυτή ακολουθεί την αντίστοιχη πρακτική του DINOCell [60] για τη σταθεροποίηση της εκπαίδευσης υπό μικρότερο batch size, περιορίζοντας παράλληλα το μέγεθος των αντίστοιχων κεφαλών και το υπολογιστικό κόστος των προβλέψεων. Αποτελεί πρακτικό συμβιβασμό για την εκπαίδευση με περιορισμένους υπολογιστικούς πόρους, χωρίς ανεξάρτητη βελτιστοποίηση για το συγκεκριμένο σύνολο δεδομένων· η επίδραση της μείωσης στην ποιότητα των αναπαραστάσεων δεν αξιολογήθηκε ανεξάρτητα.

Ο συντελεστής KoLeo διατηρήθηκε σε 0,1, με στόχο την ενθάρρυνση της διασποράς των μαθημένων χαρακτηριστικών, ενώ για την κανονικοποίηση των προβλέψεων του teacher χρησιμοποιήθηκε ο αλγόριθμος Sinkhorn--Knopp, όπως περιγράφεται στην Ενότητα 3.6.5. Οι δύο αυτές συνιστώσες διατηρήθηκαν στο πλαίσιο της μεθοδολογίας DINOv2, χωρίς περαιτέρω τροποποίηση των αντίστοιχων μηχανισμών.

Το batch size καθορίστηκε σε 224 εικόνες ανά GPU, βάσει προκαταρκτικών ελέγχων μνήμης. Η τιμή αυτή επιλέχθηκε ως συμβιβασμός μεταξύ υπολογιστικής απόδοσης και διαθέσιμου περιθωρίου μνήμης, περιορίζοντας τον κίνδυνο αποτυχίας κατά την πολύωρη εκπαίδευση.

Το learning rate προσαρμόστηκε στο επιλεγμένο batch size μέσω κλιμάκωσης με την τετραγωνική του ρίζα (*square-root scaling*):

$$\text{lr} = \text{base_lr}\sqrt{\frac{B}{1024}}, \tag{5.1}$$

όπου $B = 224$ και $\text{base_lr} = 2 \times 10^{-4}$, δίνοντας learning rate αναφοράς περίπου $9{,}35 \times 10^{-5}$. Η κλιμάκωση εφαρμόστηκε ώστε η αρχική διαμόρφωση του learning rate να λαμβάνει υπόψη τη μείωση του batch size σε σχέση με το μέγεθος αναφοράς των 1.024 εικόνων.

Η προεκπαίδευση προγραμματίστηκε για 100 epochs των 1.000 iterations, με συνολικό στόχο 100.000 iterations --- ένα σχετικά σύντομο πρόγραμμα, κατ' αναλογία με το DINOCell [60], επιλεγμένο λόγω των διαθέσιμων υπολογιστικών πόρων και όχι μέσω ανεξάρτητης αναζήτησης ή ablation. Το πρόγραμμα βελτιστοποίησης περιλάμβανε 20 epochs γραμμικής προθέρμανσης του learning rate (*warmup*), σύμφωνα με την προκαθορισμένη ρύθμιση της μεθοδολογίας DINOv2, ώστε η προσαρμογή των παραμέτρων να πραγματοποιείται σταδιακά κατά την αρχική φάση εκπαίδευσης. Το weight decay αυξανόταν έως 0,2, ενώ η παράμετρος `layerwise_decay` ορίστηκε σε 1,0, χωρίς διαφοροποίηση του learning rate μεταξύ των επιπέδων του backbone.

Η αρχική τιμή του EMA momentum για την ενημέρωση του teacher ορίστηκε σε 0,994. Η ενημέρωση μέσω EMA επιτρέπει στον teacher να μεταβάλλεται ομαλότερα από τον student, συμβάλλοντας στη σταθερότητα των στόχων αυτοεπιβλεπόμενης μάθησης.

Για τη δημιουργία πολλαπλών όψεων κάθε εικόνας χρησιμοποιήθηκαν δύο global crops ανάλυσης 224×224 και οκτώ local crops ανάλυσης 98×98 pixels ανά εικόνα. Η χρήση διαφορετικών χωρικών κλιμάκων υποστηρίζει την εκμάθηση αναπαραστάσεων από ευρύτερες και τοπικότερες περιοχές της εικόνας, ενώ η διάσταση των

local crops επιλέχθηκε ως ακέραιο πολλαπλάσιο του patch size 14, εξασφαλίζοντας συμβατότητα με την αρχιτεκτονική του Vision Transformer.

Η προεκπαίδευση πραγματοποιήθηκε στις 108.321 προεπεξεργασμένες εικόνες του HyperKvasir (Ενότητα 4.2.1), οι οποίες προσδιορίζονταν μέσω του αρχείου `train_deduped.txt`. Κατά τη δειγματοληψία των crops χρησιμοποιήθηκε επίσης το `exclusion_boxes.csv`, ώστε να αποφεύγονται περιοχές με οπτικές επικαλύψεις που θα μπορούσαν να εισαγάγουν μη ανατομικά χαρακτηριστικά στις μαθημένες αναπαραστάσεις.

Τέλος, προβλέφθηκε αποθήκευση των παραμέτρων του EMA teacher ανά 10.000 iterations, δημιουργώντας έως δέκα υποψήφια checkpoints. Η περιοδική αποθήκευση επέτρεψε τη μεταγενέστερη επιλογή checkpoint βάσει της downstream επίδοσης, χωρίς να θεωρείται εκ των προτέρων ότι το τελευταίο checkpoint θα παρείχε τις καταλληλότερες αναπαραστάσεις.

Το αρχικό checkpoint `dinov2_vits14_reg4` δεν προέκυψε από ανεξάρτητη προεκπαίδευση, αλλά μέσω *distillation* από το ViT-g/14 [19], με το ίδιο recipe να ακολουθείται και στις παραλλαγές με register tokens [98]. Ο Πίνακας 5.1 συνοψίζει τις βασικές διαφορές ανάμεσα σε αυτή την αρχική προεκπαίδευση και στη ρύθμιση του continued pretraining του παρόντος πειράματος.

Πίνακας 5.1: Σύγκριση της αρχικής (distillation) προεκπαίδευσης του `dinov2_vits14_reg4` checkpoint με τη ρύθμιση του continued pretraining του Πειράματος 1. Οι τιμές της αρχικής προεκπαίδευσης προέρχονται από το Παράρτημα B (Πίνακας 16) του DINOv2 paper [19].

Παράμετρος	**Αρχική προεκπαίδευση (distillation)**	**Continued pretraining (Πείραμα 1)**
Batch size	2.048	224
Learning rate	1×10^{-3}	$\approx 9{,}35 \times 10^{-5}$
Iterations	625.000	100.000
LR warmup	100.000 iterations	20.000 iterations
Drop path rate	0	0,2
Weight decay (τελικό)	0,2	0,2
Teacher momentum (αρχικό)	0,994	0,994
LayerScale	1×10^{-5}	1×10^{-5}
KoLeo weight	0,1	0,1

Όπως φαίνεται στον Πίνακα 5.1, το continued pretraining διατήρησε αρκετές βασικές ρυθμίσεις της αρχικής προεκπαίδευσης (weight decay, teacher momentum, LayerScale, συντελεστή KoLeo), ενώ προσάρμοσε σημαντικά το batch size, το learning rate, τη διάρκεια και το drop path rate, λόγω των διαθέσιμων υπολογιστικών πόρων.

5.2.2 Εκτέλεση και Έλεγχος Σταθερότητας

Πριν από την πλήρη εκτέλεση του continued self-supervised pretraining πραγματοποιήθηκαν προκαταρκτικοί έλεγχοι χρήσης μνήμης GPU και αριθμητικής σταθερότητας, με στόχο την επιλογή κατάλληλου batch size και την επιβεβαίωση της λειτουργικότητας του εκπαιδευτικού pipeline.

Οι δοκιμές μνήμης πραγματοποιήθηκαν σε μία GPU NVIDIA A100 40 GB. Για batch size 224 καταγράφηκε μέγιστη χρήση περίπου 30,6 GB, δηλαδή 77% της δια-

θέσιμης μνήμης, με χρόνο 3,45 δευτερόλεπτα ανά iteration και επεξεργαστική απόδοση περίπου 65 εικόνων ανά δευτερόλεπτο. Παρότι το batch size 256 ήταν επίσης εφικτό, απαιτούσε περίπου 87% της διαθέσιμης μνήμης. Επιλέχθηκε επομένως το batch size 224, ώστε να διατηρηθεί μεγαλύτερο περιθώριο μνήμης και να περιοριστεί ο κίνδυνος αποτυχίας κατά την πολύωρη εκπαίδευση.

Στη συνέχεια πραγματοποιήθηκε δοκιμαστική εκπαίδευση 2.000 iterations, οργανωμένη σε τέσσερα epochs των 500 iterations, με ένα epoch προθέρμανσης του learning rate (*warmup*). Κατά τη δοκιμή παρακολουθήθηκαν η συνολική συνάρτηση απώλειας και οι επιμέρους συνιστώσες της, με στόχο τον εντοπισμό πιθανής αριθμητικής αστάθειας ή ενδείξεων κατάρρευσης των αναπαραστάσεων (*representation collapse*).

Η εξέλιξη της συνολικής loss και των επιμέρους συνιστωσών της κατά τα τέσσερα epochs της δοκιμαστικής εκπαίδευσης παρουσιάζεται στον Πίνακα 5.2. Παρατηρείται σταθερή πτωτική τάση σε όλες τις συνιστώσες, χωρίς ενδείξεις αριθμητικής αστάθειας.

Πίνακας 5.2: Εξέλιξη της συνολικής loss και των επιμέρους συνιστωσών κατά τη δοκιμαστική εκπαίδευση τεσσάρων epochs του DINOv2 ViT-S/14.

Epoch	**Iteration**	**Συνολική loss**	**DINO global**	**DINO local**	**KoLeo**	**iBOT**
1	490	10,770	0,957	7,694	$-0,020$	2,138
2	990	9,413	0,835	6,857	$-0,021$	1,741
3	1.490	8,838	0,784	6,526	$-0,021$	1,549
4	1.999	8,753	0,775	6,466	$-0,021$	1,528

Στις διαθέσιμες καταγραφές δεν παρατηρήθηκαν μη πεπερασμένες τιμές (`NaN`) ή απότομη πτώση της συνολικής loss προς το μηδέν. Επιπλέον, η τελική τιμή παρέμεινε πάνω από το πρακτικό κατώφλι της μονάδας που είχε οριστεί στο script ελέγχου. Τα αποτελέσματα αυτά παρείχαν αρχική ένδειξη ομαλής αριθμητικής συμπεριφοράς, χωρίς ωστόσο να αποκλείουν πλήρως το representation collapse, καθώς η διακριτική ικανότητα των αναπαραστάσεων δεν μπορεί να αξιολογηθεί αποκλειστικά από τη συνάρτηση απώλειας.

Μετά τους προκαταρκτικούς ελέγχους, υποβλήθηκε η πλήρης εργασία continued pretraining στο Aristotle HPC μέσω SLURM, με στόχο 100.000 iterations και περιοδική αποθήκευση των παραμέτρων του EMA teacher. Ο συνολικός χρόνος εκπαίδευσης ήταν 25 ώρες, 50 λεπτά και 45 δευτερόλεπτα, με μέσο χρόνο περίπου 0,930 δευτερόλεπτα ανά iteration. Τα παραγόμενα checkpoints χρησιμοποιήθηκαν στη διαδικασία επιλογής που παρουσιάζεται στην Ενότητα 5.2.3.

5.2.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση

Η επιλογή του τελικού domain-adapted DINOv2 ViT-S/14 πραγματοποιήθηκε σύμφωνα με το πρωτόκολλο δύο σταδίων της Ενότητας 4.4.1, χρησιμοποιώντας αποκλειστικά το validation set του GastroHUN.

Στο πρώτο στάδιο αξιολογήθηκαν τα δέκα checkpoints του EMA teacher, αποθηκευμένα ανά 10.000 iterations (9.999--99.999), μέσω frozen linear probing σε προϋπολογισμένα χαρακτηριστικά *(cached features)*, μαζί με το generic-pretrained μοντέλο ως σημείο αναφοράς. Τα τρία καλύτερα checkpoints προχώρησαν στο δεύτερο στάδιο.

Στο δεύτερο στάδιο, τα τρία checkpoints αξιολογήθηκαν μέσω του πλήρους downstream pipeline, τόσο με frozen backbone όσο και με fine-tuning των τελευταίων 40% των transformer blocks. Πραγματοποιήθηκε μία εκτέλεση ανά συνδυασμό checkpoint και στρατηγικής, ενώ η τελική κατάταξη βασίστηκε στο άθροισμα των δύο validation Macro-F1, σύμφωνα με το κριτήριο S_{val} της Ενότητας 4.4.1. Τα αναλυτικά αποτελέσματα και των δύο σταδίων παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.2.2.

Για την τελική σύγκριση, το επιλεγμένο checkpoint και το αντίστοιχο generic-pretrained μοντέλο εκπαιδεύτηκαν με τρία διαφορετικά random seeds (1, 2 και 3), τόσο στο frozen όσο και στο fine-tuned setting. Η αξιολόγηση πραγματοποιήθηκε στο ανεξάρτητο test set του GastroHUN, το οποίο δεν χρησιμοποιήθηκε κατά την επιλογή checkpoint. Τα τελικά αποτελέσματα παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.2.3.

5.3 Πείραμα 2: Continued Pretraining με DINO ViT-S/16

Στο δεύτερο πείραμα πραγματοποιήθηκε continued self-supervised pretraining του DINO ViT-S/16 στις προεπεξεργασμένες εικόνες του HyperKvasir. Στην παρούσα ενότητα παρουσιάζονται οι ρυθμίσεις προεκπαίδευσης, οι προκαταρκτικοί έλεγχοι σταθερότητας και η διαδικασία επιλογής του τελικού domain-adapted checkpoint.

5.3.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης

Ως αρχικό checkpoint χρησιμοποιήθηκε το επίσημο προεκπαιδευμένο `dino_deitsmall16_pretrain.pth` [18], με αρχιτεκτονική ViT-S/16 και χωρίς register tokens. Οι παράμετροι του προεκπαιδευμένου backbone φορτώθηκαν στην αντίστοιχη αρχιτεκτονική, ενώ η περαιτέρω προεκπαίδευση βασίστηκε στον μηχανισμό teacher--student της αρχικής μεθόδου DINO, χωρίς τις πρόσθετες συνιστώσες iBOT και KoLeo του DINOv2.

Για την προεκπαίδευση χρησιμοποιήθηκαν οι 108.321 προεπεξεργασμένες εικόνες του HyperKvasir (Ενότητα 4.2.1), χωρίς αξιοποίηση των διαθέσιμων ετικετών. Η εκπαίδευση πραγματοποιήθηκε σε μία GPU NVIDIA A100 40 GB, με batch size 192 εικόνων. Η επιλογή αυτή βασίστηκε στους προκαταρκτικούς ελέγχους μνήμης, καθώς το batch size 224 ήταν μεν εφικτό, αλλά απαιτούσε σημαντικά μεγαλύτερο ποσοστό της διαθέσιμης μνήμης, ενώ το batch size 256 προκαλούσε σφάλμα εξάντλησης μνήμης (`Out Of Memory`, OOM). Επομένως, το batch size 192 επιλέχθηκε ώστε να διατηρείται μεγαλύτερο περιθώριο μνήμης κατά την πλήρη εκπαίδευση.

Σε αντίθεση με την υλοποίηση DINOv2 του Πειράματος 1, όπου η διάρκεια κάθε epoch καθορίστηκε σε σταθερό αριθμό iterations, στην αρχική υλοποίηση DINO ένα epoch αντιστοιχούσε σε ένα πλήρες πέρασμα από το σύνολο προεκπαίδευσης. Για να προσεγγιστεί ο κοινός στόχος των 100.000 iterations, ο απαιτούμενος αριθμός epochs υπολογίστηκε από το μέγεθος του συνόλου δεδομένων και το batch size:

$$E = \left\lceil \frac{I_{\text{target}}}{\lfloor N/B \rfloor} \right\rceil, \tag{5.2}$$

όπου $I_{\text{target}} = 100000$ ο επιθυμητός αριθμός iterations, $N = 108321$ το πλήθος εικόνων και $B = 192$ το batch size. Με 564 iterations ανά epoch προέκυψαν 178 epochs, που αντιστοιχούν σε 100.392 προγραμματισμένα iterations. Η μικρή υπέρβαση του στόχου οφείλεται στη στρογγυλοποίηση του αριθμού epochs προς τον επόμενο ακέραιο.

Το πρόγραμμα προθέρμανσης του learning rate (*warmup*) ορίστηκε σε 18 epochs, δηλαδή περίπου στο 10% της συνολικής διάρκειας εκπαίδευσης, ακολουθώντας την αντίστοιχη αναλογία της αρχικής μεθόδου DINO. Η προθέρμανση επιτρέπει τη σταδιακή προσαρμογή των παραμέτρων κατά την αρχική φάση του continued pretraining.

Για τη δημιουργία πολλαπλών όψεων κάθε εικόνας χρησιμοποιήθηκαν δύο global crops ανάλυσης 224×224 και οκτώ local crops ανάλυσης 96×96 pixels, σύμφωνα με τις προκαθορισμένες ρυθμίσεις της αρχικής υλοποίησης DINO, χωρίς τροποποίηση των αντίστοιχων παραμέτρων.

Η αποθήκευση των checkpoints προγραμματίστηκε ανά 17 epochs, ώστε να είναι διαθέσιμα ενδιάμεσα στάδια της προεκπαίδευσης για τη μεταγενέστερη διαδικασία επιλογής, αντί να αξιολογηθεί αποκλειστικά το τελικό μοντέλο.

Πίνακας 5.3: Σύγκριση της αρχικής προεκπαίδευσης του `dino_deitsmall16_pretrain.pth` checkpoint με τη ρύθμιση του continued pretraining του Πειράματος 2. Οι τιμές της αρχικής προεκπαίδευσης προέρχονται από το επίσημο αρχείο καταγραφής παραμέτρων (`args.txt`) που συνοδεύει το δημοσιευμένο checkpoint [18].

Παράμετρος	**Αρχική προεκπαίδευση**	**Continued pretraining (Πείραμα 2)**
Batch size (συνολικό)	1.024 (64×16 GPUs)	192
Learning rate (βάση)	5×10^{-4}	5×10^{-4}
Learning rate (effective)	$\approx 2 \times 10^{-3}$	$\approx 3{,}75 \times 10^{-4}$
Epochs	800	178
LR warmup	10 epochs	18 epochs
Weight decay (τελικό)	0,4	0,4
Teacher momentum	0,996	0,996
Drop path rate	0,1	0,1
Prototypes (`out_dim`)	65.536	65.536
Local crops	10	8
Teacher temperature	0,04→0,07 (30 epochs)	σταθερό 0,04

Όπως φαίνεται στον Πίνακα 5.3, το continued pretraining διατήρησε αρκετές βασικές ρυθμίσεις της αρχικής προεκπαίδευσης (weight decay, teacher momentum, drop path rate, αριθμός prototypes), ενώ προσάρμοσε σκόπιμα το batch size, το learning rate και τη διάρκεια λόγω των διαθέσιμων υπολογιστικών πόρων. Ο αριθμός local crops και το πρόγραμμα θερμοκρασίας του teacher δεν τροποποιήθηκαν ρητά και ακολούθησαν τις προεπιλογές του κώδικα, οι οποίες διαφέρουν ελαφρώς από αυτές της αρχικής προεκπαίδευσης.

5.3.2 Εκτέλεση και Έλεγχος Σταθερότητας

Πριν από την πλήρη εκτέλεση του continued pretraining πραγματοποιήθηκαν προκαταρκτικοί έλεγχοι χρήσης μνήμης GPU και αριθμητικής σταθερότητας, ακολου-

θώντας την ίδια διαδικασία ελέγχου με το Πείραμα 1.

Οι δοκιμές μνήμης πραγματοποιήθηκαν σε μία GPU NVIDIA A100 40 GB. Για batch size 192 καταγράφηκε μέγιστη χρήση περίπου 31,2 GB, ενώ η αύξηση του batch size σε 224 απαιτούσε περίπου 36,3 GB. Η περαιτέρω αύξηση σε 256 εικόνες οδήγησε σε σφάλμα εξάντλησης μνήμης (`Out Of Memory`, OOM). Με βάση τις μετρήσεις αυτές, επιλέχθηκε το batch size 192, το οποίο παρείχε μεγαλύτερο περιθώριο διαθέσιμης μνήμης για την πλήρη εκπαίδευση.

Στη συνέχεια πραγματοποιήθηκε δοκιμαστική εκπαίδευση πέντε epochs, με 564 iterations ανά epoch, ώστε να ελεγχθεί η συμπεριφορά του εκπαιδευτικού pipeline πριν από την εκτέλεση των 178 epochs. Κατά τη δοκιμή παρακολουθήθηκαν η συνολική συνάρτηση απώλειας, το learning rate και η χρήση μνήμης GPU. Η μέγιστη καταγεγραμμένη χρήση μνήμης ήταν περίπου 31,7 GB.

Η εξέλιξη της συνολικής loss και του learning rate παρουσιάζεται στον Πίνακα 5.4.

Πίνακας 5.4: Εξέλιξη της συνολικής loss και του learning rate κατά τη δοκιμαστική εκπαίδευση πέντε epochs του DINO ViT-S/16.

Epoch	**Συνολική loss**	**Learning rate**
1	10,7024	$1{,}88 \times 10^{-4}$
2	8,6707	$3{,}56 \times 10^{-4}$
3	7,1505	$2{,}58 \times 10^{-4}$
4	6,4289	$1{,}18 \times 10^{-4}$
5	6,1636	$1{,}97 \times 10^{-5}$

Κατά τη διάρκεια της δοκιμής παρατηρήθηκε σταδιακή μείωση της συνολικής loss από 10,7024 σε 6,1636, χωρίς καταγεγραμμένες μη πεπερασμένες τιμές (`NaN`) ή απότομη κατάρρευση της συνάρτησης απώλειας. Η συμπεριφορά αυτή αποτέλεσε αρχική ένδειξη αριθμητικής σταθερότητας και ομαλής λειτουργίας του pipeline. Ωστόσο, όπως και στο Πείραμα 1, η παρακολούθηση της loss δεν επαρκεί από μόνη της για τον αποκλεισμό του representation collapse ή την αξιολόγηση της διακριτικής ικανότητας των μαθημένων χαρακτηριστικών.

Μετά την ολοκλήρωση των προκαταρκτικών ελέγχων, πραγματοποιήθηκε η πλήρης εκτέλεση του continued pretraining, με προγραμματισμένη διάρκεια 178 epochs και συνολικά 100.392 iterations. Ο συνολικός χρόνος εκπαίδευσης ήταν 16 ώρες, 7 λεπτά και 42 δευτερόλεπτα, με μέσο χρόνο περίπου 0,578 δευτερόλεπτα ανά iteration. Τα ενδιάμεσα και το τελικό checkpoint του EMA teacher αποτέλεσαν τη βάση για τη διαδικασία επιλογής του domain-adapted μοντέλου, η οποία παρουσιάζεται στην Ενότητα 5.3.3.

5.3.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση

Η επιλογή του τελικού domain-adapted DINO ViT-S/16 πραγματοποιήθηκε σύμφωνα με το πρωτόκολλο δύο σταδίων της Ενότητας 4.4.1, χρησιμοποιώντας αποκλειστικά το validation set του GastroHUN.

Στο πρώτο στάδιο αξιολογήθηκαν δώδεκα checkpoints του EMA teacher: έντεκα checkpoints από τα epochs 0, 17, 34, 51, …, 170 και το τελικό checkpoint του epoch 177, μέσω frozen linear probing σε προϋπολογισμένα χαρακτηριστικά, μαζί με το generic-pretrained μοντέλο ως σημείο αναφοράς. Τα τρία καλύτερα checkpoints προχώρησαν στο δεύτερο στάδιο.

Στο δεύτερο στάδιο, τα τρία επικρατέστερα checkpoints αξιολογήθηκαν μέσω του πλήρους downstream pipeline, τόσο με frozen backbone όσο και με fine-tuning των τελευταίων 40% των transformer blocks. Πραγματοποιήθηκε μία εκτέλεση ανά συνδυασμό checkpoint και στρατηγικής εκπαίδευσης, ενώ η τελική κατάταξη βασίστηκε στο άθροισμα των δύο validation Macro-F1, σύμφωνα με το κριτήριο S_{val} της Ενότητας 4.4.1. Τα αναλυτικά αποτελέσματα και των δύο σταδίων παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.3.2.

Για την τελική σύγκριση, το επιλεγμένο checkpoint και το αντίστοιχο generic-pretrained μοντέλο εκπαιδεύτηκαν με τρία διαφορετικά random seeds (1, 2 και 3), τόσο στο frozen όσο και στο fine-tuned setting, ακολουθώντας το κοινό downstream πρωτόκολλο της Ενότητας 4.4.2. Η τελική αξιολόγηση πραγματοποιήθηκε στο ανεξάρτητο test set του GastroHUN, το οποίο δεν χρησιμοποιήθηκε κατά την επιλογή checkpoint. Τα τελικά αποτελέσματα παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.3.3.

5.4 Πείραμα 3: Continued Pretraining με DINOv2 ViT-B/14

Στο τρίτο πείραμα πραγματοποιήθηκε continued self-supervised pretraining του DINOv2 ViT-B/14 στις προεπεξεργασμένες εικόνες του HyperKvasir. Το πείραμα ακολούθησε την ίδια βασική μεθοδολογία με το DINOv2 ViT-S/14 του Πειράματος 1, με προσαρμογές στις υπολογιστικές απαιτήσεις της μεγαλύτερης αρχιτεκτονικής. Στην παρούσα ενότητα παρουσιάζονται οι ρυθμίσεις προεκπαίδευσης, οι έλεγχοι σταθερότητας και η επιλογή του τελικού domain-adapted checkpoint.

5.4.1 Αρχικό Checkpoint και Ρυθμίσεις Προεκπαίδευσης

Ως αρχικό checkpoint χρησιμοποιήθηκε το επίσημο προεκπαιδευμένο `dinov2_vitb14_reg4` [19, 98], με αρχιτεκτονική ViT-B/14 και τέσσερα register tokens. Όπως και στο Πείραμα 1, διατηρήθηκαν οι ρυθμίσεις συμβατότητας `ffn_layer=mlp`, `block_chunks=0` και `layerscale=1e-5`, ώστε η αρχιτεκτονική να αντιστοιχεί στο αρχικό checkpoint.

Η διαδικασία continued pretraining ακολούθησε την ίδια βασική διαμόρφωση DINOv2 με το Πείραμα 1 (Ενότητα 5.2.1). Συγκεκριμένα, χρησιμοποιήθηκαν 8.192 prototypes στους DINO και iBOT heads, bottleneck διάστασης 256, συντελεστής KoLeo 0,1 και κανονικοποίηση των προβλέψεων του teacher μέσω Sinkhorn--Knopp. Οι επιλογές αυτές διατηρήθηκαν σταθερές μεταξύ των δύο πειραμάτων DINOv2, ώστε να περιοριστούν οι διαφοροποιήσεις της διαδικασίας προεκπαίδευσης πέρα από την αρχιτεκτονική και τις αναγκαίες προσαρμογές στους υπολογιστικούς πόρους.

Λόγω των αυξημένων απαιτήσεων μνήμης του ViT-B/14, το batch size μειώθηκε από 224 σε 128 εικόνες ανά GPU. Η επιλογή βασίστηκε σε προκαταρκτικούς ελέγχους, κατά τους οποίους καταγράφηκε μέγιστη χρήση μνήμης περίπου 34,6 GB σε μία NVIDIA A100 40 GB. Το μικρότερο batch size επέτρεψε την εκτέλεση της προεκπαίδευσης εντός των διαθέσιμων ορίων μνήμης.

Το learning rate προσαρμόστηκε στο νέο batch size μέσω της ίδιας στρατηγικής square-root scaling που παρουσιάστηκε στην Εξίσωση 5.1. Με $B = 128$ και base_lr $= 2 \times 10^{-4}$, προέκυψε learning rate αναφοράς περίπου $7{,}07 \times 10^{-5}$, έναντι $9{,}35 \times 10^{-5}$

στο Πείραμα 1. Με τον τρόπο αυτό διατηρήθηκε κοινός κανόνας κλιμάκωσης του learning rate, λαμβάνοντας υπόψη το διαφορετικό batch size των δύο αρχιτεκτονικών.

Η προεκπαίδευση προγραμματίστηκε για 100 epochs των 1.000 iterations, με συνολικό στόχο 100.000 iterations και 20 epochs γραμμικής προθέρμανσης του learning rate (*warmup*). Το weight decay αυξανόταν έως 0,2, η παράμετρος `layerwise_decay` ορίστηκε σε 1,0 και το αρχικό EMA momentum του teacher σε 0,994. Για τη δημιουργία πολλαπλών όψεων χρησιμοποιήθηκαν δύο global crops ανάλυσης 224×224 και οκτώ local crops ανάλυσης 98×98 pixels, όπως στο Πείραμα 1.

Η προεκπαίδευση πραγματοποιήθηκε στις ίδιες 108.321 προεπεξεργασμένες εικόνες του HyperKvasir (Ενότητα 4.2.1), με χρήση των αρχείων `train_deduped.txt` και `exclusion_boxes.csv` για τον προσδιορισμό των εικόνων και την αποφυγή περιοχών με οπτικές επικαλύψεις κατά τη δειγματοληψία των crops.

Παρότι τα δύο πειράματα DINOv2 είχαν κοινό στόχο 100.000 iterations, το διαφορετικό batch size συνεπαγόταν διαφορετικό αριθμό παρουσιάσεων εικόνων κατά την εκπαίδευση: περίπου 12,8 εκατομμύρια για το ViT-B/14, έναντι 22,4 εκατομμυρίων για το ViT-S/14. Οι τιμές αυτές αναφέρονται στις παρουσιάσεις εικόνων εισόδου και όχι στον αριθμό των επιμέρους crops που παράγονται μέσω της στρατηγικής multi-crop.

Συνεπώς, η σύγκριση των δύο αρχιτεκτονικών δεν αποτελεί πλήρως ελεγχόμενη σύγκριση αποκλειστικά ως προς το μέγεθος του backbone, καθώς διαφοροποιούνται επίσης το batch size, το learning rate και ο συνολικός αριθμός παρουσιάσεων εικόνων. Οι διαφορές αυτές λαμβάνονται υπόψη κατά την ερμηνεία των αποτελεσμάτων.

Τέλος, προβλέφθηκε αποθήκευση των παραμέτρων του EMA teacher ανά 10.000 iterations, δημιουργώντας δέκα υποψήφια checkpoints για τη διαδικασία επιλογής του τελικού domain-adapted μοντέλου.

Όπως και στο Πείραμα 1 (Ενότητα 5.2.1), το αρχικό checkpoint `dinov2_vitb14_reg4` προέκυψε μέσω distillation από το ViT-g/14 και όχι μέσω ανεξάρτητης προεκπαίδευσης [19, 98]. Σύμφωνα με το Παράρτημα Β (Πίνακας 16) του DINOv2 paper, το recipe αυτής της αρχικής προεκπαίδευσης είναι κοινό για τα distilled ViT-S/14 και ViT-B/14, όπως φαίνεται στον Πίνακα 5.5.

Πίνακας 5.5: Σύγκριση της αρχικής (distillation) προεκπαίδευσης του `dinov2_vitb14_reg4` checkpoint με τη ρύθμιση του continued pretraining του Πειράματος 3. Οι τιμές της αρχικής προεκπαίδευσης προέρχονται από το Παράρτημα Β (Πίνακας 16) του DINOv2 paper [19] και ταυτίζονται με αυτές του Πίνακα 5.1 για το ViT-S/14, καθώς το recipe είναι κοινό για τα δύο distilled μεγέθη.

Παράμετρος	**Αρχική προεκπαίδευση (distillation)**	**Continued pretraining (Πείραμα 3)**
Batch size	2.048	128
Learning rate	1×10^{-3}	$\approx 7{,}07 \times 10^{-5}$
Iterations	625.000	100.000
LR warmup	100.000 iterations	20.000 iterations
Drop path rate	0	0,2
Weight decay (τελικό)	0,2	0,2
Teacher momentum (αρχικό)	0,994	0,994
LayerScale	1×10^{-5}	1×10^{-5}
KoLeo weight	0,1	0,1

5.4.2 Εκτέλεση και Έλεγχος Σταθερότητας

Πριν από την πλήρη εκτέλεση του continued pretraining πραγματοποιήθηκαν προκαταρκτικοί έλεγχοι χρήσης μνήμης GPU και αριθμητικής σταθερότητας, ακολουθώντας τη διαδικασία που εφαρμόστηκε στο Πείραμα 1.

Η δοκιμαστική εκπαίδευση πραγματοποιήθηκε σε μία GPU NVIDIA A100 40 GB, με batch size 128 και διάρκεια 2.000 iterations. Η μέγιστη καταγεγραμμένη χρήση μνήμης ήταν 33,8 GB, επιβεβαιώνοντας τη δυνατότητα εκτέλεσης της μεγαλύτερης αρχιτεκτονικής ViT-B/14 εντός των διαθέσιμων ορίων μνήμης.

Κατά τη δοκιμή παρακολουθήθηκαν η συνολική συνάρτηση απώλειας και οι επιμέρους συνιστώσες της, χωρίς να παρατηρηθούν μη πεπερασμένες τιμές (`NaN`) ή ενδείξεις απότομης αριθμητικής αστάθειας.

Μετά την ολοκλήρωση των προκαταρκτικών ελέγχων πραγματοποιήθηκε η πλήρης εκτέλεση του continued pretraining για 100.000 iterations. Ο συνολικός χρόνος εκπαίδευσης ήταν 16 ώρες, 45 λεπτά και 24 δευτερόλεπτα, με μέσο χρόνο περίπου 0,603 δευτερόλεπτα ανά iteration. Η μέγιστη καταγεγραμμένη χρήση μνήμης παρέμεινε στα 33,8 GB.

Στον Πίνακα 5.6 παρουσιάζεται η εξέλιξη της συνολικής loss και των επιμέρους συνιστωσών της, από τα τέσσερα epochs της δοκιμαστικής εκπαίδευσης έως το τελευταίο iteration της πλήρους εκτέλεσης.

Πίνακας 5.6: Εξέλιξη της συνολικής loss και των επιμέρους συνιστωσών κατά τη δοκιμαστική εκπαίδευση (4 epochs) και στο τελευταίο iteration της πλήρους εκτέλεσης του DINOv2 ViT-B/14.

Συνιστώσα	**490**	**990**	**1.490**	**1.999**	**99.999**
DINO local crops loss	7,677	6,903	6,555	6,521	5,610
DINO global crops loss	0,956	0,843	0,793	0,788	0,679
KoLeo loss	$-0,023$	$-0,024$	$-0,024$	$-0,025$	$-0,028$
iBOT loss	2,136	1,803	1,635	1,615	1,230
Συνολική loss	**10,745**	**9,526**	**8,957**	**8,897**	**7,506**

Η συνολική loss παρουσίασε σταθερή πτωτική τάση καθ' όλη τη διαδρομή, από 10,745 στο πρώτο epoch της δοκιμαστικής εκπαίδευσης σε 7,506 στο τελευταίο iteration της πλήρους εκτέλεσης. Αντίστοιχη πτωτική τάση καταγράφηκε σε όλες τις επιμέρους συνιστώσες, ενώ η συνιστώσα KoLeo παρέμεινε σταθερά κοντά στο μηδέν.

Οι καταγραφές αυτές, σε συνδυασμό με την απουσία μη πεπερασμένων τιμών, αποτελούν ενδείξεις αριθμητικά σταθερής εκπαίδευσης. Ωστόσο, η μείωση της loss δεν αρκεί από μόνη της για να αποκλειστεί το representation collapse ή να τεκμηριωθεί η βελτίωση της διακριτικής ικανότητας των χαρακτηριστικών. Για τον λόγο αυτό, η ποιότητα των μαθημένων αναπαραστάσεων εξετάστηκε μέσω της downstream αξιολόγησης των αποθηκευμένων checkpoints.

Κατά την πλήρη εκτέλεση αποθηκεύτηκαν τα checkpoints του EMA teacher ανά 10.000 iterations, τα οποία χρησιμοποιήθηκαν στη διαδικασία επιλογής του τελικού domain-adapted μοντέλου, όπως παρουσιάζεται στην Ενότητα 5.4.3.

5.4.3 Επιλογή Checkpoint και Τελική Downstream Εκτέλεση

Η επιλογή του τελικού domain-adapted DINOv2 ViT-B/14 πραγματοποιήθηκε σύμφωνα με το πρωτόκολλο δύο σταδίων της Ενότητας 4.4.1, χρησιμοποιώντας αποκλειστικά το validation set του GastroHUN.

Στο πρώτο στάδιο αξιολογήθηκαν τα δέκα checkpoints του EMA teacher, αποθηκευμένα ανά 10.000 iterations (9.999--99.999), μέσω frozen linear probing σε προϋπολογισμένα χαρακτηριστικά, μαζί με το generic-pretrained μοντέλο ως σημείο αναφοράς. Τα τρία καλύτερα checkpoints προχώρησαν στο δεύτερο στάδιο.

Στο δεύτερο στάδιο, τα τρία επικρατέστερα checkpoints αξιολογήθηκαν μέσω του πλήρους downstream pipeline, τόσο με frozen backbone όσο και με fine-tuning των τελευταίων 40% των transformer blocks. Πραγματοποιήθηκε μία εκτέλεση ανά συνδυασμό checkpoint και στρατηγικής εκπαίδευσης, ενώ η τελική κατάταξη βασίστηκε στο άθροισμα των δύο validation Macro-F1, σύμφωνα με το κριτήριο S_{val} της Ενότητας 4.4.1. Τα αναλυτικά αποτελέσματα και των δύο σταδίων παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.4.2.

Για την τελική σύγκριση, το επιλεγμένο checkpoint και το αντίστοιχο generic-pretrained μοντέλο εκπαιδεύτηκαν με τρία διαφορετικά random seeds (1, 2 και 3), τόσο στο frozen όσο και στο fine-tuned setting, ακολουθώντας το κοινό downstream πρωτόκολλο της Ενότητας 4.4.2. Η τελική αξιολόγηση πραγματοποιήθηκε στο ανεξάρτητο test set του GastroHUN, το οποίο δεν χρησιμοποιήθηκε κατά την επιλογή checkpoint. Τα τελικά αποτελέσματα παρουσιάζονται στο Κεφάλαιο 6, Ενότητα 6.4.3.

5.5 Αναπαραγωγιμότητα

Η πειραματική διαδικασία οργανώθηκε με στόχο τη διατήρηση της ιχνηλασιμότητας των εκτελέσεων και τη δυνατότητα αναπαραγωγής των αποτελεσμάτων. Για κάθε πείραμα χρησιμοποιήθηκαν διακριτά αρχεία ρυθμίσεων, SLURM scripts, αρχεία καταγραφής (*logs*) και κατάλογοι αποθήκευσης checkpoints και αποτελεσμάτων. Η οργάνωση αυτή επέτρεψε την αντιστοίχιση των παραγόμενων μοντέλων με τις συνθήκες προεκπαίδευσης και downstream αξιολόγησής τους.

Η προεπεξεργασία του HyperKvasir πραγματοποιήθηκε με καθορισμένα κριτήρια αποκλεισμού και αποδιπλοποίησης, ενώ για το GastroHUN διατηρήθηκε ο επίσημος διαχωρισμός σε επίπεδο ασθενούς, ώστε να αποφεύγεται η διαρροή δεδομένων μεταξύ των συνόλων εκπαίδευσης, επικύρωσης και ελέγχου. Επιπλέον, εφαρμόστηκε κοινό downstream πρωτόκολλο για τα generic-pretrained και domain-adapted μοντέλα, με προκαθορισμένες στρατηγικές frozen και partial fine-tuning. Η επιλογή των checkpoints βασίστηκε αποκλειστικά στο validation set, ενώ το test set χρησιμοποιήθηκε μόνο για την τελική αξιολόγηση.

Οι περιορισμοί που απορρέουν από τις παραπάνω μεθοδολογικές επιλογές συζητούνται συγκεντρωτικά, με ερμηνευτική προσέγγιση ως προς τις συνέπειές τους στα ευρήματα, στην Ενότητα 7.7.

Κεφάλαιο 6: Αποτελέσματα

Το παρόν κεφάλαιο παρουσιάζει τα αριθμητικά αποτελέσματα της πειραματικής διαδικασίας, χωρίς ερμηνεία ή συζήτηση των ευρημάτων, η οποία ακολουθεί στο Κεφάλαιο 7.

6.1 Προκαταρκτική Διερεύνηση και Καθορισμός του Downstream Training Protocol

6.1.1 Αποτελέσματα Αναπαραγωγής και Επέκτασης του GastroHUN

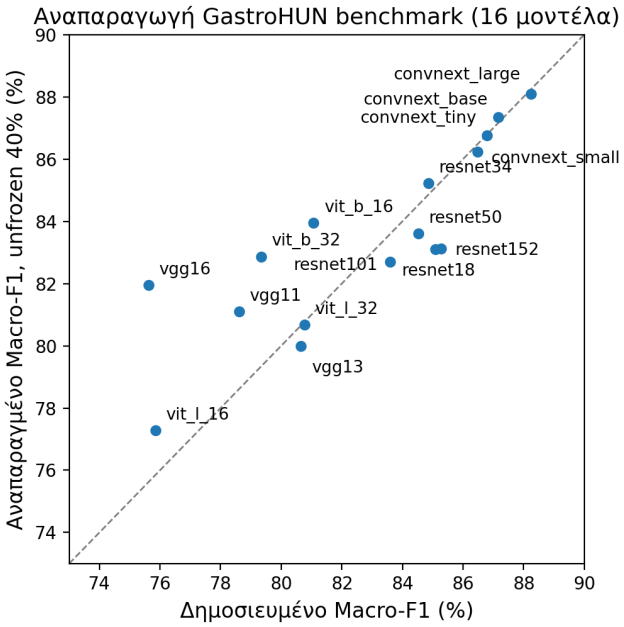
Ο Πίνακας 6.1 και το Σχήμα 6.1 συγκρίνουν τις δημοσιευμένες με τις αναπαραγμένες επιδόσεις Macro-F1 για τα 16 μοντέλα αναφοράς του GastroHUN, με partial fine-tuning και 40% unfrozen layers, όπως ορίστηκε στο δημοσιευμένο πρωτόκολλο.

Πίνακας 6.1: Σύγκριση δημοσιευμένων και αναπαραγμένων επιδόσεων Macro-F1 για τα 16 μοντέλα αναφοράς του GastroHUN, με partial fine-tuning και 40% unfrozen layers.

Μοντέλο	**Δημοσιευμένο**	**Αναπαραγμένο**	**Δ**
convnext_tiny	$86{,}79 \pm 0{,}26$	$86{,}77$	$-0{,}02$
convnext_small	$86{,}47 \pm 0{,}28$	$86{,}23$	$-0{,}24$
convnext_base	$87{,}16 \pm 0{,}29$	$87{,}34$	$+0{,}18$
convnext_large	$88{,}25 \pm 0{,}22$	$88{,}10$	$-0{,}16$
resnet18	$85{,}08 \pm 0{,}25$	$83{,}11$	$-1{,}97$
resnet34	$84{,}85 \pm 0{,}25$	$85{,}23$	$+0{,}39$
resnet50	$84{,}53 \pm 0{,}29$	$83{,}61$	$-0{,}92$
resnet101	$83{,}59 \pm 0{,}32$	$82{,}69$	$-0{,}89$
resnet152	$85{,}28 \pm 0{,}27$	$83{,}12$	$-2{,}16$
vgg11	$78{,}61 \pm 0{,}28$	$81{,}10$	$+2{,}49$
vgg13	$80{,}65 \pm 0{,}31$	$79{,}99$	$-0{,}66$
vgg16	$75{,}62 \pm 0{,}34$	$81{,}95$	$+6{,}33$
vit_b_16	$81{,}07 \pm 0{,}30$	$83{,}95$	$+2{,}88$
vit_b_32	$79{,}33 \pm 0{,}36$	$82{,}87$	$+3{,}53$
vit_l_16	$75{,}85 \pm 0{,}34$	$77{,}28$	$+1{,}42$
vit_l_32	$80{,}77 \pm 0{,}29$	$80{,}67$	$-0{,}10$

Σημείωση: Η δημοσιευμένη επίδοση δίνεται ως μέση τιμή $\pm$ περιθώριο 95% διαστήματος εμπιστοσύνης, ενώ η αναπαραγμένη ως μέση τιμή. $\Delta F_1 = F_{1,\text{αναπαραγμένο}} - F_{1,\text{δημοσιευμένο}}$.

Στη συνέχεια, ο Πίνακας 6.2 και το Σχήμα 6.2 παρουσιάζουν την κατάταξη των 24 αρχιτεκτονικών (16 αρχικά μοντέλα αναφοράς και 8 generic DINO/DINOv2 backbones) βάσει Macro-F1 μετά το partial fine-tuning.

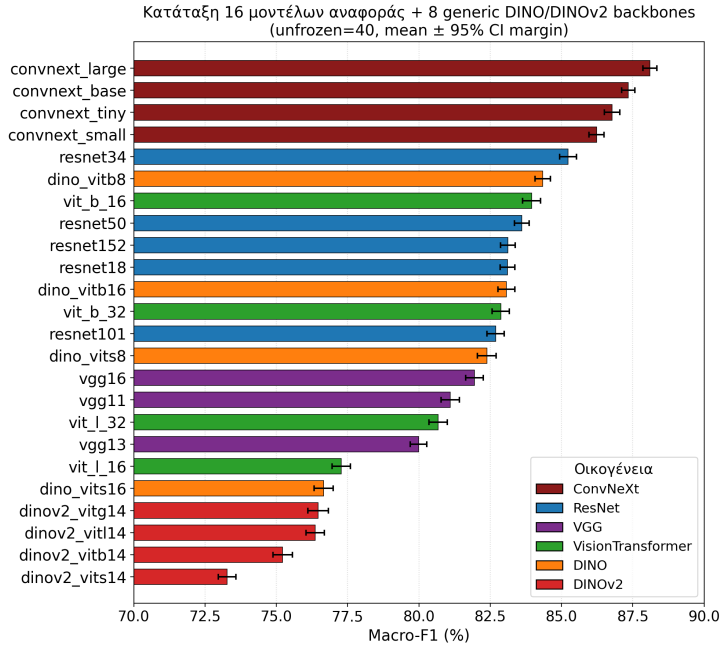


Σχήμα 6.1: Δημοσιευμένο έναντι αναπαραγμένου Macro-F1 για τα 16 μοντέλα αναφοράς, με partial fine-tuning 40%. Η διακεκομμένη γραμμή αντιστοιχεί στην ισότητα των δύο επιδόσεων ($y = x$).

Πίνακας 6.2: Κατάταξη των 24 αρχιτεκτονικών στο GastroHUN benchmark βάσει Macro-F1, με partial fine-tuning και 40% unfrozen layers.

Κατάταξη	**Μοντέλο (οικογένεια)**	**Macro-F1 (%)**
1	convnext_large (ConvNeXt)	$88{,}10 \pm 0{,}24$
2	convnext_base (ConvNeXt)	$87{,}34 \pm 0{,}23$
3	convnext_tiny (ConvNeXt)	$86{,}77 \pm 0{,}27$
4	convnext_small (ConvNeXt)	$86{,}23 \pm 0{,}26$
5	resnet34 (ResNet)	$85{,}23 \pm 0{,}29$
6	dino_vitb8 (DINO)	$84{,}34 \pm 0{,}27$
7	vit_b_16 (Vision Transformer)	$83{,}95 \pm 0{,}31$
8	resnet50 (ResNet)	$83{,}61 \pm 0{,}26$
9	resnet152 (ResNet)	$83{,}12 \pm 0{,}26$
10	resnet18 (ResNet)	$83{,}11 \pm 0{,}26$
11	dino_vitb16 (DINO)	$83{,}07 \pm 0{,}30$
12	vit_b_32 (Vision Transformer)	$82{,}87 \pm 0{,}30$
13	resnet101 (ResNet)	$82{,}69 \pm 0{,}30$
14	dino_vits8 (DINO)	$82{,}38 \pm 0{,}33$
15	vgg16 (VGG)	$81{,}95 \pm 0{,}31$
16	vgg11 (VGG)	$81{,}10 \pm 0{,}32$
17	vit_l_32 (Vision Transformer)	$80{,}67 \pm 0{,}32$
18	vgg13 (VGG)	$79{,}99 \pm 0{,}29$
19	vit_l_16 (Vision Transformer)	$77{,}28 \pm 0{,}32$
20	dino_vits16 (DINO)	$76{,}66 \pm 0{,}33$
21	dinov2_vitg14 (DINOv2)	$76{,}46 \pm 0{,}36$
22	dinov2_vitl14 (DINOv2)	$76{,}36 \pm 0{,}32$
23	dinov2_vitb14 (DINOv2)	$75{,}22 \pm 0{,}34$
24	dinov2_vits14 (DINOv2)	$73{,}27 \pm 0{,}31$

Σημείωση: Οι τιμές εκφράζονται ως μέση Macro-F1 $\pm$ ημιεύρος του 95% διαστήματος εμπιστοσύνης, σε ποσοστιαία κλίμακα. Τα οκτώ DINO/DINOv2 backbones χρησιμοποιούν τα αρχικά generic pretrained checkpoints, χωρίς continued self-supervised pretraining στο HyperKvasir.



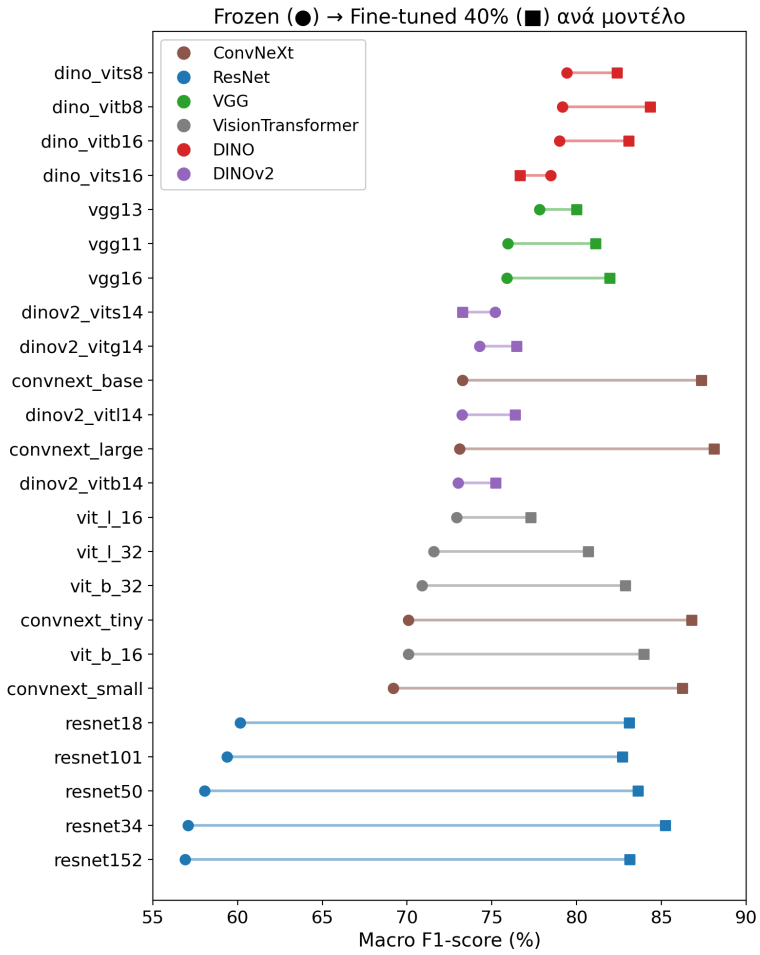
Σχήμα 6.2: Κατάταξη των 16 μοντέλων αναφοράς του GastroHUN και των 8 generic DINO/DINOv2 backbones, με unfrozen 40%, βάσει της μέσης επίδοσης Macro-F1.

Πέρα από το partial fine-tuning, τα ίδια 24 μοντέλα αξιολογήθηκαν και με πλήρως *frozen* backbone (*linear probing*). Ο Πίνακας 6.3 και το Σχήμα 6.3 συγκρίνουν τις δύο στρατηγικές, με ταξινόμηση κατά φθίνουσα frozen Macro-F1.

Πίνακας 6.3: Σύγκριση frozen linear probing και partial fine-tuning (40% unfrozen layers) στα 24 μοντέλα. Οι επιδόσεις εκφράζονται ως Macro-F1 (%) και η διαφορά Δ σε ποσοστιαίες μονάδες.

Μοντέλο	**Frozen**	**Fine-tuned (40%)**	Δ
dino_vits8	79,43	82,38	+2,95
dino_vitb8	79,17	84,34	+5,18
dino_vitb16	78,99	83,07	+4,09
dino_vits16	78,46	76,66	−1,80
vgg13	77,80	79,99	+2,18
vgg11	75,95	81,10	+5,15
vgg16	75,87	81,95	+6,08
dinov2_vits14	75,18	73,27	−1,91
dinov2_vitg14	74,26	76,46	+2,20
convnext_base	73,26	87,34	+14,08
dinov2_vitl14	73,25	76,36	+3,11
convnext_large	73,08	88,10	+15,02
dinov2_vitb14	73,02	75,22	+2,20
vit_l_16	72,91	77,28	+4,37
vit_l_32	71,56	80,67	+9,11
vit_b_32	70,87	82,87	+11,99
convnext_tiny	70,08	86,77	+16,69
vit_b_16	70,06	83,95	+13,90
convnext_small	69,17	86,23	+17,06
resnet18	60,16	83,11	+22,96
resnet101	59,39	82,69	+23,30
resnet50	58,05	83,61	+25,56
resnet34	57,08	85,23	+28,15
resnet152	56,90	83,12	+26,22

Σημείωση: Δ = fine-tuned − frozen Macro-F1.



Σχήμα 6.3: Frozen (●) έναντι fine-tuned 40% (■) Macro-F1 ανά μοντέλο, χρωματισμένο κατά οικογένεια αρχιτεκτονικής.

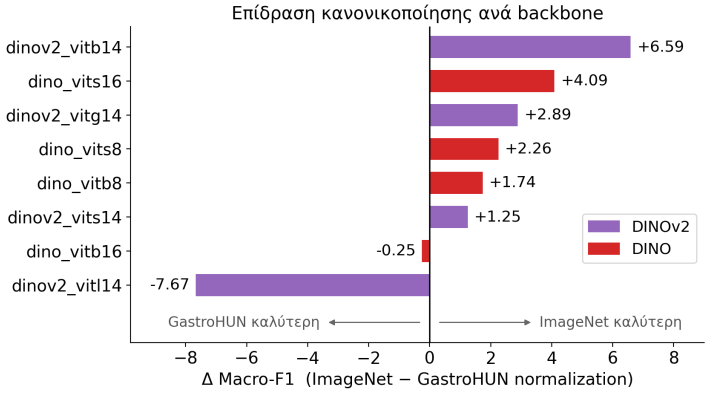
6.1.2 Αποτελέσματα Διερεύνησης Training Configuration

Ο Πίνακας 6.4 και το Σχήμα 6.4 παρουσιάζουν την επίδραση της κανονικοποίησης (στατιστικά GastroHUN έναντι ImageNet) στα οκτώ generic DINO/DINOv2 backbones.

Πίνακας 6.4: Επίδραση της κανονικοποίησης στα οκτώ generic DINO/DINOv2 backbones. Οι επιδόσεις εκφράζονται ως Macro-F1 (%) και η διαφορά Δ σε ποσοστιαίες μονάδες (ImageNet − GastroHUN).

Μοντέλο	**Οικογένεια**	**GastroHUN**	**ImageNet**	Δ
dinov2_vitb14	DINOv2	$72{,}41 \pm 0{,}32$	$79{,}00 \pm 0{,}32$	$+6{,}59$
dino_vits16	DINO	$73{,}65 \pm 0{,}36$	$77{,}74 \pm 0{,}32$	$+4{,}09$
dinov2_vitg14	DINOv2	$75{,}72 \pm 0{,}33$	$78{,}61 \pm 0{,}30$	$+2{,}89$
dino_vits8	DINO	$82{,}92 \pm 0{,}31$	$85{,}18 \pm 0{,}26$	$+2{,}26$
dino_vitb8	DINO	$82{,}73 \pm 0{,}27$	$84{,}47 \pm 0{,}30$	$+1{,}74$
dinov2_vits14	DINOv2	$72{,}96 \pm 0{,}31$	$74{,}21 \pm 0{,}31$	$+1{,}25$
dino_vitb16	DINO	$83{,}09 \pm 0{,}31$	$82{,}84 \pm 0{,}32$	$-0{,}25$
dinov2_vitl14	DINOv2	$77{,}60 \pm 0{,}31$	$69{,}93 \pm 0{,}38$	$-7{,}67$

Σημείωση: Θετικό Δ υποδηλώνει υψηλότερη επίδοση με κανονικοποίηση ImageNet.



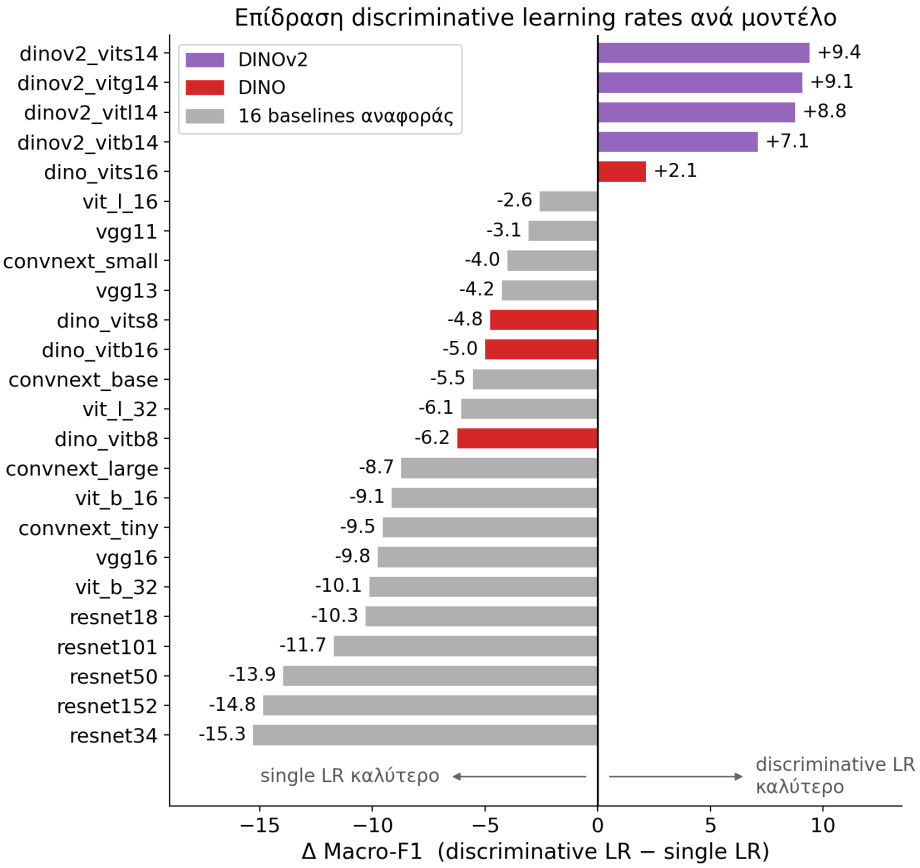
Σχήμα 6.4: Διαφορά Macro-F1 (ImageNet − GastroHUN κανονικοποίηση) ανά backbone.

Ο Πίνακας 6.5 και το Σχήμα 6.5 παρουσιάζουν τη σύγκριση frozen, ενιαίου learning rate και discriminative learning rates στις 24 αρχιτεκτονικές.

Πίνακας 6.5: Σύγκριση frozen linear probing, ενιαίου learning rate και discriminative learning rates στις 24 αρχιτεκτονικές. Οι επιδόσεις εκφράζονται ως Macro-F1 (%) και το Δ ως discriminative − single LR, σε ποσοστιαίες μονάδες.

Μοντέλο	**Frozen**	**Single LR**	**Discriminative LR**	Δ
dinov2_vits14	75,18	73,27	82,67	+9,40
dinov2_vitg14	74,26	76,46	85,55	+9,09
dinov2_vitl14	73,25	76,36	85,12	+8,76
dinov2_vitb14	73,02	75,22	82,33	+7,11
dino_vits16	78,46	76,66	78,81	+2,15
vit_l_16	72,91	77,28	74,70	−2,58
vgg11	75,95	81,10	78,04	−3,06
convnext_small	69,17	86,23	82,22	−4,01
vgg13	77,80	79,99	75,74	−4,25
dino_vits8	79,43	82,38	77,61	−4,77
dino_vitb16	78,99	83,07	78,07	−5,00
convnext_base	73,26	87,34	81,81	−5,53
vit_l_32	71,56	80,67	74,61	−6,06
dino_vitb8	79,17	84,34	78,13	−6,22
convnext_large	73,08	88,10	79,39	−8,71
vit_b_16	70,06	83,95	74,82	−9,13
convnext_tiny	70,08	86,77	77,24	−9,54
vgg16	75,87	81,95	72,20	−9,76
vit_b_32	70,87	82,87	72,74	−10,13
resnet18	60,16	83,11	72,81	−10,30
resnet101	59,39	82,69	70,99	−11,70
resnet50	58,05	83,61	69,66	−13,95
resnet152	56,90	83,12	68,28	−14,84
resnet34	57,08	85,23	69,93	−15,30

Σημείωση: Θετικό Δ υποδηλώνει βελτίωση με discriminative learning rates.



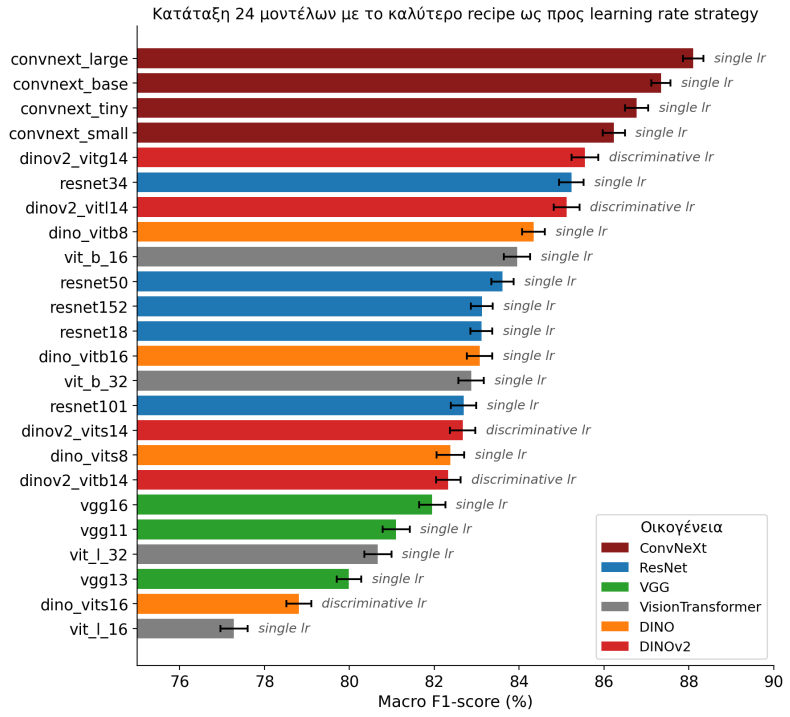
Σχήμα 6.5: Διαφορά Macro-F1 (discriminative LR − single LR) ανά μοντέλο· DINOv2 (μωβ) και DINO (κόκκινο) ξεχωρίζουν σαφώς από τις υπόλοιπες οικογένειες.

Συνοψίζοντας τις δύο προηγούμενες συγκρίσεις, ο Πίνακας 6.6 και το Σχήμα 6.6 παρουσιάζουν μια εναλλακτική κατάταξη των 24 μοντέλων, στην οποία κάθε μοντέλο εμφανίζεται με το δικό του καλύτερο επικυρωμένο recipe *ως προς τη στρατηγική learning rate* (`single_lr` ή `discriminative_lr`), αντί του ενιαίου recipe που χρησιμοποιείται στη βασική σύγκριση του Πίνακα 6.2.

Πίνακας 6.6: Κατάταξη 24 μοντέλων κατά Macro-F1, με το καλύτερο επικυρωμένο recipe ως προς learning rate strategy ανά μοντέλο.

Κατάταξη	Μοντέλο (οικογένεια)	Recipe	Macro-F1
1	convnext_large (ConvNeXt)	`single_lr`	88,10 ± 0,24
2	convnext_base (ConvNeXt)	`single_lr`	87,34 ± 0,23
3	convnext_tiny (ConvNeXt)	`single_lr`	86,77 ± 0,27
4	convnext_small (ConvNeXt)	`single_lr`	86,23 ± 0,26
5	dinov2_vitg14 (DINOv2)	`discriminative_lr`	85,55 ± 0,32
6	resnet34 (ResNet)	`single_lr`	85,23 ± 0,29
7	dinov2_vitl14 (DINOv2)	`discriminative_lr`	85,12 ± 0,30
8	dino_vitb8 (DINO)	`single_lr`	84,34 ± 0,27
9	vit_b_16 (Vision Transformer)	`single_lr`	83,95 ± 0,31
10	resnet50 (ResNet)	`single_lr`	83,61 ± 0,26
11	resnet152 (ResNet)	`single_lr`	83,12 ± 0,26
12	resnet18 (ResNet)	`single_lr`	83,11 ± 0,26
13	dino_vitb16 (DINO)	`single_lr`	83,07 ± 0,30
14	vit_b_32 (Vision Transformer)	`single_lr`	82,87 ± 0,30
15	resnet101 (ResNet)	`single_lr`	82,69 ± 0,30
16	dinov2_vits14 (DINOv2)	`discriminative_lr`	82,67 ± 0,30
17	dino_vits8 (DINO)	`single_lr`	82,38 ± 0,33
18	dinov2_vitb14 (DINOv2)	`discriminative_lr`	82,33 ± 0,29
19	vgg16 (VGG)	`single_lr`	81,95 ± 0,31
20	vgg11 (VGG)	`single_lr`	81,10 ± 0,32
21	vit_l_32 (Vision Transformer)	`single_lr`	80,67 ± 0,32
22	vgg13 (VGG)	`single_lr`	79,99 ± 0,29
23	dino_vits16 (DINO)	`discriminative_lr`	78,81 ± 0,29
24	vit_l_16 (Vision Transformer)	`single_lr`	77,28 ± 0,32

Σημείωση: Η κανονικοποίηση παραμένει σταθερή.



Σχήμα 6.6: Κατάταξη 24 μοντέλων κατά Macro-F1 με το καλύτερο επικυρωμένο recipe ως προς learning rate strategy ανά μοντέλο, με την αντίστοιχη στρατηγική σημειωμένη δίπλα σε κάθε μπάρα.

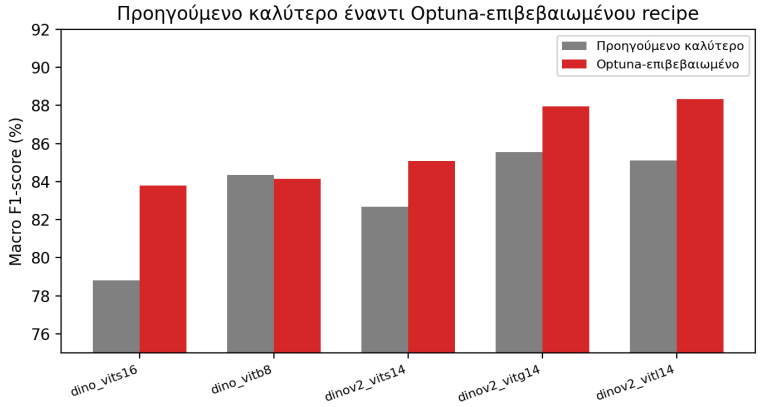
6.1.3 Αποτελέσματα Βελτιστοποίησης Υπερπαραμέτρων με Optuna

Ο Πίνακας 6.7 και το Σχήμα 6.7 συνοψίζουν τα αποτελέσματα της αναζήτησης Optuna (μεθοδολογία: Ενότητα 4.3.3) για τέσσερα DINO/DINOv2 backbones πέραν των 16 αρχικών αρχιτεκτονικών αναφοράς, καθώς και για το DINOv2 ViT-g/14, για το οποίο το recipe προέκυψε από παρεκβολή, με πλήρη εκπαίδευση και αξιολόγηση στο test set.

Πίνακας 6.7: Macro-F1 (%) στο test set, πριν και μετά το recipe που ανέδειξε η αναζήτηση Optuna, για τα DINO/DINOv2 backbones πέραν των 16 αρχικών αρχιτεκτονικών αναφοράς.

Μοντέλο	**Προηγούμενο καλύτερο**	**Optuna-επιβεβαιωμένο**	Δ
dino_vits16	78,81	83,79	+4,98
dino_vitb8	84,34	84,14	−0,20
dinov2_vits14	82,67	85,09	+2,42
dinov2_vitg14	85,55	87,95	+2,40
dinov2_vitl14	85,12	88,33	+3,21

Σημείωση: Το recipe του dinov2_vitg14 προέκυψε από παρεκβολή και όχι από ανεξάρτητη αναζήτηση.



Σχήμα 6.7: Προηγούμενο καλύτερο έναντι Optuna-επιβεβαιωμένου recipe, στο test set.

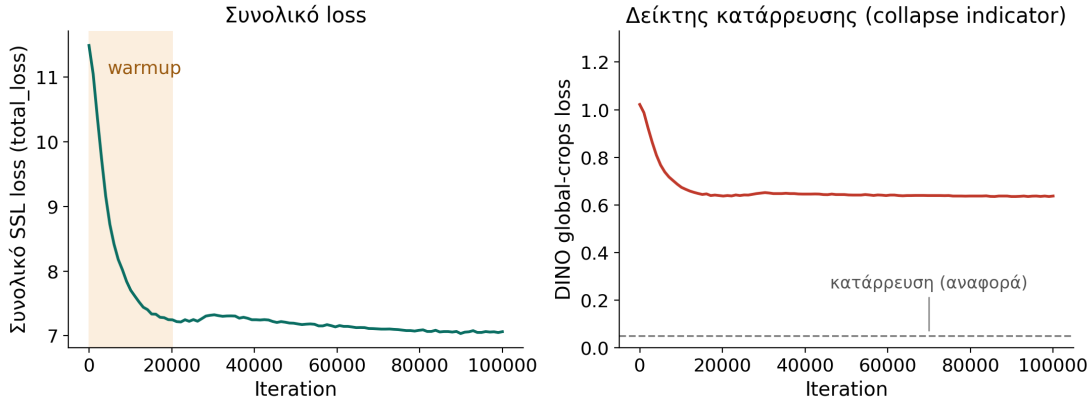
Οι επόμενες ενότητες παρουσιάζουν τα αποτελέσματα των τριών κύριων πειραμάτων continued pretraining.

6.2 Πείραμα 1: DINOv2 ViT-S/14 --- Generic έναντι Domain-Adapted

Η παρούσα ενότητα παρουσιάζει τα αποτελέσματα του πρώτου πειράματος continued pretraining (DINOv2 ViT-S/14+reg4), σύμφωνα με τη μεθοδολογία και τις ρυθμίσεις προεκπαίδευσης των Ενοτήτων 5.2.1--5.2.3.

6.2.1 Αποτελέσματα SSL Pretraining

Το Σχήμα 6.8 παρουσιάζει την εξέλιξη της συνολικής συνάρτησης απώλειας και της συνιστώσας `dino_global_crops_loss` στο σύνολο των 100.000 iterations της πλήρους εκτέλεσης.



Σχήμα 6.8: Εξέλιξη του συνολικού SSL loss (αριστερά) και της συνιστώσας `dino_global_crops_loss` (δεξιά, δείκτης representation collapse) στο σύνολο των 100.000 iterations του Πειράματος 1. Η σκιασμένη περιοχή αντιστοιχεί στη φάση warmup (20.000 πρώτα iterations).

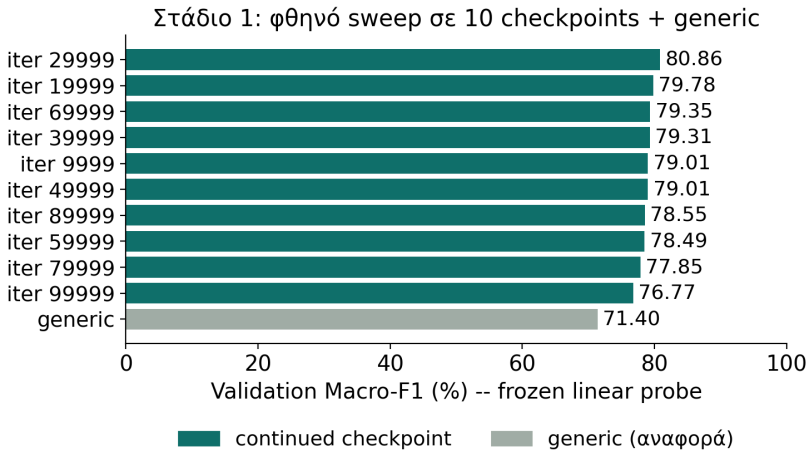
Η συνολική loss μειώνεται από $11{,}52$ σε $7{,}24$ μέχρι το τέλος του warmup (iteration 20.000) και φτάνει το $7{,}06$ στο iteration 99.999. Η συνιστώσα `dino_global_crops_loss` βρίσκεται κοντά στο $0{,}64$ από το iteration 16.000 και έπειτα.

6.2.2 Αποτελέσματα Επιλογής Checkpoint

Ο Πίνακας 6.8 και το Σχήμα 6.9 παρουσιάζουν τα αποτελέσματα του πρώτου σταδίου επιλογής (frozen linear probing σε προϋπολογισμένα χαρακτηριστικά, validation set).

Πίνακας 6.8: Στάδιο 1: validation Macro-F1 (%) από frozen linear probing, για το generic checkpoint και τα δέκα checkpoints του EMA teacher.

Checkpoint	**Macro-F1 (%)**
iter 29.999	80,86
iter 19.999	79,78
iter 69.999	79,35
iter 39.999	79,31
iter 9.999	79,01
iter 49.999	79,01
iter 89.999	78,55
iter 59.999	78,49
iter 79.999	77,85
iter 99.999	76,77
generic	71,40

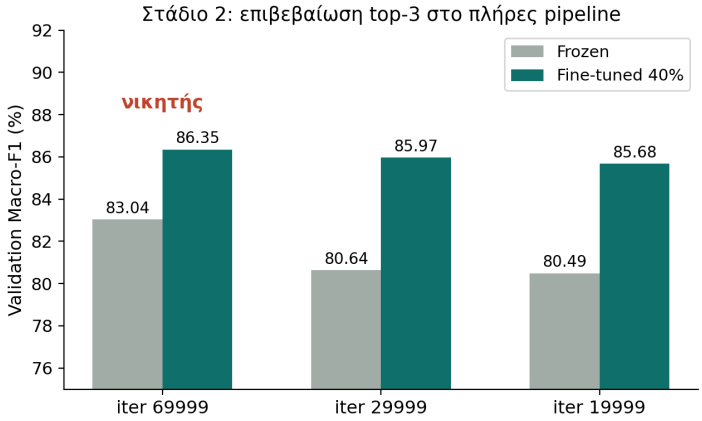


Σχήμα 6.9: Στάδιο 1 επιλογής checkpoint: validation Macro-F1 από frozen linear probing, σε φθίνουσα σειρά.

Τα τρία καλύτερα checkpoints του πρώτου σταδίου (iterations 29.999, 19.999 και 69.999) αξιολογήθηκαν στη συνέχεια μέσω του πλήρους downstream pipeline, τόσο με frozen backbone όσο και με fine-tuning 40%. Ο Πίνακας 6.9 και το Σχήμα 6.10 παρουσιάζουν τα αποτελέσματα του δεύτερου σταδίου.

Πίνακας 6.9: Στάδιο 2: validation Macro-F1 (%) για τα τρία επικρατέστερα checkpoints, με βάση το κριτήριο S_{val}.

Checkpoint	**Frozen**	**Fine-tuned**	S_{val}
iter 69.999	83,04	86,35	**169,38**
iter 29.999	80,64	85,97	166,60
iter 19.999	80,49	85,68	166,18



Σχήμα 6.10: Στάδιο 2 επιλογής checkpoint: validation Macro-F1 ανά στρατηγική αξιολόγησης, για τα τρία επικρατέστερα checkpoints. Νικητής: iteration 69.999.

Το checkpoint του iteration 69.999 παρουσίασε την υψηλότερη συνδυαστική επίδοση ($S_{\text{val}} = 169{,}38$) και επιλέχθηκε ως το τελικό domain-adapted backbone, παρότι είχε καταταχθεί τρίτο στο πρώτο στάδιο.

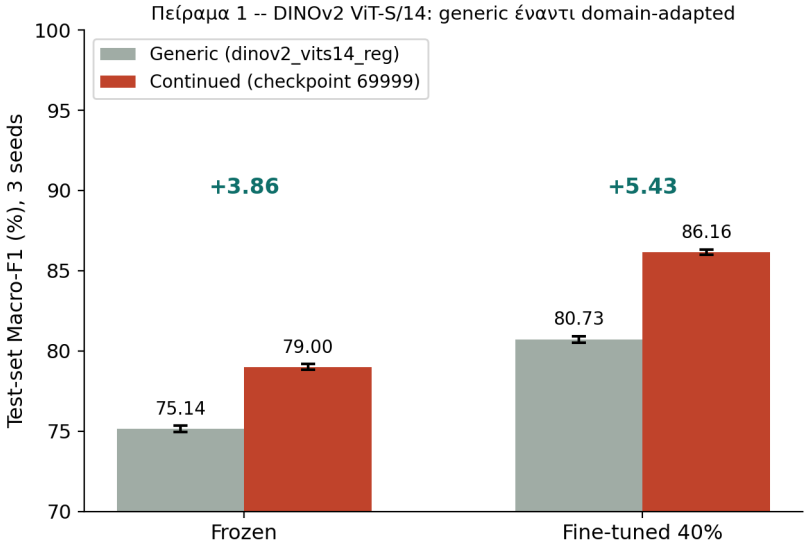
6.2.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint

Ο Πίνακας 6.10 και το Σχήμα 6.11 παρουσιάζουν την τελική σύγκριση του generic-pretrained και του επιλεγμένου domain-adapted checkpoint (iteration 69.999) στο test set, με τρία seeds ανά στρατηγική αξιολόγησης.

Πίνακας 6.10: Πείραμα 1: τελική σύγκριση generic και domain-adapted DINOv2 ViT-S/14 στο test set, μέση τιμή Macro-F1 ± περιθώριο 95% CI (3 seeds).

Στρατηγική	**Generic**	**Domain-adapted**	**Δ**
Frozen	75,14 ± 0,20	79,00 ± 0,17	+3,86
Fine-tuned (40%)	80,73 ± 0,20	86,16 ± 0,16	+5,43

Σημείωση: Generic: `dinov2_vits14_reg` (αρχικό checkpoint). Domain-adapted: `dinov2_vits14_reg`, βάρη από το iteration 69.999.



Σχήμα 6.11: Πείραμα 1: τελική σύγκριση Macro-F1 στο test set, generic έναντι domain-adapted DINOv2 ViT-S/14, frozen και fine-tuned 40% (μέση τιμή ± περιθώριο 95% CI, 3 seeds).

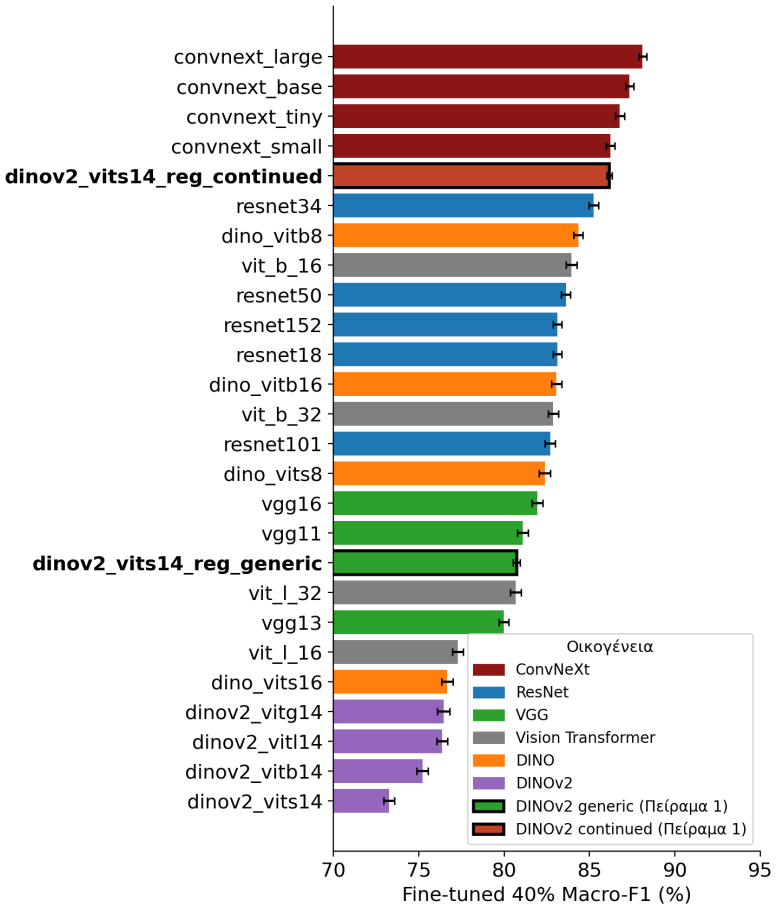
6.2.4 Τοποθέτηση στο Πλήρες Downstream Benchmark

Πέρα από την απευθείας σύγκριση generic και domain-adapted checkpoint (Ενότητα 6.2.3), τα δύο αυτά μοντέλα εντάχθηκαν στο πλήρες σύνολο των 24 αρχιτεκτονικών της Ενότητας 6.1.1, υπό τις ίδιες συνθήκες αξιολόγησης και το ίδιο recipe. Ο Πίνακας 6.11 και τα Σχήματα 6.12--6.13 παρουσιάζουν την πλήρη κατάταξη 26 μοντέλων (24 αρχικά + generic και domain-adapted DINOv2 ViT-S/14+reg4), για τα δύο σενάρια αξιολόγησης.

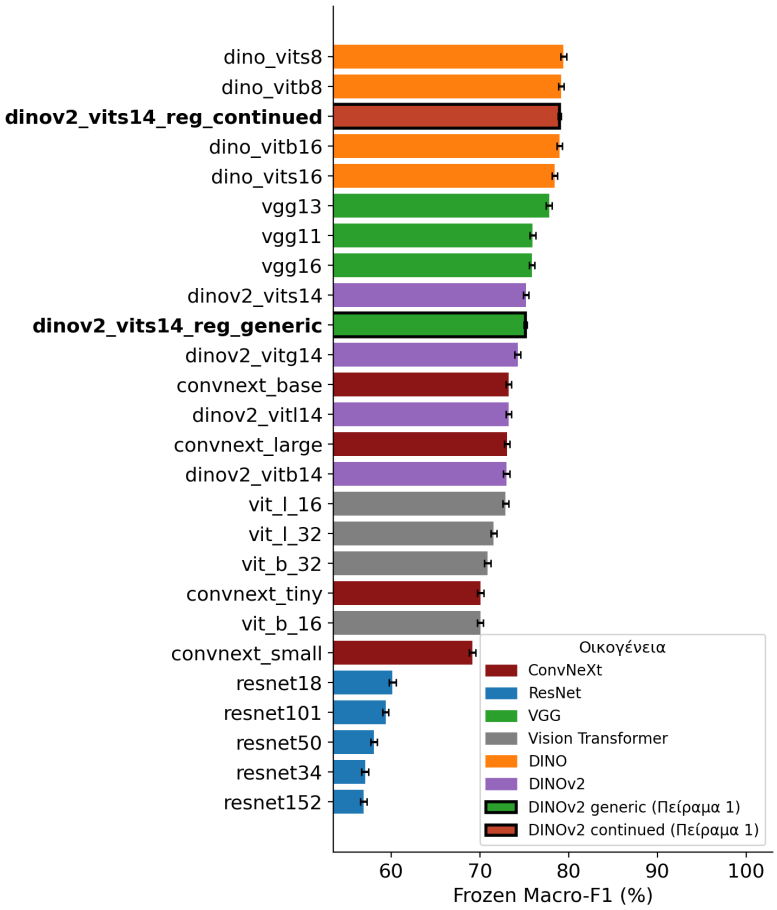
Πίνακας 6.11: Πλήρης κατάταξη 26 μοντέλων (24 αρχικά της Ενότητας 6.1.1 + generic/domain-adapted DINOv2 ViT-S/14+reg4 του Πειράματος 1), κατά φθίνουσα σειρά fine-tuned Macro-F1 (%).

Κατάταξη	**Μοντέλο (οικογένεια)**	**Frozen**	**Fine-tuned (40%)**
1	convnext_large (ConvNeXt)	$73{,}08 \pm 0{,}32$	$88{,}10 \pm 0{,}24$
2	convnext_base (ConvNeXt)	$73{,}26 \pm 0{,}30$	$87{,}34 \pm 0{,}23$
3	convnext_tiny (ConvNeXt)	$70{,}08 \pm 0{,}35$	$86{,}77 \pm 0{,}27$
4	convnext_small (ConvNeXt)	$69{,}17 \pm 0{,}36$	$86{,}23 \pm 0{,}26$
5	**dinov2_vits14_reg_continued (DINOv2, Πείραμα 1)**	$79{,}00 \pm 0{,}17$	$86{,}16 \pm 0{,}16$
6	resnet34 (ResNet)	$57{,}08 \pm 0{,}40$	$85{,}23 \pm 0{,}29$
7	dino_vitb8 (DINO)	$79{,}17 \pm 0{,}30$	$84{,}34 \pm 0{,}27$
8	vit_b_16 (Vision Transformer)	$70{,}06 \pm 0{,}32$	$83{,}95 \pm 0{,}31$
9	resnet50 (ResNet)	$58{,}05 \pm 0{,}37$	$83{,}61 \pm 0{,}26$
10	resnet152 (ResNet)	$56{,}90 \pm 0{,}37$	$83{,}12 \pm 0{,}26$
11	resnet18 (ResNet)	$60{,}16 \pm 0{,}40$	$83{,}11 \pm 0{,}26$
12	dino_vitb16 (DINO)	$78{,}99 \pm 0{,}32$	$83{,}07 \pm 0{,}30$
13	vit_b_32 (Vision Transformer)	$70{,}87 \pm 0{,}35$	$82{,}87 \pm 0{,}30$
14	resnet101 (ResNet)	$59{,}39 \pm 0{,}36$	$82{,}69 \pm 0{,}30$
15	dino_vits8 (DINO)	$79{,}43 \pm 0{,}33$	$82{,}38 \pm 0{,}33$
16	vgg16 (VGG)	$75{,}87 \pm 0{,}28$	$81{,}95 \pm 0{,}31$
17	vgg11 (VGG)	$75{,}95 \pm 0{,}34$	$81{,}10 \pm 0{,}32$
18	**dinov2_vits14_reg_generic (DINOv2, Πείραμα 1)**	$75{,}14 \pm 0{,}20$	$80{,}73 \pm 0{,}20$
19	vit_l_32 (Vision Transformer)	$71{,}56 \pm 0{,}34$	$80{,}67 \pm 0{,}32$
20	vgg13 (VGG)	$77{,}80 \pm 0{,}32$	$79{,}99 \pm 0{,}29$
21	vit_l_16 (Vision Transformer)	$72{,}91 \pm 0{,}33$	$77{,}28 \pm 0{,}32$
22	dino_vits16 (DINO)	$78{,}46 \pm 0{,}30$	$76{,}66 \pm 0{,}33$
23	dinov2_vitg14 (DINOv2)	$74{,}26 \pm 0{,}32$	$76{,}46 \pm 0{,}36$
24	dinov2_vitl14 (DINOv2)	$73{,}25 \pm 0{,}31$	$76{,}36 \pm 0{,}32$
25	dinov2_vitb14 (DINOv2)	$73{,}02 \pm 0{,}36$	$75{,}22 \pm 0{,}34$
26	dinov2_vits14 (DINOv2)	$75{,}18 \pm 0{,}30$	$73{,}27 \pm 0{,}31$

Σημείωση: Για τα δύο μοντέλα του Πειράματος 1 η κατανομή προκύπτει από 3 seeds (πλήρες test set bootstrap $\times$ seeds), για τα υπόλοιπα 24 από μία εκτέλεση.



Σχήμα 6.12: Πλήρης κατάταξη 26 μοντέλων, fine-tuned 40% Macro-F1. Το ζεύγος generic/domain-adapted DINOv2 ViT-S/14+reg4 του Πειράματος 1 επισημαίνεται με πράσινο/κόκκινο περίγραμμα.



Σχήμα 6.13: Πλήρης κατάταξη 26 μοντέλων, frozen Macro-F1. Στο σενάριο αυτό τα SSL-pretrained backbones (DINO/DINOv2) καταλαμβάνουν τις υψηλότερες θέσεις.

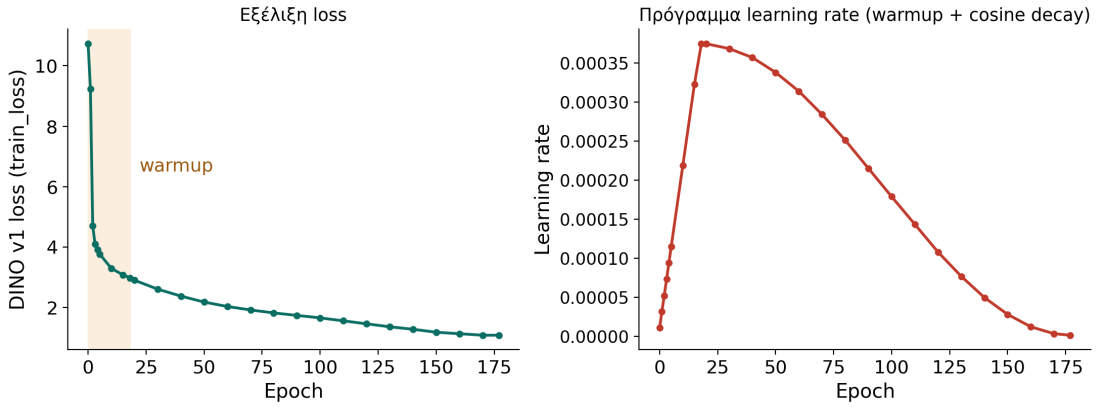
Στο fine-tuned σενάριο, το domain-adapted DINOv2 ViT-S/14+reg4 καταλαμβάνει την 5η θέση ανάμεσα σε 26 μοντέλα, αμέσως μετά τα τέσσερα ConvNeXt και πριν από κάθε ResNet, ViT, VGG, DINO ή άλλη παραλλαγή DINOv2. Στο frozen σενάριο καταλαμβάνει την 3η θέση, πίσω μόνο από δύο παραλλαγές DINO. Το αντίστοιχο generic checkpoint κατατάσσεται χαμηλότερα και στα δύο σενάρια (18η θέση fine-tuned, 10η θέση frozen).

6.3 Πείραμα 2: DINO ViT-S/16 --- Generic έναντι Domain-Adapted

Η παρούσα ενότητα παρουσιάζει τα αποτελέσματα του δεύτερου πειράματος continued pretraining (DINO ViT-S/16), σύμφωνα με τη μεθοδολογία και τις ρυθμίσεις προεκπαίδευσης των Ενοτήτων 5.3.1--5.3.3.

6.3.1 Αποτελέσματα SSL Pretraining

Το Σχήμα 6.14 παρουσιάζει την εξέλιξη της loss και του learning rate στο σύνολο των 178 epochs της πλήρους εκτέλεσης. Σε αντίθεση με τη DINOv2 υλοποίηση του Πειράματος 1, η αρχική υλοποίηση DINO καταγράφει έναν μέσο όρο loss ανά epoch, χωρίς ανάλυση σε επιμέρους συνιστώσες.



Σχήμα 6.14: Εξέλιξη του loss (αριστερά) και του learning rate (δεξιά) στο σύνολο των 178 epochs του Πειράματος 2. Η σκιασμένη περιοχή αντιστοιχεί στη φάση warmup (πρώτα 18 epochs).

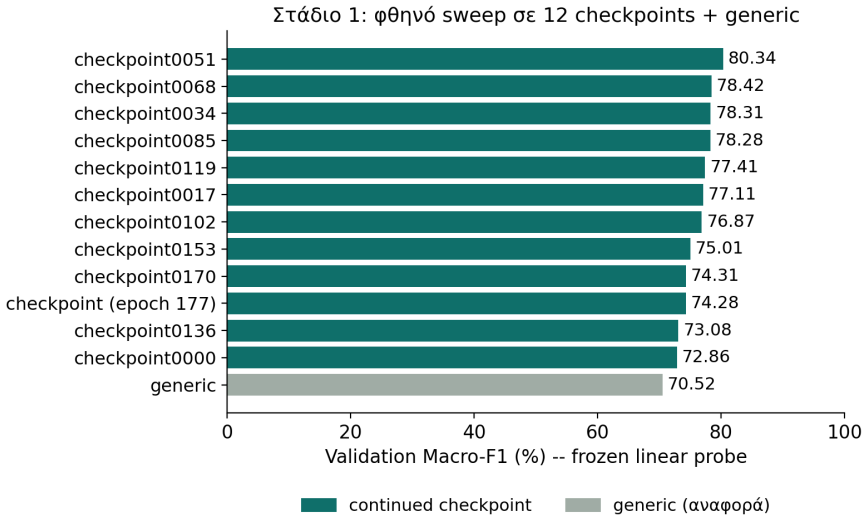
Η loss μειώνεται από $10{,}72$ σε $2{,}98$ μέχρι το τέλος του warmup (epoch 18) και φτάνει το $1{,}09$ στο epoch 177. Το learning rate αυξάνεται γραμμικά (warmup) μέχρι τη μέγιστη τιμή περίπου $3{,}75 \times 10^{-4}$ γύρω στο epoch 18 και στη συνέχεια μειώνεται με cosine decay.

6.3.2 Αποτελέσματα Επιλογής Checkpoint

Ο Πίνακας 6.12 και το Σχήμα 6.15 παρουσιάζουν τα αποτελέσματα του πρώτου σταδίου επιλογής (frozen linear probing σε προϋπολογισμένα χαρακτηριστικά, validation set).

Πίνακας 6.12: Στάδιο 1: validation Macro-F1 (%) από frozen linear probing, για το generic checkpoint και τα δώδεκα checkpoints του EMA teacher.

Checkpoint	**Macro-F1 (%)**
checkpoint0051	80,34
checkpoint0068	78,42
checkpoint0034	78,31
checkpoint0085	78,28
checkpoint0119	77,41
checkpoint0017	77,11
checkpoint0102	76,87
checkpoint0153	75,01
checkpoint0170	74,31
checkpoint (epoch 177)	74,28
checkpoint0136	73,08
checkpoint0000	72,86
generic	70,52

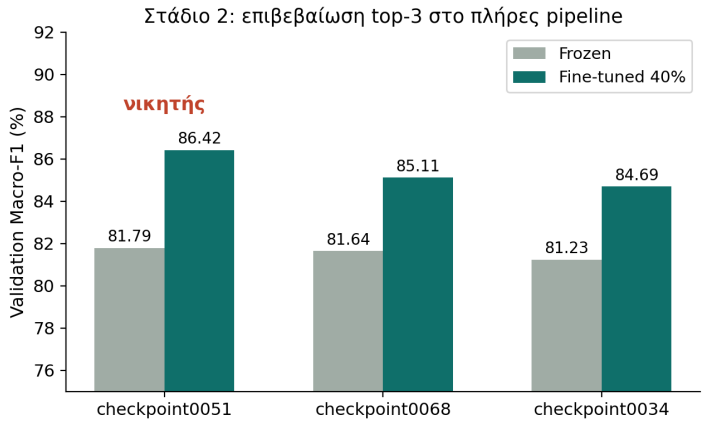


Σχήμα 6.15: Στάδιο 1 επιλογής checkpoint: validation Macro-F1 από frozen linear probing, σε φθίνουσα σειρά.

Τα τρία καλύτερα checkpoints του πρώτου σταδίου (epochs 51, 68 και 34) αξιολογήθηκαν στη συνέχεια μέσω του πλήρους downstream pipeline. Ο Πίνακας 6.13 και το Σχήμα 6.16 παρουσιάζουν τα αποτελέσματα του δεύτερου σταδίου.

Πίνακας 6.13: Στάδιο 2: validation Macro-F1 (%) για τα τρία επικρατέστερα checkpoints, με βάση το κριτήριο S_{val}.

Checkpoint	**Frozen**	**Fine-tuned**	$\boldsymbol{S_{\text{val}}}$
epoch 51	81,79	86,42	**168,21**
epoch 68	81,64	85,11	166,75
epoch 34	81,23	84,69	165,92



Σχήμα 6.16: Στάδιο 2 επιλογής checkpoint: validation Macro-F1 ανά στρατηγική αξιολόγησης, για τα τρία επικρατέστερα checkpoints. Νικητής: epoch 51.

Το checkpoint του epoch 51 παρουσίασε την υψηλότερη συνδυαστική επίδοση ($S_{\text{val}} = 168{,}21$) και επιλέχθηκε ως το τελικό domain-adapted backbone, διατηρώντας την πρώτη θέση και στα δύο στάδια επιλογής.

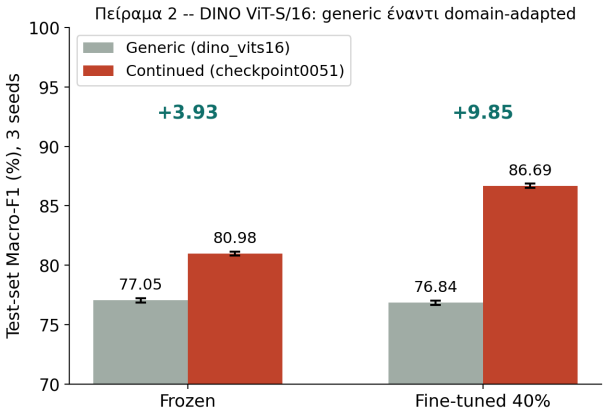
6.3.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint

Ο Πίνακας 6.14 και το Σχήμα 6.17 παρουσιάζουν την τελική σύγκριση του generic-pretrained και του επιλεγμένου domain-adapted checkpoint (epoch 51) στο test set, με τρία seeds ανά στρατηγική αξιολόγησης.

Πίνακας 6.14: Πείραμα 2: τελική σύγκριση generic και domain-adapted DINO ViT-S/16 στο test set, μέση τιμή Macro-F1 $\pm$ περιθώριο 95% CI (3 seeds).

Στρατηγική	**Generic**	**Domain-adapted**	Δ
Frozen	$77{,}05 \pm 0{,}18$	$80{,}98 \pm 0{,}17$	$+3{,}93$
Fine-tuned (40%)	$76{,}84 \pm 0{,}19$	$86{,}69 \pm 0{,}18$	$+9{,}85$

Σημείωση: Generic: `dino_vits16` (αρχικό checkpoint). Domain-adapted: `dino_vits16`, βάρη από το epoch 51.



Σχήμα 6.17: Πείραμα 2: τελική σύγκριση Macro-F1 στο test set, generic έναντι domain-adapted DINO ViT-S/16, frozen και fine-tuned 40% (μέση τιμή $\pm$ περιθώριο 95% CI, 3 seeds).

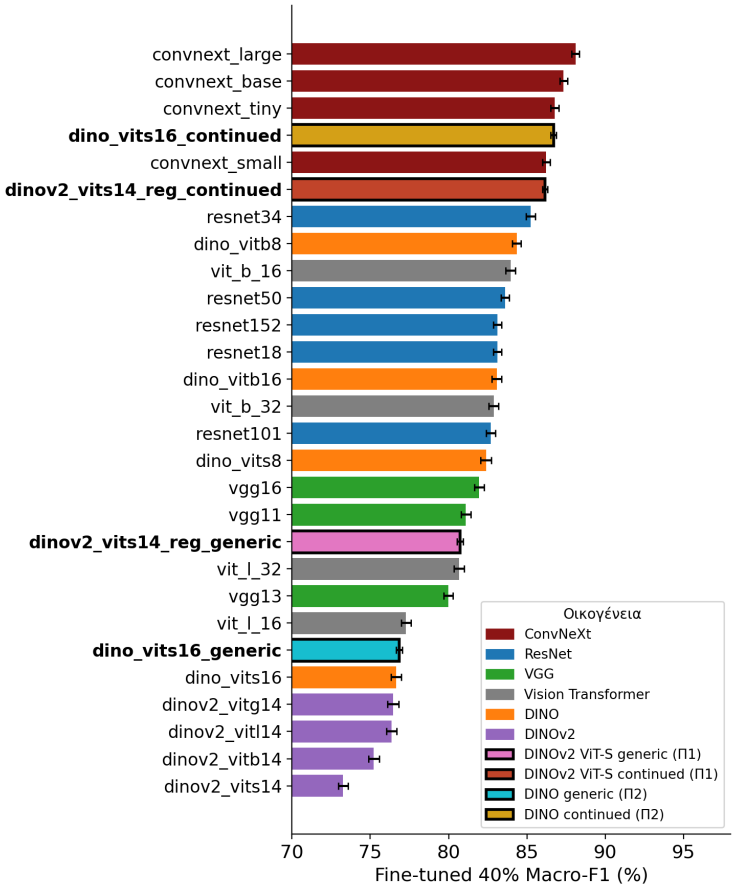
6.3.4 Τοποθέτηση στο Πλήρες Downstream Benchmark

Με την προσθήκη του δεύτερου ζεύγους generic/domain-adapted, το πλήρες σύνολο σύγκρισης περιλαμβάνει πλέον 28 μοντέλα (24 αρχικά, συν τα δύο ζεύγη των Πειραμάτων 1 και 2). Ο Πίνακας 6.15 και τα Σχήματα 6.18--6.19 παρουσιάζουν την πλήρη κατάταξη.

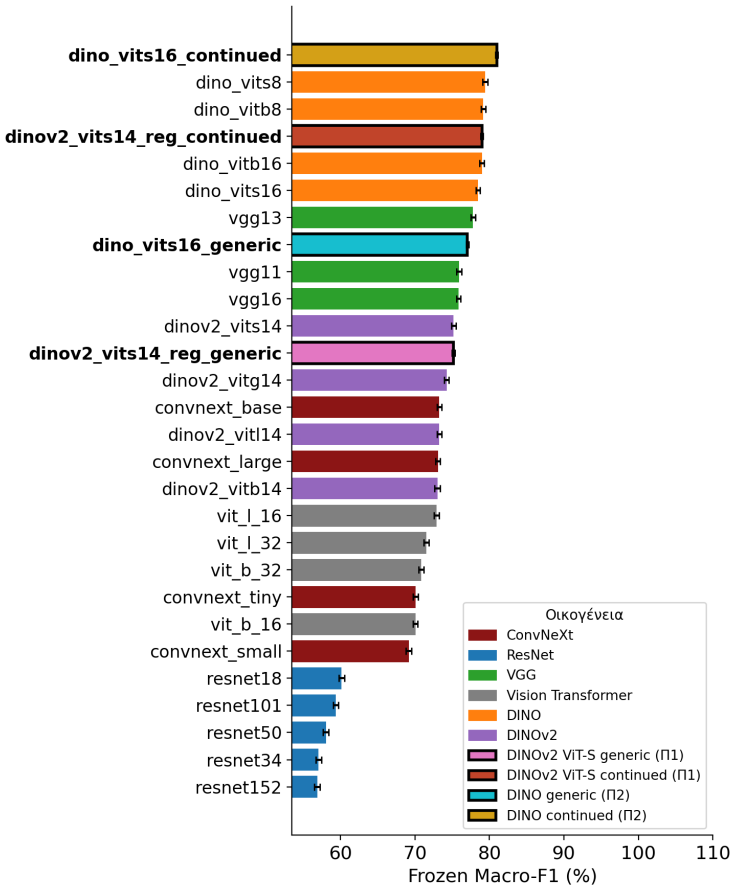
Πίνακας 6.15: Πλήρης κατάταξη 28 μοντέλων (24 αρχικά + τα ζεύγη generic/domain-adapted των Πειραμάτων 1 και 2), κατά φθίνουσα σειρά fine-tuned Macro-F1 (%).

Κατάταξη	Μοντέλο (οικογένεια)	Frozen	Fine-tuned (40%)
1	convnext_large (ConvNeXt)	$73{,}08 \pm 0{,}32$	$88{,}10 \pm 0{,}24$
2	convnext_base (ConvNeXt)	$73{,}26 \pm 0{,}30$	$87{,}34 \pm 0{,}23$
3	convnext_tiny (ConvNeXt)	$70{,}08 \pm 0{,}35$	$86{,}77 \pm 0{,}27$
4	**dino_vits16_continued (DINO, Πείραμα 2)**	$80{,}98 \pm 0{,}17$	$86{,}69 \pm 0{,}18$
5	convnext_small (ConvNeXt)	$69{,}17 \pm 0{,}36$	$86{,}23 \pm 0{,}26$
6	**dinov2_vits14_reg_continued (DINOv2, Πείραμα 1)**	$79{,}00 \pm 0{,}17$	$86{,}16 \pm 0{,}16$
7	resnet34 (ResNet)	$57{,}08 \pm 0{,}40$	$85{,}23 \pm 0{,}29$
8	dino_vitb8 (DINO)	$79{,}17 \pm 0{,}30$	$84{,}34 \pm 0{,}27$
9	vit_b_16 (Vision Transformer)	$70{,}06 \pm 0{,}32$	$83{,}95 \pm 0{,}31$
10	resnet50 (ResNet)	$58{,}05 \pm 0{,}37$	$83{,}61 \pm 0{,}26$
11	resnet152 (ResNet)	$56{,}90 \pm 0{,}37$	$83{,}12 \pm 0{,}26$
12	resnet18 (ResNet)	$60{,}16 \pm 0{,}40$	$83{,}11 \pm 0{,}26$
13	dino_vitb16 (DINO)	$78{,}99 \pm 0{,}32$	$83{,}07 \pm 0{,}30$
14	vit_b_32 (Vision Transformer)	$70{,}87 \pm 0{,}35$	$82{,}87 \pm 0{,}30$
15	resnet101 (ResNet)	$59{,}39 \pm 0{,}36$	$82{,}69 \pm 0{,}30$
16	dino_vits8 (DINO)	$79{,}43 \pm 0{,}33$	$82{,}38 \pm 0{,}33$
17	vgg16 (VGG)	$75{,}87 \pm 0{,}28$	$81{,}95 \pm 0{,}31$
18	vgg11 (VGG)	$75{,}95 \pm 0{,}34$	$81{,}10 \pm 0{,}32$
19	**dinov2_vits14_reg_generic (DINOv2, Πείραμα 1)**	$75{,}14 \pm 0{,}20$	$80{,}73 \pm 0{,}20$
20	vit_l_32 (Vision Transformer)	$71{,}56 \pm 0{,}34$	$80{,}67 \pm 0{,}32$
21	vgg13 (VGG)	$77{,}80 \pm 0{,}32$	$79{,}99 \pm 0{,}29$
22	vit_l_16 (Vision Transformer)	$72{,}91 \pm 0{,}33$	$77{,}28 \pm 0{,}32$
23	**dino_vits16_generic (DINO, Πείραμα 2)**	$77{,}05 \pm 0{,}18$	$76{,}84 \pm 0{,}19$
24	dino_vits16 (DINO)	$78{,}46 \pm 0{,}30$	$76{,}66 \pm 0{,}33$
25	dinov2_vitg14 (DINOv2)	$74{,}26 \pm 0{,}32$	$76{,}46 \pm 0{,}36$
26	dinov2_vitl14 (DINOv2)	$73{,}25 \pm 0{,}31$	$76{,}36 \pm 0{,}32$
27	dinov2_vitb14 (DINOv2)	$73{,}02 \pm 0{,}36$	$75{,}22 \pm 0{,}34$
28	dinov2_vits14 (DINOv2)	$75{,}18 \pm 0{,}30$	$73{,}27 \pm 0{,}31$

Σημείωση: Για τα τέσσερα μοντέλα των Πειραμάτων 1 και 2 η κατανομή προκύπτει από 3 seeds, για τα υπόλοιπα 24 από μία εκτέλεση.



Σχήμα 6.18: Πλήρης κατάταξη 28 μοντέλων, fine-tuned 40% Macro-F1. Τα δύο ζεύγη generic/domain-adapted των Πειραμάτων 1 και 2 επισημαίνονται με έγχρωμο περίγραμμα.



Σχήμα 6.19: Πλήρης κατάταξη 28 μοντέλων, frozen Macro-F1.

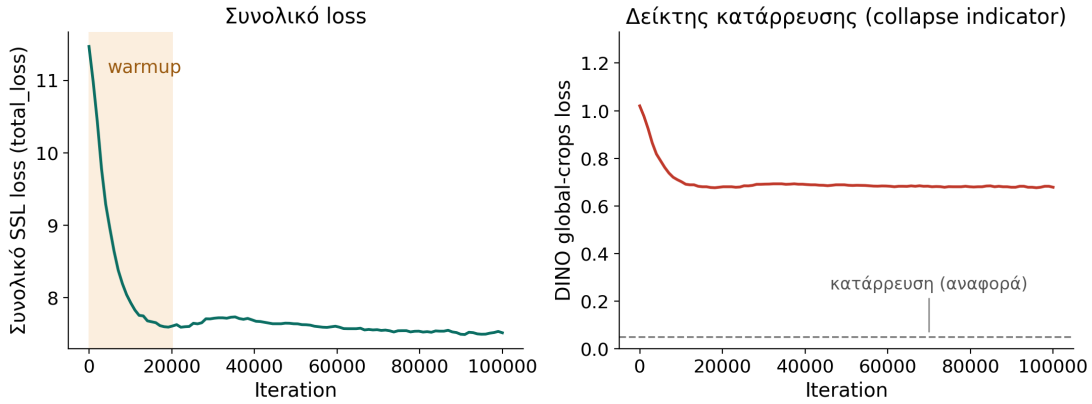
Στο fine-tuned σενάριο, το domain-adapted DINO ViT-S/16 καταλαμβάνει την 4η θέση ανάμεσα σε 28 μοντέλα --- την υψηλότερη θέση από τα δύο domain-adapted μοντέλα, μπροστά και από το domain-adapted DINOv2 ViT-S/14+reg4 (6η θέση). Στο frozen σενάριο καταλαμβάνει την 1η θέση συνολικά. Τα αντίστοιχα generic checkpoints κατατάσσονται χαμηλότερα και στα δύο σενάρια (DINO: 23η θέση fine-tuned, 8η θέση frozen· DINOv2: 19η θέση fine-tuned, 12η θέση frozen).

6.4 Πείραμα 3: DINOv2 ViT-B/14 --- Generic έναντι Domain-Adapted

Η παρούσα ενότητα παρουσιάζει τα αποτελέσματα του τρίτου πειράματος continued pretraining (DINOv2 ViT-B/14+reg4), σύμφωνα με τη μεθοδολογία και τις ρυθμίσεις προεκπαίδευσης των Ενοτήτων 5.4.1--5.4.3.

6.4.1 Αποτελέσματα SSL Pretraining

Το Σχήμα 6.20 παρουσιάζει την εξέλιξη της συνολικής συνάρτησης απώλειας και της συνιστώσας `dino_global_crops_loss` στο σύνολο των 100.000 iterations της πλήρους εκτέλεσης.



Σχήμα 6.20: Εξέλιξη του συνολικού SSL loss (αριστερά) και της συνιστώσας `dino_global_crops_loss` (δεξιά, δείκτης representation collapse) στο σύνολο των 100.000 iterations του Πειράματος 3. Η σκιασμένη περιοχή αντιστοιχεί στη φάση warmup (20.000 πρώτα iterations).

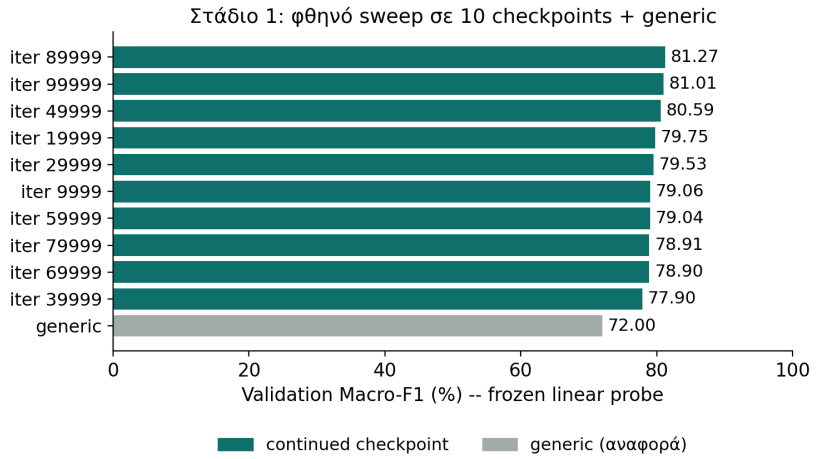
Η συνολική loss μειώνεται από $11{,}50$ σε $7{,}59$ μέχρι το τέλος του warmup (iteration 20.000) και φτάνει το $7{,}51$ στο iteration 99.999. Η συνιστώσα `dino_global_crops_loss` βρίσκεται κοντά στο $0{,}68$ από το iteration 20.000 και έπειτα.

6.4.2 Αποτελέσματα Επιλογής Checkpoint

Ο Πίνακας 6.16 και το Σχήμα 6.21 παρουσιάζουν τα αποτελέσματα του πρώτου σταδίου επιλογής (frozen linear probing σε προϋπολογισμένα χαρακτηριστικά, validation set).

Πίνακας 6.16: Στάδιο 1: validation Macro-F1 (%) από frozen linear probing, για το generic checkpoint και τα δέκα checkpoints του EMA teacher.

Checkpoint	**Macro-F1 (%)**
iter 89.999	81,27
iter 99.999	81,01
iter 49.999	80,59
iter 19.999	79,75
iter 29.999	79,53
iter 9.999	79,06
iter 59.999	79,04
iter 79.999	78,91
iter 69.999	78,90
iter 39.999	77,90
generic	72,00

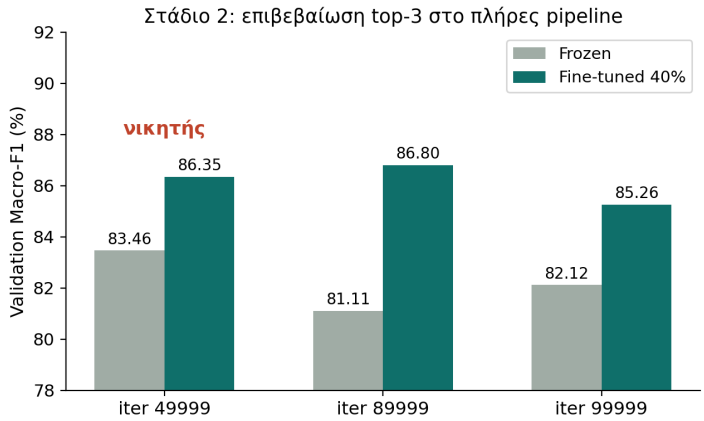


Σχήμα 6.21: Στάδιο 1 επιλογής checkpoint: validation Macro-F1 από frozen linear probing, σε φθίνουσα σειρά.

Τα τρία καλύτερα checkpoints του πρώτου σταδίου (iterations 89.999, 99.999 και 49.999) αξιολογήθηκαν στη συνέχεια μέσω του πλήρους downstream pipeline. Ο Πίνακας 6.17 και το Σχήμα 6.22 παρουσιάζουν τα αποτελέσματα του δεύτερου σταδίου.

Πίνακας 6.17: Στάδιο 2: validation Macro-F1 (%) για τα τρία επικρατέστερα checkpoints, με βάση το κριτήριο S_{val}.

Checkpoint	**Frozen**	**Fine-tuned**	$\boldsymbol{S_{\text{val}}}$
iter 49.999	83,46	86,35	**169,81**
iter 89.999	81,11	**86,80**	167,90
iter 99.999	82,12	85,26	167,38



Σχήμα 6.22: Στάδιο 2 επιλογής checkpoint: validation Macro-F1 ανά στρατηγική αξιολόγησης, για τα τρία επικρατέστερα checkpoints. Νικητής: iteration 49.999.

Το checkpoint του iteration 49.999 παρουσίασε την υψηλότερη συνδυαστική επίδοση ($S_{\text{val}} = 169{,}81$) και επιλέχθηκε ως το τελικό domain-adapted backbone, παρότι είχε καταταχθεί τρίτο στο πρώτο στάδιο: πέτυχε την καλύτερη frozen επίδοση στο δεύτερο στάδιο (83,46%), ενώ η fine-tuned επίδοσή του (86,35%) ήταν ελαφρώς χαμηλότερη από εκείνη του checkpoint 89.999 (86,80%).

6.4.3 Αποτελέσματα Generic έναντι Domain-Adapted Checkpoint

Ο Πίνακας 6.18 και το Σχήμα 6.23 παρουσιάζουν την τελική σύγκριση του generic-pretrained και του επιλεγμένου domain-adapted checkpoint (iteration 49.999) στο test set, με τρία seeds ανά στρατηγική αξιολόγησης.

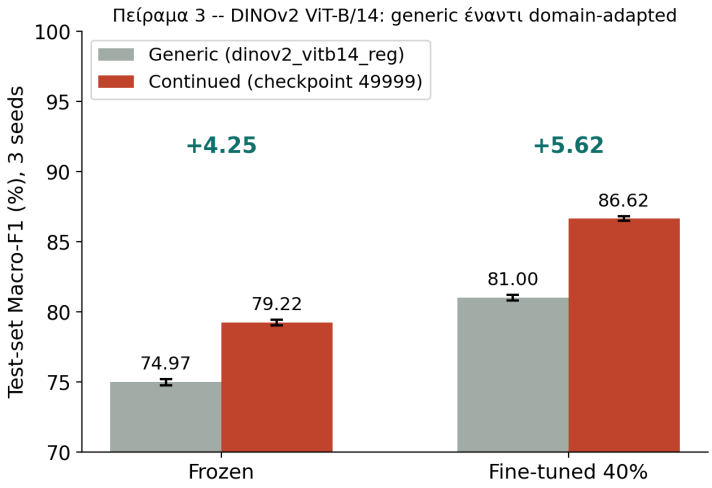
Πίνακας 6.18: Πείραμα 3: τελική σύγκριση generic και domain-adapted DINOv2 ViT-B/14 στο test set, μέση τιμή Macro-F1 $\pm$ περιθώριο 95% CI (3 seeds).

Στρατηγική	**Generic**	**Domain-adapted**	Δ
Frozen	$74{,}97 \pm 0{,}22$	$79{,}22 \pm 0{,}19$	$+4{,}25$
Fine-tuned (40%)	$81{,}00 \pm 0{,}19$	$86{,}62 \pm 0{,}16$	$+5{,}62$

Σημείωση: Generic: `dinov2_vitb14_reg` (αρχικό checkpoint). Domain-adapted: `dinov2_vitb14_reg`, βάρη από το iteration 49.999.

6.4.4 Τοποθέτηση στο Πλήρες Downstream Benchmark

Με την προσθήκη του τρίτου ζεύγους generic/domain-adapted, το πλήρες σύνολο σύγκρισης περιλαμβάνει πλέον 30 μοντέλα (24 αρχικά, συν τα τρία ζεύγη των Πειραμάτων 1, 2 και 3). Ο Πίνακας 6.19 και τα Σχήματα 6.24--6.25 παρουσιάζουν την πλήρη κατάταξη.

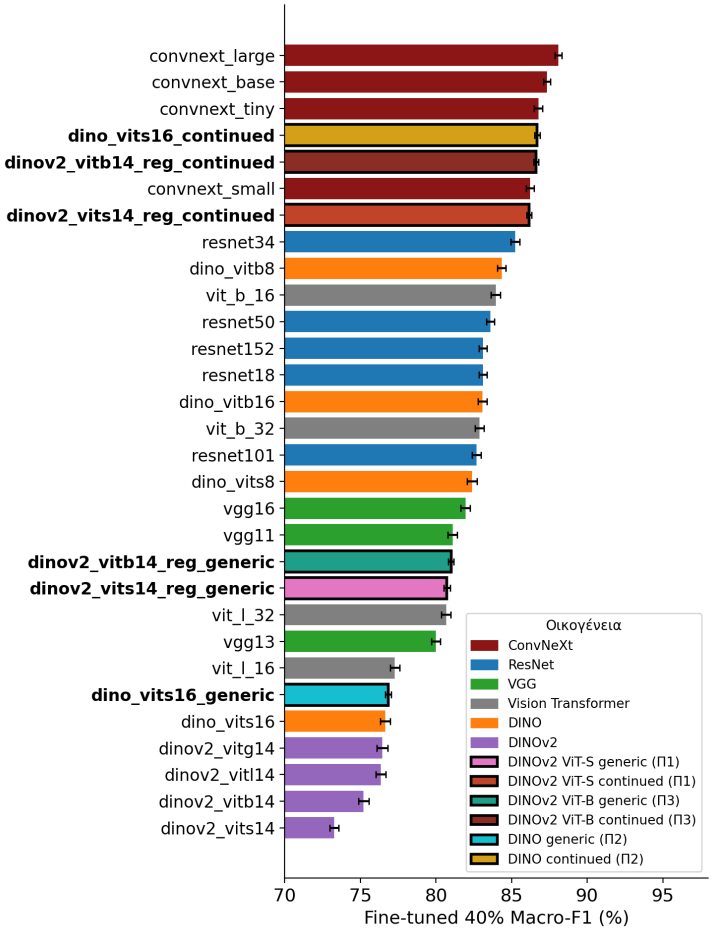


Σχήμα 6.23: Πείραμα 3: τελική σύγκριση Macro-F1 στο test set, generic έναντι domain-adapted DINOv2 ViT-B/14, frozen και fine-tuned 40% (μέση τιμή ± περιθώριο 95% CI, 3 seeds).

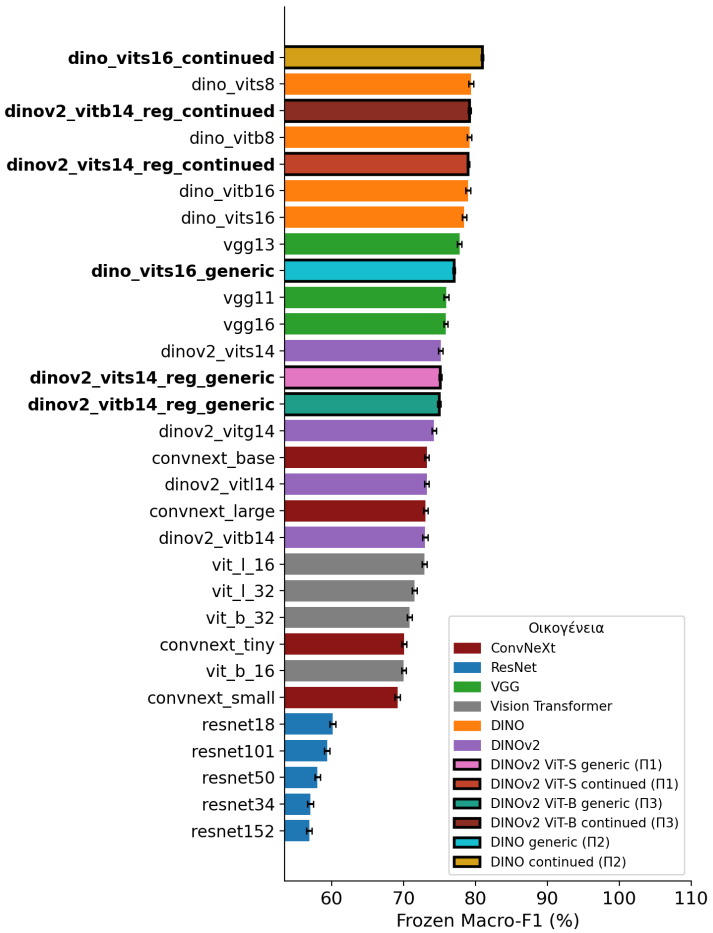
Πίνακας 6.19: Πλήρης κατάταξη 30 μοντέλων (24 αρχικά + τα ζεύγη generic/domain-adapted των Πειραμάτων 1, 2 και 3), κατά φθίνουσα σειρά fine-tuned Macro-F1 (%).

Κατ.	**Μοντέλο (οικογένεια)**	**Frozen**	**Fine-tuned (40%)**
1	convnext_large (ConvNeXt)	73,08 ± 0,32	88,10 ± 0,24
2	convnext_base (ConvNeXt)	73,26 ± 0,30	87,34 ± 0,23
3	convnext_tiny (ConvNeXt)	70,08 ± 0,35	86,77 ± 0,27
4	**dino_vits16_continued (DINO, Π2)**	80,98 ± 0,17	86,69 ± 0,18
5	**dinov2_vitb14_reg_continued (DINOv2-B, Π3)**	79,22 ± 0,19	86,62 ± 0,16
6	convnext_small (ConvNeXt)	69,17 ± 0,36	86,23 ± 0,26
7	**dinov2_vits14_reg_continued (DINOv2-S, Π1)**	79,00 ± 0,17	86,16 ± 0,16
8	resnet34 (ResNet)	57,08 ± 0,40	85,23 ± 0,29
9	dino_vitb8 (DINO)	79,17 ± 0,30	84,34 ± 0,27
10	vit_b_16 (Vision Transformer)	70,06 ± 0,32	83,95 ± 0,31
11	resnet50 (ResNet)	58,05 ± 0,37	83,61 ± 0,26
12	resnet152 (ResNet)	56,90 ± 0,37	83,12 ± 0,26
13	resnet18 (ResNet)	60,16 ± 0,40	83,11 ± 0,26
14	dino_vitb16 (DINO)	78,99 ± 0,32	83,07 ± 0,30
15	vit_b_32 (Vision Transformer)	70,87 ± 0,35	82,87 ± 0,30
16	resnet101 (ResNet)	59,39 ± 0,36	82,69 ± 0,30
17	dino_vits8 (DINO)	79,43 ± 0,33	82,38 ± 0,33
18	vgg16 (VGG)	75,87 ± 0,28	81,95 ± 0,31
19	vgg11 (VGG)	75,95 ± 0,34	81,10 ± 0,32
20	**dinov2_vitb14_reg_generic (DINOv2-B, Π3)**	74,97 ± 0,22	81,00 ± 0,19
21	**dinov2_vits14_reg_generic (DINOv2-S, Π1)**	75,14 ± 0,20	80,73 ± 0,20
22	vit_l_32 (Vision Transformer)	71,56 ± 0,34	80,67 ± 0,32
23	vgg13 (VGG)	77,80 ± 0,32	79,99 ± 0,29
24	vit_l_16 (Vision Transformer)	72,91 ± 0,33	77,28 ± 0,32
25	**dino_vits16_generic (DINO, Π2)**	77,05 ± 0,18	76,84 ± 0,19
26	dino_vits16 (DINO)	78,46 ± 0,30	76,66 ± 0,33
27	dinov2_vitg14 (DINOv2)	74,26 ± 0,32	76,46 ± 0,36
28	dinov2_vitl14 (DINOv2)	73,25 ± 0,31	76,36 ± 0,32
29	dinov2_vitb14 (DINOv2)	73,02 ± 0,36	75,22 ± 0,34
30	dinov2_vits14 (DINOv2)	75,18 ± 0,30	73,27 ± 0,31

Σημείωση: Για τα έξι μοντέλα των Πειραμάτων 1, 2 και 3 η κατανομή προκύπτει από 3 seeds, για τα υπόλοιπα 24 από μία εκτέλεση.



Σχήμα 6.24: Πλήρης κατάταξη 30 μοντέλων, fine-tuned 40% Macro-F1. Τα τρία ζεύγη generic/domain-adapted των Πειραμάτων 1, 2 και 3 επισημαίνονται με έγχρωμο περίγραμμα.



Σχήμα 6.25: Πλήρης κατάταξη 30 μοντέλων, frozen Macro-F1.

Στο fine-tuned σενάριο, το domain-adapted DINOv2 ViT-B/14 καταλαμβάνει την 5η θέση ανάμεσα σε 30 μοντέλα, ανάμεσα στα δύο άλλα domain-adapted μοντέλα (DINO ViT-S/16: 4η θέση· DINOv2 ViT-S/14: 7η θέση). Στο frozen σενάριο καταλαμβάνει την 3η θέση. Τα τρία domain-adapted μοντέλα καταλαμβάνουν τις θέσεις 4, 5 και 7 της συνολικής κατάταξης fine-tuned, αμέσως μετά τα τρία μεγαλύτερα ConvNeXt, με το convnext_small στην ενδιάμεση 6η θέση. Τα αντίστοιχα generic checkpoints παραμένουν συγκεντρωμένα χαμηλότερα στην κατάταξη και στα δύο σενάρια (θέσεις 20--21 fine-tuned, 13--14 frozen).

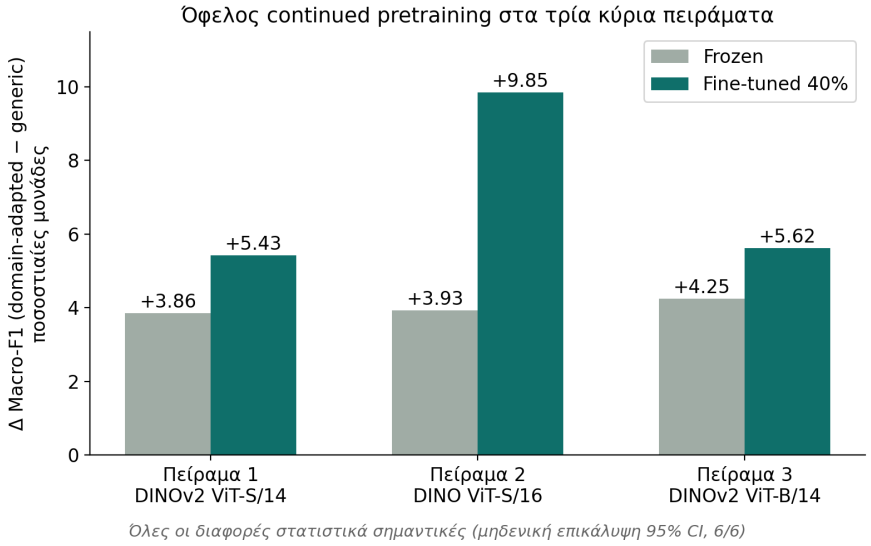
6.5 Συγκεντρωτική Σύγκριση των Τριών Πειραμάτων

Η παρούσα ενότητα συγκεντρώνει τα αποτελέσματα των τριών πειραμάτων continued pretraining (Ενότητες 6.2--6.4), ώστε να καταστεί δυνατή η άμεση σύγκριση του οφέλους που προσφέρει η domain-specific προσαρμογή ανά αρχιτεκτονική και στρατηγική αξιολόγησης.

Πίνακας 6.20: Συγκεντρωτική σύγκριση generic και domain-adapted checkpoints στα τρία κύρια πειράματα, μέση τιμή Macro-F1 (%) ± περιθώριο 95% CI (3 seeds ανά τιμή).

Πείραμα	**Στρατηγική**	**Generic**	**Domain-adapted**	**Δ**
1: DINOv2 ViT-S/14	Frozen	$75{,}14 \pm 0{,}20$	$79{,}00 \pm 0{,}17$	$+3{,}86$
	Fine-tuned (40%)	$80{,}73 \pm 0{,}20$	$86{,}16 \pm 0{,}16$	$+5{,}43$
2: DINO ViT-S/16	Frozen	$77{,}05 \pm 0{,}18$	$80{,}98 \pm 0{,}17$	$+3{,}93$
	Fine-tuned (40%)	$76{,}84 \pm 0{,}19$	$86{,}69 \pm 0{,}18$	$+9{,}85$
3: DINOv2 ViT-B/14	Frozen	$74{,}97 \pm 0{,}22$	$79{,}22 \pm 0{,}19$	$+4{,}25$
	Fine-tuned (40%)	$81{,}00 \pm 0{,}19$	$86{,}62 \pm 0{,}16$	$+5{,}62$

Σημείωση: Δ = domain-adapted − generic.



Σχήμα 6.26: Όφελος Macro-F1 (domain-adapted − generic) ανά πείραμα και στρατηγική αξιολόγησης. Όλες οι διαφορές είναι στατιστικά σημαντικές.

Κεφάλαιο 7: Συζήτηση

Το παρόν κεφάλαιο ερμηνεύει τα αποτελέσματα του Κεφαλαίου 6, τοποθετεί τη μελέτη απέναντι στη σχετική βιβλιογραφία και συζητά τους περιορισμούς της.

7.1 Ερμηνεία της Προκαταρκτικής Διερεύνησης

Κεντρικό ερώτημα: Γιατί τα generic DINO/DINOv2 backbones υστερούν έναντι των baselines του GastroHUN, και οφείλεται αυτό σε περιορισμένη ποιότητα αναπαραστάσεων ή σε μη κατάλληλο recipe βελτιστοποίησης;

7.1.1 Ερμηνεία: Αναπαραγωγή και Επέκταση

Η αναπαραγωγή του benchmark (Ενότητα 6.1.1) επιβεβαίωσε ότι το downstream pipeline λειτουργεί όπως αναμενόταν, με τις αναπαραγμένες επιδόσεις να προσεγγίζουν στενά τις δημοσιευμένες τιμές (Πίνακας 6.1), χωρίς όμως να ταυτίζονται ακριβώς. Οι μικρές αυτές αποκλίσεις είναι αναμενόμενες και συνδέονται με τη μεθοδολογία της αναπαραγωγής (Ενότητα 4.3.1): ο επίσημος κώδικας του benchmark δεν καθορίζει σταθερό τυχαίο σπόρο, οπότε κάθε εκτέλεση οδηγεί σε ελαφρώς διαφορετική αρχικοποίηση και σειρά δειγματοληψίας, ενώ η αναπαραγωγή αντιστοιχεί σε μία μόνο εκτέλεση ανά μοντέλο, γεγονός που ενισχύει την πιθανότητα μικρών αριθμητικών διαφορών. Πάνω σε αυτή τη βάση, η επέκταση με τα οκτώ generic DINO/DINOv2 backbones ανέδειξε ένα σαφές εύρημα: τα περισσότερα (έξι από τα οκτώ) κατατάσσονται στο κάτω μισό των 24 μοντέλων, με τα τέσσερα DINOv2 backbones να καταλαμβάνουν τις τέσσερις τελευταίες θέσεις. Αυτό το αρχικό αποτέλεσμα θα μπορούσε να ερμηνευτεί ως ένδειξη ότι οι αναπαραστάσεις DINO/DINOv2 είναι απλώς λιγότερο κατάλληλες για το συγκεκριμένο downstream έργο.

Η σύγκριση frozen έναντι fine-tuned (Ενότητα 6.1.1) δείχνει όμως κάτι διαφορετικό. Τα DINO, DINOv2 και VGG backbones εμφανίζουν τις υψηλότερες frozen επιδόσεις αλλά μικρά ή και αρνητικά οφέλη από το fine-tuning, ενώ τα ResNet εμφανίζουν το αντίστροφο μοτίβο (χαμηλότερη frozen επίδοση, μεγαλύτερο όφελος από το fine-tuning, έως $+28$ μονάδες). Το μοτίβο αυτό υποδεικνύει ότι η χαμηλή τελική κατάταξη των DINO/DINOv2 backbones δεν οφείλεται σε κατώτερες αναπαραστάσεις, αλλά στο ότι το κοινό downstream recipe δεν αξιοποιεί εξίσου αποτελεσματικά τις ήδη ισχυρές, γραμμικά διαχωρίσιμες αναπαραστάσεις τους.

7.1.2 Ερμηνεία: Ρύθμιση Εκπαίδευσης

Η διερεύνηση training configuration (Ενότητα 6.1.2) εξετάζει δύο ανεξάρτητους παράγοντες, με πολύ διαφορετικά συμπεράσματα.

Η κανονικοποίηση (Πίνακας 6.4) δεν αναδεικνύει κανένα σαφές μοτίβο ανά οικογένεια μοντέλου: η στρατηγική ImageNet υπερτερεί στα περισσότερα backbones (6

από τα 8, με μέγιστη βελτίωση $+6{,}6$ μονάδες στο DINOv2 ViT-B/14), αλλά η στρατηγική GastroHUN υπερτερεί σημαντικά στο DINOv2 ViT-L/14 ($+7{,}7$ μονάδες) --- ακριβώς το αντίθετο αποτέλεσμα, στην ίδια οικογένεια μοντέλων. Η κανονικοποίηση φαίνεται συνεπώς να είναι μια ιδιοσυγκρασιακή ιδιότητα κάθε backbone και όχι μια προβλέψιμη επιλογή ανά αρχιτεκτονική ή μέγεθος. Αυτή η έλλειψη συνέπειας είναι ακριβώς ο λόγος για τον οποίο στα τρία κύρια πειράματα διατηρήθηκε η απλή, σταθερή επιλογή (στατιστικά GastroHUN) σε όλα τα backbones και checkpoints, αντί να αναζητηθεί η βέλτιστη κανονικοποίηση ανά μοντέλο.

Τα discriminative learning rates (Πίνακας 6.5), αντίθετα, αναδεικνύουν ένα σαφές και συνεπές μοτίβο ανά μέθοδο SSL. Αποκαθιστούν σχεδόν πλήρως το χάσμα επίδοσης για τα τέσσερα DINOv2 backbones ($+7{,}1$ έως $+9{,}4$ μονάδες), ενώ για τα DINO backbones το όφελος είναι οριακό ή ανύπαρκτο (θετικό μόνο για το ViT-S/16). Η ασυμμετρία αυτή δείχνει ότι η ευαισθησία στο recipe δεν είναι γενικό χαρακτηριστικό των SSL μεθόδων, αλλά συγκεκριμένο στην αρχιτεκτονική/μέθοδο DINOv2 --- σε αντίθεση με την κανονικοποίηση, πρόκειται για ένα αναπαραγώγιμο, ανά-μέθοδο εύρημα και όχι για ιδιοσυγκρασιακή διακύμανση ανά backbone.

7.1.3 Ερμηνεία: Επιβεβαίωση μέσω Optuna

Η ανεξάρτητη αναζήτηση Optuna (Ενότητα 6.1.3) επιβεβαιώνει το ίδιο μοτίβο μέσω αυτοματοποιημένης, συστηματικής αναζήτησης αντί χειροκίνητων σημείων, αποκλείοντας το ενδεχόμενο τυχαίας επιλογής ευνοϊκών τιμών: η βελτίωση ήταν συνεπής και στα τρία μεγέθη DINOv2 ($+2{,}4$ έως $+3{,}2$ μονάδες), ενώ στα DINO backbones ήταν ανομοιογενής: σημαντική στο ViT-S/16 ($+5{,}0$ μονάδες) και ουσιαστικά μηδενική στο ViT-B/8.

Το εύρημα αυτό έχει διττή σημασία για την ερμηνεία των τριών κύριων πειραμάτων που ακολουθούν. Πρώτον, δείχνει ότι η αρχική υστέρηση του DINOv2 είναι εν μέρει *recipe-driven* και όχι αποκλειστικά ζήτημα ποιότητας αναπαραστάσεων --- εύρημα που για το DINO v1 δεν επιβεβαιώνεται ομοιόμορφα, αφού τα discriminative learning rates δεν βοήθησαν τα περισσότερα DINO backbones (Πίνακας 6.5). Δεύτερον, δικαιολογεί εκ των υστέρων τη μεθοδολογική επιλογή να μην υιοθετηθούν τα per-architecture βελτιστοποιημένα recipes (discriminative LR, Optuna) στα τρία κύρια πειράματα (Ενότητα 4.3.2): αν τα πειράματα continued pretraining χρησιμοποιούσαν ήδη βελτιστοποιημένο recipe, οποιοδήποτε όφελος θα συγχεόταν με το όφελος της ίδιας της βελτιστοποίησης recipe, καθιστώντας αδύνατο τον καθαρό διαχωρισμό της επίδρασης του domain-specific continued pretraining. Η διατήρηση σταθερού, μη βελτιστοποιημένου recipe και στα δύο checkpoints κάθε ζεύγους (generic/continued) αποτελεί συνεπώς προϋπόθεση για την έγκυρη ερμηνεία των ευρημάτων των Ενοτήτων 7.2--7.4.

7.2 Ερμηνεία του Πειράματος 1: DINOv2 ViT-S/14

Κεντρικό ερώτημα: Βελτιώνει το continued domain-adaptive pretraining στο HyperKvasir την downstream επίδοση του DINOv2 ViT-S/14+reg4 στην ανατομική ταξινόμηση, και είναι η διαδικασία επιλογής checkpoint αρκετά αξιόπιστη για να στηρίξει αυτό το συμπέρασμα;

7.2.1 Ερμηνεία: SSL Pretraining

Η εξέλιξη του SSL loss (Ενότητα 6.2.1) δεν αποτελεί απλή τεχνική λεπτομέρεια, αλλά προϋπόθεση εγκυρότητας για όλα όσα ακολουθούν: μια ασταθής ή καταρρέουσα προεκπαίδευση θα ακύρωνε οποιαδήποτε σύγκριση generic/domain-adapted. Η σταθεροποίηση της συνιστώσας `dino_global_crops_loss` κοντά στο 0,64, χωρίς πτώση προς το μηδέν (που θα υποδήλωνε *representation collapse*, δηλαδή σύγκλιση teacher και student σε σταθερή, μη πληροφοριακή έξοδο) ή μη πεπερασμένες τιμές, επιβεβαιώνει ότι η προεκπαίδευση εξελίχθηκε κανονικά σε όλα τα 100.000 iterations. Αξίζει επίσης να σημειωθεί ότι η συνολική loss μειώνεται απότομα κατά το warmup ($11{,}52 \rightarrow 7{,}24$) και στη συνέχεια σταθεροποιείται σταδιακά, με περαιτέρω μείωση μόλις έως $7{,}06$ στο τέλος της εκπαίδευσης --- ένδειξη ότι το μεγαλύτερο μέρος της προσαρμογής στο domain συμβαίνει σχετικά πρόωρα, εύρημα που αποκτά ιδιαίτερη σημασία στην ερμηνεία της επιλογής checkpoint που ακολουθεί.

7.2.2 Ερμηνεία: Επιλογή Checkpoint

Η επιλογή του checkpoint του iteration 69.999, παρότι είχε καταταχθεί μόλις τρίτο στο πρώτο στάδιο (Ενότητα 6.2.2), αναδεικνύει τη χρησιμότητα της δεύτερης, πιο δαπανηρής φάσης αξιολόγησης. Αν η επιλογή σταματούσε στο φθηνό frozen linear probing του πρώτου σταδίου, θα επιλεγόταν το checkpoint του iteration 29.999, το οποίο όμως αποδεικνύεται υποδεέστερο υπό το πλήρες downstream pipeline. Αυτό υποδηλώνει ότι η frozen γραμμική διαχωρισιμότητα των χαρακτηριστικών δεν αποτελεί τέλειο προγνωστικό δείκτη της τελικής, fine-tuned επίδοσης --- ένα εύρημα συμβατό με την ασυμμετρία frozen/fine-tuned που παρατηρήθηκε ήδη στην προκαταρκτική διερεύνηση (Ενότητα 7.1.1). Επιπλέον, το γεγονός ότι το βέλτιστο checkpoint (iteration 69.999) εμφανίζεται πολύ μετά τη σταθεροποίηση της SSL loss (iteration 20.000, Ενότητα 7.2.1) δείχνει ότι ούτε η εξέλιξη της loss από μόνη της αποτελεί επαρκή proxy για την downstream ποιότητα του checkpoint. Αμφότερες οι παρατηρήσεις δικαιολογούν εκ των υστέρων την υιοθέτηση του διασταδιακού πρωτοκόλλου αντί μιας απλοϊκής επιλογής βάσει τελικού ή ελάχιστου-loss checkpoint.

7.2.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint

Η τελική σύγκριση (Ενότητα 6.2.3) αποτελεί το κεντρικό αποτέλεσμα του Πειράματος 1: το domain-adapted checkpoint υπερτερεί στατιστικά σημαντικά του generic και στις δύο στρατηγικές αξιολόγησης, υπό το ίδιο, σταθερό recipe και στα δύο checkpoints (Ενότητα 7.1). Καθώς το recipe δεν ευνοήθηκε εκ των προτέρων για το DINOv2 --- αντίθετα, γνωρίζουμε από την Ενότητα 7.1.2 ότι ένα βελτιστοποιημένο recipe θα αύξανε σημαντικά και τα δύο checkpoints εξίσου --- η παρατηρούμενη διαφορά μπορεί να αποδοθεί καθαρά στο continued pretraining και όχι σε τυχαία ευνοϊκή επιλογή ρυθμίσεων. Το μεγαλύτερο όφελος στο fine-tuned setting ($+5{,}43$) σε σχέση με το frozen ($+3{,}86$) δείχνει ότι το continued pretraining δεν βελτιώνει μόνο τη γραμμική διαχωρισιμότητα των αναπαραστάσεων, αλλά παράγει επίσης χαρακτηριστικά που αξιοποιούνται καλύτερα όταν επιτρέπεται περαιτέρω προσαρμογή του backbone --- δύο διακριτές, αθροιστικές πηγές οφέλους.

7.2.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark

Η ένταξη των δύο checkpoints στο πλήρες σύνολο 26 μοντέλων (Ενότητα 6.2.4) δείχνει ότι το όφελος του continued pretraining δεν είναι απλώς στατιστικά σημαντικό σε απομονωμένη σύγκριση, αλλά και *πρακτικά ουσιαστικό* σε σχέση με το ευρύτερο benchmark: το domain-adapted checkpoint μετακινείται από μια θέση συγκρίσιμη με τα υπόλοιπα generic DINO/DINOv2 backbones (18η θέση fine-tuned) σε θέση αμέσως μετά τα τέσσερα κορυφαία ConvNeXt (5η θέση), ξεπερνώντας κάθε ResNet, VGG, συμβατικό ViT, DINO backbone και κάθε άλλη παραλλαγή DINOv2. Στο frozen σενάριο, η άνοδος είναι ακόμη πιο έντονη (από 10η σε 3η θέση), πίσω μόνο από δύο παραλλαγές DINO --- συνεπές με το γενικό μοτίβο της Ενότητας 7.1.1, όπου τα SSL backbones κυριαρχούν στο frozen σενάριο. Το continued pretraining στο HyperKvasir, συνεπώς, δεν κλείνει απλώς το χάσμα με τα generic checkpoints, αλλά τοποθετεί το DINOv2 ViT-S/14 ανάμεσα στις πλέον ανταγωνιστικές αρχιτεκτονικές του benchmark, παρά το μικρότερο μέγεθός του σε σχέση με τα ConvNeXt που προηγούνται.

7.3 Ερμηνεία του Πειράματος 2: DINO ViT-S/16

Κεντρικό ερώτημα: Γενικεύεται το όφελος του continued domain-adaptive pretraining που παρατηρήθηκε στο DINOv2 (Πείραμα 1) και σε μια παλαιότερη, εννοιολογικά διαφορετική μέθοδο SSL όπως το DINO v1, ή πρόκειται για ιδιοσυγκρασιακό χαρακτηριστικό της DINOv2;

7.3.1 Ερμηνεία: SSL Pretraining

Σε αντίθεση με το Πείραμα 1, όπου η loss σταθεροποιούνταν ήδη από το iteration 20.000 (Ενότητα 7.2.1), εδώ η loss συνεχίζει να μειώνεται καθ' όλη τη διάρκεια των 178 epochs, χωρίς ένδειξη plateau (Ενότητα 6.3.1). Η διαφορά αυτή είναι αναμενόμενη, καθώς οι δύο υλοποιήσεις διαφέρουν τόσο στη διατύπωση της loss όσο και στο διαθέσιμο επίπεδο λεπτομέρειας καταγραφής --- η αρχική υλοποίηση DINO δεν παρέχει την ανάλυση σε επιμέρους συνιστώσες (π.χ. `dino_global_crops_loss`) που επέτρεψε στο Πείραμα 1 έναν άμεσο έλεγχο έναντι representation collapse. Η απουσία αστάθειας ή απότομων μεταβολών στη συνολική loss παραμένει ωστόσο επαρκής ένδειξη ότι η προεκπαίδευση εξελίχθηκε κανονικά, επιτρέποντας την ίδια εμπιστοσύνη στα downstream αποτελέσματα που ακολουθούν όπως και στο Πείραμα 1.

7.3.2 Ερμηνεία: Επιλογή Checkpoint

Το checkpoint του epoch 51 κέρδισε και τα δύο στάδια επιλογής (Ενότητα 6.3.2), σε αντίθεση με το Πείραμα 1, όπου ο νικητής του δεύτερου σταδίου είχε καταταχθεί μόλις τρίτος στο πρώτο (Ενότητα 7.2.2). Η συμφωνία αυτή δεν καθιστά το δεύτερο στάδιο περιττό γενικά --- το Πείραμα 1 έδειξε ότι η φθηνή frozen αξιολόγηση μπορεί να αποτύχει να εντοπίσει το βέλτιστο checkpoint, οπότε η επιβεβαίωση μέσω του πλήρους pipeline παραμένει απαραίτητη ακόμη και όταν, εκ των υστέρων, αποδεικνύεται περιττή για το συγκεκριμένο πείραμα. Αξίζει να σημειωθεί ότι το epoch 51 αντιστοιχεί σε μόλις το 29% της συνολικής εκπαίδευσης (51 από 178 epochs), ενώ

η loss συνεχίζει να μειώνεται μέχρι το epoch 177 (Ενότητα 7.3.1). Το γεγονός ότι το βέλτιστο downstream checkpoint εμφανίζεται τόσο πρόωρα, παρά τη συνεχιζόμενη πτώση της loss, ενισχύει ακόμη περισσότερο το συμπέρασμα του Πειράματος 1: η εξέλιξη της SSL loss δεν αποτελεί αξιόπιστο proxy της downstream ποιότητας, και το φαινόμενο αυτό δεν περιορίζεται σε μία μόνο μέθοδο SSL.

7.3.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint

Το όφελος του continued pretraining είναι στατιστικά σημαντικό και στις δύο στρατηγικές αξιολόγησης (Ενότητα 6.3.3), επιβεβαιώνοντας ότι το εύρημα του Πειράματος 1 γενικεύεται και σε διαφορετική μέθοδο SSL. Το μέγεθος του οφέλους, ωστόσο, χρειάζεται προσεκτική ερμηνεία. Το φαινομενικά σχεδόν διπλάσιο όφελος στο fine-tuned setting ($+9{,}85$ έναντι $+5{,}43$ στο Πείραμα 1) δεν προκύπτει από μια ιδιαίτερα ισχυρότερη απόλυτη επίδοση του domain-adapted checkpoint --- οι δύο domain-adapted τιμές είναι στην πραγματικότητα συγκρίσιμες ($86{,}69$ εδώ έναντι $86{,}16$ στο Πείραμα 1) --- αλλά κυρίως από μια ασυνήθιστα χαμηλή fine-tuned επίδοση του generic DINO ViT-S/16 ($76{,}84\%$), η οποία είναι μάλιστα χαμηλότερη και από την frozen επίδοση του ίδιου checkpoint ($77{,}05\%$). Πρόκειται για το ίδιο ανώμαλο μοτίβο αρνητικού οφέλους από fine-tuning που εντοπίστηκε ήδη σε δύο backbones κατά την προκαταρκτική διερεύνηση (Ενότητα 7.1.1), ένα από τα οποία είναι ακριβώς αυτό το checkpoint. Το μεγάλο αριθμητικό όφελος, συνεπώς, αντανακλά σε μεγάλο βαθμό μια ασθενή, σχεδόν παθολογική αφετηρία του generic μοντέλου υπό fine-tuning, και όχι απαραίτητα ισχυρότερη επίδραση του continued pretraining στο DINO v1 σε σχέση με το DINOv2. Το όφελος στο frozen setting ($+3{,}93$), αντίθετα, είναι σχεδόν ίδιο με αυτό του Πειράματος 1 ($+3{,}86$) --- μια πρώτη ένδειξη ότι το frozen όφελος του continued pretraining παραμένει σταθερό ανεξάρτητα από τη μέθοδο SSL, μοτίβο που εξετάζεται συστηματικότερα στην Ενότητα 7.5.

7.3.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark

Η τοποθέτηση του domain-adapted DINO ViT-S/16 στο πλήρες σύνολο 28 μοντέλων (Ενότητα 6.3.4) ενισχύει περαιτέρω το συμπέρασμα ότι το όφελος γενικεύεται πέρα από το DINOv2: το μοντέλο καταλαμβάνει την 4η θέση fine-tuned, ξεπερνώντας ακόμη και το domain-adapted DINOv2 ViT-S/14+reg4 του Πειράματος 1 (6η θέση), και την 1η θέση συνολικά στο frozen σενάριο. Το ότι μια παλαιότερη, απλούστερη αρχιτεκτονικά μέθοδος SSL --- χωρίς register tokens και με διαφορετική διατύπωση loss από τη DINOv2 --- επιτυγχάνει τελική κατάταξη τουλάχιστον εξίσου ανταγωνιστική μετά το continued pretraining, υποδηλώνει ότι το όφελος του domain-adaptive continued pretraining δεν εξαρτάται από τις ιδιαιτερότητες μιας συγκεκριμένης SSL αρχιτεκτονικής. Παράλληλα, η πτώση του generic DINO ViT-S/16 στην 23η θέση fine-tuned, παρά τη σχετικά υψηλή 8η θέση του στο frozen σενάριο, αναπαράγει στο επίπεδο της πλήρους κατάταξης την ίδια ασυνήθιστη ασυμμετρία frozen/fine-tuned που συζητήθηκε στην Ενότητα 7.3.3.

7.4 Ερμηνεία του Πειράματος 3: DINOv2 ViT-B/14

Κεντρικό ερώτημα: Γενικεύεται το όφελος του continued domain-adaptive pretraining και σε μεγαλύτερο backbone (ViT-B/14 αντί ViT-S/14) εντός της ίδιας οικογένειας DINOv2, και τι προσθέτει αυτό στα ευρήματα των δύο προηγούμενων πειραμάτων;

7.4.1 Ερμηνεία: SSL Pretraining

Η δυναμική της προεκπαίδευσης (Ενότητα 6.4.1) είναι πολύ κοντά σε αυτή του Πειράματος 1: ίδιος αριθμός iterations, παρόμοια απότομη πτώση κατά το warmup και σταθεροποίηση της `dino_global_crops_loss` σε παρόμοια τάξη μεγέθους ($0{,}68$ εδώ έναντι $0{,}64$ στο Πείραμα 1), χωρίς ενδείξεις collapse. Η συνέπεια αυτή είναι αναμενόμενη, καθώς πρόκειται για την ίδια μέθοδο SSL (DINOv2) σε μεγαλύτερο backbone, και επιβεβαιώνει ότι ο έλεγχος σταθερότητας που εφαρμόστηκε στο Πείραμα 1 γενικεύεται και σε μεγαλύτερη κλίμακα μοντέλου, χωρίς να απαιτούνται πρόσθετες προσαρμογές στη διαδικασία παρακολούθησης της προεκπαίδευσης.

7.4.2 Ερμηνεία: Επιλογή Checkpoint

Η επιλογή του checkpoint του iteration 49.999 (Ενότητα 6.4.2) αναδεικνύει μια ακόμη πιο ξεκάθαρη περίπτωση της τάσης που περιγράφηκε στο Πείραμα 1: το νικητήριο checkpoint δεν είναι το καλύτερο και στις δύο επιμέρους μετρικές του δεύτερου σταδίου, παρά μόνο στο συνδυαστικό κριτήριο S_{val} -- υπερτερεί σαφώς στο frozen (83,46 έναντι 82,12 και 81,11) αλλά υπολείπεται ελαφρώς στο fine-tuned (86,35 έναντι 86,80 του iteration 89.999). Αυτό δείχνει ότι το κριτήριο επιλογής δεν αναζητά απαραίτητα το checkpoint που είναι βέλτιστο ταυτόχρονα και στις δύο μετρικές, αλλά εκείνο με τη βέλτιστη συνολική ισορροπία frozen και fine-tuned επίδοσης --- μια σκόπιμη σχεδιαστική επιλογή, εφόσον και οι δύο στρατηγικές αξιολόγησης θεωρούνται εξίσου σχετικές με τους στόχους της εργασίας.

7.4.3 Ερμηνεία: Generic έναντι Domain-Adapted Checkpoint

Η τελική σύγκριση (Ενότητα 6.4.3) αποτελεί την τρίτη, ανεξάρτητη επιβεβαίωση του κεντρικού ευρήματος της εργασίας, πλέον σε διαφορετική κλίμακα backbone εντός της ίδιας οικογένειας DINOv2. Το όφελος στο frozen setting ($+4{,}25$) βρίσκεται και εδώ πολύ κοντά στα αντίστοιχα οφέλη των Πειραμάτων 1 ($+3{,}86$) και 2 ($+3{,}93$), παρά τις διαφορές σε μέγεθος backbone και μέθοδο SSL --- τρίτη συνεπής ένδειξη ότι το frozen όφελος του continued pretraining είναι σχετικά σταθερό, ανεξάρτητο αυτών των παραγόντων. Το όφελος στο fine-tuned setting ($+5{,}62$) βρίσκεται ανάμεσα στα Πειράματα 1 και 2, αλλά πολύ πιο κοντά στο Πείραμα 1 ($+5{,}43$) παρά στο Πείραμα 2 ($+9{,}85$). Αυτό επιβεβαιώνει την ερμηνεία της Ενότητας 7.3.3: το generic DINOv2 ViT-B/14 δεν παρουσιάζει το ανώμαλο αρνητικό όφελος fine-tuning που παρατηρήθηκε στο generic DINO ViT-S/16 (η fine-tuned επίδοσή του, $81{,}00\%$, υπερβαίνει κανονικά την frozen, $74{,}97\%$), και το αντίστοιχο fine-tuned όφελος του continued pretraining παραμένει σε παρόμοια τάξη μεγέθους με το Πείραμα 1. Το εξαιρετικά μεγάλο όφελος του Πειράματος 2 αναδεικνύεται έτσι ακόμη πιο καθαρά ως εξαίρεση συνδεδεμένη με τη συγκεκριμένη, ασυνήθιστη συμπεριφορά του generic baseline εκείνου του πειράματος, και όχι ως ο κανόνας.

7.4.4 Ερμηνεία: Τοποθέτηση στο Πλήρες Downstream Benchmark

Με τα τρία πειράματα πλέον ενταγμένα στο πλήρες σύνολο 30 μοντέλων (Ενότητα 6.4.4), αναδεικνύεται ένα δομικό μοτίβο που δεν ήταν ορατό με ένα ή δύο πειράματα μεμονωμένα: τα τρία domain-adapted checkpoints καταλαμβάνουν τις θέσεις 4, 5 και 7 της κατάταξης fine-tuned, σχηματίζοντας ένα συνεκτικό σύνολο αμέσως μετά τα τρία μεγαλύτερα ConvNeXt (με το convnext_small στην ενδιάμεση 6η θέση) και πριν από κάθε άλλη αρχιτεκτονική, ενώ τα αντίστοιχα generic checkpoints παραμένουν συγκεντρωμένα πολύ χαμηλότερα (θέσεις 20--21). Η σαφής αυτή διαχωριστική γραμμή ανάμεσα στις δύο ομάδες --- τρία εννοιολογικά και αρχιτεκτονικά διαφορετικά μοντέλα (δύο μεγέθη DINOv2, ένα DINO) στην κορυφή μετά το continued pretraining, και τα generic αντίστοιχά τους σταθερά χαμηλότερα --- αποτελεί την πιο ισχυρή συνολική ένδειξη ότι το εύρημα της εργασίας είναι συστηματικό και αναπαραγώγιμο, και όχι αποτέλεσμα τύχης σε ένα μεμονωμένο πείραμα. Η συστηματική σύγκριση των τριών πειραμάτων μεταξύ τους ακολουθεί στην Ενότητα 7.5.

7.5 Ερμηνεία της Συγκεντρωτικής Σύγκρισης

Κεντρικό ερώτημα: Τι προσθέτει η από κοινού εξέταση των τριών πειραμάτων (Ενότητα 6.5) σε σχέση με όσα ήδη αναδείχθηκαν μεμονωμένα στις Ενότητες 7.2--7.4, και πόσο γενικό είναι, τελικά, το βασικό εύρημα της εργασίας;

Η συγκεντρωτική σύγκριση (Πίνακας 6.20, Σχήμα 6.26) επιβεβαιώνει, με όλα τα δεδομένα δίπλα-δίπλα, το σημαντικότερο ενιαίο εύρημα της εργασίας: το όφελος του continued pretraining στο frozen setting παραμένει σχεδόν σταθερό ($+3{,}86$ έως $+4{,}25$ μονάδες) σε τρία πειράματα που διαφέρουν ταυτόχρονα σε μέγεθος backbone (ViT-S έναντι ViT-B) *και* σε μέθοδο SSL (DINOv2 έναντι DINO v1). Το frozen setting μετρά αποκλειστικά την ποιότητα των ήδη μαθημένων αναπαραστάσεων, χωρίς καμία επιπλέον προσαρμογή βαρών κατά την downstream αξιολόγηση· η συνέπεια αυτού του οφέλους αποτελεί συνεπώς την πλέον καθαρή, λιγότερο επιβαρυμένη από συγχυτικούς παράγοντες απόδειξη ότι το continued pretraining στο HyperKvasir βελτιώνει συστηματικά την ποιότητα των αναπαραστάσεων για το συγκεκριμένο downstream έργο --- πρόκειται για ένα γενικεύσιμο αποτέλεσμα του domain-adaptive continued pretraining, όχι για ιδιοσυγκρασία μιας συγκεκριμένης αρχιτεκτονικής ή μεθόδου.

Το φαινομενικά ανομοιογενές όφελος στο fine-tuned setting αποκτά διαφορετική σημασία υπό το φως της ανάλυσης των Ενοτήτων 7.3.3 και 7.4.3: δεν αντανακλά ασυνέπεια του ίδιου του φαινομένου, αλλά την ασυνήθιστα αδύναμη fine-tuned επίδοση του generic DINO ViT-S/16 ($76{,}84\%$, χαμηλότερη και από την ίδια του frozen επίδοση). Αφαιρώντας αυτή την ιδιομορφία, τα δύο πειράματα DINOv2 συμφωνούν στενά μεταξύ τους ($+5{,}43$ και $+5{,}62$ μονάδες), και το Πείραμα 2 εμφανίζεται ως η εξαίρεση που επιβεβαιώνει, αντί να αμφισβητεί, τον κανόνα: το domain-adapted checkpoint του Πειράματος 2 δεν πέτυχε ασυνήθιστα υψηλή απόλυτη επίδοση ($86{,}69\%$, συγκρίσιμη με τα $86{,}16\%$ και $86{,}62\%$ των άλλων δύο πειραμάτων) --- απλώς ξεκίνησε από χαμηλότερη αφετηρία.

Η στατιστική σημαντικότητα σε όλες τις 6 συγκρίσεις (2 στρατηγικές $\times$ 3 πειράματα, μηδενική επικάλυψη 95% CI) ενισχύει περαιτέρω την εμπιστοσύνη στο εύρημα: δεν πρόκειται για οριακό αποτέλεσμα σε ένα μόνο πείραμα, αλλά για ένα

αποτέλεσμα που αναπαράγεται με συνέπεια κάθε φορά που δοκιμάζεται, κάτω από σταθερές, μη βελτιστοποιημένες ανά αρχιτεκτονική συνθήκες (Ενότητα 7.1). Η επόμενη ενότητα τοποθετεί αυτό το εύρημα απέναντι στη σχετική βιβλιογραφία για continued/domain-adaptive SSL pretraining σε ιατρικές εικόνες.

7.6 Σύγκριση με τη Βιβλιογραφία

Τα ευρήματα των Ενοτήτων 7.2--7.5 μπορούν τώρα να τοποθετηθούν απέναντι στις σχετικές εργασίες της Ενότητας 3.7.2 και του Κεφαλαίου 2, οι οποίες διερευνούν με διαφορετικούς τρόπους την αξία της αυτοεπιβλεπόμενης προσαρμογής σε ενδοσκοπικά δεδομένα.

Το πλέον άμεσα συγκρίσιμο προηγούμενο είναι η μελέτη των Sanderson και Matuszewski [51], η οποία χρησιμοποίησε το ίδιο σύνολο δεδομένων (περίπου 100.000 μη επισημασμένες εικόνες HyperKvasir) και κατέληξε ότι τα ImageNet self-supervised μοντέλα υπερείχαν της αυτοεπιβλεπόμενης προεκπαίδευσης στο ίδιο το HyperKvasir, στις περισσότερες downstream εφαρμογές. Το εύρημα αυτό, εκ πρώτης όψεως, φαίνεται να αντιτίθεται στο κεντρικό συμπέρασμα της παρούσας εργασίας. Η φαινομενική αντίφαση εξηγείται, ωστόσο, από μια κρίσιμη μεθοδολογική διαφορά: οι Sanderson και Matuszewski εκπαίδευσαν αυτοεπιβλεπόμενα μοντέλα *από τυχαία αρχικοποίηση* στο HyperKvasir, ενώ η παρούσα εργασία *συνεχίζει* την προεκπαίδευση ενός ήδη ισχυρού, γενικά προεκπαιδευμένου DINO/DINOv2 backbone στο ίδιο σύνολο δεδομένων (Ενότητα 3.7.2). Τα δύο ευρήματα είναι, συνεπώς, συμβατά παρά αντικρουόμενα: περίπου 100.000 εικόνες φαίνεται να είναι ανεπαρκείς για να παράγουν από το μηδέν αναπαραστάσεις συγκρίσιμες με αυτές μεγάλης κλίμακας γενικής προεκπαίδευσης, αλλά επαρκούν για να βελτιώσουν μετρήσιμα και σταθερά ένα ήδη ισχυρό σημείο εκκίνησης μέσω continued pretraining. Η διάκριση αυτή μεταξύ προεκπαίδευσης από το μηδέν και προσαρμογής ενός ήδη προεκπαιδευμένου μοντέλου αποτελεί, στην ουσία, το κεντρικό μεθοδολογικό στοίχημα της παρούσας εργασίας.

Στο αντίθετο άκρο της κλίμακας δεδομένων βρίσκονται οι Boers et al. [52] και το GastroNet-5M [53], οι οποίοι έδειξαν ότι η in-domain αυτοεπιβλεπόμενη προεκπαίδευση --- μεταξύ άλλων με DINO --- μπορεί να υπερέχει της προεκπαίδευσης σε φυσικές εικόνες, αξιοποιώντας όμως πάνω από πέντε εκατομμύρια ενδοσκοπικές εικόνες, περίπου δύο τάξεις μεγέθους περισσότερες από το HyperKvasir. Το εύρημα αυτό, σε συνδυασμό με το προηγούμενο, υποδηλώνει ότι η κλίμακα δεδομένων παίζει καθοριστικό ρόλο όταν η αυτοεπιβλεπόμενη εκπαίδευση γίνεται από το μηδέν. Η παρούσα εργασία επιτυγχάνει ένα συγκρίσιμο, στατιστικά σημαντικό όφελος προσαρμογής με δύο τάξεις μεγέθους λιγότερα δεδομένα και πολύ μικρότερο υπολογιστικό κόστος, ακριβώς επειδή δεν ξεκινά από τυχαία αρχικοποίηση αλλά συνεχίζει μια ήδη ολοκληρωμένη γενική προεκπαίδευση. Επιπλέον, όπως σημειώθηκε ήδη στην Ενότητα 3.7.2 (Κεφάλαιο 2), η ελεγχόμενη σύγκριση αρχικοποίησης των Boers et al. πραγματοποιήθηκε για το ResNet50, όχι όμως για το DINO ViT-S/16, το οποίο αναφέρεται με τυχαία αρχικοποίηση. Τα τρία πειράματα της παρούσας εργασίας παρέχουν ακριβώς αυτή την ελλείπουσα, ελεγχόμενη σύγκριση για Vision Transformers, σε τρεις διαφορετικές διαμορφώσεις αρχιτεκτονικής/μεθόδου.

Πιο κοντά ως προς τη στρατηγική βρίσκεται η εργασία των Roth et al. [54], η οποία ακολουθεί την ίδια γενική λογική continued/domain-adaptive pretraining από

ένα ήδη προεκπαιδευμένο μοντέλο (EVA-02) σε περίπου 226.000 ενδοσκοπικές εικόνες. Η παρούσα εργασία επεκτείνει αυτή τη γενική στρατηγική σε διαφορετική οικογένεια αυτοεπιβλεπόμενης μάθησης (DINO/DINOv2 self-distillation αντί masked image modeling), σε διαφορετικό downstream πρόβλημα (ανατομική ταξινόμηση 23 κλάσεων αντί ταξινόμησης παθολογικών ευρημάτων σε capsule endoscopy) και με ρητή, ελεγχόμενη σύγκριση του ίδιου backbone πριν και μετά την προσαρμογή, υπό πανομοιότυπο downstream recipe. Το ότι η ίδια γενική στρατηγική αποδίδεται συστηματικά σε δύο εννοιολογικά διαφορετικές SSL μεθόδους (self-distillation και masked image modeling) ενισχύει την εικόνα ότι το όφελος του continued pretraining δεν συνδέεται με μια συγκεκριμένη SSL οικογένεια, αλλά με την ίδια τη λογική της προσαρμογής ενός γενικού μοντέλου σε νέο πεδίο.

Τέλος, εργασίες όπως τα Endo-FM, ArgesFM [55, 56] και ιδίως το EndoDINO [57] ακολουθούν μια διαφορετική στρατηγική: την ανάπτυξη εξειδικευμένων ενδοσκοπικών foundation models μέσω μεγάλης κλίμακας in-domain προεκπαίδευσης, αντί της προσαρμογής ενός υπάρχοντος γενικού μοντέλου. Το EndoDINO, συγκεκριμένα, εφαρμόζει μεθοδολογία DINOv2 σε γαστρεντερικά δεδομένα και αξιολογεί frozen representations στην ταξινόμηση ανατομικών landmarks --- το πλέον συγγενικό υπάρχον έργο ως προς τη μέθοδο (DINOv2) και το downstream πρόβλημα (ανατομική ταξινόμηση). Ωστόσο, όπως ήδη επισημάνθηκε στην Ενότητα 3.7.2, το EndoDINO επικεντρώνεται στην ανάπτυξη ενός νέου, εξειδικευμένου foundation model και όχι στην ελεγχόμενη σύγκριση ενός δημοσιευμένου generic checkpoint πριν και μετά από πρόσθετη προσαρμογή. Η παρούσα εργασία καλύπτει ακριβώς αυτό το κενό: αντί να αναπτύξει ένα νέο foundation model από την αρχή, τεκμηριώνει ποσοτικά πόσο όφελος προσφέρει, από μόνη της, η πρόσθετη domain-specific προσαρμογή ενός ήδη υπάρχοντος, ευρέως διαθέσιμου generic checkpoint --- με πολύ μικρότερες απαιτήσεις δεδομένων και υπολογιστικών πόρων από την ανάπτυξη ενός πλήρους foundation model, έναντι ενός μετριότερου, αλλά σαφώς τεκμηριωμένου και στατιστικώς σημαντικού οφέλους.

Συνολικά, η παρούσα εργασία δεν αντιτίθεται στα ευρήματα της υπάρχουσας βιβλιογραφίας, αλλά γεφυρώνει δύο φαινομενικά αποκλίνουσες γραμμές έρευνας (αποτυχία αυτοεπιβλεπόμενης εκπαίδευσης από το μηδέν σε περιορισμένα in-domain δεδομένα έναντι επιτυχία σε πολύ μεγάλης κλίμακας in-domain προεκπαίδευση), προσφέροντας μια ενδιάμεση, υπολογιστικά οικονομικότερη εναλλακτική: τη συνέχιση της προεκπαίδευσης ενός ήδη ισχυρού γενικού μοντέλου. Η επόμενη ενότητα εξετάζει τους περιορισμούς της προσέγγισης αυτής.

7.7 Περιορισμοί

Η ερμηνεία των ευρημάτων των Ενοτήτων 7.2--7.6 πρέπει να λαμβάνει υπόψη ορισμένους περιορισμούς της πειραματικής διαδικασίας (Ενότητα 5.5), οι οποίοι οριοθετούν το εύρος και την εμπιστοσύνη με την οποία μπορούν να διατυπωθούν τα συμπεράσματα της εργασίας.

Ένας πρώτος περιορισμός αφορά την απουσία επανάληψης του ίδιου του continued pretraining με διαφορετικά random seeds: κάθε αρχιτεκτονική προσαρμόστηκε μία μόνο φορά. Η μεταβλητότητα που ενδέχεται να εισάγει η ίδια η στοχαστικότητα της αυτοεπιβλεπόμενης διαδικασίας --- π.χ. στην ακριβή θέση και τιμή του βέλτιστου checkpoint, όπως αυτά συζητήθηκαν στις Ενότητες 7.2.2, 7.3.2 και 7.4.2 --- δεν

εκτιμήθηκε πειραματικά. Η συνέπεια του ποιοτικού ευρήματος σε τρία ανεξάρτητα πειράματα με διαφορετική αρχιτεκτονική και μέθοδο SSL (Ενότητα 7.5) παρέχει έμμεση ένδειξη ανθεκτικότητας, δεν αποδεικνύει όμως ότι η επανάληψη της ίδιας προεκπαίδευσης με άλλο seed θα οδηγούσε σε πανομοιότυπο βέλτιστο checkpoint ή ακριβώς στο ίδιο μέγεθος οφέλους.

Σχετικός είναι και ο περιορισμός που αφορά το δεύτερο στάδιο επιλογής checkpoint, όπου πραγματοποιήθηκε μία μόνο downstream εκτέλεση ανά υποψήφιο checkpoint και στρατηγική αξιολόγησης, πριν από την τελική σύγκριση με τρία seeds. Η παρατήρηση της Ενότητας 7.4.2, ότι το νικητήριο checkpoint του Πειράματος 3 δεν ήταν το καλύτερο και στις δύο μετρικές αλλά μόνο στο συνδυαστικό κριτήριο, δείχνει ότι η επιλογή μπορεί να είναι ευαίσθητη σε μικρές διαφορές επίδοσης. Ο κίνδυνος αυτός περιορίζεται από το γεγονός ότι, και στα τρία πειράματα, τα τρία κορυφαία υποψήφια checkpoints του πρώτου σταδίου παρουσίαζαν ήδη παρόμοιες, υψηλές επιδόσεις μεταξύ τους (Ενότητες 6.2.2--6.4.2), οπότε μια διαφορετική τελική επιλογή ανάμεσά τους δεν θα άλλαζε ουσιωδώς το συμπέρασμα της σύγκρισης με το generic checkpoint, έστω κι αν θα μετέβαλλε ελαφρώς το ακριβές μέγεθος του αναφερόμενου οφέλους.

Ένας τρίτος περιορισμός προκύπτει από τους διαθέσιμους υπολογιστικούς πόρους: η χρήση μίας GPU ανά εργασία επέβαλε διαφορετικά batch sizes στα τρία πειράματα (224 στο Πείραμα 1, 128 στο Πείραμα 3, διαφορετικό epoch-based πρόγραμμα στο Πείραμα 2), με αντίστοιχες διαφοροποιήσεις στο effective learning rate και στον συνολικό αριθμό παρουσιάσεων εικόνων. Το εύρημα της Ενότητας 7.4.1, ότι η δυναμική της loss παρέμεινε ωστόσο πολύ παρόμοια μεταξύ Πειράματος 1 και 3, περιορίζει εν μέρει την ανησυχία αυτή για τη σταθερότητα της προεκπαίδευσης. Δεν αναιρεί όμως πλήρως το γεγονός ότι η σύγκριση μεγέθους backbone (Ενότητα 7.4.3) δεν είναι απόλυτα ελεγχόμενη ως προς έναν και μόνο παράγοντα: μέρος της μικρής διαφοράς μεταξύ των οφελών των Πειραμάτων 1 και 3 θα μπορούσε, εν μέρει, να αντανακλά τη διαφορά στο training budget και όχι αποκλειστικά τη διαφορά μεγέθους του backbone.

Ο πλέον συστηματικά συζητημένος περιορισμός αφορά το σταθερό, κοινό downstream recipe που υιοθετήθηκε και στα τρία πειράματα, παρά τις ενδείξεις ευαισθησίας στη ρύθμιση προεπεξεργασίας και βελτιστοποίησης που αναδείχθηκαν στην προκαταρκτική διερεύνηση (Ενότητα 7.1). Η επιλογή αυτή ήταν σκόπιμη και αναγκαία για τον καθαρό διαχωρισμό της επίδρασης του continued pretraining από την επίδραση της βελτιστοποίησης recipe (Ενότητα 7.1.3), έχει όμως ένα αναπόφευκτο κόστος: οι απόλυτες επιδόσεις που αναφέρονται και για τα 6 generic/domain-adapted checkpoints δεν αντιστοιχούν στη μέγιστη δυνατή επίδοσή τους. Γνωρίζουμε συγκεκριμένα (Ενότητα 7.1.2) ότι τα discriminative learning rates θα μπορούσαν να προσθέσουν ακόμη 7 έως 9 ποσοστιαίες μονάδες ειδικά στα backbones DINOv2. Οι συγκρίσεις *εντός* κάθε ζεύγους generic/domain-adapted παραμένουν έγκυρες, καθώς και τα δύο checkpoints κάθε ζεύγους αξιολογούνται υπό το ίδιο μειονεκτικό recipe (Ενότητα 7.1). Οι συγκρίσεις όμως *μεταξύ* διαφορετικών αρχιτεκτονικών στην πλήρη κατάταξη (π.χ. η θέση του domain-adapted DINOv2 ViT-S/14 αμέσως μετά τα ConvNeXt, Ενότητα 7.2.4) πρέπει να διαβάζονται ως αποτέλεσμα ενός συγκεκριμένου, κοινού και μη βελτιστοποιημένου πρωτοκόλλου, και όχι ως σύγκριση των μέγιστων δυνατών επιδόσεων κάθε αρχιτεκτονικής.

Τέλος, η αξιολόγηση περιορίστηκε σε ένα μόνο downstream σύνολο δεδομένων (GastroHUN) και έργο (ταξινόμηση 23 ανατομικών κλάσεων). Ο διαχωρισμός σε

επίπεδο ασθενούς προστατεύει από διαρροή δεδομένων εντός του GastroHUN, δεν εξασφαλίζει όμως γενίκευση εκτός αυτού. Όπως προέκυψε από τη σύγκριση με τη βιβλιογραφία (Ενότητα 7.6), άλλες εργασίες εξετάζουν διαφορετικά downstream προβλήματα, όπως η ταξινόμηση παθολογικών ευρημάτων σε capsule endoscopy [54] ή πολλαπλές ενδοσκοπικές εργασίες [52]. Η συνέπεια του ευρήματος σε τρία πειράματα (Ενότητα 7.5) τεκμηριώνει την ανθεκτικότητά του ως προς την αρχιτεκτονική και τη μέθοδο SSL, όχι όμως ως προς το downstream σύνολο δεδομένων ή το είδος της εργασίας· το κατά πόσο η ίδια στρατηγική domain-adaptive continued pretraining θα απέδιδε ανάλογο όφελος σε διαφορετικό ενδοσκοπικό dataset ή σε διαφορετικό κλινικό έργο (π.χ. εντοπισμός βλαβών) παραμένει ανοιχτό ερώτημα.

Συνοψίζοντας, οι περιορισμοί αυτοί εμπίπτουν σε δύο ευρύτερες κατηγορίες. Οι δύο πρώτοι (απουσία επανάληψης seed στην προεκπαίδευση, στοχαστικότητα επιλογής checkpoint) αφορούν την ακρίβεια και βεβαιότητα των συγκεκριμένων αναφερόμενων τιμών, χωρίς να αμφισβητούν το ποιοτικό συμπέρασμα, το οποίο επιβεβαιώνεται ανεξάρτητα σε τρία πειράματα. Οι τρεις τελευταίοι (υπολογιστικοί πόροι, σταθερό recipe, μοναδικό dataset/έργο) οριοθετούν αντίθετα το εύρος γενίκευσης του συμπεράσματος: η εργασία τεκμηριώνει πειστικά ότι το domain-adaptive continued pretraining βελτιώνει τις αναπαραστάσεις για το συγκεκριμένο downstream έργο, κάτω από ένα συγκεκριμένο, σταθερό πρωτόκολλο, χωρίς ωστόσο να τεκμηριώνει τη βέλτιστη δυνατή του επίδοση ανά αρχιτεκτονική ή τη γενίκευσή του σε άλλα datasets και κλινικά προβλήματα. Οι περιορισμοί αυτοί αποτελούν, παράλληλα, το σημείο εκκίνησης για τις κατευθύνσεις μελλοντικής έρευνας του Κεφαλαίου 8.

Κεφάλαιο 8: Συμπεράσματα και Μελλοντική Εργασία

8.1 Σύνοψη της Εργασίας

Η παρούσα εργασία διερεύνησε κατά πόσο το domain-adaptive continued self-supervised pretraining σε μη επισημασμένα ενδοσκοπικά δεδομένα του HyperKvasir βελτιώνει τις αναπαραστάσεις μοντέλων DINO/DINOv2 για την αναγνώριση ανατομικής θέσης στο GastroHUN benchmark. Η μεθοδολογία συνδύασε την επέκταση του δημοσιευμένου benchmark με επιπλέον γενικά προεκπαιδευμένα μοντέλα DINO/DINOv2, μια προκαταρκτική διερεύνηση της ευαισθησίας στο downstream recipe και τρία ανεξάρτητα πειράματα ελεγχόμενης σύγκρισης generic και domain-adapted checkpoints, για δύο μεγέθη backbone (ViT-S, ViT-B) και δύο μεθόδους αυτοεπιβλεπόμενης μάθησης (DINO, DINOv2). Σε κάθε πείραμα, το generic-pretrained checkpoint μιας αρχιτεκτονικής συγκρίθηκε με την εκδοχή του μετά από πρόσθετη προεκπαίδευση στο HyperKvasir, υπό κοινό, σταθερό downstream πρωτόκολλο και στις δύο στρατηγικές αξιολόγησης (frozen linear probing και partial fine-tuning). Τα αποτελέσματα αυτής της διαδικασίας παρουσιάστηκαν στο Κεφάλαιο 6 και ερμηνεύθηκαν στο Κεφάλαιο 7. Οι επόμενες ενότητες συνοψίζουν τα κύρια συμπεράσματα, τις συνεισφορές της εργασίας και τις κατευθύνσεις μελλοντικής έρευνας που προκύπτουν από αυτή.

8.2 Κύρια Συμπεράσματα

8.2.1 Συνέπεια του Οφέλους Continued Pretraining

Το domain-adaptive continued pretraining στο HyperKvasir βελτιώνει συστηματικά και στατιστικά σημαντικά την ποιότητα των αναπαραστάσεων για την αναγνώριση ανατομικής θέσης, όπως τεκμηριώνεται και στα τρία πειράματα (6/6 συγκρίσεις, μηδενική επικάλυψη 95% CI). Το όφελος στο frozen setting παραμένει ιδιαίτερα σταθερό ($+3{,}86$ έως $+4{,}25$ μονάδες Macro-F1), ανεξάρτητα από το μέγεθος του backbone ή τη μέθοδο SSL, αποτελώντας την πλέον ισχυρή, λιγότερο επιβαρυμένη από συγχυτικούς παράγοντες απόδειξη του φαινομένου (Ενότητα 7.5).

8.2.2 Η Ευαισθησία στο Recipe ως Αρχιτεκτονικο-ειδικό Φαινόμενο

Η προκαταρκτική διερεύνηση ανέδειξε ότι η αρχική υστέρηση των generic DINOv2 backbones έναντι των baselines του GastroHUN οφείλεται εν μέρει σε μη κατάλληλο downstream recipe και όχι αποκλειστικά σε κατώτερη ποιότητα αναπαραστάσεων: τα discriminative learning rates και η ανεξάρτητη αναζήτηση Optuna απέδωσαν σημαντική βελτίωση ειδικά στα DINOv2 backbones, ενώ στα DINO v1 το όφελος ήταν περιορισμένο και ανομοιογενές (Ενότητα 7.1). Το εύρημα αυτό δικαιολόγησε εκ

των υστέρων τη μεθοδολογική επιλογή ενός σταθερού, μη βελτιστοποιημένου ανά αρχιτεκτονική recipe στα τρία κύρια πειράματα, ώστε η επίδραση του continued pretraining να απομονώνεται καθαρά από την επίδραση της βελτιστοποίησης recipe.

8.2.3 Γενίκευση ως προς Μέθοδο SSL και Μέγεθος Backbone

Το όφελος του continued pretraining δεν περιορίζεται σε μία συγκεκριμένη αρχιτεκτονική: επιβεβαιώνεται τόσο στη DINOv2 (δύο μεγέθη backbone, ViT-S/14 και ViT-B/14) όσο και σε μια παλαιότερη, εννοιολογικά διαφορετική μέθοδο SSL (DINO v1, ViT-S/16). Στην πλήρη κατάταξη του benchmark, τα τρία domain-adapted checkpoints καταλαμβάνουν θέσεις αμέσως μετά τα τρία κορυφαία ConvNeXt (με μόνο το convnext_small να παρεμβάλλεται), ενώ τα αντίστοιχα generic checkpoints παραμένουν συγκεντρωμένα πολύ χαμηλότερα (Ενότητα 7.4.4) --- η πιο πειστική ένδειξη ότι πρόκειται για συστηματικό και αναπαραγώγιμο εύρημα.

8.2.4 Τοποθέτηση απέναντι στη Βιβλιογραφία

Η εργασία γεφυρώνει δύο φαινομενικά αποκλίνουσες γραμμές της υπάρχουσας βιβλιογραφίας: την αποτυχία της αυτοεπιβλεπόμενης εκπαίδευσης από το μηδέν σε περιορισμένα in-domain δεδομένα [51] και την επιτυχία της in-domain προεκπαίδευσης σε πολύ μεγάλη κλίμακα δεδομένων [52, 53], δείχνοντας ότι η συνέχιση της προεκπαίδευσης ενός ήδη ισχυρού γενικού μοντέλου προσφέρει ανάλογο όφελος με πολύ μικρότερες απαιτήσεις δεδομένων και υπολογιστικών πόρων. Παράλληλα, παρέχει την πρώτη ελεγχόμενη σύγκριση ενός δημοσιευμένου generic DINO/DINOv2 checkpoint πριν και μετά από domain-specific προσαρμογή για Vision Transformers, καλύπτοντας ένα κενό που παρέμενε ανοιχτό στη σχετική βιβλιογραφία [52, 57] (Ενότητα 7.6).

8.3 Συνεισφορές

Οι στόχοι της εργασίας, όπως διατυπώθηκαν στην Ενότητα 1.4, επιτεύχθηκαν στο σύνολό τους: υλοποιήθηκε η επέκταση του GastroHUN benchmark, αναπτύχθηκε το αναπαράξιμο πλαίσιο continued pretraining στις τρεις προβλεπόμενες διαμορφώσεις, πραγματοποιήθηκε η ελεγχόμενη σύγκριση generic/domain-adapted αναπαραστάσεων με στατιστική αξιολόγηση σε τρία seeds, εφαρμόστηκε το πολυσταδιακό πρωτόκολλο επιλογής checkpoint και τεκμηριώθηκε η γενικευσιμότητα της προσαρμογής ως προς τη μέθοδο SSL και το μέγεθος backbone (Ενότητες 7.5, 8.2.3). Πέρα, ωστόσο, από αυτούς τους εξ αρχής προβλεπόμενους στόχους, η εργασία καταλήγει και σε δύο επιπλέον συνεισφορές που δεν ήταν διατυπωμένες ως στόχοι στην Ενότητα 1.4, αλλά προέκυψαν κατά τη διεξαγωγή της:

- **Εμπειρική χαρτογράφηση της ευαισθησίας στο downstream recipe.** Η συστηματική διερεύνηση κανονικοποίησης, learning rate strategy και αυτοματοποιημένης αναζήτησης Optuna σε 24 αρχιτεκτονικές ανέδειξε μια αρχιτεκτονικοειδική ευαισθησία (ιδιαίτερα έντονη και συνεπής στο DINOv2, περιορισμένη και ανομοιογενής στο DINO v1· Ενότητα 7.1), με αυτοτελές ενδιαφέρον πέρα

από το κεντρικό ερευνητικό ερώτημα: αποτελεί ένδειξη χρήσιμη για κάθε μελλοντική εφαρμογή DINOv2 σε ιατρικές εικόνες, ανεξάρτητα από το ζήτημα του domain-adaptive pretraining.

- **Τοποθέτηση απέναντι σε δύο φαινομενικά αντικρουόμενες γραμμές της βιβλιογραφίας.** Η εργασία συμβιβάζει το αρνητικό εύρημα της αυτοεπιβλεπόμενης εκπαίδευσης από το μηδέν σε περιορισμένα δεδομένα [51] με το θετικό εύρημα της in-domain προεκπαίδευσης σε πολύ μεγάλη κλίμακα [52, 53], και καλύπτει ένα κενό ελεγχόμενης σύγκρισης που παρέμενε ρητά ανοιχτό για Vision Transformers [52, 57] (Ενότητα 7.6).

8.4 Μελλοντική Έρευνα

Οι περιορισμοί που συζητήθηκαν στην Ενότητα 7.7 υποδεικνύουν άμεσα τις ακόλουθες κατευθύνσεις μελλοντικής έρευνας:

- **Επανάληψη με πολλαπλά seeds προεκπαίδευσης.** Η επανάληψη ολόκληρης της διαδικασίας continued pretraining --- και της επακόλουθης διασταδιακής επιλογής checkpoint --- με διαφορετικά random seeds θα επέτρεπε να εκτιμηθεί η μεταβλητότητα που εισάγει η ίδια η στοχαστικότητα της αυτοεπιβλεπόμενης εκπαίδευσης, πέρα από τη μεταβλητότητα της downstream αξιολόγησης που ήδη καλύπτεται από τα τρία seeds της τελικής σύγκρισης.

- **Συνδυασμός per-architecture βελτιστοποιημένου recipe με continued pretraining.** Η παρούσα εργασία απομόνωσε σκόπιμα την επίδραση του continued pretraining από την επίδραση της βελτιστοποίησης recipe, χρησιμοποιώντας σταθερό πρωτόκολλο. Μια φυσική επέκταση θα ήταν η εφαρμογή discriminative learning rates ή recipe προερχόμενου από αναζήτηση Optuna στα ήδη domain-adapted checkpoints, ώστε να εξεταστεί αν τα δύο οφέλη (recipe και domain-adaptation) είναι αθροιστικά ή αλληλοεπικαλυπτόμενα.

- **Σύγκριση μεγέθους backbone υπό ομοιόμορφους υπολογιστικούς πόρους.** Η επανάληψη των Πειραμάτων 1 και 3 με κοινό batch size και αριθμό παρουσιάσεων εικόνων --- αντί του διαφορετικού batch size που επιβλήθηκε από τους διαθέσιμους πόρους --- θα επέτρεπε μια πλήρως ελεγχόμενη σύγκριση αποκλειστικά ως προς το μέγεθος του backbone.

- **Επέκταση σε μεγαλύτερα backbones και πλήρες fine-tuning.** Η εφαρμογή της ίδιας στρατηγικής σε μεγαλύτερα DINOv2 backbones (ViT-L/14, ViT-g/14) θα εξέταζε αν το όφελος του continued pretraining διατηρείται σε μεγαλύτερη κλίμακα μοντέλου, ενώ η σύγκριση partial έναντι πλήρους fine-tuning θα συμπλήρωνε την εικόνα της επίδρασης στο εύρος παραμέτρων που ενημερώνεται κατά το downstream training.

- **Επέκταση σε άλλα datasets και downstream εργασίες.** Η εφαρμογή της ίδιας στρατηγικής domain-adaptive continued pretraining σε διαφορετικά ενδοσκοπικά σύνολα δεδομένων ή διαγνωστικά προβλήματα, όπως ο εντοπισμός ή η ταξινόμηση βλαβών, θα εξέταζε κατά πόσο το εύρημα γενικεύεται πέρα από το GastroHUN και την αναγνώριση ανατομικής θέσης.

Βιβλιογραφία

[1] F. Bray, M. Laversanne, H. Sung, J. Ferlay, R. L. Siegel, I. Soerjomataram, and A. Jemal, ``Global cancer statistics 2022: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries,'' *CA: A Cancer Journal for Clinicians*, vol. 74, no. 3, pp. 229--263, 2024.

[2] F. Lordick, F. Carneiro, S. Cascinu, T. Fleitas, K. Haustermans, G. Piessen, A. Vogel, and E. C. Smyth, ``Gastric cancer: Esmo clinical practice guideline for diagnosis, treatment and follow-up,'' *Annals of Oncology*, vol. 33, no. 10, pp. 1005--1020, 2022.

[3] J. K. Y. Hooi, W. Y. Lai, W. K. Ng, M. M. Y. Suen, F. E. Underwood, D. Tanyingoh, P. Malfertheiner, D. Y. Graham, V. W. S. Wong, J. C. Y. Wu, F. K. L. Chan, J. J. Y. Sung, G. G. Kaplan, and S. C. Ng, ``Global prevalence of helicobacter pylori infection: Systematic review and meta-analysis,'' *Gastroenterology*, vol. 153, no. 2, pp. 420--429, 2017.

[4] P. Correa, ``Human gastric carcinogenesis: A multistep and multifactorial process,'' *Cancer Research*, vol. 52, no. 24, pp. 6735--6740, 1992.

[5] Japanese Gastric Cancer Association, ``Japanese gastric cancer treatment guidelines 2021 (6th edition),'' *Gastric Cancer*, vol. 26, no. 1, pp. 1--25, 2023.

[6] P. Pimentel-Nunes, D. Libânio, R. Marcos-Pinto, M. Areia, M. Leja, G. Esposito, M. Garrido, I. Kikuste, F. Mégraud, T. Matysiak-Budnik, B. Annibale, J.-M. Dumonceau, R. Barros, J.-F. Fléjou, F. Carneiro, J. E. van Hooft, E. J. Kuipers, and M. Dinis-Ribeiro, ``Management of epithelial precancerous conditions and lesions in the stomach (maps ii): Guideline update 2019,'' *Endoscopy*, vol. 51, no. 4, pp. 365--388, 2019.

[7] S. Gupta, D. Li, H. B. El-Serag, P. Davitkov, O. Altayar, S. Sultan, Y. Falck-Ytter, and R. A. Mustafa, ``Aga clinical practice guidelines on management of gastric intestinal metaplasia,'' *Gastroenterology*, vol. 158, no. 3, pp. 693--702, 2020.

[8] R. Bisschops, M. Areia, E. Coron, D. Dobru, B. Kaskas, R. Kuvaev, O. Pech, K. Ragunath, B. Weusten, P. Familiari, D. Domagk, R. Valori, M. F. Kaminski, C. Spada, M. Bretthauer, C. Bennett, C. Senore, M. Dinis-Ribeiro, and M. D. Rutter, ``Performance measures for upper gastrointestinal endoscopy: A european society of gastrointestinal endoscopy quality improvement initiative,'' *Endoscopy*, vol. 48, no. 9, pp. 843--864, 2016.

[9] K. Yao, ``The endoscopic diagnosis of early gastric cancer,'' *Annals of Gastroenterology*, vol. 26, no. 1, pp. 11--22, 2013.

[10] K. Yao, N. Uedo, M. Muto, and H. Ishikawa, ``Development of an e-learning system for teaching endoscopists how to diagnose early gastric cancer: Basic principles for

improving early detection," *Gastric Cancer*, vol. 20, no. Supplement 1, pp. 28--38, 2017.

[11] T. Kawamura, H. Wada, N. Sakiyama, Y. Ueda, A. Shirakawa, Y. Okada, K. Sanada, K. Nakase, K. Mandai, A. Suzuki, *et al.*, ``Examination time as a quality indicator of screening upper gastrointestinal endoscopy for asymptomatic examinees,'' *Digestive Endoscopy*, vol. 29, no. 5, pp. 569--575, 2017.

[12] J. M. Park, S. M. Huo, H. H. Lee, B. I. Lee, H. J. Song, and M. G. Choi, ``Longer observation time increases proportion of neoplasms detected by esophagogastroduodenoscopy,'' *Gastroenterology*, vol. 153, no. 2, pp. 460--469.e1, 2017.

[13] S. Menon and N. Trudgill, ``How commonly is upper gastrointestinal cancer missed at endoscopy? a meta-analysis,'' *Endoscopy International Open*, vol. 2, no. 2, pp. E46--E50, 2014.

[14] G. Chadwick, O. Groene, S. Riley, R. H. Hardwick, T. Crosby, J. Hoare, G. B. Hanna, K. Greenaway, and D. A. Cromwell, ``Gastric cancers missed during endoscopy in england,'' *Clinical Gastroenterology and Hepatology*, vol. 13, no. 7, pp. 1264--1270.e1, 2015.

[15] H. Takiyama, T. Ozawa, S. Ishihara, M. Fujishiro, S. Shichijo, S. Nomura, M. Miura, and T. Tada, ``Automatic anatomical classification of esophagogastroduodenoscopy images using deep convolutional neural networks,'' *Scientific Reports*, vol. 8, no. 1, p. 7497, 2018.

[16] X. Su, W. Liu, S. Jiang, X. Gao, Y. Chu, and L. Ma, ``Deep learning-based anatomical position recognition for gastroscopic examination,'' *Technology and Health Care*, vol. 32, no. 1_suppl, pp. 39--48, 2024.

[17] P. Yuan, Z.-H. Ma, Y. Yan, S.-J. Li, J. Wang, and Q. Wu, ``Artificial intelligence-based classification of anatomical sites in esophagogastroduodenoscopy images,'' *International Journal of General Medicine*, vol. 17, pp. 6127--6138, 2024.

[18] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin, ``Emerging properties in self-supervised vision transformers,'' in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 9650--9660, 2021.

[19] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, M. Assran, N. Ballas, W. Galuba, R. Howes, P.-Y. Huang, S.-W. Li, I. Misra, M. Rabbat, V. Sharma, G. Synnaeve, H. Xu, H. Jégou, J. Mairal, P. Labatut, A. Joulin, and P. Bojanowski, ``Dinov2: Learning robust visual features without supervision,'' *Transactions on Machine Learning Research*, 2024.

[20] H. Borgli, V. Thambawita, P. H. Smedsrud, S. Hicks, D. Jha, S. L. Eskeland, K. R. Randel, K. Pogorelov, M. Lux, D. T. D. Nguyen, D. Johansen, C. Griwodz, H. K. Stensland, E. Garcia-Ceja, P. T. Schmidt, H. L. Hammer, M. A. Riegler, P. Halvorsen, and T. de Lange, ``Hyperkvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy,'' *Scientific Data*, vol. 7, p. 283, 2020.

[21] D. Bravo, J. Frias, F. Vera, J. Trejos, C. Martínez, M. Gómez, F. González, and E. Romero, ``Gastrohun: An endoscopy dataset of complete systematic screening protocol for the stomach,'' *Scientific Data*, vol. 12, p. 102, 2025.

[22] A. A. Arif, S. X. Jiang, and M. F. Byrne, ``Artificial intelligence in endoscopy: Overview, applications, and future directions,'' *Saudi Journal of Gastroenterology*, vol. 29, no. 1, pp. 3--11, 2023.

[23] C. Labaki, E. N. Uche-Anya, and T. M. Berzin, ``Artificial intelligence in gastrointestinal endoscopy,'' *Gastroenterology Clinics of North America*, vol. 53, no. 4, pp. 773--786, 2024.

[24] T. K. L. Lui, C. L. T. Guo, and W. K. Leung, ``Accuracy of artificial intelligence on histology prediction and detection of colorectal polyps: A systematic review and meta-analysis,'' *Gastrointestinal Endoscopy*, vol. 92, no. 1, pp. 11--22.e6, 2020.

[25] P. Wang, X. Xiao, J. R. Glissen Brown, T. M. Berzin, M. Tu, F. Xiong, X. Hu, P. Liu, Y. Song, D. Zhang, X. Yang, L. Li, J. He, X. Yi, J. Liu, and X. Liu, ``Development and validation of a deep-learning algorithm for the detection of polyps during colonoscopy,'' *Nature Biomedical Engineering*, vol. 2, no. 10, pp. 741--748, 2018.

[26] A. Repici, M. Badalamenti, R. Maselli, L. Correale, F. Radaelli, E. Rondonotti, E. Ferrara, M. Spadaccini, A. Alkandari, A. Fugazza, A. Anderloni, P. A. Galtieri, G. Pellegatta, S. Carrara, M. Di Leo, V. Craviotto, L. Lamonaca, R. Lorenzetti, A. Andrealli, G. Antonelli, M. Wallace, P. Sharma, T. Rosch, and C. Hassan, ``Efficacy of real-time computer-aided detection of colorectal neoplasia in a randomized trial,'' *Gastroenterology*, vol. 159, no. 2, pp. 512--520.e7, 2020.

[27] C. Hassan, M. Spadaccini, A. Iannone, R. Maselli, M. Jovani, V. T. Chandrasekar, G. Antonelli, H. Yu, M. Areia, M. Dinis-Ribeiro, P. Bhandari, P. Sharma, D. K. Rex, T. Rosch, M. Wallace, and A. Repici, ``Performance of artificial intelligence in colonoscopy for adenoma and polyp detection: A systematic review and meta-analysis,'' *Gastrointestinal Endoscopy*, vol. 93, no. 1, pp. 77--85.e6, 2021.

[28] T. K. L. Lui, V. W. M. Tsui, and W.-K. Leung, ``Accuracy of artificial intelligence-assisted detection of upper gastrointestinal lesions: A systematic review and meta-analysis,'' *Gastrointestinal Endoscopy*, vol. 92, no. 4, pp. 821--830.e9, 2020.

[29] M. Tokat, L. van Tilburg, A. D. Koch, and M. C. W. Spaander, ``Artificial intelligence in upper gastrointestinal endoscopy,'' *Digestive Diseases*, vol. 40, no. 4, pp. 395--408, 2022.

[30] T. Hirasawa, K. Aoyama, T. Tanimoto, S. Ishihara, S. Shichijo, T. Ozawa, T. Ohnishi, M. Fujishiro, K. Matsuo, J. Fujisaki, and T. Tada, ``Application of artificial intelligence using a convolutional neural network for detecting gastric cancer in endoscopic images,'' *Gastric Cancer*, vol. 21, no. 4, pp. 653--660, 2018.

[31] P. Sharma and C. Hassan, ``Artificial intelligence and deep learning for upper gastrointestinal neoplasia,'' *Gastroenterology*, vol. 162, no. 4, pp. 1056--1066, 2022.

[32] E. Nakao, D. Watabe, K. Yamashita, M. Iwaizumi, S. Baba, S. Osawa, and H. Sugimura, ``Randomized controlled trial of an artificial intelligence diagnostic system for the detection of esophageal squamous cell carcinoma in clinical practice,'' *Endoscopy*, vol. 57, no. 3, pp. 210--217, 2025.

[33] Q. He, S. Bano, O. F. Ahmad, B. Yang, X. Chen, P. Valdastri, L. B. Lovat, D. Stoyanov, and S. Zuo, ``Deep learning-based anatomical site classification for upper gastrointestinal endoscopy,'' *International Journal of Computer Assisted Radiology and Surgery*, vol. 15, no. 7, pp. 1085--1094, 2020.

[34] L. Wu, J. Zhang, W. Zhou, P. An, L. Shen, J. Liu, X. Jiang, X. Huang, G. Mu, X. Wan, *et al.*, ``Randomised controlled trial of wisense, a real-time quality improving system for monitoring blind spots during esophagogastroduodenoscopy,'' *Gut*, vol. 68, no. 12, pp. 2161--2169, 2019.

[35] L. Wu, X. He, M. Liu, H. Xie, P. An, J. Zhang, H. Zhang, Y. Ai, Q. Tong, M. Guo, *et al.*, ``Evaluation of the effects of an artificial intelligence system on endoscopy quality and preliminary testing of its performance in detecting early gastric cancer: A randomized controlled trial,'' *Endoscopy*, vol. 53, no. 12, pp. 1199--1207, 2021.

[36] Y. Li, S. Wang, Y. Wang, Z. Lu, L. Wu, X. He, X. Zhao, Y. Zhu, Z. Dong, H. Luo, H. Du, X. Zhu, and H. Yu, ``Intelligent detection endoscopic assistant: An artificial-intelligence-based system for monitoring blind spots during esophagogastroduodenoscopy in real-time,'' *Digestive and Liver Disease*, vol. 53, no. 2, pp. 216--223, 2021.

[37] M. Sun, L. Ma, X. Su, X. Gao, Z. Liu, and L. Ma, ``Channel separation-based network for the automatic anatomical site recognition using endoscopic images,'' *Biomedical Signal Processing and Control*, vol. 71, p. 103167, 2022.

[38] K. Zhang, Y. Zhang, Y. Ding, M. Wang, P. Bai, X. Wang, Z. Qin, and X. Zhang, ``Anatomical sites identification in both ordinary and capsule gastroduodenoscopy via deep learning,'' *Biomedical Signal Processing and Control*, vol. 90, p. 105911, 2024.

[39] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. W. M. van der Laak, B. van Ginneken, and C. I. Sánchez, ``A survey on deep learning in medical image analysis,'' *Medical Image Analysis*, vol. 42, pp. 60--88, 2017.

[40] V. Cheplygina, M. de Bruijne, and J. P. W. Pluim, ``Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis,'' *Medical Image Analysis*, vol. 54, pp. 280--296, 2019.

[41] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, ``Imagenet: A large-scale hierarchical image database,'' in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 248--255, 2009.

[42] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, ``How transferable are features in deep neural networks?,'' *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014.

[43] H.-C. Shin, H. R. Roth, M. Gao, L. Lu, Z. Xu, I. Nogues, J. Yao, D. Mollura, and R. M. Summers, ``Deep convolutional neural networks for computer-aided detection: Cnn architectures, dataset characteristics and transfer learning,'' *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1285--1298, 2016.

[44] M. Raghu, C. Zhang, J. Kleinberg, and S. Bengio, ``Transfusion: Understanding transfer learning for medical imaging,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.

[45] K. He, R. Girshick, and P. Dollár, ``Rethinking imagenet pre-training,'' in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4918--4927, 2019.

[46] J. Anton, L. Castelli, M. F. Chan, M. Outters, W. H. Tang, V. Cheung, P. Shukla, R. Walambe, and K. Kotecha, ``How well do self-supervised models transfer to medical imaging?,'' *Journal of Imaging*, vol. 8, no. 12, p. 320, 2022.

[47] Z. Zhou, V. Sodha, J. Pang, M. B. Gotway, and J. Liang, ``Models genesis,'' *Medical Image Analysis*, vol. 67, p. 101840, 2021.

[48] S. Azizi, B. Mustafa, F. Ryan, Z. Beaver, J. Freyberg, J. Deaton, A. Loh, A. Karthikesalingam, S. Kornblith, T. Chen, V. Natarajan, and M. Norouzi, ``Big self-supervised models advance medical image classification,'' in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 3478--3488, 2021.

[49] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. von Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill, E. Brynjolfsson, S. Buch, D. Card, R. Castellon, N. Chatterji, *et al.*, ``On the opportunities and risks of foundation models,'' *arXiv preprint arXiv:2108.07258*, 2021.

[50] M. Moor, O. Banerjee, Z. S. H. Abad, H. M. Krumholz, J. Leskovec, E. J. Topol, and P. Rajpurkar, ``Foundation models for generalist medical artificial intelligence,'' *Nature*, vol. 616, no. 7956, pp. 259--265, 2023.

[51] E. Sanderson and B. J. Matuszewski, ``A study on self-supervised pretraining for vision problems in gastrointestinal endoscopy,'' *IEEE Access*, vol. 12, pp. 46181--46201, 2024.

[52] T. G. W. Boers, K. N. Fockens, J. A. van der Putten, T. J. M. Jaspers, C. H. J. Kusters, J. B. Jukema, M. R. Jong, M. R. Struyvenberg, J. de Groof, J. J. Bergman, P. H. N. de With, and F. van der Sommen, ``Foundation models in gastrointestinal endoscopic ai: Impact of architecture, pre-training approach and data efficiency,'' *Medical Image Analysis*, vol. 98, p. 103298, 2024.

[53] M. R. Jong, T. Boers, K. Fockens, J. Jukema, C. Kusters, T. Jaspers, R. van Eijck van Heslinga, F. Slooter, M. Struyvenberg, R. Bisschops, J. van der Putten, P. H. N. de With, F. van der Sommen, J. de Groof, and J. J. Bergman, ``Gastronet-5m: A multicenter dataset for developing foundation models in gastrointestinal endoscopy,'' *Gastroenterology*, vol. 170, no. 1, pp. 174--187, 2026.

[54] M. Roth, M. V. Nowak, A. Krenzer, and F. Puppe, ``Domain-adaptive pre-training of self-supervised foundation models for medical image classification in gastrointestinal endoscopy,'' *arXiv preprint arXiv:2410.21302*, 2024.

[55] Z. Wang, C. Liu, S. Zhang, and Q. Dou, ``Foundation model for endoscopy video analysis via large-scale self-supervised pre-train,'' in *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2023.

[56] K. Chaitanya, P. F. Damasceno, S. Fadnavis, P. Mobadersany, C. Parmar, E. Scherer, N. Zemlianskaia, L. Surace, L. R. Ghanem, O. G. Cula, T. Mansi, and K. Standish, ``Arges: Spatio-temporal transformer for ulcerative colitis severity assessment in endoscopy videos,'' *arXiv preprint arXiv:2410.00536*, 2024.

[57] P. Dermyer, A. Kalra, and M. Schwartz, ``Endodino: A foundation model for gi endoscopy,'' *arXiv preprint arXiv:2501.05488*, 2025.

[58] V. Koch, S. J. Wagner, S. Kazeminia, E. Sancar, M. Hehr, J. Schnabel, T. Peng, and C. Marr, ``Dinobloom: A foundation model for generalizable cell embeddings in hematology,'' in *Medical Image Computing and Computer Assisted Intervention (MICCAI)*, 2024.

[59] B. Roth, V. Koch, S. J. Wagner, J. A. Schnabel, C. Marr, and T. Peng, ``Low-resource finetuning of foundation models beats state-of-the-art in histopathology,'' in *IEEE International Symposium on Biomedical Imaging (ISBI)*, 2024.

[60] K. Stillwagon, A. D. VandeLoo, B. Magondu, and C. R. Forest, ``Self-supervised pretraining of cell segmentation models,'' *arXiv preprint arXiv:2604.10609*, 2026.

[61] Y. Bengio, A. Courville, and P. Vincent, ``Representation learning: A review and new perspectives,'' *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798--1828, 2013.

[62] Y. LeCun, Y. Bengio, and G. Hinton, ``Deep learning,'' *Nature*, vol. 521, no. 7553, pp. 436--444, 2015.

[63] V. Nair and G. E. Hinton, ``Rectified linear units improve restricted boltzmann machines,'' in *Proceedings of the 27th International Conference on Machine Learning (ICML)*, pp. 807--814, 2010.

[64] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

[65] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, ``Learning representations by back-propagating errors,'' *Nature*, vol. 323, no. 6088, pp. 533--536, 1986.

[66] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, ``Gradient-based learning applied to document recognition,'' *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278--2324, 1998.

[67] A. Krizhevsky, I. Sutskever, and G. E. Hinton, ``Imagenet classification with deep convolutional neural networks,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 25, 2012.

[68] M. D. Zeiler and R. Fergus, ``Visualizing and understanding convolutional networks,'' in *European Conference on Computer Vision (ECCV)*, pp. 818--833, 2014.

[69] K. Simonyan and A. Zisserman, ``Very deep convolutional networks for large-scale image recognition,'' in *International Conference on Learning Representations (ICLR)*, 2015.

[70] K. He, X. Zhang, S. Ren, and J. Sun, ``Deep residual learning for image recognition,'' in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770--778, 2016.

[71] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, ``A convnet for the 2020s,'' in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11976--11986, 2022.

[72] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, ``An image is worth 16x16 words: Transformers for image recognition at scale,'' in *International Conference on Learning Representations*, 2021.

[73] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, ``Attention is all you need,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[74] J. L. Ba, J. R. Kiros, and G. E. Hinton, ``Layer normalization,'' *arXiv preprint arXiv:1607.06450*, 2016.

[75] D. Hendrycks and K. Gimpel, ``Gaussian error linear units (gelus),'' *arXiv preprint arXiv:1606.08415*, 2016.

[76] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, ``Bert: Pre-training of deep bidirectional transformers for language understanding,'' in *Proceedings of NAACL-HLT*, pp. 4171--4186, 2019.

[77] S. J. Pan and Q. Yang, ``A survey on transfer learning,'' *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345--1359, 2010.

[78] S. Kornblith, J. Shlens, and Q. V. Le, ``Do better imagenet models transfer better?,'' *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2661--2671, 2019.

[79] L. Jing and Y. Tian, ``Self-supervised visual feature learning with deep neural networks: A survey,'' *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 11, pp. 4037--4058, 2020.

[80] A. Jaiswal, A. R. Babu, M. Z. Zadeh, D. Banerjee, and F. Makedon, ``A survey on contrastive self-supervised learning,'' *Technologies*, vol. 9, no. 1, p. 2, 2021.

[81] S. Gidaris, P. Singh, and N. Komodakis, ``Unsupervised representation learning by predicting image rotations,'' in *International Conference on Learning Representations (ICLR)*, 2018.

[82] C. Doersch, A. Gupta, and A. A. Efros, ``Unsupervised visual representation learning by context prediction,'' in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 1422--1430, 2015.

[83] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, ``A simple framework for contrastive learning of visual representations,'' in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pp. 1597--1607, 2020.

[84] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, ``Momentum contrast for unsupervised visual representation learning,'' in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9729--9738, 2020.

[85] J.-B. Grill, F. Strub, F. Altché, C. Tallec, P. H. Richemond, E. Buchatskaya, C. Doersch, B. A. Pires, Z. D. Guo, M. G. Azar, B. Piot, K. Kavukcuoglu, R. Munos, and M. Valko, ``Bootstrap your own latent: A new approach to self-supervised learning,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.

[86] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, ``Masked autoencoders are scalable vision learners,'' in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 16000--16009, 2022.

[87] A. van den Oord, Y. Li, and O. Vinyals, ``Representation learning with contrastive predictive coding,'' *arXiv preprint arXiv:1807.03748*, 2018.

[88] C.-Y. Chuang, J. Robinson, Y.-C. Lin, A. Torralba, and S. Jegelka, ``Debiased contrastive learning,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.

[89] J. Zbontar, L. Jing, I. Misra, Y. LeCun, and S. Deny, ``Barlow twins: Self-supervised learning via redundancy reduction,'' in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pp. 12310--12320, 2021.

[90] G. Hinton, O. Vinyals, and J. Dean, ``Distilling the knowledge in a neural network,'' *arXiv preprint arXiv:1503.02531*, 2015.

[91] T. Hua, W. Wang, Z. Xue, S. Ren, Y. Wang, and H. Zhao, ``On feature decorrelation in self-supervised learning,'' in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9598--9608, 2021.

[92] L. Jing, P. Vincent, Y. LeCun, and Y. Tian, ``Understanding dimensional collapse in contrastive self-supervised learning,'' in *International Conference on Learning Representations (ICLR)*, 2022.

[93] M. Caron, P. Bojanowski, A. Joulin, and M. Douze, ``Deep clustering for unsupervised learning of visual features,'' in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

[94] M. Caron, I. Misra, J. Mairal, P. Goyal, P. Bojanowski, and A. Joulin, ``Unsupervised learning of visual features by contrasting cluster assignments,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.

[95] J. Zhou, C. Wei, H. Wang, W. Shen, C. Xie, A. Yuille, and T. Kong, ``ibot: Image bert pre-training with online tokenizer,'' in *International Conference on Learning Representations (ICLR)*, 2022.

[96] E. Pizzi, S. D. Roy, S. N. Ravindra, P. Goyal, and M. Douze, ``A self-supervised descriptor for image copy detection,'' in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 14532--14542, 2022.

[97] L. F. Kozachenko and N. N. Leonenko, ``Sample estimate of the entropy of a random vector,'' *Problems of Information Transmission*, vol. 23, no. 2, pp. 95--101, 1987.

[98] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, ``Vision transformers need registers,'' in *International Conference on Learning Representations (ICLR)*, 2024.

[99] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, ``Learning transferable visual models from natural language supervision,'' in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pp. 8748--8763, 2021.

[100] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, ``Segment anything,'' in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4015--4026, 2023.

[101] J. Quiñonero-Candela, M. Sugiyama, A. Schwaighofer, and N. D. Lawrence, eds., *Dataset Shift in Machine Learning*. MIT Press, 2009.

[102] S. Gururangan, A. Marasović, S. Swayamdipta, K. Lo, I. Beltagy, D. Downey, and N. A. Smith, ``Don't stop pretraining: Adapt language models to domains and tasks,'' in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 8342--8360, 2020.

[103] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, ``Optuna: A next-generation hyperparameter optimization framework,'' in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pp. 2623--2631, 2019.

[104] A. B. Yoo, M. A. Jette, and M. Grondona, ``Slurm: Simple linux utility for resource management,'' in *Job Scheduling Strategies for Parallel Processing (JSSPP)*, pp. 44--60, 2003.

[105] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, ``Pytorch: An imperative style, high-performance deep learning library,'' in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.

[106] W. Falcon and The PyTorch Lightning team, ``Pytorch lightning.'' `https://github.com/Lightning-AI/lightning`, 2019.